


$$\sum_{j=1}^m c_j \vec{v}_j = \vec{0}, \quad \vec{c} \neq \vec{0}$$

$$A\vec{x} = \vec{b}$$

线性代数及其应用

Linear Algebra and Its Applications

从结构到几何 / 从理论到应用 / 从工程到理性




$$F_{k+2} = F_{k+1} + F_k$$

$$T : \mathbb{R}^n \longrightarrow \mathbb{R}^m$$

2026

第一版



先看见，再理解，最后计算。

DEDICATION / 献词

*For the fifteen-year-old girl
searching for her own coordinates in the dim light,*

献给那个在暗淡微光中，
寻找自己坐标的十五岁女孩，

and for all those still learning to discern order out of chaos.

也献给每一个仍在混沌中，努力辨认秩序的人。

To the unseen structure beneath the world,

献给隐藏在世界之下、那看不见的结构，

and to everyone building their own basis.

也献给每一个正在为自己搭建基底的人。

Autumn 2026, Nanchang

2026 年秋，于南昌

前言

我们身处的世界，藏着一层看不见的线性骨架。

八十多年前，洛斯阿拉莫斯的深夜里，一群年轻人抱着成堆的演算纸，手指被机械计算器的摇柄磨得发烫。他们中最杰出的头脑，正在用大型稀疏矩阵的临界估计，在毁灭与拯救的边缘撑起核反应堆的第一次运转。没有人知道这堆符号最终会指向什么，他们只是相信：混沌之中，必有秩序。

今天，当你滑动手机，屏幕亮起，短视频推荐的本质是高维向量空间里的相似度匹配；当你戴上 VR 眼镜，流畅的 3D 画面是顶点向量经过一次次线性变换的渲染；当你走过跨海大桥，钢铁与混凝土在巨浪与狂风中保持稳固，依靠的是结构刚度矩阵的特征值分析。而那个让机器第一次像人类一样理解语言的 Transformer 架构，剥开所有炫目的技术包装，底层也只是大规模的矩阵乘法与注意力权重的线性组合。从 PageRank 为整个互联网排序，到图像压缩剥离冗余；从离散动力系统的长期演化，到最小二乘法在误差中寻找最优解。这些看似毫不相干的领域，共享着同一套数学语言——**线性代数**。

然而，很可惜。大多数人学习它的时候，只看见行变换、行列式、特征值公式，只看见没完没了的计算，却看不见这堆符号支撑起来的广阔世界。我们被困在公式的泥潭里，误以为这只是一场为了出题而发明的算术游戏。我们从未被告知：那些潦草的矩阵背后，曾经站着活生生的人，他们也曾像我们一样，在深夜里为一道解不开的题而辗转反侧。

我也曾困在这样的境地。直到后来我才慢慢明白：线性代数从不是为了考试而存在的符号游戏，它是人类从真实世界的混沌中，用理性与想象一点一点打捞出来的秩序。它描述空间的拉伸与旋转，描述变量之间的线性关联，描述复杂系统里最本质的结构。工程师用它求解工程难题，计算机科学家用它构建算法，物理学家用它描述物理规律——它是所有理工科最底层的通用语言，是人类用少量公理撑起整个世界的、最谦卑也最壮丽的尝试之一。

所以我试着按照自己理解的脉络，重新编排了这门课的内容，写成了这份讲义。我没有从冰冷的定义和公式开始，而是用一整章的预备直观，带你从三个维度看见向量：它是几何里带箭头的线段，是数据里有序排列的数字，也是工程里描述系统状态的一组量。**先看见，再理解，最后计算**。我把线性方程组作为全书的起点，由问题引出矩阵，由矩阵引出线性变换，再一步步展开秩、行列式、子空间、特征值、对角化与二次型。每

一个概念的出现，都对应着一个要解决的问题；每一个定理的背后，都藏着一处真实世界的落点。它从哪里来，要到哪去，是我在这本讲义里最想讲清的事。

你会在选读章节里遇见很多工程与科学史里的故事：你会看见格什戈林圆盘定理如何在没有电子计算机的年代，用几分钟的计算给出上百阶矩阵的特征值范围，撑起最早的核反应堆设计；你会看到 PageRank 如何用特征向量为整个互联网排序，让数十亿个网页在数学的秩序里各归其位；你会看到钱学森弹道如何通过高维坐标系的变换，在变轨中把握飞行器的姿态，在苍穹中划出一道跨越时代的轨迹；你也会看见短视频推荐系统如何把每条视频变成一个向量，用向量的夹角衡量内容的相似，在数据的洪流中为你打捞起一小片属于你的世界。这些不是无关的闲笔——它们正是线性代数力量的证明：最抽象的数学结论，往往能给出最干脆、最可靠的答案。而每一个答案背后，都站着活生生的人，他们用这些符号，解决过我们曾以为无解的难题。

而我最想让你瞥见的，是它的美感。线性代数的美，不在于复杂的证明技巧，而在于一种**深刻的秩序与统一**。人类用少量公理，便撑起了一个理解世界的稳固框架。这种用理性对抗混沌的秩序感，是数学最动人的地方。它不喧哗，不张扬，却在每一个深夜的演算里，在每一次笔尖的停顿中，安静地照亮着我们脚下的路。

当然，我也十分清楚，对很多同学而言，这终究只是一门需要及格的必修课。所以这份讲义做了清晰的分层：**每章的主线内容严格紧扣课程要求**，覆盖全部考点，定义、定理、例题完整齐备，只研读主线部分，就足以应对考试。**所有的工程背景、几何直觉、拓展应用，都被放在了「选读」与「案例」之中，不做考核要求**。你完全可以跳过它们，专心于公式与计算。

我只是忍不住，为那扇门推开了一条缝。

如果你愿意，偶尔往缝里看一眼。你会看见藏在计算背后的，那个由向量张成、由变换塑造、由特征值锚定的线性世界。它安静、精确、充满力量，默默支撑着我们眼前的一切技术与文明。它不会催促你，也不会责备你，它只是在那里，等待你愿意抬头的那一瞬间。

愿你在埋头演算的间隙，能有那么一瞬间，忽然读懂符号背后的逻辑，与那份藏在抽象里的、秩序的美。**哪怕只有一秒，这份讲义就有了超出分数的意义。**

因为我们终其一生，都在寻找某种秩序。而线性代数，是人类找到的最美的秩序之一。

编者

2026年9月

于江西南昌

目录

第 0 章 预备知识: 从二维、三维向量到 n 维向量	1
0.1 从二维、三维向 n 维推广	2
0.2 向量的线性组合	6
0.3 几何中的直线、平面与子空间	8
0.4 向量之间的关系	10
0.5 坐标系与基的直观	12
0.6 线性代数究竟研究什么?	14
0.7 向量的度量: 点积、长度与夹角	16
0.8 案例总结: 从箭头到数据——三种眼光看向量	22
第 1 章 $\mathbb{R}^n$ 中的线性关系、基与维数	25
1.1 $\mathbb{R}^n$ 中的向量与线性运算	25
1.2 线性组合、线性表示与向量组等价	28
1.3 张成空间、子空间与直和	32
1.4 线性相关与线性无关	37
1.5 极大线性无关组与向量组的秩	45
1.6 基、维数与基扩充定理	48
1.7 【选读】抽象向量空间的公理化定义	54
1.8 【应用案例】抖音推荐系统中的向量结构	60
本章小结	63
第 2 章 线性方程组与矩阵: 从方程到 $Ax = b$	64
2.1 从鸡兔同笼看消元思想	67
2.2 高斯消元法: 从二元到 n 元	70
2.3 矩阵与初等行变换	74
2.4 行最简形与高斯-若尔当消元法	79
2.5 向量方程与标准形式 $Ax = b$	82
2.6 解的存在性与唯一性判定	87
2.7 【应用案例】抖音视频推荐: 从用户偏好反求组合权重	95

本章小结	100
第 3 章 矩阵: 线性映射的代数表示	101
3.1 线性映射: 矩阵的本质	106
3.2 矩阵的线性运算: 映射的加法与数乘	115
3.3 矩阵乘法: 映射的复合	117
3.4 逆矩阵: 逆映射	125
3.5 转置与分块矩阵	128
3.5.1 矩阵的转置	129
3.5.2 分块矩阵	138
3.6 初等变换与初等矩阵: 消元的矩阵形式	142
3.7 LU 分解: 把一个方程组拆成两次三角求解	145
3.7.1 为什么要做 LU 分解?	145
3.7.2 图解 LU 分解的结构	145
3.7.3 具体方程组的演练	147
3.7.4 为什么工程上喜欢 LU 分解?	151
3.8 【选读】PLU 分解: 选主元与数值稳定性	154
3.9 【选读】列秩分解 (CR 分解)	156
3.10 【应用案例】抖音推荐系统: 从数据到预测	161
本章小结	171
第 4 章 线性变换与基变换: 矩阵背后的变换	173
4.1 线性变换的几何直观与零空间	177
4.1.1 计算机图形学中的线性变换	177
4.1.2 零空间与单射性	191
4.2 值域与满射性	196
4.3 线性映射基本定理: 秩与零度	200
4.4 基变换与相似矩阵	203
4.5 【选读】坐标变换的工程语言: 以钱学森弹道为例	209
4.6 【选读】秩与零度定理的证明及行秩性质	214
4.7 【应用案例】图像压缩: 从像素到频率的基变换	217
本章小结	221
第 5 章 线性方程组的再研究: 解的结构	222
5.1 齐次方程组: 从自由变量到基础解系	226
5.2 非齐次方程组: 一个特解与全部解	231
5.3 行变换与原像: 为什么消元保持解集	234
5.4 一个矩阵, 四个基本子空间	236

5.4.1	四个子空间的定义与维数	237
5.4.2	正交与直和: 拆开输入与输出	240
5.4.3	直观总结: 正交互补的两组子空间	242
5.5	四个子空间怎样共同决定解	245
5.6	解的判定: 参数分类与结构反推	249
5.7	无解时的最优近似: 最小二乘解与正规方程	254
5.8	【选读】从斐波那契到状态递推: 离散系统中的线性代数	263
5.9	【选读】从逐步更新到连续变化: 微分方程与矢量场	269
5.10	【应用案例】抖音推荐系统: 从组合权重到解的结构	277
	本章小结	281
第 6 章	行列式: 从体积到可逆性	282
6.0	结构之后: 度量变换的缩放因子	282
6.1	几何直观与公理化定义: 面积、体积与交错多重线性映射	289
6.2	从公理到性质: 代数骨架的搭建	294
6.3	行列式的计算	299
6.3.1	高斯消元与上下三角矩阵: 工程中最常用的计算路径	299
6.3.2	代数余子式展开 (Laplace 展开): 从正交补到展开定理	300
6.3.3	伴随矩阵与逆矩阵公式	303
6.4	几何形式的深化: 微积分思想下的体积度量	306
第 7 章	内积空间与正交性: 线性空间中的几何	310
第 8 章	特征空间与相似变换: 寻找最自然的坐标系	311
第 9 章	矩阵对角化: 寻找最简单的表示	312
第 10 章	二次型: 从矩阵到几何形状	313
第 11 章	奇异值分解: 数据中的主方向 (选读)	314
	后记	315
附录 A	复数: 从数轴走向平面	316
A.1	扩充数系: 从一个新单位开始	316
A.2	分部相加, 依律相乘	317
A.3	共轭看镜像, 模长看距离	318
A.4	换一种坐标: 模定长短, 角定方向	320
A.5	欧拉公式: 把旋转写成指数	321
A.6	反复旋转: 乘方与开方	323

A.7 回到线性代数: 对象可变, 结构相通	325
附录 B 多元微积分初步: 从线性化到雅可比	326
B.1 偏导数、梯度与方向导数	327
B.2 多重积分与换元法	329
B.3 向量场、散度与旋度	331
B.4 非线性变换的局部线性化与链式法则	334
B.5 【应用案例】梯度下降与反向传播	336
术语表	338
参考文献	358

第 0 章

预备知识：

从二维、三维向量到 n 维向量

在高中和中职阶段，我们已经认识了向量 (Vector)，接触过平面向量 (Plane Vector) 和空间向量 (Space Vector)。平面里的向量可以用两个坐标表示，空间里的向量可以用三个坐标表示。我们学过向量的加法与数乘，也用向量计算过长度、角度，解决过平面几何和立体几何中的问题。对很多同学来说，向量就是几何里带箭头的线段，是一种熟悉的解题工具。

那么，为什么到了大学，还要继续学习向量？线性代数 (Linear Algebra) 与高中阶段的向量知识有什么区别？

区别首先在于我们要处理的问题变多了。描述一名学生的学业情况，可能需要记录语文、数学、英语和多门专业课的成绩；描述一条短视频，可能需要记录许多内容特征；描述一个物理系统的状态，也可能需要同时记录多个位置、速度或其他物理量。两个或三个数往往不够用，我们需要由更多数值组成的向量。

这些高维向量虽然不容易画成箭头，却仍然遵循我们熟悉的运算规则：对应分量相加，每个分量乘同一个数。**从二维、三维走向高维，不是把旧知识推倒重来，而是把同样的规则用到更多分量上。**低维几何中的直觉可以帮助我们理解高维问题，高维向量的计算又使我们能够处理更复杂的数据与系统。

本章将从二维、三维向量出发，介绍 n 维向量的表示与运算，然后讨论线性组合与张成，看看一组向量能够表示哪些向量。接着，我们从过原点的直线、平面认识子空间，从共线、共面认识线性相关与线性无关，再用熟悉的坐标系理解基与坐标。最后，我们概括线性代数研究的问题，整理点积、长度与夹角的坐标公式，再用短视频推荐的简化案例把这些概念联系起来。

本章以高中向量知识为起点。已学过的运算与基本定理集中复习，子空间、线性相关与基等概念则结合例子逐步引入；系统的判定与计算方法将在后续章节展开。

0.1 从二维、三维向 n 维推广

从熟悉的平面与空间出发

平面向量可记为 $\mathbf{u} = (u_1, u_2) \in \mathbb{R}^2$ ，空间向量可记为 $\mathbf{a} = (a_1, a_2, a_3) \in \mathbb{R}^3$ 。将起点置于原点时，终点坐标就是向量的分量。以下讨论自由向量 (Free Vector)：平移不改变向量，向量相等要求大小相等且方向相同。零向量 (Zero Vector) 的长度为零，没有确定的方向。

性质 0.1 (向量的加法、减法与数乘)

下面分别列出向量加法 (Vector Addition)、向量减法 (Vector Subtraction) 与数乘 (Scalar Multiplication) 的坐标规则。设 $\mathbf{u} = (u_1, u_2)$ 、 $\mathbf{v} = (v_1, v_2)$ ， $c \in \mathbb{R}$ ，则

$$\begin{aligned}\mathbf{u} + \mathbf{v} &= (u_1 + v_1, u_2 + v_2), \\ \mathbf{u} - \mathbf{v} &= (u_1 - v_1, u_2 - v_2) = \mathbf{u} + (-\mathbf{v}), \\ c\mathbf{u} &= (cu_1, cu_2).\end{aligned}$$

加法的三角形定则 (Triangle Rule)：首尾相接，首尾相连，即 $\overrightarrow{OA} + \overrightarrow{AB} = \overrightarrow{OB}$ 。

加法的平行四边形定则 (Parallelogram Rule)：以同一起点的两个向量为邻边，作平行四边形；从共同起点出发的对角线表示它们的和。

减法的三角形定则：将 $\overrightarrow{OA}$ 、 $\overrightarrow{OB}$ 置于同一起点，则 $\overrightarrow{OA} - \overrightarrow{OB} = \overrightarrow{BA}$ ，即从减向量的终点指向被减向量的终点。

数乘的长度与方向： $\|c\mathbf{u}\| = |c|\|\mathbf{u}\|$ 。当 $\mathbf{u} \neq \mathbf{0}$ 时， $c > 0$ 保持方向， $c < 0$ 改变为相反方向， $c = 0$ 得到零向量。

例如， $\mathbf{u} = (2, 1)$ 、 $\mathbf{v} = (-1, 2)$ 时，

$$\mathbf{u} + \mathbf{v} = (1, 3), \quad \mathbf{u} - \mathbf{v} = (3, -1), \quad 2\mathbf{u} = (4, 2).$$

减去一个向量，也可以转化为加上它的相反向量 (Additive Inverse)：沿 $\mathbf{v}$ 的反方向取等长向量 $-\mathbf{v}$ ，再按加法定则作出 $\mathbf{u} + (-\mathbf{v})$ ，就得到 $\mathbf{u} - \mathbf{v}$ ，如图 0.1(b) 所示。注意， $\mathbf{u} - \mathbf{v}$ 与 $\mathbf{v} - \mathbf{u}$ 互为相反向量；一般不能交换减法的顺序。




图 0.1: 加法、减法与数乘的几何意义。图 (b) 中的绿色虚线表示反向延伸得到的 $-v$ 及其平移, 红色向量表示 $u + (-v)$ 。

在三维直角坐标系中, 向量要用三个分量表示, 例如 $a = (1, 2, -1)$ 。所有有序实数三元组组成 $\mathbb{R}^3$ 。从二维到三维, 只是多了一个分量, 运算仍然逐个分量进行。例如, 对于 $b = (2, -1, 3)$, 有

$$a + b = (3, 1, 2), \quad -2a = (-2, -4, 2).$$




图 0.2: 空间向量 $(1, 2, -1)$ 及其坐标分解。虚线表示沿坐标方向的辅助线。

高中结论：平面向量与空间向量基本定理

定理 0.2 (平面向量基本定理)

若 e_1, e_2 是同一平面内的两个不共线向量, 则对于该平面内任意向量 a , 存在唯一的一对实数 x, y , 使

$$a = xe_1 + ye_2.$$

向量 e_1, e_2 构成该平面的一组基 (Basis)。确定顺序后, x, y 就是 a 关于这组基的坐标 (Coordinates)。

定理 0.3 (空间向量基本定理)

若 e_1, e_2, e_3 是三个不共面的向量，则对于空间中任意向量 a ，存在**唯一**的一组实数 x, y, z ，使

$$a = xe_1 + ye_2 + ze_3.$$

这三个向量构成空间的一组基；固定顺序后， x, y, z 为相应坐标。

上述平面向量基本定理 (Fundamental Theorem of Plane Vectors) 与空间向量基本定理 (Fundamental Theorem of Space Vectors) 都包含**存在性与唯一性**：任何向量都能表示，而且表示系数唯一。基向量不必是单位向量 (Unit Vector)，也不必互相垂直；不共线或不共面的条件才是关键。第 0.5 节将结合图形进一步说明更换基与更换坐标的关系。

增加分量，而不改变运算规则

假设按“语文、数学、英语、程序设计”的固定顺序记录成绩，那么 $(82, 90, 78, 95)$ 就是一名学生的四维成绩向量。我们不必先画出四条互相垂直的轴，才能理解这四个数：只要知道每个位置记录什么，就能阅读这份数据。

定义 0.4 (n 维实向量)

按固定顺序排列的 n 个实数构成一个 n 维实向量 (n -Dimensional Real Vector)，记作

$$x = (x_1, x_2, \dots, x_n).$$

其中 x_i 称为第 i 个分量 (Component)。所有 n 维实向量组成的集合记作 $\mathbb{R}^n$ 。

“有序”很重要。交换成绩向量中的数学与英语分量，就改变了它所记录的信息。比较两个向量时，不仅分量个数要相同，各位置对应的含义与单位也应一致。

向量可以横着写成一行，也可以竖着写成一列。为便于阅读，本章多采用行式记法；以后用矩阵表示方程组时，常采用列式记法。例如， $x = (x_1, x_2, x_3)$ 的列式记法是

$$x = \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix}.$$

这两种记法在这里记录的是同一组分量；进入矩阵运算以后，行与列的位置有明确作用，不能随意互换。

若 $\mathbf{x}, \mathbf{y} \in \mathbb{R}^n$, c 为实数, 则

$$\mathbf{x} + \mathbf{y} = (x_1 + y_1, x_2 + y_2, \dots, x_n + y_n),$$

$$c\mathbf{x} = (cx_1, cx_2, \dots, cx_n).$$

零向量记作 $\mathbf{0} = (0, \dots, 0)$; $\mathbf{x}$ 的相反向量是 $-\mathbf{x}$, 所以向量减法也可理解为加上相反向量。分量个数不同的两个向量, 不能直接按上述规则相加。

例题 0.5 (四维运算并不需要四维图像)

设 $\mathbf{x} = (1, 2, 0, -1)$, $\mathbf{y} = (2, -1, 3, 1)$ 。先把 $\mathbf{x}$ 的每个分量乘以 2, 再加上 $\mathbf{y}$, 得到

$$2\mathbf{x} + \mathbf{y} = (2, 4, 0, -2) + (2, -1, 3, 1) = (4, 3, 3, -1).$$

与二维、三维计算相比, 唯一增加的工作是多处理几个分量。

怎样理解“维度”

对 $\mathbb{R}^n$ 来说, n 表示一个向量具有 n 个可分别指定的坐标分量。它不要求我们在日常物理空间中找到 n 个方向。在数据表示中, 可以把每个分量理解为一个特征位置; 有多少个特征位置, 就使用多少维的表示。

这里要区分“分别记录”与“彼此没有关系”。四门课的成绩可能相关, 但记录四门课仍使用四个分量。因此, **特征的个数不等于数据中一定有同样多的独立信息**。例如, 把 (a, b) 连同它们的和一起记录为 $(a, b, a + b)$, 表示形式有三个分量, 第三个分量却已由前两个确定。有关独立性与维数的关系, 我们将在下一章继续研究。

研究 n 维空间, 是为了用一套统一方法处理不同规模的问题。 $n = 2$ 或 $n = 3$ 时可以画图, n 很大时仍然可以用坐标计算。实数运算律逐个分量成立, 因而向量的交换律 (Commutative Law)、结合律 (Associative Law) 与分配律 (Distributive Law) 也逐个分量成立, 得到如下统一结论。

性质 0.6 ($\mathbb{R}^n$ 中向量的运算律)

设 $u, v, w \in \mathbb{R}^n$, $c, d \in \mathbb{R}$, 则

$$u + v = v + u, \quad \text{加法交换律,}$$

$$(u + v) + w = u + (v + w), \quad \text{加法结合律,}$$

$$u + 0 = u, \quad u + (-u) = 0, \quad \text{零向量与相反向量,}$$

$$c(u + v) = cu + cv, \quad \text{对向量加法分配,}$$

$$(c + d)u = cu + du, \quad \text{对实数加法分配,}$$

$$c(du) = (cd)u, \quad 1u = u, \quad \text{数乘的基本性质.}$$

减法统一定义为 $u - v = u + (-v)$ 。

0.2 向量的线性组合

先伸缩, 再相加

由数乘与加法得到的 $2u + v$ 、 $3u - v$ 等表达式, 都是线性组合。几何上先按系数伸缩或反向, 再依三角形定则首尾相接; 平移箭头只是作图步骤, 不改变向量。

定义 0.7 (线性组合)

给定同一个 $\mathbb{R}^n$ 中的向量 $v_1, \dots, v_k$, 取实数 $c_1, \dots, c_k$, 形如

$$c_1 v_1 + c_2 v_2 + \cdots + c_k v_k$$

的向量, 称为这些向量的一个**线性组合 (Linear Combination)**。实数 $c_1, \dots, c_k$ 称为系数 (Coefficient)。

系数可以为正数、负数或零。正负号决定是否反向, 绝对值决定伸缩程度, 零系数表示暂时不使用相应的向量。

例题 0.8 (用两个方向到达目标)

取 $u = (1, 1)$ 、 $v = (1, -1)$ ，则

$$2u + v = 2(1, 1) + (1, -1) = (3, 1).$$

因此，目标向量 $b = (3, 1)$ 可以由 u 与 v 表示。这里的“沿 u 走两份，再沿 v 走一份”，就是线性组合的几何解释。




图 0.3: 线性组合 $2u + v = (3, 1)$: 按系数数乘，再用三角形定则相加。

让系数变化：张成的范围

固定一个非零向量 u ，让实数 t 任意变化， tu 的终点就遍布一条过原点的直线。固定两个不共线的平面向量，让两个系数分别变化，它们的线性组合就能到达平面中的任意位置。

一组向量的所有可能的线性组合所构成的集合，称为它们的张成空间 (Span)，也就是它们张成的集合，记作

$$\text{span}\{v_1, \dots, v_k\} = \{c_1 v_1 + \dots + c_k v_k : c_1, \dots, c_k \in \mathbb{R}\}.$$

英文词 span 在这里可以理解为“用这些向量能够覆盖的范围”。一个线性组合给出一个向量，张成的集合则包含所有这样的结果。

对于刚才的 $u = (1, 1)$ 与 $v = (1, -1)$ ，任意 (a, b) 都可写成

$$(a, b) = \frac{a+b}{2}u + \frac{a-b}{2}v.$$

因此，它们张成整个 $\mathbb{R}^2$ 。但 $(1, 1)$ 与 $(2, 2)$ 始终指向同一条直线，任何线性组合仍是 (t, t) ，不能表示 $(1, 0)$ 。

在 $\mathbb{R}^3$ 中，两个不共线向量张成一个过原点的平面；三个不共面的向量张成整个三

维空间。一个非零向量仍只张成一条直线。决定范围的，不只是向量的数量，还有它们之间的关系。




图 0.4: 张成范围的变化：直线、平面与三维空间。阴影只显示无限平面的一部分。

“能否表示”为什么会变成方程组

给定目标 $\mathbf{b} = (3, 1)$ ，要求它是否能写成 $c_1\mathbf{u} + c_2\mathbf{v}$ ，就要让两个分量分别相等：

$$c_1(1, 1) + c_2(1, -1) = (3, 1) \iff \begin{cases} c_1 + c_2 = 3, \\ c_1 - c_2 = 1. \end{cases}$$

解得 $c_1 = 2$ 、 $c_2 = 1$ ，就找到了表示方法。若没有满足要求的系数，目标向量就在张成范围之外。

以后研究更大的方程组，核心问题仍可以这样理解：这个目标向量，能不能由给定的这组向量表示出来？方程组中的未知数，正是待求的线性组合系数。

0.3 几何中的直线、平面与子空间

运算以后，还在不在里面

考虑平面中经过原点、方向为 $(1, 2)$ 的直线

$$L = \{t(1, 2) : t \in \mathbb{R}\}.$$

取直线上的两个向量 $s(1, 2)$ 与 $t(1, 2)$ ，它们的和为 $(s + t)(1, 2)$ ，仍在 L 上；把其中一个向量乘以任意实数 c ，得到 $(ct)(1, 2)$ ，也仍在 L 上。也就是说，在这条直线内部进行加法和数乘，不会走出这条直线。

三维空间中的 xy 平面具有相同的特点。它由所有第三个分量为零的向量组成：

$$P = \{(x, y, 0) : x, y \in \mathbb{R}\}.$$

两个第三分量为零的向量相加，第三分量仍然为零；乘以任意实数以后也是如此。它虽然放在三维空间中，内部却保留了一个平面向量世界。

我们把这种“运算后的结果仍留在集合内部”的性质称为**对运算封闭 (Closure under an Operation)**。这里的“封闭”说的是运算，不是图形有没有围成一圈。




图 0.5: 子空间对加法封闭：直线与平面内的向量相加，结果仍在原集合中。

把这个想法推广到高维

在 $\mathbb{R}^n$ 中, 也有一些非空子集, 使得其中任意两个向量相加、任意一个向量乘以任意实数, 结果都还在这个子集中。这样的集合就是我们本章要直观认识的**子空间 (Subspace)**。它沿用所在空间的加法与数乘, 可以看成大空间内部能够独立进行线性运算的“小空间”。

例如, $\mathbb{R}^4$ 中的集合

$$W = \{(a, b, 0, 0) : a, b \in \mathbb{R}\}$$

就像嵌在四维空间中的一个平面。虽然每个向量写成四个分量, 但只有前两个分量可以自由选择。在 W 内相加或数乘, 最后两个分量总保持为零。

上一节的张成也提供了这样的集合。两份线性组合相加, 可以合并对应向量的系数; 一份线性组合乘以一个数, 只需把各系数同时乘以这个数。因此, 一组向量张成的集合对这两种运算都封闭。

子空间不限于直线和平面。只包含零向量的集合 $\{0\}$ 是最小的例子, 整个 $\mathbb{R}^n$ 也是它自己的子空间。本章先抓住这些例子与运算特点, 不急于展开一般理论。

为什么必须经过原点

如果一个非空集合对任意数乘封闭, 那么取其中任意向量乘以 0, 就得到 0 。所以, **子空间一定包含零向量**。在几何图上, 这正是“经过原点”的含义。

反过来看直线 $y = 1$ 。向量 $(0, 1)$ 在这条直线上, 但 $2(0, 1) = (0, 2)$ 不在这条直线上, $0(0, 1) = (0, 0)$ 也不在。因此, 一条不过原点的直线, 即使看起来很“直”, 也不是子空间。三维空间中不过原点的平面同样如此。




图 0.6: 直线 $y = 1$ 不对数乘封闭: $(1, 1)$ 的两倍和零倍都不在该直线上。

还要注意，经过原点只是必要条件，并不是唯一要求。例如，两条坐标轴的并集包含原点，但 $(1, 0)$ 与 $(0, 1)$ 都在这个集合内，它们的和 $(1, 1)$ 却不在。判断时，必须同时留意零向量、加法与任意实数的数乘，不能只看图形是否穿过原点。

0.4 向量之间的关系

从共线、共面看“重复的方向”

定理 0.9 (向量共线的充要条件)

设 $u \neq 0$ 。向量 v 与 u 共线 (Collinear)，当且仅当存在实数 λ ，使

$$v = \lambda u.$$

当 $v \neq 0$ 时， $\lambda > 0$ 表示同向， $\lambda < 0$ 表示反向； $\lambda = 0$ 对应零向量。通常约定零向量与任意向量共线，但不赋予它确定方向。

定理 0.10 (空间向量共面的判定)

设 u, v 不共线。向量 w 与它们共面 (Coplanar)，当且仅当存在实数 s, t ，使

$$w = su + tv.$$

这里的共面，是指将起点置于同一点后，三个向量位于同一个平面。

把两个非零向量的起点放在一起，如果它们的方向相同或相反，就称它们共线。用坐标表达，就是其中一个可以写成另一个的数倍。例如， $(2, 4) = 2(1, 2)$ 。在张成的意义下，已经有了 $(1, 2)$ ，再加入 $(2, 4)$ ，能够到达的范围并没有扩大。

把三个空间向量的起点放在原点，如果它们能放在同一个过原点的平面内，就称它

们共面。例如，

$$\mathbf{u} = (1, 0, 0), \quad \mathbf{v} = (0, 1, 0), \quad \mathbf{w} = (1, 1, 0)$$

都在 xy 平面内，并且 $\mathbf{w} = \mathbf{u} + \mathbf{v}$ 。前两个向量已经能够表示这个平面内的全部向量，第三个向量没有带来新的表示能力。




图 0.7: 共线、共面与不共面的向量组：是否增加新的表示方向，是理解线性关系的关键。

线性相关：至少有一个向量可以省去

把上述现象推广到高维，就得到线性相关的直观含义：一组向量里至少有一个向量能够由其余向量线性表示，它在张成这件事上是多余的。这样的向量组称为线性相关 (Linearly Dependent) 的。

比如，若 $\mathbf{w} = \mathbf{u} + \mathbf{v}$ ，那么任何使用了 $\mathbf{w}$ 的组合都可以改写为

$$a\mathbf{u} + b\mathbf{v} + c\mathbf{w} = (a + c)\mathbf{u} + (b + c)\mathbf{v}.$$

去掉 $\mathbf{w}$ ，张成的集合不会改变。“多余”在这里具有明确含义：它不是说这份数据没有应用价值，而是说它没有扩大线性组合能够表示的范围。

例题 0.11 (四个分量也能直接看出关系)

设

$$\mathbf{p} = (1, 0, 1, 0), \quad \mathbf{q} = (0, 1, 0, 1), \quad \mathbf{r} = (1, 1, 1, 1).$$

逐个分量相加可得 $\mathbf{r} = \mathbf{p} + \mathbf{q}$ 。因此，这三个四维向量线性相关。这个结论来自表示关系，不需要画出四维图形。

线性无关：每一个都不可省去

如果一组向量中，没有任何一个能够由其余向量线性表示，就称这组向量线性无关 (Linearly Independent)。去掉其中任意一个，原来能够表示的某些向量就无法再表示。

二维平面中的两个不共线向量线性无关，因为一个向量的所有数倍只能落在它所在的直线上，无法得到另一个方向的向量。三维空间中的三个不共面向量也线性无关：任意两个的线性组合都在它们张成的平面内，无法得到第三个向量。

零向量需要单独留意。它没有确定的方向，却可以由任意向量乘以 0 得到。因此，只要一个向量组含有零向量，它就是线性相关的。只含一个零向量的组也约定为线性相关；只含一个非零向量的组则线性无关。

后续章节会把这些说法写成统一的方程条件，并介绍系统的判定方法。现在先记住这一对问题：张成问的是“能表示哪些向量？”，相关性问的是“其中有没有可以省去的向量？”

0.5 坐标系与基的直观

坐标来自一组约定好的向量

在平面直角坐标系中，沿 x 轴与 y 轴正方向的单位向量分别为

$$e_1 = (1, 0), \quad e_2 = (0, 1).$$

平面中任意向量 $x = (a, b)$ 都可以写成

$$x = ae_1 + be_2.$$

而且这种表示只有一种：两个分量分别要求第一个系数为 a 、第二个系数为 b 。我们平时所说的坐标，正是这两个系数。按上述顺序排列的 e_1, e_2 ，称为 $\mathbb{R}^2$ 的**标准基 (Standard Basis)**。

这给了“基”一个直观解释：选定若干向量作为表示工具，让空间里的每个向量都能用它们表示，并且表示方法是唯一的。

换一组基，同一个向量可以有不同坐标

基不一定由互相垂直的单位向量组成。由平面向量基本定理，平面中任意两个不共线向量都可以成为一组基。例如，选择

$$b_1 = (1, 0), \quad b_2 = (1, 1),$$

它们不垂直，却仍能表示任意平面向量，因为

$$(a, b) = (a - b)b_1 + bb_2.$$

一旦基的顺序固定，这两个系数也就确定了。

例题 0.12 (同一支箭头, 两份坐标)

考虑向量 $x = (3, 2)$ 。相对于标准基,

$$x = 3e_1 + 2e_2.$$

相对于有序基 $B = (b_1, b_2)$, 则有

$$x = 1b_1 + 2b_2 = (1, 0) + 2(1, 1) = (3, 2).$$

所以, 它的标准坐标为 $(3, 2)$, 而关于基 B 的坐标为 $(1, 2)$, 可记作 $[x]_B = (1, 2)$ 。两份坐标描述的是同一个向量。




图 0.8: 同一个向量 $(3, 2)$ 的两种分解。红色箭头不变, 所选的基与表示系数改变。

坐标是相对于基的表示, 不能脱离所选的基来解释。更换基时, 向量本身没有移动, 改变的是用来描述它的系数。这也与后面要学习的“把向量真正变成另一个向量”的线性变换有所区别。

这里并不否定我们此前把 $\mathbb{R}^n$ 的向量定义为有序数组: 在 $\mathbb{R}^n$ 的标准基下, 一个向量的坐标数组恰好就是它原来的分量数组。换成别的基以后, 应当区分原向量 x 与它的新坐标 $[x]_B$ 。

“够用”并且“没有多余”, 就是基

结合前两节的概念, 一组向量要成为所讨论空间的一组基, 需要同时满足两点: 它们张成整个空间, 并且线性无关。前者保证每个向量都有表示, 后者保证没有重复的表示方式。因此, 基既是“够用的一组”, 也是“没有多余的一组”。讨论坐标时, 还要固定基向量的先后顺序。

例如, 在三维空间里, $e_1 = (1, 0, 0)$ 与 $e_2 = (0, 1, 0)$ 是 xy 平面的一组基, 却不是整个 $\mathbb{R}^3$ 的一组基, 因为它们无法表示 $(0, 0, 1)$ 。谈基时, 总要说明它是哪一个空间的基。

在 $\mathbb{R}^n$ 中，标准基由 n 个向量组成：第 i 个向量 $\mathbf{e}_i$ 的第 i 个分量为 1，其余分量全为 0。于是

$$\mathbf{x} = (x_1, \dots, x_n) = x_1 \mathbf{e}_1 + \dots + x_n \mathbf{e}_n.$$

这就是高中平面坐标分解在 n 维空间中的直接推广。

0.6 线性代数究竟研究什么？

回看前面的讨论，我们做的并不只是把两个分量换成 n 个分量。更重要的是，我们开始围绕向量的表示、关系与结构提出问题。

第一层：向量之间的线性关系

给定一组向量，一个目标能否由它们表示？让系数任意变化，它们能够覆盖多大的范围？这组向量是否含有多余的成员？能否找出一组既够用又没有多余的向量，作为整个空间的基？

这些问题分别把线性组合、张成、线性相关与基联系起来。我们所说的向量空间 (Vector Space)，可以先理解为一个允许进行加法与数乘、并遵循熟悉运算规则的向量世界。 $\mathbb{R}^n$ 及其子空间是本书首先研究的对象。

第二层：向量怎样发生线性变化

除了比较向量，线性代数还研究把向量变成另一个向量的规则。例如，平面中的整体旋转、沿某个轴的伸缩，或者把三维向量投影到一个过原点的平面，都能用线性变换 (Linear Transformation) 描述。

“线性”并不只是说图形看起来像直线，而是说变换与加法、数乘相容。若用 T 表示这种规则，就有

$$T(\mathbf{u} + \mathbf{v}) = T(\mathbf{u}) + T(\mathbf{v}), \quad T(c\mathbf{u}) = cT(\mathbf{u}).$$

第一条表示“先相加再变换”与“先分别变换再相加”相同；第二条表示数乘也可以与变换交换顺序。本章先理解这两句话的意思，后续再系统学习它们。

例如，规则 $T(x, y) = (2x, y)$ 把水平方向的位移放大为两倍、保留竖直方向的位移，是一个线性变换。把所有点整体平移一个非零向量则不是线性变换，因为它会把原点移走。线性变换总把零向量送到零向量。




图 0.9: 线性伸缩与平移的区别: $T(x, y) = (2x, y)$ 保持原点不动, 非零平移不保持原点。

怎样让计算机执行这样的变换? 选定基后, 可以把变换所需的信息组织成一张数表, 这就是后续要使用的**矩阵 (Matrix)**。矩阵既能整理方程组的系数, 也能表示线性变换, 使几何问题成为可以按规则进行的数值运算。

第三层：不同应用共享的语言

在物理与工程中, 向量可以记录多个力或多个状态量; 在线性模型中, 方程描述这些量之间的约束。在计算机中, 向量可以记录图形的顶点、数据的特征, 矩阵可以组织坐标变换与数据运算。具体含义不同, 背后的表示关系却可以用同样的数学工具分析。

当然, 并非所有实际问题都是线性的。线性代数提供的是研究线性结构的一套通用语言, 也常被用作复杂模型的一部分。它的价值在于: 一旦认出了**相同的线性结构**, 就能把**同一种方法**用到不同的问题中。

下一章开始, 我们将在 $\mathbb{R}^n$ 中系统研究向量的线性关系、基与维数。在此之前, 先整理高中熟悉的点积, 补充描述长度与夹角的工具。

0.7 向量的度量：点积、长度与夹角

前六节讨论的是向量的线性结构 (Linear Structure)：怎样相加、数乘，哪些方向能由给定向量表示，怎样张成空间、选取基。这些问题并不衡量两个方向有多接近。章末短视频案例将提出一个具体问题：两条视频都有较强科技特征，哪一条更贴近用户偏好？这需要补充有关长度与夹角的度量结构 (Metric Structure)。高中已经接触过这样的运算——数量积，也用它计算恒力做功。本节先整理熟悉的几何结论，再把坐标公式推广到 n 维。

从长度与夹角定义点积

把两个非零向量的起点移到同一点，两支箭头之间不超过平角的角称为向量夹角 (Angle Between Vectors)，记作 $\theta \in [0, \pi]$ 。


定义 0.13 (数量积 (点积))

设非零平面或空间向量 a, b 的夹角为 θ ，定义它们的数量积 (点积) (Dot Product) 为

$$a \cdot b = |a| |b| \cos \theta. \quad (0.1)$$

规定零向量与任意向量的点积均为 0。点积的结果是一个数，而不是向量。

点积同时携带长度与夹角的信息。若只想比较方向，应当除去长度之积，观察 $\cos \theta$ ；不能仅凭点积较大，就断定夹角较小。



$$a \cdot b = |a| |b| \cos \theta$$

长度之积 $\times$ 夹角的余弦

图 0.10: 点积把两个向量的长度与夹角联系起来；右侧给出点积的数值关系。

同向时 $\theta = 0$ ，点积等于长度之积；反向时 $\theta = \pi$ ，点积等于长度之积的相反数。锐角对应正点积，钝角对应负点积，直角恰好对应零点积。




图 0.11: 对两个非零向量, 夹角为锐角、直角、钝角时, 点积依次为正、零、负。

定理 0.14 (两个非零向量垂直的充要条件)

对两个非零平面或空间向量, 有

$$a \perp b \iff a \cdot b = 0. \quad (0.2)$$

证明: 若两向量垂直, 则 $\theta = \pi/2$, 因而 $\cos \theta = 0$, 点积为 0。反之, 点积为 0 且两向量均非零, 则长度之积大于 0, 由式(0.1)可得 $\cos \theta = 0$ 。在 $[0, \pi]$ 中, 这意味着 $\theta = \pi/2$, 即两向量垂直。 ■

非零条件不能省略。 零向量与任意向量的点积都是 0, 但它没有确定的方向; 在这里的几何意义下, 不讨论零向量的夹角与垂直。

用坐标计算：对应分量相乘，再相加

几何定义说明了点积的含义, 但怎样把长度与夹角转化为坐标运算? 关键是先回顾高中学过的余弦定理 (Law of Cosines)。它把勾股定理从直角三角形推广到任意三角形, 再把这条边长关系用于向量。

定理 0.15 (余弦定理)

在三角形 OPQ 中, 设 $OP = r$ 、 $OQ = s$ 、 $PQ = c$, 两边 OP 与 OQ 的夹角为 θ , 则

$$c^2 = r^2 + s^2 - 2rs \cos \theta. \quad (0.3)$$

即：一边的平方, 等于另外两边的平方和, 减去这两边与它们夹角余弦的乘积的两倍。这里 c 必须是角 θ 所对的边。

当 $\theta = 90^\circ$ 时, 余弦项为 0, 公式恰好变成勾股定理; 当 θ 为锐角时, $c^2 < r^2 + s^2$; 当 θ 为钝角时, $c^2 > r^2 + s^2$ 。因此, $-2rs \cos \theta$ 正是相对于直角情形的修正项。已知两

边及夹角，可以求第三边；反过来，已知三边，也可以求夹角：

$$\cos \theta = \frac{r^2 + s^2 - c^2}{2rs}. \quad (0.4)$$




图 0.12: 余弦定理的辅助图。锐角时垂足 H 在射线 OP 上，钝角时在其反向延长线上；灰色虚线表示高与辅助延长线。

证明: 以 O 为原点，沿 OP 建立横轴，在三角形所在平面内建立直角坐标系。于是 $P = (r, 0)$ 。由三角函数的几何意义， $Q = (s \cos \theta, s \sin \theta)$ ，垂足 $H = (s \cos \theta, 0)$ 。

注意， $s \cos \theta$ 是 H 的横坐标，不总是线段 OH 的长度：钝角时它为负数。这使同一个计算能够同时处理锐角、直角与钝角，无须另换公式。由勾股定理得到的两点距离公式，有

$$c^2 = (r - s \cos \theta)^2 + (s \sin \theta)^2 \quad (0.5)$$

$$= r^2 - 2rs \cos \theta + s^2 \cos^2 \theta + s^2 \sin^2 \theta \quad (0.6)$$

$$= r^2 + s^2 - 2rs \cos \theta. \quad (0.7)$$

最后一步使用了 $\cos^2 \theta + \sin^2 \theta = 1$ 。这里仅用了勾股定理与三角函数，没有使用点积的坐标公式。 ■

现在令 $\overrightarrow{OP} = \mathbf{a}$ 、 $\overrightarrow{OQ} = \mathbf{b}$ 。三角形的第三边满足 $\overrightarrow{QP} = \mathbf{a} - \mathbf{b}$ ，因此三边长分别是 $|\mathbf{a}|$ 、 $|\mathbf{b}|$ 、 $|\mathbf{a} - \mathbf{b}|$ 。把它们代入余弦定理，再使用点积的几何定义，就得到

$$|\mathbf{a} - \mathbf{b}|^2 = |\mathbf{a}|^2 + |\mathbf{b}|^2 - 2\mathbf{a} \cdot \mathbf{b}. \quad (0.8)$$

若 $\mathbf{a} = (a_1, a_2)^T$ 、 $\mathbf{b} = (b_1, b_2)^T$ ，利用由勾股定理得到的模长公式展开两边：

$$(a_1 - b_1)^2 + (a_2 - b_2)^2 = a_1^2 + a_2^2 + b_1^2 + b_2^2 - 2\mathbf{a} \cdot \mathbf{b}, \quad (0.9)$$

$$\underbrace{a_1^2 + a_2^2 + b_1^2 + b_2^2}_{\text{两边相同的平方项}} - 2(a_1b_1 + a_2b_2) = a_1^2 + a_2^2 + b_1^2 + b_2^2 - 2\mathbf{a} \cdot \mathbf{b}. \quad (0.10)$$

消去相同的平方项，再除以 -2 ，便得到

$$\mathbf{a} \cdot \mathbf{b} = a_1 b_1 + a_2 b_2. \quad (0.11)$$

这说明“对应分量相乘，再相加”是由几何定义推导出来的计算公式。两向量共线时，分别取 $\theta = 0$ 或 π ，退化三角形的边长关系仍满足上述等式；有零向量时，两边也同为 0。

空间中的两个不共线向量同样确定一个平面，可以在该平面内应用余弦定理；再用三维坐标展开模长平方，便得到

$$\mathbf{a} \cdot \mathbf{b} = a_1 b_1 + a_2 b_2 + a_3 b_3. \quad (0.12)$$

这条推导连接了两种语言：几何上用长度与夹角定义，计算时用对应分量的乘积求和。

例题 0.16 (由坐标读出夹角)

设 $\mathbf{a} = (1, 2, 2)^T$ 、 $\mathbf{b} = (2, -1, 1)^T$ ，则

$$\mathbf{a} \cdot \mathbf{b} = 1 \times 2 + 2 \times (-1) + 2 \times 1 = 2, \quad (0.13)$$

$$|\mathbf{a}| = \sqrt{1 + 4 + 4} = 3, \quad |\mathbf{b}| = \sqrt{4 + 1 + 1} = \sqrt{6}, \quad (0.14)$$

$$\cos \theta = \frac{2}{3\sqrt{6}} \approx 0.272, \quad \theta \approx 74.2^\circ. \quad (0.15)$$


点积为正，与夹角是锐角的判断一致。

长度：自己与自己的点积

令两个向量相同，非零向量与自身的夹角为 0，故 $\mathbf{a} \cdot \mathbf{a} = |\mathbf{a}|^2$ ；零向量也满足这个等式。向量的模长 (Euclidean Length) 因而可以从点积直接读出：

$$|\mathbf{a}| = \sqrt{\mathbf{a} \cdot \mathbf{a}} = \sqrt{a_1^2 + a_2^2 + a_3^2}. \quad (0.16)$$

这正是高中熟悉的模长公式。长度不是与点积无关的另一个读数，而是点积在“自己与自己”这一情形下确定的量。



$$|\mathbf{a}|^2 = \mathbf{a} \cdot \mathbf{a}$$

与自己比较，读出长度

图 0.13: 向量与自身的点积等于长度的平方。虚线只作坐标辅助。

例题 0.17 (用点积判断垂直)

设 $\mathbf{a} = (1, 2, 2)^T$ 、 $\mathbf{c} = (2, 2, -3)^T$ 。由

$$\mathbf{a} \cdot \mathbf{c} = 1 \times 2 + 2 \times 2 + 2 \times (-3) = 0, \quad (0.17)$$

且两个向量都非零，可知 $\mathbf{a} \perp \mathbf{c}$ 。不必先求出夹角，再检查它是否为直角。

回看前面的夹角算例，点积的坐标计算可以概括为下面的流程。




图 0.14: 三维点积的坐标计算：对应分量相乘，把三个乘积相加。

推广到 n 维：沿用同一条坐标规则

四维、五维的箭头不能直接画在普通空间里，但“对应分量相乘再相加”仍然清楚。这提示我们把二维、三维的坐标公式直接作为 n 维点积的定义，无须另造计算规则。

定义 0.18 (n 维向量的点积)

对 $\mathbf{x} = (x_1, \dots, x_n)^T$ 、 $\mathbf{y} = (y_1, \dots, y_n)^T \in \mathbb{R}^n$ ，定义

$$\mathbf{x} \cdot \mathbf{y} = x_1 y_1 + \dots + x_n y_n = \sum_{i=1}^n x_i y_i. \quad (0.18)$$

相应地，长度与两个非零向量的夹角由下式给出：

$$|\mathbf{x}| = \sqrt{\mathbf{x} \cdot \mathbf{x}} = \sqrt{x_1^2 + \dots + x_n^2}, \quad \cos \theta = \frac{\mathbf{x} \cdot \mathbf{y}}{|\mathbf{x}| |\mathbf{y}|}, \quad \theta \in [0, \pi]. \quad (0.19)$$

柯西-施瓦茨不等式 (Cauchy-Schwarz Inequality) 保证点积的绝对值不超过长度之积，因此这个比值落在 $[-1, 1]$ 内，确实能够定义夹角；证明留到第 7 章。对两个非零向量，垂直的判定仍为

$$\mathbf{x} \perp \mathbf{y} \iff \mathbf{x} \cdot \mathbf{y} = 0. \quad (0.20)$$

高维中通常把这一关系称为正交性 (Orthogonality)。这里先用非零向量的直角理解它；第 7 章将用内积为 0 统一定义正交，届时也包含零向量的情形。

例题 0.19 (四维向量的方向关系)

取 $\mathbf{x} = (1, 2, 0, -1)^T$ 、 $\mathbf{y} = (2, -1, 3, 1)^T$ ，则

$$\mathbf{x} \cdot \mathbf{y} = 1 \times 2 + 2 \times (-1) + 0 \times 3 + (-1) \times 1 = -1, \quad (0.21)$$

$$|\mathbf{x}| = \sqrt{6}, \quad |\mathbf{y}| = \sqrt{15}, \quad (0.22)$$

$$\cos \theta = -\frac{1}{\sqrt{90}} \approx -0.105, \quad \theta \approx 96.1^\circ. \quad (0.23)$$

夹角略大于直角。虽然画不出完整的四维图形，仍能通过点积的符号及除以长度之积后的数值，判断方向关系。

本节只做了两件事：把高中的点积按坐标形式整理清楚，把公式推广到 n 维。由此得到的长度、夹角与正交，将成为后续几章的几何语言。第 1 章仍以加法、数乘研究线性关系，不需要点积；第 6 章讨论行列式与体积时会用到长度与垂直的直观；第 7 章则将点积推广为内积，系统研究正交投影、正交基、施密特正交化与最小二乘。现在带着这套初步的度量工具，回到向量所描述的数据。

0.8 案例总结：从箭头到数据 ——三种眼光看向量

同一个向量，三种观察角度

从**几何视角**看，向量可以画成有大小和方向的箭头，加法是位移的合成，数乘是伸缩或反向。从**数学视角**看，本章的向量是有序实数组，是 $\mathbb{R}^n$ 中的元素，我们关心它能怎样参与线性运算。从**计算机应用视角**看，向量可以记录特征、测量值或系统状态，每个分量都有约定好的含义。

这不是三种互不相干的对象，而是对同一套表示与运算的不同解释。几何图帮助我们看见关系，数学记号帮助我们准确描述关系，应用则说明这些关系为什么值得研究。高维数据不能完整画成普通空间中的箭头，并不妨碍我们保留伸缩、相加与表示范围的直觉。




图 0.15: 三种眼光看向量：箭头提供几何直观，数组给出数学表示，分量含义由应用约定。

案例：把短视频表示成向量（选读）

下面以抖音这类短视频应用的推荐场景为背景，建立一个教学用的简化模型。**这些特征、分值和推荐规则均为示例，不代表平台实际采用的内部算法。**这里的目的是，理解“把内容变成向量”意味着什么。

假设我们只观察“搞笑、科技、美食、游戏”四类内容，并约定各项分值在 0 到 1 之间，数值越大表示相应内容特征越明显。按固定顺序排列这些分值，一条视频就得到一个四维特征向量（数据表示）（Feature Vector）：

$$v = (\text{搞笑分值}, \text{科技分值}, \text{美食分值}, \text{游戏分值}).$$

一个视频可以同时具有多种特征。例如，一条用幽默方式介绍电脑硬件的视频，可以既有较高科技分值，也有一定搞笑分值。这些分值不要求相加等于 1，在本例中它们并不是互斥类别的概率。

视频	搞笑	科技	美食	游戏
A: 电脑硬件讲解	0.2	0.9	0.0	0.3
B: 家常菜制作	0.1	0.1	0.9	0.0
C: 游戏设备评测	0.4	0.8	0.0	0.8

于是，视频 A 对应 $v_A = (0.2, 0.9, 0, 0.3)$ ，视频 B 与 C 也各自对应一个向量。若再增加时长、画面风格或更多内容指标，分量数就随之增加；具体系统还可以由模型学习特征，这些特征不一定都能被人直接命名。无论采用多少个分量，“按同一顺序记录、按同一位置比较”的原则都一样。

在最简单的推荐规则中，如果用户主要喜欢科技内容，就优先考虑科技分值高的视频。只比较第二个分量，会把 A 与 C 排在 B 前面。这一步甚至不需要复杂的公式：我们只是在利用向量中特定位置的数值。



图 0.16: 短视频推荐的教学简化模型：固定特征顺序后，先用“科技”分量筛选候选内容。图中分值与规则均为示例。

从比较一个分量，到比较整个向量

现在问题更细了：A 与 C 都有较强科技特征，究竟哪一个更符合用户喜好？如果用户也偏好游戏内容，仅看“科技”这一项就可能不够。

我们同样可以用四个分量记录用户偏好，例如

$$p = (0.2, 0.9, 0, 0.8).$$

这时要比较的，是视频的整个特征向量与用户的整个偏好向量。哪些特征应该占更大权重？一个向量整体变大，是否就意味着它更符合偏好？两个向量在各个分量上的分布模式接近，又该怎样用一个数表达？这些问题需要比“比较单个分量大小”更精确的工具。

第 0.7 节已经给出了点积、长度与夹角的计算方法，它们为比较向量方向提供了初步工具。如何把这些量用于相似程度的衡量，以及怎样解释相应的几何关系，将在第 7

章“内积空间与正交性”中系统讨论。现在先明确这个问题为什么会出现：**当一个对象由许多特征共同描述时，我们需要比较的不再只是一个数，而是整组数值之间的关系。**

还要区分数学运算与应用约束。 $\mathbb{R}^4$ 允许任意实数分量，但本例只取 0 到 1 之间的特征值。这些实际视频向量的集合不一定对加法和数乘封闭，因此不能因为它们都是向量，就把它们的集合直接叫作子空间。

这个案例说明， n 维向量并不是必须先画出来才能使用的概念。课程成绩、视频特征和系统状态，都可以通过选定分量含义而获得向量表示。线性代数进一步研究这些向量的线性关系、变换与结构。

回到本章的出发点，高中阶段的箭头并没有被丢弃，而是成为理解更一般向量的入口。从逐个分量计算，到讨论表示范围；从辨认多余向量，到选择一组基——沿着这条路线，我们已经具备继续学习 $\mathbb{R}^n$ 中线性关系的直观基础。

第 1 章

$\mathbb{R}^n$ 中的线性关系、基与维数

第 0 章从二维、三维向量出发，把向量的概念推广到了 n 维，并通过直线、平面和数据的例子，初步认识了张成、线性关系、基与坐标。本章要在这些直观的基础上，给出准确的定义，说明各个概念之间的联系，并用基本运算推导出相应性质。

本章的主线是：从向量的加法与数乘出发，研究一个向量能否由一组向量表示；把所有能够表示的向量汇集起来，得到张成空间；再判断原向量组中是否存在多余的向量，提取极大线性无关组，最终建立秩、基与维数的概念。这些概念共同构成后续学习的基础。

本章的判定和计算均从定义出发。遇到线性表示或线性相关性问题的，我们把向量等式逐个分量展开，直接求出系数或确定系数之间的关系。下一章引入矩阵后，将进一步学习适合大量分量和未知数的计算方法。本章首先要解决的是：我们究竟在判断什么，为什么这样判断。

1.1 $\mathbb{R}^n$ 中的向量与线性运算

向量、分量与书写形式

定义 1.1 (n 维实向量与 $\mathbb{R}^n$)

设 n 为正整数。由 n 个实数按确定次序组成的数组

$$\alpha = (a_1, a_2, \dots, a_n)^T$$

称为一个 n 维实向量， a_i 称为它的第 i 个分量。所有 n 维实向量组成的集合记作

$$\mathbb{R}^n = \{(a_1, \dots, a_n)^T : a_i \in \mathbb{R}, i = 1, \dots, n\}.$$

两个向量相等，当且仅当它们的分量个数相同，且对应分量分别相等。

这里的“有序”不能省略。例如 $(1, 2, 3)^T$ 与 $(3, 2, 1)^T$ 是不同的向量。若分量依次表

示语文、数学、英语成绩，交换分量就改变了数据的含义。讨论同一组数据时，分量的含义和排列次序必须统一。下面说明上标 T 的含义。

定义 1.2 (行向量、列向量与转置)

将分量按次序横排，得到**行向量 (Row Vector)**；将分量按相同次序竖排，得到**列向量 (Column Vector)**。把行向量改排成列向量，或把列向量改排成行向量，称为**转置 (Transpose)**，记作上标 T。

$$\alpha = \begin{pmatrix} a_1 \\ a_2 \\ \vdots \\ a_n \end{pmatrix} = (a_1, a_2, \dots, a_n)^T, \quad \alpha^T = (a_1, a_2, \dots, a_n).$$

因此，行向量是相应列向量的转置，列向量也是相应行向量的转置。

本章采用列向量记法。为节省篇幅，通常写成 $(a_1, \dots, a_n)^T$ ；虽然分量印在同一行，带上 T 后表示的仍是列向量。第 0 章采用的坐标数组写法，在本章由这一记号进一步区分排列形式。

转置只改变横、竖排列，不改变分量数值和次序。例如

$$(1, -2, 3)^T = \begin{pmatrix} 1 \\ -2 \\ 3 \end{pmatrix}, \quad (\alpha^T)^T = \alpha.$$

上标 T 是转置符号，不是乘方，也不是把分量倒序。行向量与列向量含有同样的分量信息，但排列形式不同，不直接将它们写成相等；作加法时应统一为同分量数的行向量，或统一为同分量数的列向量。




图 1.1: 转置改变排列方向，保留分量的数值和先后次序；连续转置两次恢复原向量。

线性运算及其八条基本性质

定义 1.3 (向量的加法与数乘)

对 $\alpha = (a_1, \dots, a_n)^T$ 、 $\beta = (b_1, \dots, b_n)^T \in \mathbb{R}^n$ 和 $c \in \mathbb{R}$, 规定

$$\begin{aligned}\alpha + \beta &= (a_1 + b_1, \dots, a_n + b_n)^T, \\ c\alpha &= (ca_1, \dots, ca_n)^T.\end{aligned}$$

加法与数乘统称为**线性运算 (Linear Operations)**。零向量与 α 的相反向量分别记为

$$\mathbf{0} = (0, \dots, 0)^T, \quad -\alpha = (-a_1, \dots, -a_n)^T.$$

减法定义为 $\alpha - \beta = \alpha + (-\beta)$ 。

推论 1.4 (转置与加法、数乘)

对同分量数的列向量 α, β 和实数 c , 有

$$(\alpha + \beta)^T = \alpha^T + \beta^T, \quad (c\alpha)^T = c\alpha^T.$$

即先按分量运算再转置, 与先同时转置再作相应运算, 结果相同。

这两式按上述分量运算规则即可验证。它们说明行、列形式可以统一转换, 不能在同一个向量等式中任意混用两种形式。

性质 1.5 (八条基本运算性质)

对任意 $\alpha, \beta, \gamma \in \mathbb{R}^n$ 及 $c, d \in \mathbb{R}$, 有

- | | |
|---|------------|
| (1) $\alpha + \beta = \beta + \alpha$ | 加法交换律, |
| (2) $(\alpha + \beta) + \gamma = \alpha + (\beta + \gamma)$ | 加法结合律, |
| (3) $\alpha + \mathbf{0} = \alpha$ | 零向量, |
| (4) $\alpha + (-\alpha) = \mathbf{0}$ | 相反向量, |
| (5) $c(\alpha + \beta) = c\alpha + c\beta$ | 对向量加法的分配律, |
| (6) $(c + d)\alpha = c\alpha + d\alpha$ | 对实数加法的分配律, |
| (7) $c(d\alpha) = (cd)\alpha$ | 数乘结合律, |
| (8) $1\alpha = \alpha$ | 单位数乘. |

这些性质可逐个分量验证。例如第 (5) 条的第 i 个分量等式为 $c(a_i + b_i) = ca_i + cb_i$, 它正是实数的分配律。其余性质同样来自实数运算的相应性质。

加法的两个向量必须属于同一个 $\mathbb{R}^n$ 。例如 $(1, 2)^T + (1, 2, 3)^T$ 在本章的规则下没有定义。数乘中的 c 是一个实数, 与向量要作区分: 0 是数, $\mathbf{0}$ 是向量。

利用这些性质, 可以在不逐个写出分量的情况下进行向量推导。例如, 若 $\alpha + \gamma = \beta + \gamma$, 在两边加上 $-\gamma$, 由结合律可得 $\alpha = \beta$, 这就是**加法消去律 (Cancellation Law for Addition)**。又如

$$0\alpha = \mathbf{0}, \quad c\mathbf{0} = \mathbf{0}, \quad (-1)\alpha = -\alpha.$$

以第一式为例, 由 $(0 + 0)\alpha = 0\alpha + 0\alpha$, 在两边消去一个 0α 即得。若 $c\alpha = \mathbf{0}$ 且 $c \neq 0$, 再数乘 $1/c$, 便有 $\alpha = \mathbf{0}$ 。因此

$$c\alpha = \mathbf{0} \iff c = 0 \text{ 或 } \alpha = \mathbf{0}.$$

例题 1.6 (按运算性质整理表达式)

设 $\alpha = (1, -2, 0, 3)^T$ 、 $\beta = (2, 1, -1, 0)^T$ 。计算 $2(\alpha - \beta) + 3\beta$ 。

解: 先利用分配律合并同类向量, 再作分量计算:

$$2(\alpha - \beta) + 3\beta = 2\alpha + \beta = (4, -3, -1, 6)^T.$$

整理向量表达式时, 可以像整理实数的一次式一样使用加法、数乘和分配律; 此处没有定义两个向量之间的乘法。

以上八条性质是本章结构性结论的共同依据。第 1.7 节将看到, 只要另一类对象也具有满足这些性质的加法和数乘, 就可以讨论它们的线性组合、无关性、基与维数。涉及有限维数的结论还需要相应的有限性条件。

1.2 线性组合、线性表示与向量组等价

线性组合与线性表示

以下所说的**向量组 (Vector List)**, 指同一 $\mathbb{R}^n$ 中有限个向量组成的一列, 如 $\alpha_1, \dots, \alpha_m$ 。向量组允许出现零向量和重复向量; 下标用于区分各个位置。

定义 1.7 (线性组合与线性表示)

设 $\alpha_1, \dots, \alpha_m \in \mathbb{R}^n$ 。对任意实数 $c_1, \dots, c_m$ ，向量

$$c_1\alpha_1 + \dots + c_m\alpha_m$$

称为这组向量的一个**线性组合**， $c_1, \dots, c_m$ 称为组合系数。

若存在一组实数 $c_1, \dots, c_m$ ，使

$$\beta = c_1\alpha_1 + \dots + c_m\alpha_m,$$

则称 β 可由 $\alpha_1, \dots, \alpha_m$ **线性表示 (Linear Representation)**。

“线性组合”描述一种构造方式，“线性表示”询问给定目标能否由这种方式得到。呼应第 0 章的说法，就是目标向量能不能被这组向量“凑出来”。系数可以为正、为负或为零，没有“系数之和必须为 1”的要求。

例题 1.8 (从向量等式得到分量方程)

设 $\alpha_1 = (1, 0, 1)^T$ 、 $\alpha_2 = (0, 1, 1)^T$ ，判断 $\beta = (2, 3, 5)^T$ 、 $\gamma = (2, 3, 4)^T$ 是否可由它们线性表示。

解：对一般目标 $(p, q, r)^T$ ，设

$$c_1(1, 0, 1)^T + c_2(0, 1, 1)^T = (p, q, r)^T.$$

对应分量相等，得到

$$c_1 = p, \quad c_2 = q, \quad c_1 + c_2 = r.$$

故存在表示的充要条件是 $r = p + q$ 。于是

$$\beta = 2\alpha_1 + 3\alpha_2,$$

而 γ 不能被表示，因为前两个分量要求 $c_1 = 2, c_2 = 3$ ，第三个分量却要求 $c_1 + c_2 = 4$ ，两者矛盾。

这个例子表明，**线性表示问题本质上是关于组合系数的线性方程组求解问题**。本章只需依据分量相等列出方程，直接比较、代入或整理，判断系数是否存在。这里“不能表示”必须说明方程为何矛盾，而不能只说没有试出合适的系数。

若一个向量可以表示，表示系数是否唯一？例如 $(1, 1)^T$ 可由 $(1, 0)^T, (0, 1)^T$ 表示，也可由更长的向量组 $(1, 0)^T, (0, 1)^T, (1, 1)^T$ 表示；后一组给出

$$(1, 1)^T = 1(1, 0)^T + 1(0, 1)^T + 0(1, 1)^T = 0(1, 0)^T + 0(0, 1)^T + 1(1, 1)^T.$$

系数可能不唯一。第 1.4 节将说明，唯一性取决于所用向量组是否线性无关。

向量组等价

定义 1.9 (向量组的线性表示与等价)

若向量组 $\beta_1, \dots, \beta_s$ 中每个向量，都能由 $\alpha_1, \dots, \alpha_m$ 线性表示，就称前一向量组可由后一向量组线性表示。

若两个向量组可以相互线性表示，则称它们等价，也称这两组为等价向量组 (Equivalent Sets of Vectors)。

等价不要求两个向量组包含相同的向量，也不要求向量个数相等。它表达的是两组向量具有相同的线性表示能力。

性质 1.10 (向量组等价的三条基本性质)

反身性 (Reflexivity): 任何向量组都与自身等价。

对称性 (Symmetry): 若第一组与第二组等价，则第二组与第一组等价。

传递性 (Transitivity): 若第一组与第二组等价，第二组与第三组等价，则第一组与第三组等价。

证明: 每个向量都是自身的 1 倍与其余向量的 0 倍之和，所以反身性成立；对称性直接来自“相互表示”的定义。

传递性的关键是线性组合的线性组合仍是线性组合。若

$$\beta_i = \sum_{j=1}^m c_{ji} \alpha_j, \quad \gamma = \sum_{i=1}^s d_i \beta_i,$$

代入并整理有限项之和，得

$$\gamma = \sum_{j=1}^m \left(\sum_{i=1}^s d_i c_{ji} \right) \alpha_j.$$

对两个方向分别使用这一结论，即得传递性。 ■

例题 1.11 (向量不同, 表示能力相同)

设 $\alpha_1 = (1, 0)^T$ 、 $\alpha_2 = (0, 1)^T$, 并令

$$\beta_1 = \alpha_1 + \alpha_2 = (1, 1)^T, \quad \beta_2 = \alpha_1 - \alpha_2 = (1, -1)^T.$$

显然 β_1, β_2 可由 α_1, α_2 表示; 反过来,

$$\alpha_1 = \frac{1}{2}(\beta_1 + \beta_2), \quad \alpha_2 = \frac{1}{2}(\beta_1 - \beta_2).$$

所以这两个向量组等价。再给第一组添加 $\alpha_1 + \alpha_2$, 所得三个向量仍与原来的两个向量等价。




图 1.2: 三个不同向量组都能表示平面内的任意向量, 因此相互等价。第三组比第一组多一个向量, 但表示范围没有扩大。淡色区域表示同一个平面的一部分。

推论 1.12 (添入或删除可表示的向量)

若 β 可由 $\alpha_1, \dots, \alpha_m$ 线性表示, 则

$$\alpha_1, \dots, \alpha_m \quad \text{与} \quad \alpha_1, \dots, \alpha_m, \beta$$

这两个向量组等价。反过来, 若某个向量可由组内其余向量表示, 删去它后所得组与原组等价。

证明: 原组中的每个向量都在扩大的组中; 扩大的组中唯一新添的 β 又能由原组表示, 所以两个方向的线性表示都成立。删去向量的结论就是同一事实的反向表述。 ■

只验证一个方向的线性表示, 不足以证明等价。例如, 单向量组 $\alpha_1 = (1, 0)^T$ 可由 $\alpha_1, \alpha_2 = (0, 1)^T$ 表示, 但 α_2 不可能是 α_1 的倍数, 反方向不成立。第一组只能表示 x 轴上的向量, 第二组能表示整个平面。



图 1.3: 能被另一组表示, 不一定与另一组等价: 直线内的向量都能由两个坐标方向表示, 平面内的向量却不一定能由一个方向表示。

1.3 张成空间、子空间与直和

从所有线性组合到张成空间

定义 1.13 (张成空间)

向量组 $\alpha_1, \dots, \alpha_m$ 的所有线性组合组成的集合

$$\text{Span}\{\alpha_1, \dots, \alpha_m\} = \{c_1\alpha_1 + \dots + c_m\alpha_m : c_1, \dots, c_m \in \mathbb{R}\}$$

称为该向量组的**张成空间**。记号 Span 读作“张成”。

张成空间把“某个向量能否被表示”改写成集合的语言： β 能由该组向量线性表示，当且仅当 $\beta \in \text{Span}\{\alpha_1, \dots, \alpha_m\}$ 。系数全取 0，说明任何张成空间都包含 $\mathbf{0}$ 。

例如， $\text{Span}\{(1, 2)^T\} = \{(t, 2t)^T : t \in \mathbb{R}\}$ 是平面中过原点的直线。下面把视角放到 $\mathbb{R}^3$ 中，观察两个非标准方向怎样张成一个平面。

例题 1.14 (两个非标准向量张成一个斜平面)

取 $\alpha = (1, 0, 1)^T, \beta = (0, 1, 1)^T$ 。它们都不是标准基向量，且不共线。若 $c_1\alpha + c_2\beta = \mathbf{0}$ ，比较前两个分量即得 $c_1 = c_2 = 0$ ，所以它们线性无关；这一判定将在第 1.4 节正式定义。

任取 $s, t \in \mathbb{R}$ ，有

$$s\alpha + t\beta = (s, t, s+t)^T.$$

这个向量总满足 $z = x + y$ 。反过来，平面上任意向量 $(x, y, x+y)^T$ 都等于 $x\alpha + y\beta$ 。因此

$$\text{Span}\{\alpha, \beta\} = \{(x, y, z)^T : z = x + y\}.$$

图 1.4 中，两个向量都从原点出发。改变系数 s, t ，其线性组合的终点便遍及整个斜

平面，而不是仅落在两支箭头之间。图中的平行四边形和网格只是无限平面的一部分，系数可以取任意实数。




图 1.4: $\mathbb{R}^3$ 中两个线性无关的非标准向量张成平面 $z = x + y$ 。蓝、绿色箭头给出两个生成方向，红色箭头是其中一个线性组合；淡色网格表示张成平面的一部分。

性质 1.15 (线性表示与张成范围)

一个向量组能由另一向量组线性表示，当且仅当前者的张成空间包含于后者的张成空间。特别地，两个向量组等价，当且仅当它们的张成空间相同。

理由是：已能表示的向量再作线性组合，仍能由原向量组表示；反过来，每个生成向量本身属于它的张成空间。添加一个已在张成空间中的向量，不会扩大张成范围；添加一个不在其中的向量，则一定会扩大范围。

子空间的判定

定义 1.16 ($\mathbb{R}^n$ 的子空间)

设 $W \subseteq \mathbb{R}^n$ 。若 W 满足以下三个条件，就称 W 是 $\mathbb{R}^n$ 的一个子空间：

非空： $W \neq \emptyset$ 。

对加法封闭： 若 $\alpha, \beta \in W$ ，则 $\alpha + \beta \in W$ 。

对数乘封闭： 若 $\alpha \in W$ 、 $c \in \mathbb{R}$ ，则 $c\alpha \in W$ 。

推论 1.17 (子空间必含零向量)

若 W 是子空间，则 $\mathbf{0} \in W$ 。因此，子空间判定中的“非空”也可替换为“包含零向量”。

证明: 由非空性, 取 $\alpha \in W$. 由数乘封闭性, $0\alpha = \mathbf{0} \in W$. 反过来, 包含零向量当然保证非空。

包含零向量只是必要条件, 并非充分条件. 还必须检查两种封闭性. 子空间沿用 $\mathbb{R}^n$ 中的加法与数乘, 因此八条基本运算性质自动成立, 不需要重新验证。

例题 1.18 (子空间与非子空间)

设

$$W = \{(x, y, z)^T : z = x + y\}, \quad S = \{(x, y, z)^T : z = x + y + 1\}.$$

解: $\mathbf{0} \in W$. 若 $(x_i, y_i, z_i)^T \in W$, $i = 1, 2$, 则

$$z_1 + z_2 = (x_1 + x_2) + (y_1 + y_2), \quad cz_1 = cx_1 + cy_1.$$

所以 W 对加法和数乘都封闭, 是子空间. S 不含零向量, 故不是子空间.

另设 $Q = \{(x, y)^T : x \geq 0, y \geq 0\}$. 它包含零向量, 但 $(1, 0)^T \in Q$ 而 $-(1, 0)^T \notin Q$, 所以 Q 也不是子空间.

最简单的两个子空间是**零子空间 (Zero Subspace)** $\{\mathbf{0}\}$ 和**全空间 (Whole Space)** $\mathbb{R}^n$, 统称为**平凡子空间 (Trivial Subspaces)**. 注意 $\{\mathbf{0}\}$ 是仅含一个元素的集合, 既不是空集, 也不是实数 0.




图 1.5: 三维空间中的平面与子空间。左图 W 经过原点, 并对加法和数乘封闭, 是子空间; 右图 S 是平移后的平面, 不含原点, 因而不是子空间。阴影只显示各平面的一部分。

定理 1.19 (张成空间的子空间性质)

$\text{Span}\{\alpha_1, \dots, \alpha_m\}$ 是 $\mathbb{R}^n$ 的子空间, 而且是**包含 $\alpha_1, \dots, \alpha_m$ 的最小子空间**。

证明: 零向量属于张成空间。两个线性组合相加, 只需把对应系数相加; 一个线性组合数乘 c , 只需把所有系数乘 c 。结果仍是原向量组的线性组合, 故两种封闭性成立。

若子空间 W 含有全部 α_i , 由两种封闭性, 它也含有这些向量的一切线性组合。因此 $\text{Span}\{\alpha_1, \dots, \alpha_m\} \subseteq W$, 这就是“最小”的含义。■

子空间的交与和

定义 1.20 (子空间的交与和)

设 U, V 是 $\mathbb{R}^n$ 的子空间。它们的子空间的交 (Intersection of Subspaces) 与子空间的和 (Sum of Subspaces) 分别为

$$U \cap V = \{w : w \in U \text{ 且 } w \in V\},$$

$$U + V = \{u + v : u \in U, v \in V\}.$$

交保留两个空间共同拥有的向量; 和允许从两个空间各取一个向量相加。两者仍然是子空间。

对于交, 零向量同时属于两个空间; 属于交的向量相加或数乘后, 仍同时属于两个空间。对于和, $\mathbf{0} = \mathbf{0} + \mathbf{0} \in U + V$, 并且

$$(u_1 + v_1) + (u_2 + v_2) = (u_1 + u_2) + (v_1 + v_2),$$

$$c(u + v) = cu + cv.$$

右端仍是一个 U 中的向量与一个 V 中的向量之和, 所以封闭性成立。

例题 1.21 (两个坐标平面的交与和)

在 $\mathbb{R}^3$ 中, 取 $U = \{(x, y, 0)^T : x, y \in \mathbb{R}\}$, 即 xy 平面; 取 $V = \{(x, 0, z)^T : x, z \in \mathbb{R}\}$, 即 xz 平面。

同时属于两平面的向量必须满足 $y = z = 0$, 故

$$U \cap V = \{(x, 0, 0)^T : x \in \mathbb{R}\},$$

即 x 轴。又因任意 $(x, y, z)^T = (x, y, 0)^T + (0, 0, z)^T$, 故 $U + V = \mathbb{R}^3$ 。

不要把子空间的和 $U + V$ 与集合的并 $U \cup V$ 混淆。平面中的 x 轴与 y 轴的并只包含两条轴, $(1, 0)^T$ 与 $(0, 1)^T$ 都在其中, 但它们的和 $(1, 1)^T$ 不在其中, 所以并集一般不是子空间。这两条轴的和则是整个 $\mathbb{R}^2$ 。




图 1.6: 并与和的区别: 左图只有两条轴; 右图允许从两轴各取一个向量相加, 得到整个平面。淡色区域仅示意平面的一部分。

直和与分解的唯一性

定义 1.22 (两个子空间的直和)

若子空间 U, V 满足 $U \cap V = \{\mathbf{0}\}$, 就称它们的和 $U + V$ 为直和 (Direct Sum), 记作 $U \oplus V$ 。

写 $W = U \oplus V$ 时, 既要求 $W = U + V$, 又要求 $U \cap V = \{\mathbf{0}\}$ 。

条件 $U \cap V = \{\mathbf{0}\}$ 表示两个子空间没有共同的非零方向。它不表示两个集合完全不相交, 因为它们至少都含零向量; 也不要求两个空间在几何上互相垂直。

定理 1.23 (直和的等价判定)

子空间的和 $U + V$ 是直和, 当且仅当其中每个向量 w 都能唯一写成

$$w = u + v, \quad u \in U, \quad v \in V.$$

证明: 由和的定义, 分解总是存在。若 $U \cap V = \{\mathbf{0}\}$, 且 $u_1 + v_1 = u_2 + v_2$, 则

$$u_1 - u_2 = v_2 - v_1 \in U \cap V.$$

故两边都为零, 两个分解相同。反过来, 若 $w \in U \cap V$, 则 $w = w + \mathbf{0} = \mathbf{0} + w$ 是两个分解; 唯一性迫使 $w = \mathbf{0}$ 。■

在三维空间中, 取 U 为 xy 平面, V 为 z 轴。它们只有零向量是共同的, 且任意向量都有唯一分解

$$(x, y, z)^T = (x, y, 0)^T + (0, 0, z)^T.$$

所以 $\mathbb{R}^3 = U \oplus V$ 。图 1.7 展示了这种分解。




图 1.7: xy 平面与 z 轴的直和：每个向量唯一分解为平面内的分量与轴上的分量。

相比之下， xy 平面与 xz 平面的和虽然也是 $\mathbb{R}^3$ ，却不是直和。因为交中含有整个 x 轴，分解可沿这个共同方向调整。例如，对任意 $t \in \mathbb{R}$ ，

$$(1, 2, 3)^T = (t, 2, 0)^T + (1 - t, 0, 3)^T.$$

“能够分解”对应子空间的和，“分解唯一”才对应直和。

1.4 线性相关与线性无关

从零向量的表示定义相关性

定义 1.24 (线性相关与线性无关)

对向量组 $\alpha_1, \dots, \alpha_m$ ，考虑

$$k_1 \alpha_1 + \dots + k_m \alpha_m = \mathbf{0}.$$

若存在不全为零的实数 $k_1, \dots, k_m$ 使等式成立，则称该向量组**线性相关**；若等式成立只能推出 $k_1 = \dots = k_m = 0$ ，则称该向量组**线性无关**。

紧接定义，先看 $\mathbb{R}^3$ 中的三个几何例子。将各向量的起点放在原点，共线、共面都是指这些箭头所在的过原点直线或平面；每个例子都用上面的系数等式验证结论。

例题 1.25 (共线：两个方向重复的向量)

取 $\alpha = (1, 0, 1)^T$ 、 $\beta = (2, 0, 2)^T$ 。两向量同向共线，且 $\beta = 2\alpha$ ，因此

$$2\alpha - \beta = \mathbf{0}.$$

系数 $2, -1$ 不全为零，故两向量**线性相关**。几何上，第二个向量只改变长度，没有增加独立方向。

例题 1.26 (共面：三个向量只提供两个独立方向)

取 $\alpha = (1, 0, 1)^T$ 、 $\beta = (0, 1, 1)^T$ ，再取 $\gamma = (1, 1, 2)^T$ 。前两个不共线，但第三个满足

$$\alpha + \beta - \gamma = 0.$$

所以三个向量**线性相关**。它们都在斜平面 $z = x + y$ 内，第三个方向没有超出前两个向量张成的平面。

例题 1.27 (不共面：三个互不垂直的无关向量)

取

$$\alpha = (1, 0, 1)^T, \quad \beta = (0, 1, 1)^T, \quad \gamma = (1, 1, 3)^T.$$

前两个向量张成平面 $z = x + y$ ，第三个向量的终点不在该平面内，因为 $3 \neq 1 + 1$ 。按定义，设 $a\alpha + b\beta + c\gamma = 0$ ，则

$$a + c = 0, \quad b + c = 0, \quad a + b + 3c = 0.$$

由前两式得 $a = b = -c$ ，代入第三式得 $c = 0$ ，继而 $a = b = 0$ 。所以三个向量**线性无关**。

这三个向量没有任何两个相互垂直，却仍然无关。**线性无关要求没有多余的表示方向，并不要求方向之间成直角。**




图 1.8: 定义的三维直观：共线的两个非零向量相关；共面的三个向量相关；三个不共面的向量无关，即使它们互不垂直。箭头统一从原点出发，阴影表示前两个向量张成的斜平面的一部分。

要区分向量的个数：**两个向量即使共面，也可以无关；三个向量共面才必然相关**。上面后两个例子使用相同的前两个向量，只改变第三个向量是否落在它们张成的平面内。判断共面时，必须把起点统一放在原点，不能任意平移每支箭头后再看终点的位置。

系数全为零总能使等式成立，称为**零解 (Trivial Solution)**。线性相关要求存在至少一个系数非零的解，称为**非零解 (Nontrivial Solution)**；“不全为零”并不是“每一

个都不为零”。线性无关也不是说向量之间“没有任何联系”，而是不存在上述非零系数关系。

定理 1.28 (线性相关的等价判定)

含至少两个向量的向量组线性相关，当且仅当至少有一个向量可以由其余向量线性表示。

证明： 若存在非零系数关系，选取 $k_j \neq 0$ ，移项并除以 k_j ，得到

$$\alpha_j = -\sum_{i \neq j} \frac{k_i}{k_j} \alpha_i.$$

反过来，若 $\alpha_j = \sum_{i \neq j} c_i \alpha_i$ ，移项后 α_j 的系数为 1，得到一组不全为零的系数关系，故原组相关。 ■

这就把第 0 章的“有没有多余向量”变成了严格判定：相关组中至少有一个向量可以删去而不改变张成空间；无关组中的每个向量都不可由剩下的向量表示。对于只含一个向量的组，定义直接给出：**单个零向量相关，单个非零向量无关。**

四条基本判别法则

性质 1.29 (相关性的基本判别)

- (1) 含零向量必相关。取该零向量的系数为 1，其余系数为 0 即可。
- (2) 两个向量相关，当且仅当它们中至少一个是另一个的实数倍。两个非零向量的这种关系通常称为分量成比例。
- (3) 部分相关，则整体相关。等价地，线性无关组的任意非空部分组仍然无关。
- (4) $\mathbb{R}^n$ 中多于 n 个向量必线性相关。

第 (2) 条是等价判定定理在两个向量时的特例。“成比例”应理解为同一个倍数作用于所有分量，**不能对可能为零的分量直接相除**。例如 $(1,0,2)^T$ 与 $(3,0,6)^T$ 相关； $(1,0)^T$ 与 $(0,1)^T$ 无关。如果某个向量为零，用第 (1) 条判断即可，不需要定义分量之比。

第 (3) 条可由补零系数说明：已有部分向量的非零关系，在其余位置补上系数 0，仍是整体的非零关系。两个向量相关就足以使更大的组相关，但**两两无关并不能保证整体无关**。例如 $(1,0)^T, (0,1)^T, (1,1)^T$ 中任意两个都无关，三个却满足

$$(1,0)^T + (0,1)^T - (1,1)^T = \mathbf{0}.$$

第 (4) 条需要比较“无关向量的个数”与“生成向量的个数”。能够张成一个空间的向量组称为生成组 (Spanning Set)。以下引理也将为秩和维数的定义提供依据。

引理 1.30 (无关组与生成组的个数比较)

若线性无关组 $\beta_1, \dots, \beta_s$ 中的每个向量都可由 $\alpha_1, \dots, \alpha_m$ 线性表示, 则 $s \leq m$ 。

证明: 用逐次替换说明。因为 $\beta_1 \neq \mathbf{0}$, 它在 $\alpha_1, \dots, \alpha_m$ 中的一种表示至少有一个非零系数。解出对应的 α_j , 就可以用 β_1 替换它, 而不改变这 m 个向量的张成空间。

假设已用 $\beta_1, \dots, \beta_{i-1}$ 替换了 $i-1$ 个原向量。表示 β_i 时, 尚未替换的原向量中必有一个系数非零; 否则 β_i 可由前面的 β 表示, 与无关性矛盾。因此又可替换一个原向量。

每加入一个 β_i , 就占用一个原有位置。一共只有 m 个位置; 若 $s > m$, 第 $m+1$ 个 β 就必须由前 m 个表示, 仍与无关性矛盾。所以 $s \leq m$ 。 ■

在 $\mathbb{R}^n$ 中, 令 e_i 的第 i 个分量为 1, 其余分量为 0, 则

$$(a_1, \dots, a_n)^T = a_1 e_1 + \dots + a_n e_n.$$

因此所有向量都可由这 n 个向量表示。由个数比较引理, 无关组至多含 n 个向量, 于是第 (4) 条成立。注意其逆命题不成立: 不超过 n 个向量仍然可能相关。

线性相关与无关的典型边界情形

例题 1.31 (一个向量也能谈相关与无关)

- (1) 单个零向量线性相关。因为 $1\mathbf{0} = \mathbf{0}$, 系数 1 非零。
- (2) 单个非零向量线性无关。若 $\alpha \neq \mathbf{0}$, 从 $k\alpha = \mathbf{0}$ 可得 $k = 0$ 。无论分量多么小, 例如 $\alpha = (10^{-100}, 0)^T$, 只要不为零, 结论就不变。
- (3) 两个相同的非零向量线性相关。向量组 α, α 满足 $1\alpha - 1\alpha = \mathbf{0}$ 。两个位置虽然写着相同向量, 却仍分别有自己的系数。
- (4) 两个相反的非零向量也线性相关。因为 $1\alpha + 1(-\alpha) = \mathbf{0}$ 。方向相反, 并不意味着提供了新的独立方向。




图 1.9: 最小规模的相关性判定。零向量画作原点处的点; 重复向量的两支箭头用粗实线和细虚线重叠表示。非零向量本身无关, 重复或反向后组成的两个向量却相关。

例题 1.32 (向量全部不同、全部非零, 仍可能相关)

取 $\alpha = (1, 2)^T$ 、 $\beta = (2, 4)^T$ 、 $\gamma = (-3, -6)^T$ 。它们彼此不同且均非零, 却都位于同一直线上, 并满足

$$2\alpha - \beta + 0\gamma = 0.$$

系数 $2, -1, 0$ 不全为零, 所以这一组相关。这也说明, 证明相关时允许某些系数等于 0。

将这三个向量都添上 98 个零分量, 变成 $\mathbb{R}^{100}$ 中的向量, 上面的等式仍成立。环境维数很高, 不会自动使一组向量无关。

例题 1.33 (几乎共线, 却仍然线性无关)

令 $\alpha = (1, 0)^T$ 、 $\beta = (1, \varepsilon)^T$ 。若 $a\alpha + b\beta = 0$, 比较分量得

$$a + b = 0, \quad \varepsilon b = 0.$$

当 $\varepsilon = 0$ 时, 两向量相同, 线性相关; 当 $\varepsilon \neq 0$ 时, 第二式迫使 $b = 0$, 再得 $a = 0$, 所以线性无关。

即使 $\varepsilon = 10^{-6}$, 两支箭头看起来几乎重合, 它们在严格数学意义下仍无关。“很接近零”与“等于零”是不同的条件。画图用于建立直观, 最终结论须由分量关系确定。




图 1.10: 从相关到无关的边界: 左图 $\varepsilon = 0$, 两向量重合; 右图以 $\varepsilon = 0.3$ 示意非零情形。无关性只要求 $\varepsilon \neq 0$, 并不要求夹角足够大。

例题 1.34 (两两无关, 整体仍可能相关)

在 $\mathbb{R}^3$ 中, 取


$$\alpha = (1, 0, 0)^T, \quad \beta = (0, 1, 0)^T, \quad \gamma = (1, 1, 0)^T.$$

任意两个都不是彼此的倍数, 因而两两无关; 但 $\gamma = \alpha + \beta$, 所以三个向量整体相关。它们虽有三个分量, 实际都在 xy 平面内。


若把第三个向量改为 $\gamma_\varepsilon = (1, 1, \varepsilon)^T$, 其中 $\varepsilon \neq 0$, 则

$$a\alpha + b\beta + c\gamma_\varepsilon = \mathbf{0} \implies a + c = 0, \quad b + c = 0, \quad \varepsilon c = 0.$$

从而 $a = b = c = 0$, 新组无关。第三个向量只要离开原平面, 就增加了一个原来无法表示的方向。



(a) 两两无关, 整体相关



(b) 整体线性无关

图 1.11: 三个向量的整体关系: 左图第三个向量仍在前两个张成的平面内, 整体相关; 右图第三个向量离开平面, 整体无关 (以 $\varepsilon = 1$ 示意)。

以上例子分别排除了几种误判: 非零不等于无关, 互不相同不等于无关, 两两无关不等于整体无关, 图上几乎重合也不等于相关。所有情形都应回到同一个问题: 能否找到一组不全为零的系数, 使组合结果为零向量。

定义法：设系数、列分量方程、判定解

例题 1.35 (参数怎样影响线性相关性)

在 $\mathbb{R}^3$ 中, 设

$$\alpha_1 = (1, 0, 1)^T, \quad \alpha_2 = (0, 1, 1)^T, \quad \alpha_3 = (1, 1, t)^T.$$

讨论这三个向量的线性相关性。

解： 设 $k_1\alpha_1 + k_2\alpha_2 + k_3\alpha_3 = \mathbf{0}$, 比较分量得

$$k_1 + k_3 = 0, \quad k_2 + k_3 = 0, \quad k_1 + k_2 + tk_3 = 0.$$

前两式给出 $k_1 = k_2 = -k_3$, 代入第三式得 $(t-2)k_3 = 0$ 。

若 $t \neq 2$, 则 $k_3 = 0$, 从而全部系数为 0, 三个向量**线性无关**。

若 $t = 2$, 可取 $(k_1, k_2, k_3) = (-1, -1, 1)$, 得到非零解, 三个向量**线性相关**, 且 $\alpha_3 = \alpha_1 + \alpha_2$ 。

定义法的结论必须完整：证明相关，只需找到**一组非零解**；证明无关，则必须说明**所有解都只能是零解**。仅代入零解验证成立，不能证明无关。向量个数和分量较多时，这种逐个比较的方法会变得繁琐，更高效的计算将在下一章学习。

定理 1.36 (无关性与表示系数的唯一性)

$\alpha_1, \dots, \alpha_m$ 线性无关，当且仅当其张成空间中的每个向量，都有关于这组向量的唯一线性表示。

证明： 若同一向量有两种表示，相减得 $\sum_{i=1}^m (c_i - d_i)\alpha_i = \mathbf{0}$ 。无关性给出 $c_i = d_i$, 故表示唯一。反过来，若每个向量的表示唯一，则零向量只能由全零系数表示，因而该组无关。

■

更具体地，若向量组相关，取一个非零关系 $\sum k_i \alpha_i = \mathbf{0}$ 。给已有表示 $\beta = \sum c_i \alpha_i$ 加上它的 t 倍，便得到

$$\beta = \sum_{i=1}^m (c_i + tk_i) \alpha_i, \quad t \in \mathbb{R}.$$

所以相关组对任何可表示的向量都给出不止一种表示。表示是否存在由张成范围决定，表示是否唯一由无关性决定。

由定义与定理得到的常用推论

推论 1.37 (无关组中添入一个向量)

设 $\alpha_1, \dots, \alpha_m$ 线性无关, 则

$$\alpha_1, \dots, \alpha_m, \beta \text{ 线性相关} \iff \beta \text{ 可由 } \alpha_1, \dots, \alpha_m \text{ 线性表示.}$$

能表示时, 表示系数唯一; 不能表示时, 添入 β 后仍然无关。

证明: 若新组相关, 取一个非零关系 $\sum k_i \alpha_i + c\beta = \mathbf{0}$ 。必有 $c \neq 0$, 否则旧组无关会迫使全部系数为零。解出 β 即得表示; 唯一性由旧组无关保证。反方向由移项得到一个非零关系。 ■

这里**旧组无关**是必要前提。例如, $(1,0)^T, (2,0)^T$ 已经相关, 加入 $(0,1)^T$ 后整体仍相关, 但新向量不能由前两个表示。

推论 1.38 (分量的延长与截短)

无关组延长分量后仍无关: 给组中每个向量在相同位置添加同样数目的分量, 原分量保持不变, 若原组无关, 延长后的组仍无关。

相关组截短分量后仍相关: 从组中每个向量删去相同位置的若干分量 (保留至少一个分量), 若原组相关, 截短后的组仍相关。

证明: 若延长后的向量存在系数关系, 只看原有位置的分量, 就得到旧组的系数关系。旧组无关, 故系数只能全为零。若旧组相关, 原来的非零系数关系在删去同样位置的分量后仍成立, 故截短后的组仍相关。 ■

两个逆命题都不成立。一维向量组 $(1), (1)$ 相关, 将它们延长为 $(1,0)^T, (1,1)^T$ 后变为无关; 反过来, 把后两个向量都删去第二个分量, 原来的无关组又变为相关。注意“给每个向量增加分量”与“给向量组增加一个向量”是两种不同操作。

推论 1.39 (非零数乘与同时转置不改变相关性)

将各个向量分别乘以任意非零实数, 线性相关性不变; 将整组列向量同时转置为行向量, 线性相关性也不变。

对第一条, 若每个 $c_i \neq 0$, 则 $\sum k_i (c_i \alpha_i) = \mathbf{0}$ 等价于 $\sum (k_i c_i) \alpha_i = \mathbf{0}$, 两组系数同时为零或同时不全为零。对第二条, 只需将整个向量等式同时转置, 再利用转置与加法、数乘的性质。数乘中的“非零”不能省略, 因为乘以 0 会产生零向量。

1.5 极大线性无关组与向量组的秩

从原向量组中提取核心部分

定义 1.40 (极大线性无关组)

从向量组 $\alpha_1, \dots, \alpha_m$ 中选出的部分组 $\alpha_{i_1}, \dots, \alpha_{i_r}$, 若满足

(1) 自身线性无关;

(2) 原向量组的每个向量都能由它线性表示,

就称它为原向量组的一个极大线性无关组 (Maximal Linearly Independent Subset), 简称极大无关组。

“极大”针对的是给定的原向量组: 不能再从原组中加入一个未选向量而仍保持无关。它不表示已经张成整个 $\mathbb{R}^n$ 。条件 (2) 与这种“不能再添加”的说法等价: 若某个原向量不能由已选组表示, 将它加入后仍无关; 若能表示, 加入后即相关。

极大无关组必须是原组的部分组。一组来自原组之外的向量即使具有相同的张成空间, 也不能称为该原组的极大无关组。概括而言, 极大无关组就是原组里“既够用, 又没有多余”的核心部分。

定理 1.41 (极大无关组的基本性质)

有限向量组存在极大无关组。它的任意一个极大无关组都与原组等价; 同一向量组的任意两个极大无关组, 所含向量个数相同, 但选出的向量可以不同。

证明: 从原组中逐个选取向量, 每次仅当新向量不能由已选组表示时才加入。每次加入后仍无关; 原组有限, 所以过程一定结束, 结束时被略过的向量都能由已选组表示, 故得到极大无关组。

极大无关组能表示原组, 而它本身又是原组的一部分, 所以两者等价。设两个极大无关组分别含 r 个和 s 个向量。它们相互表示且各自无关, 由前节的个数比较引理分别得到 $r \leq s$ 和 $s \leq r$, 故 $r = s$ 。 ■

为统一处理零向量组, 约定空向量组线性无关, 空组的张成空间为 $\{0\}$: 没有向量参与的和取为零向量。因此, 全由零向量组成的组, 其极大无关组取为空组, 所含向量个数为 0。空组与“只含一个零向量的组”不同, 后者线性相关。

向量组的秩

定义 1.42 (向量组的秩)

向量组 $\alpha_1, \dots, \alpha_m$ 的任意一个极大无关组所含的向量个数, 称为**向量组的秩 (Rank of a Set of Vectors)**, 简称秩, 记作

$$r(\alpha_1, \dots, \alpha_m).$$

全零向量组的秩为 0. 对 $\mathbb{R}^n$ 中的 m 个向量, 有

$$0 \leq r(\alpha_1, \dots, \alpha_m) \leq \min\{m, n\}.$$

性质 1.43 (秩与线性相关性的关系)

对含 $m \geq 1$ 个向量的向量组, 有

$$\begin{aligned} r(\alpha_1, \dots, \alpha_m) = m &\iff \alpha_1, \dots, \alpha_m \text{ 线性无关,} \\ r(\alpha_1, \dots, \alpha_m) < m &\iff \alpha_1, \dots, \alpha_m \text{ 线性相关.} \end{aligned}$$

如果原组无关, 它自身就是极大无关组; 反之, 秩等于 m 意味着所选的 m 个向量就是全部向量, 因而原组无关. 相关的情形由此立即得到.

推论 1.44 (线性表示与秩的大小)

若 $\beta_1, \dots, \beta_s$ 可由 $\alpha_1, \dots, \alpha_m$ 线性表示, 则

$$r(\beta_1, \dots, \beta_s) \leq r(\alpha_1, \dots, \alpha_m).$$

特别地, **等价向量组的秩相等**. 若上述两组都线性无关, 则还有 $s \leq m$.

证明: 取两组的极大无关组. 第一组的极大无关组, 能由第二组的极大无关组表示; 由无关组与生成组的个数比较引理, 即得秩的不等式. 等价时可在两个方向比较; 两组都无关时, 秩分别等于各自的向量个数. ■

秩相等不保证等价. 例如, $(1, 0)^T$ 与 $(0, 1)^T$ 这两个单向量组的秩都是 1, 张成的直线却不同. 另一方面, **等价也不保证两个向量组同时相关或同时无关:** e_1, e_2 与 $e_1, e_2, e_1 + e_2$ 等价, 前者无关而后者相关, 二者的秩同为 2. 只有在向量个数也相同时, 等价才能保证相关性一致.

推论 1.45 (添加一个向量时秩的变化)

设 $r = r(\alpha_1, \dots, \alpha_m)$ 。添加一个向量 β 后, 秩只能为 r 或 $r + 1$ 。更确切地,

$$\beta \in \text{Span}\{\alpha_1, \dots, \alpha_m\} \implies r(\alpha_1, \dots, \alpha_m, \beta) = r,$$

$$\beta \notin \text{Span}\{\alpha_1, \dots, \alpha_m\} \implies r(\alpha_1, \dots, \alpha_m, \beta) = r + 1.$$

理由是: 若新向量可表示, 原极大无关组仍然够用; 若不可表示, 把它加入原极大无关组后便得到新组的极大无关组。这使“逐个添加”的方法有了直接的理论依据。

逐个添加的定义法

求极大无关组可以按照原组次序逐个检查。第一步跳过零向量, 保留遇到的第一个非零向量; 以后每遇到一个新向量, 就设它是已选向量的线性组合, 比较分量。若能表示则略过, 若不能表示则加入。**每次都检验“能否由已选组表示”, 并保持已选组无关。**

例题 1.46 (求一个极大无关组与秩)

设

$$\alpha_1 = (1, 0, 1)^T, \quad \alpha_2 = (0, 1, 1)^T,$$

$$\alpha_3 = (1, 1, 2)^T, \quad \alpha_4 = (0, 0, 1)^T.$$

解: 先保留非零向量 α_1 。 α_2 不是 α_1 的倍数, 所以加入 α_2 。又因为 $\alpha_3 = \alpha_1 + \alpha_2$, 略过 α_3 。

若 $\alpha_4 = c_1\alpha_1 + c_2\alpha_2$, 前两个分量迫使 $c_1 = c_2 = 0$, 第三个分量却要求 $c_1 + c_2 = 1$, 矛盾。因此加入 α_4 。

于是 $\alpha_1, \alpha_2, \alpha_4$ 是一个极大无关组,

$$r(\alpha_1, \alpha_2, \alpha_3, \alpha_4) = 3.$$

检查最终答案时, 两个条件缺一不可。上述三个向量无关, 因为

$$a\alpha_1 + b\alpha_2 + c\alpha_4 = (a, b, a + b + c)^T = \mathbf{0}$$

只能给出 $a = b = c = 0$; 它们能表示原组, 因为唯一未选的 $\alpha_3 = \alpha_1 + \alpha_2$ 。

换一种检查顺序, 也可以选出 $\alpha_1, \alpha_3, \alpha_4$: $\alpha_2 = \alpha_3 - \alpha_1$, 并且这三个向量同样无关。**选择可以不同, 秩始终为 3。**如果原组只有前三个向量, 则 α_1, α_2 已是极大无关组, 秩为 2。




图 1.12: 逐个添加: 新向量若在已选组的张成空间内, 就不增加秩; 否则加入, 秩增加 1。

逐个添加法反映了秩的含义, 适合本章的小规模例题。高维数据往往难以直接看出表示关系; 下一章的计算工具会把这一步系统化。

1.6 基、维数与基扩充定理

基: 无关且张成整个空间

定义 1.47 (子空间的基)

设 V 是 $\mathbb{R}^n$ 的子空间。若 $b_1, \dots, b_d \in V$ 满足

(1) 线性无关;

(2) $V = \text{Span}\{b_1, \dots, b_d\}$,

则称这组向量是 V 的一组**基**。讨论坐标时, 要固定基向量的顺序, 记作 $\mathcal{B} = (b_1, \dots, b_d)$ 。

基的两个条件各有作用: 张成保证空间里的每个向量**都能表示**, 无关保证表示系数**唯一**。基向量不必是单位向量, 也不必互相垂直。

极大无关组与基的联系是: 向量组的任意极大无关组, 都是其张成空间的一组基。区别在于, 极大无关组须从指定向量组中选出; 空间的基则可在该空间内任意选取, 只要满足无关与张成。

例题 1.48 ($\mathbb{R}^n$ 的标准基)

令 e_i 的第 i 个分量为 1, 其余分量为 0。任意 $\alpha = (a_1, \dots, a_n)^T$ 满足

$$\alpha = a_1 e_1 + \dots + a_n e_n,$$

故 $e_1, \dots, e_n$ 张成 $\mathbb{R}^n$ 。若 $k_1 e_1 + \dots + k_n e_n = \mathbf{0}$, 比较第 i 个分量得 $k_i = 0$, 故它们无关。

因此 $\mathcal{E} = (e_1, \dots, e_n)$ 是 $\mathbb{R}^n$ 的一组基, 称为**标准基**。

基扩充定理与基的存在

定理 1.49 (基扩充定理)

设 $V \subseteq \mathbb{R}^n$ 是子空间, $\alpha_1, \dots, \alpha_r \in V$ 线性无关. 则存在整数 s ($r \leq s \leq n$) 及向量 $\alpha_{r+1}, \dots, \alpha_s \in V$, 使

$$\mathcal{B} = (\alpha_1, \dots, \alpha_r, \alpha_{r+1}, \dots, \alpha_s)$$

成为 V 的一组基. 允许 $r = 0$, 即从空组开始; 若 $s = r$, 则不必添加向量.

证明: 记 $W_k = \text{Span}\{\alpha_1, \dots, \alpha_k\}$, 并约定 $W_0 = \{\mathbf{0}\}$. 若 $W_r = V$, 原组已满足基的两个条件, 结论成立. 以下考虑 $W_r \neq V$ 的情形.

(1) 在张成空间之外添加向量, 仍保持线性无关. 设已得无关组 $\alpha_1, \dots, \alpha_k$, 且 $W_k \subsetneq V$. 选取

$$\alpha_{k+1} \in V \setminus W_k.$$

为检验新组的无关性, 设

$$c_1\alpha_1 + \dots + c_k\alpha_k + c_{k+1}\alpha_{k+1} = \mathbf{0}.$$

若 $c_{k+1} \neq 0$, 则

$$\alpha_{k+1} = -\sum_{i=1}^k \frac{c_i}{c_{k+1}} \alpha_i \in W_k,$$

与选取条件矛盾. 因此 $c_{k+1} = 0$; 再由旧组线性无关, 得 $c_1 = \dots = c_k = 0$. 故新组线性无关, 且 $W_k \subsetneq W_{k+1} \subseteq V$.

(2) 添加过程必在有限步后张成 V . 只要 $W_k \neq V$, 就按 (1) 继续添加. 由前面的个数比较结论, $\mathbb{R}^n$ 中的无关组至多含 n 个向量, 所以最多添加 $n - r$ 个向量. 若已有 n 个无关向量却仍未张成 V , 按 (1) 再添加一个就得到 $n + 1$ 个无关向量, 矛盾.

因此, 必存在 s , $r \leq s \leq n$, 使得

$$\alpha_1, \dots, \alpha_s \text{ 线性无关, } \text{Span}\{\alpha_1, \dots, \alpha_s\} = V.$$

这正是基的两个条件, 且原来的 r 个向量始终保留, 故扩充完成. ■

上述基扩充定理 (Basis Extension Theorem) 的证明只使用无关性的定义和个数比较引理, 并不预先假定 V 已有一组基. 从空组开始作同样的添加, 就说明 $\mathbb{R}^n$ 的每个子空间都有基. 对零子空间, 空组就是它的基.

几何上, 基扩充就是逐步增加尚未覆盖的方向. 对于平面 $V = \{(x, y, 0)^T\}$, 已有向量 $(1, 0, 0)^T$ 时, 加入 $(0, 1, 0)^T$ 就得到 V 的一组基. 若目标改为整个 $\mathbb{R}^3$, 还须加入一个不在该平面内的向量, 如 $(0, 0, 1)^T$. 扩充到哪里, 由目标空间决定.




图 1.13: 基的逐步扩充: 一个方向张成直线, 加入线外向量张成平面, 再加入平面外向量张成三维空间。

维数: 基所含向量的个数

定理 1.50 (同一空间的基等长)

若 V 是 $\mathbb{R}^n$ 的子空间, 则 V 的任意两组基所含向量的个数相同。

证明: 两组基都张成 V , 所以相互线性表示; 又都线性无关, 由个数比较引理在两个方向分别比较, 即知其向量个数相同。 ■

定义 1.51 (维数)

子空间 V 的任意一组基所含向量的个数, 称为 V 的**维数 (Dimension)**, 记作 $\dim V$ 。特别地, $\dim\{\mathbf{0}\} = 0$ 。

标准基给出 $\dim \mathbb{R}^n = n$ 。过原点的直线有一向量的基, 维数为 1; 过原点的平面有两向量的基, 维数为 2。位于 $\mathbb{R}^3$ 中的平面, 其向量虽然都写成三个分量, 但这个平面本身的维数是 2。分量个数描述所在的环境, 维数描述子空间自身需要多少个独立方向。

性质 1.52 (维数的基本结论)

设 $U \subseteq V \subseteq \mathbb{R}^n$ 均为子空间, 且 $\dim V = d$ 。

- (1) $0 \leq \dim U \leq \dim V \leq n$; 若 $\dim U = \dim V$, 则 $U = V$ 。
- (2) V 中任意 d 个线性无关向量都是 V 的一组基; V 中任意 d 个能张成 V 的向量也都是一组基。
- (3) V 中多于 d 个向量必相关; 少于 d 个向量不可能张成 V 。

这些结论可由基扩充和个数比较得到。例如, 把 U 的一组基扩充成 V 的基, 向量个数不会减少; 若两空间维数已相等, 就无需添加向量, 原基已张成 V , 故 $U = V$ 。第

(2) 条中, 无关组扩充后仍只能有 d 个向量; 而 d 个生成向量若相关, 就能删去一个而保持张成, 与第 (3) 条矛盾。

对任意有限向量组, 秩与维数的联系为

$$r(\alpha_1, \dots, \alpha_m) = \dim \text{Span}\{\alpha_1, \dots, \alpha_m\}.$$

因为极大无关组正是其张成空间的一组基。秩针对给定向量组, 维数针对空间; 两者在这里给出相同的数。

向量在一组基下的坐标

定义 1.53 (关于有序基的坐标)

设 $\mathcal{B} = (\mathbf{b}_1, \dots, \mathbf{b}_d)$ 是 V 的一组有序基 (Ordered Basis)。任意 $\mathbf{v} \in V$ 都有唯一表示

$$\mathbf{v} = c_1 \mathbf{b}_1 + \dots + c_d \mathbf{b}_d.$$

这组系数称为 $\mathbf{v}$ 关于基 $\mathcal{B}$ 的坐标, 记作

$$[\mathbf{v}]_{\mathcal{B}} = \begin{pmatrix} c_1 \\ \vdots \\ c_d \end{pmatrix}.$$

把这些坐标按顺序排成的列称为坐标向量 (Coordinate Vector)。坐标的存在来自张成, 唯一性来自无关。基的顺序改变, 坐标的排列也随之改变。在标准基下, 向量原有的分量就是坐标; 在其他基下, 坐标需要由表示关系求得。

例题 1.54 (三分量向量可以用两个基坐标描述)

在平面 $V = \{(x, y, z)^T : z = x + y\}$ 中, 取

$$\mathbf{b}_1 = (1, 0, 1)^T, \quad \mathbf{b}_2 = (0, 1, 1)^T.$$

它们无关, 且任意 $(x, y, x+y)^T = x\mathbf{b}_1 + y\mathbf{b}_2$, 故 $\mathcal{B} = (\mathbf{b}_1, \mathbf{b}_2)$ 是 V 的基, $\dim V = 2$ 。令 $\mathbf{v} = (2, 3, 5)^T$ 。由 $\mathbf{v} = 2\mathbf{b}_1 + 3\mathbf{b}_2$, 得

$$[\mathbf{v}]_{\mathcal{B}} = \begin{pmatrix} 2 \\ 3 \end{pmatrix}.$$

这里 $\mathbf{v} \in \mathbb{R}^3$, 而它关于平面基的坐标属于 $\mathbb{R}^2$, 两者不能混为同一个有序数组。

再取 $c_1 = b_1 + b_2$ 、 $c_2 = b_1 - b_2$ 。它们与原基相互表示，且若 $sc_1 + tc_2 = \mathbf{0}$ ，则

$$(s+t)b_1 + (s-t)b_2 = \mathbf{0},$$

从而 $s+t = s-t = 0$ ，即 $s = t = 0$ 。所以 $\mathcal{C} = (c_1, c_2)$ 也是 V 的基。由于

$$v = \frac{5}{2}c_1 - \frac{1}{2}c_2, \quad [v]_{\mathcal{C}} = \begin{pmatrix} 5/2 \\ -1/2 \end{pmatrix},$$

同一个向量的坐标随基改变。这里仅由系数关系求坐标，不需要任何新运算。

子空间和的维数公式

定理 1.55 (维数公式)

设 U, V 是 $\mathbb{R}^n$ 的子空间，则

$$\dim(U + V) = \dim U + \dim V - \dim(U \cap V).$$

特别地，若 $U \cap V = \{\mathbf{0}\}$ ，则

$$\dim(U \oplus V) = \dim U + \dim V.$$

证明 (借助基向量集合的维恩图): 先为交空间 $U \cap V$ 选基，再分别扩充为 U 和 V 的基。设交空间的一组基为 $\gamma_1, \dots, \gamma_k$ ，扩充后的基分别为

$$U: \gamma_1, \dots, \gamma_k, \alpha_1, \dots, \alpha_p,$$

$$V: \gamma_1, \dots, \gamma_k, \beta_1, \dots, \beta_q.$$

把上述两组基中的向量分别组成有限集合 $\mathcal{B}_U, \mathcal{B}_V$ 。它们的公共部分恰好是 $\gamma_1, \dots, \gamma_k$ ：任何新添的 α_i 或 β_j 都不在 $U \cap V$ 中，否则相应的扩充组就会相关；两个新增部分也不可能出现同一个向量，否则它同时属于 U, V 。




图 1.14: 维数公式的维恩图证明: 图中两个椭圆表示两组基向量的有限集合, 共有的 k 个基向量只计一次。合并后得到 $U + V$ 的基, 因此计数为 $p + k + q$ 。

这里 $|\mathcal{B}|$ 表示有限集合 $\mathcal{B}$ 的元素个数。图中使用的是**两组基的集合并集**, 不是把子空间的和 $U + V$ 当作集合的并 $U \cup V$ 。维恩图给出正确计数, 还须验证合并后的向量确实构成 $U + V$ 的基。

把公共部分只保留一次, 得到

$$\gamma_1, \dots, \gamma_k, \alpha_1, \dots, \alpha_p, \beta_1, \dots, \beta_q.$$

该组显然张成 $U + V$ 。它也无关: 若三部分的某个线性组合为零, 则其中 β 部分的组合既属于 V , 又等于 γ, α 部分组合的相反向量, 故属于 $U \cap V$, 可由 γ 表示。利用 V 中所选基的无关性, 所有 β 系数为零; 再利用 U 中所选基的无关性, 其余系数也全为零。因此上面合并的组是 $U + V$ 的基。

于是 $\dim(U + V) = k + p + q = (k + p) + (k + q) - k$, 即得公式。交为零子空间时, $k = 0$, 便得到直和的维数性质。

几何上, 维数公式 (Dimension Formula) 是在计算两组方向合并后还剩多少个独立方向: 公共方向在 $\dim U + \dim V$ 中被算了两次, 所以需要减去一次。这与集合元素个数的加减形式相似, 但这里计数的是**基向量的个数**, 不是空间中所有向量的个数。

例题 1.56 (两个平面为什么只张成三维空间)

取 U 为 xy 平面, V 为 xz 平面。两者维数都是 2, 交是维数为 1 的 x 轴, 故

$$\dim(U + V) = 2 + 2 - 1 = 3.$$

这与 $U + V = \mathbb{R}^3$ 一致。若改取 V 为 z 轴, 则 $U \cap V = \{\mathbf{0}\}$, 有

$$\dim(U \oplus V) = 2 + 1 = 3.$$




图 1.15: 两个坐标平面的共同方向是 x 轴。两组平面基合并时, e_1 只计一次, 因此 $2 + 2 - 1 = 3$ 。

推论 1.57 (两个子空间的公共方向)

若 $U, V \subseteq \mathbb{R}^n$ 是子空间, 则

$$\dim(U \cap V) \geq \dim U + \dim V - n.$$

因而当 $\dim U + \dim V > n$ 时, 两者必有共同的非零向量, 它们的和不可能是直和。

由维数公式及 $\dim(U + V) \leq n$ 即得。例如, $\mathbb{R}^3$ 中两个二维子空间的交至少是一维的: $\dim(U \cap V) \geq 2 + 2 - 3 = 1$ 。所以两个过原点的平面不可能仅交于原点; 不同平面交成一条直线, 相同平面的交则是它本身。

1.7 【选读】抽象向量空间的公理化定义

本书主线始终围绕实数域 $\mathbb{R}$ 上的 $\mathbb{R}^n$ 展开。本节只说明这些知识还可以怎样推广, 帮助理解不同对象背后的共同结构; 域的理论及泰勒公式都不作为本章的学习要求。

从实数域到一般的域

到目前为止, 我们讨论的向量, 分量都是实数; 数乘运算的系数, 也都是实数。我们一直在**实数域 (Field of Real Numbers)** $\mathbb{R}$ 的框架下研究 n 维向量空间 $\mathbb{R}^n$ 。

但是, 前面关于线性组合、张成、线性相关、极大无关组、基与维数的推理, 并不依赖于“数必须是实数”。例如, 从 $c\alpha = 0$ 且 $c \neq 0$ 推出 $\alpha = 0$, 所用的是可以乘以 c 的倒数; 在一个向量等式中移项、合并系数, 所用的是加法、乘法及其运算律。只要所选数系仍支持这些运算, 相应的线性推理就可以继续使用。

通俗地说, 一个含有 0 和 1 (且 $0 \neq 1$)、对**加、减、乘、除 (除数不为 0)** 封闭, 并

满足熟悉的交换律、结合律、分配律等基本规则的数系，称为一个**域 (Field)**。本节不列出域的完整公理，只用 $\mathbb{F}$ 表示选定的一个域，作为向量分量与数乘系数的来源。

实数域 $\mathbb{R}$ 是最常用的例子。**有理数域 (Field of Rational Numbers)** $\mathbb{Q}$ 也符合要求：两个有理数相加、相减、相乘，或除以非零有理数，结果仍是有理数。**复数域 (Field of Complex Numbers)** $\mathbb{C}$ 同样符合要求，它允许形如 $a + bi$ 的数，其中 $a, b \in \mathbb{R}$ 、 $i^2 = -1$ 。整数集 $\mathbb{Z}$ 则不行，因为 $1 \div 2$ 不再是整数。一般的域还可以只有有限个元素，称为有限域 (Finite Field)，此处不展开。

$\mathbb{R}$ 是域这一一般概念的一个具体实例，也就是 $\mathbb{F} = \mathbb{R}$ 这一特例。 $\mathbb{F}$ 可以选作 $\mathbb{Q}$ 、 $\mathbb{R}$ 或 $\mathbb{C}$ 等。这里的“更一般”指允许选择不同数系，不表示每个 $\mathbb{F}$ 都包含全部实数；例如 $\mathbb{F} = \mathbb{Q}$ 时就不是这样。为了包含一般情形，下文使用“域上的向量空间”这一说法。

把分量和系数推广到 $\mathbb{F}$

把分量的取值从 $\mathbb{R}$ 换成 $\mathbb{F}$ ，就得到

$$\mathbb{F}^n = \{(a_1, \dots, a_n)^T : a_i \in \mathbb{F}, i = 1, \dots, n\}.$$

对 $\alpha = (a_1, \dots, a_n)^T$ 、 $\beta = (b_1, \dots, b_n)^T$ 和 $c \in \mathbb{F}$ ，仍规定

$$\begin{aligned}\alpha + \beta &= (a_1 + b_1, \dots, a_n + b_n)^T, \\ c\alpha &= (ca_1, \dots, ca_n)^T.\end{aligned}$$

加法还是对应分量相加，数乘还是把每个分量乘同一个数；八条基本运算性质也仍成立。这就是域 $\mathbb{F}$ 上的 n 维向量空间。取 $\mathbb{F} = \mathbb{R}$ ，便回到熟悉的 $\mathbb{R}^n$ 。

需要同时改变的是**允许使用的系数**：在 $\mathbb{F}$ 上讨论线性组合时，系数必须属于 $\mathbb{F}$ 。只依赖这些线性运算的定义和定理，可以按同样方式推广；有关有限基、维数计数的结论，仍保留有限维的前提。实数的大小比较、平面或空间中的几何图像，则不能不加区分地搬到任意域上。

本书后续计算仍主要取 $\mathbb{F} = \mathbb{R}$ 。引入 $\mathbb{F}$ 的目的，是看清实数情形在一般理论中的位置，而不是要求现在学习其他域的计算。




图 1.16: 两步抽象：先允许分量与系数来自不同的域，再去掉“向量必须是有序数组”的限制。箭头表示推广过程，不是集合包含关系。

去掉有序数组的外形：抽象向量空间

从熟悉的数组走向抽象向量空间 (Abstract Vector Space)，现在再抽象一步：向量一定要是有序数组吗？表示系数唯一性的证明，只使用了加法、数乘及无关性的定义，并没有要求向量有几个可见的分量。因此，可以把向量看成某个集合中的元素，直接对运算提出要求。

定义 1.58 (域 $\mathbb{F}$ 上的向量空间)

设 V 为非空集合，定义了加法 $V \times V \rightarrow V$ 与数乘 $\mathbb{F} \times V \rightarrow V$ 。若对任意 $u, v, w \in V$ 及 $\lambda, \mu \in \mathbb{F}$ ，下列八条公理成立，则称 V 为域 $\mathbb{F}$ 上的向量空间：

- (1) $u + v = v + u$;
- (2) $(u + v) + w = u + (v + w)$;
- (3) 存在 $0_V \in V$ ，使每个 $v \in V$ 都满足 $v + 0_V = v$;
- (4) 每个 $v \in V$ 都存在 $-v \in V$ ，使 $v + (-v) = 0_V$;
- (5) $\lambda(u + v) = \lambda u + \lambda v$;
- (6) $(\lambda + \mu)v = \lambda v + \mu v$;
- (7) $\lambda(\mu v) = (\lambda\mu)v$;
- (8) $1v = v$.

V 中的元素称为**向量**， $\mathbb{F}$ 中的元素称为**标量 (Scalar)**。两个运算的取值仍在 V 中，已经包含封闭性要求。

取 $\mathbb{F} = \mathbb{R}$ ，就得到**实向量空间 (Real Vector Space)**；取 $\mathbb{F} = \mathbb{C}$ ，就得到**复向量空间 (Complex Vector Space)**。这里的 0_V 是该空间的零元素，不一定写成一列 0。判断一个集合是否构成向量空间，需要同时说明**元素是什么、标量取自哪里、两种运算怎样定义**。

下面回到实数域，用函数说明：即使向量不再是数组，前面学习的子空间、基、线性组合与坐标仍然有具体含义。

连续函数也可以作为向量

固定实数 $a < b$ ，考虑连续函数空间 (Space of Continuous Functions)，记

$$V = C[a, b] = \{f : [a, b] \rightarrow \mathbb{R} : f \text{ 在 } [a, b] \text{ 上连续}\}.$$

这里的 C 表示连续函数，不是表示复数集的 $\mathbb{C}$ 。把**整个函数**作为一个向量，以实数为标量，定义逐点运算：对每个 $t \in [a, b]$,

$$(f+g)(t) = f(t) + g(t), \quad (\lambda f)(t) = \lambda f(t).$$

连续函数的和、实数倍仍连续，因此两种运算封闭；八条公理由每个点处的实数运算规律成立。所以 $C[a, b]$ 是一个实向量空间。其零向量是恒等于 0 的函数 $0_V(t) = 0$ ，相反向量则是函数 $(-f)(t) = -f(t)$ 。

例题 1.59 (函数的线性运算是逐点进行的)

在 $C[-1, 1]$ 中，取 $f(t) = t^2$ 、 $g(t) = 1$ 。它们的和为 $h(t) = t^2 + 1$ ，而 $2f(t) = 2t^2$ 。例如，在 $t = \frac{1}{2}$ 处， f 的值为 $\frac{1}{4}$ ， g 的值为 1，故 h 的值为 $\frac{5}{4}$ 。对每个 t 都作同样的相加，就得到整个和函数。**函数图像不必是直线，函数之间仍然可以作线性组合。**




图 1.17: 函数向量的加法：在同一个横坐标处，把两个函数值相加。虚线标出 $t = \frac{1}{2}$ ，三个点的高度分别为 $\frac{1}{4}$ 、1 和 $\frac{5}{4}$ 。

多项式子空间、基与坐标

在 $C[a, b]$ 中，固定非负整数 n ，考虑多项式空间 (Polynomial Space)，取

$$P_n = \{p : p(t) = c_0 + c_1t + \cdots + c_nt^n, c_0, \dots, c_n \in \mathbb{R}\}.$$

这里把多项式看成限制在 $[a, b]$ 上的函数。 P_n 包含次数不超过 n 的多项式以及零多项式。它是 $C[a, b]$ 的**子空间**：零函数属于其中，两个这样的多项式相加或数乘后，次数仍不超过 n 。

每个 $p \in P_n$ 都可表示成 $1, t, \dots, t^n$ 的线性组合。若

$$c_0 + c_1t + \cdots + c_nt^n = 0 \quad \text{对所有 } t \in [a, b] \text{ 成立,}$$

则所有系数都为 0，因为非零多项式不可能在一个非退化区间上处处为零。因此

$$\mathcal{B}_n = (1, t, \dots, t^n)$$

是 P_n 的一组**有序基**，且 $\dim P_n = n + 1$ 。多出的 1 来自常数函数 1，它也是一个基向量。

关于这组基，函数 $p(t) = c_0 + c_1 t + \dots + c_n t^n$ 的坐标为

$$[p]_{\mathcal{B}_n} = (c_0, c_1, \dots, c_n)^T.$$

这里 p 是一个函数，坐标是一个有序实数组。选定基以后，数组准确记录了这个函数需要怎样组合出来；函数与它的坐标仍是需要区分的两个对象。




图 1.18: P_3 的四个基向量是四个函数： $1, t, t^2, t^3$ 。它们的图像形状不同，但都使用函数的逐点加法和实数数乘。

要注意，“次数不超过 n ”与“次数恰好为 n ”不同。后者不含零多项式，而且两个最高次项可能相消，所以后者不能构成这里的子空间。

具有有限基的向量空间称为有限维空间 (Finite-Dimensional Space)；没有有限基的称为无限维空间 (Infinite-Dimensional Space)。另一方面，整个 $C[a, b]$ 不是有限维空间：对每个 n ，它都含有 $n + 1$ 个无关函数 $1, t, \dots, t^n$ 。若它有一个含 d 个函数的有限基，取 $n = d$ ，便与无关组的个数比较结论矛盾。八条公理并不保证空间有限维；有限维的 P_n 可以位于无限维的 $C[a, b]$ 中。

截断泰勒展开：用有限个基函数表示近似函数

下面把区间取为 $[-1, 1]$ 。许多连续函数不属于任何一个 P_n ，但在适当条件下，可以用多项式近似它。**连续本身不足以保证能够使用泰勒公式**；以下只考察足够光滑的函数。没有学过导数或泰勒公式的读者，可以直接从后面的 e^t 例子开始，把列出的多项式当作已经给定的线性组合。

若 f 在包含 $[-1, 1]$ 的开区间上具有连续的 $n + 1$ 阶导数，则在 0 处的 n 阶泰勒多项式 (Taylor Polynomial) 为

$$T_n(t) = \sum_{k=0}^n \frac{f^{(k)}(0)}{k!} t^k = f(0) + f'(0)t + \dots + \frac{f^{(n)}(0)}{n!} t^n.$$

其中 $f^{(0)} = f$ 、 $0! = 1$ 。“截断”表示只保留到 t^n 这一项，所得 T_n 一定属于 P_n 。应把原函数与这个多项式分开，写成

$$f(t) = T_n(t) + R_n(t),$$

其中 R_n 为余项 (Remainder)，即近似误差。除非余项恒为零，否则不能把 f 与 T_n 写成完全相等。

例题 1.60 (e^t 的三阶截断与四个核心概念)

对 $f(t) = e^t$ ，各阶导数在 0 处的值均为 1，因此

$$T_3(t) = 1 + t + \frac{t^2}{2} + \frac{t^3}{6}.$$

子空间： $T_3 \in P_3 \subset C[-1, 1]$ ；原函数 e^t 不属于 P_3 。

基： $B_3 = (1, t, t^2, t^3)$ 是 P_3 的一组有序基。

线性组合： $T_3 = 1 \cdot 1 + 1 \cdot t + \frac{1}{2}t^2 + \frac{1}{6}t^3$ 。

坐标： $[T_3]_{B_3} = (1, 1, \frac{1}{2}, \frac{1}{6})^T$ 。

这里的四个系数描述的是**多项式** T_3 ，不能称作 e^t 关于 B_3 的坐标，因为 B_3 只张成 P_3 。同样的概念既能描述前文的三维向量，也能描述这里的函数，区别只在于向量的具体对象改变了。




图 1.19: 函数空间中的包含关系： $P_2 \subset P_3 \subset C[-1, 1]$ 。 $T_2 = 1 + t + t^2/2$ 属于 P_2 ， T_3 属于 P_3 而不属于 P_2 ， e^t 在 P_3 之外。这是集合关系示意图，不是函数曲线。

从曲线观察截断误差

依次取

$$T_1(t) = 1 + t, \quad T_2(t) = 1 + t + \frac{t^2}{2}, \quad T_3(t) = 1 + t + \frac{t^2}{2} + \frac{t^3}{6}.$$

它们分别取自 P_1, P_2, P_3 。图 1.20 左侧将这些多项式与原函数放在同一坐标系中，右侧单独画出绝对误差。靠近展开点 0 时，曲线之间的差异较小；离开 0 以后，误差才逐渐显现。




图 1.20: e^t 的截断泰勒多项式与绝对误差。左图比较函数值；右图画出 $|e^t - T_j(t)|$, $j = 1, 2, 3$, 显示本例中各阶截断在 $[-1, 1]$ 上的实际误差。

在 $t = 1$ 处, $e \approx 2.71828$, 而 $T_1(1) = 2$ 、 $T_2(1) = 2.5$ 、 $T_3(1) = \frac{8}{3} \approx 2.66667$ 。对应误差约为 0.71828、0.21828、0.05162, 与图中曲线一致。

若使用泰勒公式的余项结论, 本例还可给出一个统一的误差界: 对 $t \in [-1, 1]$ 、 $t \neq 0$, 存在介于 0 与 t 之间的 ξ , 使

$$e^t - T_n(t) = \frac{e^\xi t^{n+1}}{(n+1)!}, \quad |e^t - T_n(t)| \leq \frac{e}{(n+1)!}.$$

在 $t = 0$ 处误差为 0, 上界同样成立。对这个具体函数, 右端随 n 增大趋于 0, 说明多项式能够在该区间上一致逼近原函数; 这来自 e^t 的性质与误差估计, 不能仅由向量空间公理推出。本节不要求记忆余项公式, 重点是理解: 选取有限维子空间, 确定一组基, 再用有限个系数描述其中的近似函数。

回顾这条路线: $\mathbb{R}$ 是域 $\mathbb{F}$ 的一种取法, $\mathbb{R}^n$ 是 $\mathbb{F}^n$ 的实数情形; 进一步只保留运算与公理, 就能够把函数也纳入向量空间。抽象的意义在于, 不同对象可以共享同一套线性结构。本书主线仍回到实数域上的 $\mathbb{R}^n$; 这些选读例子只是帮助我们看清, 已经学过的概念为什么还能用于更广泛的对象。

1.8 【应用案例】抖音推荐系统中的向量结构

本节为应用拓展, 不作考核要求。承接第 0 章的短视频案例, 下面用一个四维教学模型说明本章概念怎样组织内容数据。所有向量、权重和规则均为人为设置, 用于理解推荐问题, 不代表抖音实际系统的内部实现。

把视频与用户偏好放入同一个特征空间

固定特征顺序为“搞笑、科技、美食、游戏”，每条视频用四个非负数描述对应特征的强弱。设四条示例视频的向量为

$$\begin{aligned}\alpha_1 &= (1, 0, 1, 0)^T, & \alpha_2 &= (0, 1, 0, 1)^T, \\ \alpha_3 &= (\tfrac{1}{2}, \tfrac{1}{2}, \tfrac{1}{2}, \tfrac{1}{2})^T, & \alpha_4 &= (1, 1, 1, 1)^T.\end{aligned}$$

第一条偏向“搞笑与美食”，第二条偏向“科技与游戏”，后两条在该模型中具有混合特征。这里的特征数是 4，因此它们都属于 $\mathbb{R}^4$ 。

为便于演示，定义用户偏好向量为看过的视频向量的加权线性组合。例如，用户分别以权重 0.2, 0.5, 0.3 对应前三条视频，则

$$\begin{aligned}p &= 0.2\alpha_1 + 0.5\alpha_2 + 0.3\alpha_3 \\ &= (0.35, 0.65, 0.35, 0.65)^T.\end{aligned}$$

这说明线性组合可以把多条记录汇总成一份特征描述。此处权重非负且和为 1 是模型的选择，**不是一般线性组合的必要条件**。换用不同权重，便会得到不同的偏好向量。

内容空间、冗余向量与秩

令

$$W = \text{Span}\{\alpha_1, \alpha_2, \alpha_3, \alpha_4\},$$

把它称为这个示例视频集合张成的**内容空间 (Content Space)**。它包含所有实系数线性组合，因此也包含上述偏好向量。有限的视频集合本身通常不是子空间； W 是把它们放在一起作线性组合之后得到的空间，其中某些向量未必对应真实视频。

观察可知

$$\alpha_3 = \tfrac{1}{2}\alpha_1 + \tfrac{1}{2}\alpha_2, \quad \alpha_4 = \alpha_1 + \alpha_2.$$

所以后两个向量没有扩大张成范围，这四个向量线性相关。另一方面，若 $a\alpha_1 + b\alpha_2 = \mathbf{0}$ ，比较前两个分量就得 $a = b = 0$ ，所以 α_1, α_2 无关。

因此 α_1, α_2 是原组的一个极大无关组，也是 W 的一组基，且

$$r(\alpha_1, \alpha_2, \alpha_3, \alpha_4) = 2, \quad \dim W = 2.$$

本例的内容空间可进一步写成

$$W = \{(a, b, a, b)^T : a, b \in \mathbb{R}\}.$$

虽然记录了四个特征分量，但第 1 与第 3 分量总是相同，第 2 与第 4 分量也总是相同，实际只需要两个独立系数。这正是**环境空间维数为 4，内容子空间维数为 2**的具体表现。




图 1.21: 在内容空间的基 $B = (\alpha_1, \alpha_2)$ 下, 用两个系数表示四维视频向量及偏好向量。图中横、纵轴是基坐标, 不是原来的四个特征轴。

在这个解释中, 应区分**特征名称**与**特征向量**。基由向量组成, 而不是由“科技”“美食”等文字标签组成。我们选出的核心向量组能够表示样本内容空间; 只有它所含的向量个数, 才等于这个空间的维数, 不能把原始特征标签的总数一概当作内容空间的维数。

严格的线性关系与实际的内容相似

本例的相关性来自可直接验证的**精确等式**。实际数据中, 内容高度相似可能表现为分量接近, 但**相似并不自动推出线性相关**。例如 $(1, 0)^T$ 与 $(1, 0.01)^T$ 看起来很接近, 若

$$a(1, 0)^T + b(1, 0.01)^T = (0, 0)^T,$$

则第二分量给出 $0.01b = 0$, 继而 $b = a = 0$, 所以它们仍然无关。

同样, 某个视频向量能由其他向量线性表示, 只表示它在**线性张成范围**上没有增加新方向, 不能据此断言真实视频可以直接替换或删除。线性组合的系数可能为负, 真实内容的语义和用户反馈也不会由这种表示关系自动保留。

本章已经能够回答: 偏好向量由哪些记录组合而成? 这些记录张成多大的空间? 哪些向量不增加张成范围? 需要多少个核心向量才能描述该空间? 但我们还没有定义一个数来衡量视频与用户偏好的接近程度。**如何精确衡量向量相似度, 将留到第 7 章“内积空间与正交性”学习。**

本章小结

本章把第 0 章的直观认识整理成了一条可以据以推理的逻辑链：

向量运算 $\longrightarrow$ 线性组合 $\longrightarrow$ 张成空间
 $\longrightarrow$ 线性相关与无关 $\longrightarrow$ 极大无关组与秩 $\longrightarrow$ 基与维数.

线性表示与张成空间回答“能否表示”。目标向量属于张成空间，就存在表示；两个向量组等价，就是它们具有相同的张成空间。

线性无关回答“表示是否唯一”。无关组只有全零系数才能组合成零向量，因此对其张成空间中的每个向量都给出唯一表示。相关组存在冗余，可以删去某个向量而不改变张成范围。

极大无关组与秩回答“需要保留多少个向量”。极大无关组必须从原组中选出，自身无关且能够表示全体；秩是其中的向量个数。对 m 个向量，秩等于 m 当且仅当原组无关。

基与维数把这个问题提升到空间层面。基同时满足无关与张成，确定有序基后，表示系数就是坐标。基扩充定理保证已有的无关方向可以继续补足；所有基的向量个数相同，这个数就是 $\dim V$ 。

子空间的交记录共同方向，和汇集两边的线性表示能力；直和要求交只有零向量，等价于分解唯一。相应的计数关系是

$$\dim(U + V) = \dim U + \dim V - \dim(U \cap V).$$

学习时要特别区分三对概念：**含零向量与构成子空间、向量个数与向量组的秩、环境的分量个数与子空间的维数**。判断子空间须检查非空及两种封闭性；判断无关须证明系数方程只有零解；验证基须同时检查无关与张成，不能只验证其中一项。

这些定义和性质是线性代数的通用语言。本章用分量方程解决了若干小规模问题，但当未知系数和分量增多，直接整理会越来越繁琐。下一章将从线性方程组出发引入矩阵工具，系统研究线性表示的求解方法，使本章的概念获得更高效的计算支持。

第 2 章

线性方程组与矩阵：从方程到 $Ax = b$

介绍性实例 物理与工程中的线性模型 ——曼哈顿计划的大型方程组

1942 年，曼哈顿计划启动。在研制第一代核反应堆与原子弹的过程中，物理学家与工程师面临的核心问题之一，是精确计算核系统的中子扩散过程与临界条件。当中子在铀燃料与慢化剂中运动时，不同空间位置的中子通量满足相应的物理规律；为了进行数值求解，工程师将空间划分为上百个网格节点，把连续的物理过程离散化为每个节点上的数值平衡关系。最终，整个问题被归结为求解一个包含上百个未知数、上百个方程的大型线性方程组。方程组的解直接决定了反应堆能否达到临界状态，以及核材料的最小临界质量。

这是一个简化到 5 个节点的一维平板模型方程组，它保留了当年工程计算的核心形式：

$$\begin{cases} \phi_1 = 0 \\ -\phi_1 + 3\phi_2 - \phi_3 = 0 \\ -\phi_2 + 3\phi_3 - \phi_4 = 0 \\ -\phi_3 + 3\phi_4 - \phi_5 = 0 \\ \phi_5 = 0 \end{cases}$$

其中未知量 $\phi_1, \phi_2, \dots, \phi_5$ 分别对应 5 个空间位置的中子通量。在真实的反应堆设计中，空间会被划分为更多节点，还会区分不同能量的中子群，最终得到的方程组往往包含数百甚至上千个未知数。



图 2.1: 曼哈顿计划洛斯阿拉莫斯实验室的人工计算团队。在电子计算机普及前，科研人员依靠机械计算器与逐行消元法，求解反应堆临界计算中的大型线性方程组。

在电子计算机尚未普及的年代，求解这样规模的方程组绝非易事。洛斯阿拉莫斯实验室组建了专门的计算小组，动用数十名科研人员与机械台式计算器，以人工流水线的方式逐行迭代计算，完成一次完整的求解需要耗费数周时间。

到了 1945 年，世界第一台电子计算机 ENIAC 建成后，最早的核心任务之一就是为氢弹研制计算中子输运与爆轰流体力学方程组。线性方程组的求解需求，直接推动了早期计算机技术的发展；而计算能力的每一次提升，又反过来让更大规模的线性模型成为可能。




图 2.2: 世界第一台通用电子计算机 ENIAC。大型线性方程组的求解需求，是早期电子计算机最核心的发展动力之一。

线性代数在应用中的重要性随着计算能力的增强而迅速增加，而每一代新的硬件和软件都引发了对计算能力的更大需求。因此，计算机科学就通过并行处理和大规模计算的爆炸性增长与线性代数密切联系在一起。

科学家和工程师正在研究大量极其复杂的问题，这在几十年前是不可想象的。今天，线性代数对许多科学技术和商业领域中的学生的重要性可以说超过了大学其他数学课程。本书中的材料是在许多有趣领域中作进一步研究的基础。这里举出几个例子，以后将列举其他一些领域。

- **核工程与反应堆设计：**从第一代实验堆到现代商用核电站，堆芯物理的数值模拟核心始终是大型稀疏线性方程组的求解，问题规模可达数万甚至数十万阶。
- **石油勘探：**当勘探船寻找海底石油储藏时，它的计算机每天要解几千个线性方程组。方程组的地震数据从气枪的爆炸引起水下冲击波获得。这些冲击波引起海底岩石的震动，并通过用几英里长的电缆拖在船后的地震测波器采集数据。
- **电路设计：**工程师使用仿真软件来设计电路和微芯片，它们包含数百万个晶体管。这样的软件技术依赖于线性代数方法与线性方程组。
- **计算机图形学：**3D 模型的渲染、视角变换、光影计算，本质上都是对顶点向量做线性变换，最终都可归结为线性方程组与矩阵运算。

但你或许不知道，这类能决定反应堆临界性、驱动早期计算机发展的大型方程组，其核心解法的思想，我们小学就已经接触过——那就是「鸡兔同笼」问题里的消元思路。从最简单的二元问题，到成百上千未知数的工程模型，底层的逻辑完全一致。

本章我们就从最朴素的鸡兔同笼问题出发，提炼线性方程组的系统求解方法，再引入矩阵这一高效的代数工具，最终把所有线性问题统一为标准形式 $Ax = b$ 。

2.1 从鸡兔同笼看消元思想

把数量关系写成方程

一个笼子里有鸡和兔，共有 35 个头、94 只脚，求鸡和兔各有多少只。设鸡有 x_1 只、兔有 x_2 只，则每只动物对应一个头，鸡有两只脚，兔有四只脚，因而

$$\begin{cases} x_1 + x_2 = 35, \\ 2x_1 + 4x_2 = 94. \end{cases} \quad (2.1)$$

一组数要成为这个方程组的解，必须同时满足两个方程。例如 $(35, 0)$ 满足头数关系，却不满足脚数关系，所以不是方程组的解。




图 2.3: 二元线性方程组的几何意义。两条直线的交点坐标就是方程组的解。

图中横坐标表示鸡的数量，纵坐标表示兔的数量。作为实数方程，每个方程对应一条直线；共同的解对应两条直线的交点。原应用还要求 x_1, x_2 为非负整数，求出代数解后，要再检查它是否符合这一要求。

两种消元方法，同一个目的

例题 2.1 (代入消元法)

用代入消元法 (Substitution Method): 由第一个方程得 $x_1 = 35 - x_2$ ，代入第二个方程：

$$2(35 - x_2) + 4x_2 = 94 \implies 2x_2 = 24 \implies x_2 = 12.$$

再代回 $x_1 = 35 - x_2$ ，得到 $x_1 = 23$ 。因此鸡有 23 只，兔有 12 只。

代入之后，第二个方程只含 x_2 。这正是消元的作用：先把两个未知量之间的关系转化为一个未知量的方程，再恢复另一个未知量。

例题 2.2 (加减消元法)

用加减消元法 (Addition Method of Elimination), 并以 E_1, E_2 分别表示当前的第一、第二个方程。作

$$E_2 \leftarrow E_2 - 2E_1,$$

即用第二个方程减去第一个方程的两倍, **同时保留第一个方程**, 得到

$$\begin{cases} x_1 + x_2 = 35, \\ 2x_2 = 24. \end{cases} \implies \begin{cases} x_1 + x_2 = 35, \\ x_2 = 12. \end{cases}$$

后一箭头对应 $E_2 \leftarrow \frac{1}{2}E_2$ 。这种从下往上求解的过程称为回代 (Back Substitution), 仍得 $x_2 = 12, x_1 = 23$ 。

把所有动物暂时看成鸡, 脚数应为 $2 \times 35 = 70$; 多出的 $94 - 70 = 24$ 只脚, 每只兔贡献两只, 于是兔有 12 只。这个小学算术过程, 对应的恰好就是 $E_2 - 2E_1$ 。写成方程后, 操作可以推广到更多未知量。

验算得 $23 + 12 = 35, 2 \times 23 + 4 \times 12 = 94$, 且两个数均为非负整数。**消元的核心是把方程组变成更易求解的形式, 同时保持解集不变。**

线性方程与线性方程组**定义 2.3 (线性方程、解与同解方程组)**

关于未知数 $x_1, \dots, x_n$ 的方程

$$a_1x_1 + a_2x_2 + \cdots + a_nx_n = b$$

称为**线性方程 (Linear Equation)**, 其中 $a_1, \dots, a_n, b$ 是已知实数, 右端 b 称为常数项 (Constant Term)。由若干这样的方程组成的整体称为**线性方程组 (Linear System)**。

同时满足其中每个方程的一组有序数, 称为方程组的一个**解 (Solution)**; 全体解构成**解集 (Solution Set)**。解集相同的两个方程组称为**同解方程组 (Equivalent Linear Systems)**。

线性方程中未知数只以一次项出现, 彼此不相乘。例如 $2x_1 - 3x_2 = 1$ 是线性方程, 而 $x_1x_2 = 1, x_1^2 + x_2 = 1$ 都不是。系数可以为 0; 消元中出现的 $0 = 0$ 或 $0 = 1$ 也必须纳入讨论。

由 m 个方程组成的 n 元线性方程组的一般形式是

$$\begin{cases} a_{11}x_1 + a_{12}x_2 + \cdots + a_{1n}x_n = b_1, \\ a_{21}x_1 + a_{22}x_2 + \cdots + a_{2n}x_n = b_2, \\ \vdots \\ a_{m1}x_1 + a_{m2}x_2 + \cdots + a_{mn}x_n = b_m. \end{cases} \quad (2.2)$$

这里 m 是方程个数, n 是未知数个数, 两者不必相等。解通常写为列向量 $\mathbf{x} = (x_1, \dots, x_n)^T$ 。

三种同解初等变换

定理 2.4 (线性方程组的初等变换)

下列三种操作都保持方程组的解集不变：

交换： 交换两个方程的位置，记为 $E_i \leftrightarrow E_j$ 。

倍乘： 用非零实数 c 乘一个方程的两边，记为 $E_i \leftarrow cE_i$ ，其中 $c \neq 0$ 。

倍加： 把一个方程的 c 倍加到另一个方程上，记为 $E_i \leftarrow E_i + cE_j$ ，其中 $i \neq j$ ；方程 E_j 保持不变。

它们称为方程组的**同解初等变换 (Elementary Equation Operations)**。

证明： 交换只改变书写次序。倍乘后，可以再乘 $1/c$ 恢复原方程。倍加后，保留着 E_j ，再作 $E_i \leftarrow E_i - cE_j$ 就能恢复原方程。因此每一步的解既满足变换前的方程组，也满足变换后的方程组，反过来同样成立。 ■

推论 2.5 (连续变换仍然同解)

有限次初等变换得到的方程组与原方程组同解。消元时只要每一步都合法，最后求出的就是原方程组的全部解。

注意倍乘的数不能为 0，否则原方程的信息会丢失。例如 $x_1 = 1$ 乘 0 后变成 $0 = 0$ ，任意 x_1 都满足后者。倍加时也不能只留下相加得到的一个方程、同时删去原来的两个方程。

从图 2.3 看，消元后两个单独的方程所表示的直线可以改变，但共同交点不变。我们希望逐步得到这样的形式：上面的方程可以含较多未知数，下面的方程依次消去前面的未知数。这就是下一节要建立的**行阶梯形方程组 (Row Echelon System)**；再从下往上回代，完成求解。

2.2 高斯消元法：从二元到 n 元

贯穿本章的三元例题

例题 2.6 (由三个方程逐步消元)

求解

$$\begin{cases} x_1 + x_2 + x_3 = 6, \\ 2x_1 - x_2 + x_3 = 3, \\ x_1 + 2x_2 - x_3 = 2. \end{cases} \quad (2.3)$$

第一步：用第一个方程消去下面两个方程中的 x_1 。依次作

$$E_2 \leftarrow E_2 - 2E_1, \quad E_3 \leftarrow E_3 - E_1.$$

逐项计算有

$$(2x_1 - x_2 + x_3) - 2(x_1 + x_2 + x_3) = 3 - 2 \times 6,$$

$$(x_1 + 2x_2 - x_3) - (x_1 + x_2 + x_3) = 2 - 6.$$

因此原方程组化为

$$\begin{cases} x_1 + x_2 + x_3 = 6, \\ -3x_2 - x_3 = -9, \\ x_2 - 2x_3 = -4. \end{cases}$$

第二步：选择方便的方程继续消去 x_2 。第三个方程的 x_2 系数为 1，先作 $E_2 \leftrightarrow E_3$ ，再作 $E_3 \leftarrow E_3 + 3E_2$ ：

$$\begin{cases} x_1 + x_2 + x_3 = 6, \\ x_2 - 2x_3 = -4, \\ -7x_3 = -21. \end{cases} \quad (2.4)$$

此处最后一式来自 $(-3x_2 - x_3) + 3(x_2 - 2x_3) = -9 + 3(-4)$ 。每一个新方程都按同样的规则处理了左右两边。

第三步：从最后一个方程开始回代。

$$-7x_3 = -21 \Rightarrow x_3 = 3, \quad x_2 = -4 + 2x_3 = 2, \quad x_1 = 6 - x_2 - x_3 = 1.$$

所以唯一解为 $x = (1, 2, 3)^T$ 。代入原式，左边依次为 6, 3, 2，与右边相同。变量从两个增加到三个，但方法没有改变：先通过同解变换减少未知数，再利用已经求出的量回代。




图 2.4: 三元线性方程组的几何意义。三个平面两两相交，三条交线共同经过点 $P(1, 2, 3)$ ，它的坐标就是方程组的唯一解。浅色区域仅表示各平面的一部分，粗线突出两两交线。

三个平面两两相交，并不自动保证三个平面有同一个交点。本例有且只有一个公共点，是由消元结果确定的，不能仅凭透视图判断。

主元、行阶梯形与自由变量

定义 2.7 (方程组的行阶梯形)

固定未知数次序 $x_1, \dots, x_n$ ，把方程右端的常数项也看成书写在系数之后的一项。对左端不全为 0 的方程，第一个非零系数称为该行的主元 (Pivot)，它所在的未知数称为主元变量 (Basic Variable)。

若所有 $0 = 0$ 的全零方程位于最下方，且其余各行从上到下第一个非零项的位置严格右移，就称方程组为行阶梯形方程组。若出现 $0 = c$ ($c \neq 0$)，将其非零常数看作位于所有未知数之后；它表示矛盾，而不对应主元变量。

在没有矛盾方程的行阶梯形中，不属于主元变量的未知数称为自由变量 (Free Variable)。

主元是一个非零数，主元变量是它对应的未知数，两者需要区分。例如式(2.4)的主元依次为 $1, 1, -7$ ，主元变量依次为 x_1, x_2, x_3 。主元不必等于 1。

“逐行右移”说的是首个非零位置，不要求每往下一行恰好少一个非零项，也不要求它恰好移到紧邻的一列。例如

$$\begin{cases} x_1 + 2x_2 - x_3 + x_4 = 3, \\ x_3 + x_4 = 2 \end{cases}$$

已经是行阶梯形。主元变量为 x_1, x_3 ， x_2, x_4 是自由变量。令 $x_2 = s$ 、 $x_4 = t$ ，则

$$x_3 = 2 - t, \quad x_1 = 5 - 2s - 2t, \quad s, t \in \mathbb{R}.$$

“自由”指可以独立指定这两个参数；一旦指定，主元变量就随之确定。**只有在方程组有解时，才可以把自由变量任意取值并得到解。**这里有解 (Consistent) 也称相容，无解 (Inconsistent) 也称不相容。

上述方法推广到一般方程组，就是高斯消元法 (Gaussian Elimination)。

定理 2.8 (高斯消元法的基本步骤)

向前消元 (Forward Elimination): 从最左侧尚未处理的未知数开始，在尚未使用的方程中寻找该未知数的非零系数；需要时交换方程，再用倍加消去它下方的系数。

逐步推进: 移到下一行、右侧各列，重复上述过程；若某列在剩余各行中全为 0，就跳过该列。最终得到行阶梯形。

判断并回代: 先检查有无矛盾方程。若没有，指定自由变量，再从最后一个非零方程开始回代，求出所有主元变量。

每次只能用已经选定的非零系数作为消元依据。若当前系数为 0，可以向下寻找并交换；若这一列下方全为 0，就改看右边一列，不能把 0 当作除数。未知数的次序在本章始终固定。

消元结果怎样告诉我们解的个数

例题 2.9 (无解：出现矛盾)

对方程组

$$\begin{cases} x_1 + x_2 = 2, \\ 2x_1 + 2x_2 = 5, \end{cases} \quad E_2 \leftarrow E_2 - 2E_1,$$

得到 $x_1 + x_2 = 2$ 、 $0 = 1$ 。不存在任何一组数能满足 $0 = 1$ ，所以原方程组**无解**。

例题 2.10 (唯一解：每个未知数都有主元)

对方程组

$$\begin{cases} x_1 + x_2 = 2, \\ x_1 - x_2 = 0, \end{cases} \quad \xrightarrow{E_2 \leftarrow E_2 - E_1} \begin{cases} x_1 + x_2 = 2, \\ -2x_2 = -2, \end{cases}$$

回代得到 $x_2 = 1$ 、 $x_1 = 1$ 。没有矛盾，也没有自由变量，所以有**唯一解 (Unique Solution)**。


例题 2.11 (无穷多解：有自由变量)

对方程组

$$\begin{cases} x_1 + x_2 = 2, \\ 2x_1 + 2x_2 = 4, \end{cases} \xrightarrow{E_2 \leftarrow E_2 - 2E_1} \begin{cases} x_1 + x_2 = 2, \\ 0 = 0, \end{cases}$$

第二式不再增加限制。令 $x_2 = t$ ，就有 $x_1 = 2 - t$ ，因此全部解为

$$\mathbf{x} = (2 - t, t)^T, \quad t \in \mathbb{R}.$$

不同的 t 给出不同的解，所以方程组有**无穷多解 (Infinitely Many Solutions)**。**图 2.5:** 二元线性方程组解的三种情形。每个子图中的曲线对应上面相应例题的方程；重合的两条直线用粗实线与虚线区分。**定理 2.12 (由行阶梯形判断解的个数)**对 n 元实线性方程组，先用初等变换得到行阶梯形。若出现 $0 = c$ ($c \neq 0$)，则**无解**。在**没有矛盾方程**的前提下，设主元变量有 p 个：若 $p = n$ ，则有唯一解；若 $p < n$ ，则有 $n - p$ 个自由变量，从而有无穷多解。**推论 2.13 (实线性方程组解的三分性)**

实线性方程组只有无解、唯一解、无穷多解三种可能，不会恰好有两个或三个不同的解。一旦方程组有解且存在自由变量，就可以让参数在实数范围内连续取值。

零方程 $0 = 0$ 与矛盾方程 $0 = c$ 必须分清。出现零方程并不一定有无穷多解，例如 $x_1 = 1$ 、 $x_2 = 2$ 、 $0 = 0$ 仍然唯一确定两个未知数。反过来，方程数等于未知数个数，也不保证存在唯一解。

在三维中看自由变量

例如 $x_1 = 1$ 、 $x_2 = 2$ 两个方程留下自由变量 $x_3 = t$ ，解为 $(1, 2, t)^T$ ，在空间中是一条直线。如果只有 $x_3 = 0$ 这一个有效方程，便有两个自由变量，解为 $(s, t, 0)^T$ ，构成一个平面。这些图形是解向量所在的集合。




图 2.6: 自由变量与解集的形状。左图两个平面交成一条直线，用一个参数表示解；右图解集本身是一个平面，需要两个参数。

高维解集不一定能画出来，但自由变量的含义不变：它们记录全部解所需要的独立参数。不能把“有几个方程”直接当成“有几个独立限制”，是否重复要通过消元辨认。

2.3 矩阵与初等行变换

把反复出现的未知数暂时省去

在前面的计算中， x_1, x_2, x_3 的位置始终固定，真正发生变化的是它们的系数与方程右端的常数。只要约定列的次序，就可以把这些数排成一个数表，省去重复书写的未知数和等号。

定义 2.14 (矩阵、系数矩阵与增广矩阵)

由 $m \times n$ 个数按照 m 行、 n 列排列成的矩形数表，称为一个 $m \times n$ **矩阵**，记作 $A = (a_{ij})_{m \times n}$ 。其中 a_{ij} 是第 i 行、第 j 列的元素。

对于式(2.2)，按未知数次序排成的

$$A = \begin{pmatrix} a_{11} & a_{12} & \cdots & a_{1n} \\ a_{21} & a_{22} & \cdots & a_{2n} \\ \vdots & \vdots & & \vdots \\ a_{m1} & a_{m2} & \cdots & a_{mn} \end{pmatrix}$$

称为**系数矩阵 (Coefficient Matrix)**。把常数项列 $\mathbf{b} = (b_1, \dots, b_m)^T$ 附在右边，得到**增广矩阵 (Augmented Matrix)**

$$\bar{A} = (A \mid \mathbf{b}) = \left(\begin{array}{cccc|c} a_{11} & a_{12} & \cdots & a_{1n} & b_1 \\ a_{21} & a_{22} & \cdots & a_{2n} & b_2 \\ \vdots & \vdots & & \vdots & \vdots \\ a_{m1} & a_{m2} & \cdots & a_{mn} & b_m \end{array} \right).$$

系数矩阵有 n 列，增广矩阵有 $n + 1$ 列；竖线只用来区分系数列与常数项列。

一个方程对应一行，一个未知数对应一个系数列。某个未知数没有出现时，其系数必须填 0，不能跳过这一列。增广矩阵右端的常数项列并不代表一个新增的未知数。

鸡兔同笼方程组的两种矩阵分别为

$$A = \begin{pmatrix} 1 & 1 \\ 2 & 4 \end{pmatrix}, \quad \bar{A} = \left(\begin{array}{cc|c} 1 & 1 & 35 \\ 2 & 4 & 94 \end{array} \right).$$

贯穿例题(2.3)的两种矩阵则为

$$A = \begin{pmatrix} 1 & 1 & 1 \\ 2 & -1 & 1 \\ 1 & 2 & -1 \end{pmatrix}, \quad \bar{A} = \left(\begin{array}{ccc|c} 1 & 1 & 1 & 6 \\ 2 & -1 & 1 & 3 \\ 1 & 2 & -1 & 2 \end{array} \right).$$

从增广矩阵的第 2 行读回去，就是 $2x_1 - x_2 + x_3 = 3$ 。能够在方程和数表之间双向转换，才真正理解了这种记法。

方程操作与行操作一一对应

定义 2.15 (矩阵的初等行变换)

用 R_i 表示当前矩阵的第 i 行。下列操作称为**初等行变换 (Elementary Row Operations)**:

$$\begin{array}{ll} R_i \leftrightarrow R_j & \text{交换两行;} \\ R_i \leftarrow cR_i \quad (c \neq 0) & \text{用非零数乘一行;} \\ R_i \leftarrow R_i + cR_j \quad (i \neq j) & \text{把一行的倍数加到另一行。} \end{array}$$

可经过有限次初等行变换互相得到的两个矩阵称为**行等价 (Row Equivalence)**, 本章用 $\sim$ 或标有操作的箭头表示。

定理 2.16 (增广矩阵行变换保持解集)

对增广矩阵作初等行变换, 等价于对方程组作相应的同解初等变换。因而行变换前后的增广矩阵表示同解方程组。

理由是每一行的系数与常数项共同记录一个方程, 两边始终按同一操作改变。**常数项列必须与系数列一起变换**。只改变系数而不改变常数项, 一般就改变了原来的问题。

例如鸡兔同笼的加减消元可压缩为

$$\left(\begin{array}{cc|c} 1 & 1 & 35 \\ 2 & 4 & 94 \end{array} \right) \xrightarrow{R_2 \leftarrow R_2 - 2R_1} \left(\begin{array}{cc|c} 1 & 1 & 35 \\ 0 & 2 & 24 \end{array} \right) \xrightarrow{R_2 \leftarrow \frac{1}{2}R_2} \left(\begin{array}{cc|c} 1 & 1 & 35 \\ 0 & 1 & 12 \end{array} \right).$$

从未行读出 $x_2 = 12$, 回代第一行得 $x_1 = 23$ 。数表的写法省去了符号, 却保留了完整的计算信息。

同一个三元例题: 方程与矩阵对照

以下每一行左侧是方程组, 右侧是同一步骤的增广矩阵。所有行号均指**当前**的行, 而不是原始方程中永远固定的编号。

起点:

$$\begin{cases} x_1 + x_2 + x_3 = 6, \\ 2x_1 - x_2 + x_3 = 3, \\ x_1 + 2x_2 - x_3 = 2 \end{cases} \longleftrightarrow \left(\begin{array}{ccc|c} 1 & 1 & 1 & 6 \\ 2 & -1 & 1 & 3 \\ 1 & 2 & -1 & 2 \end{array} \right)$$

第一次倍加： $E_2 \leftarrow E_2 - 2E_1$ 对应 $R_2 \leftarrow R_2 - 2R_1$ 。

$$\begin{cases} x_1 + x_2 + x_3 = 6, \\ -3x_2 - x_3 = -9, \\ x_1 + 2x_2 - x_3 = 2 \end{cases} \longleftrightarrow \left(\begin{array}{ccc|c} 1 & 1 & 1 & 6 \\ 0 & -3 & -1 & -9 \\ 1 & 2 & -1 & 2 \end{array} \right)$$

第二次倍加： $E_3 \leftarrow E_3 - E_1$ 对应 $R_3 \leftarrow R_3 - R_1$ 。

$$\begin{cases} x_1 + x_2 + x_3 = 6, \\ -3x_2 - x_3 = -9, \\ x_2 - 2x_3 = -4 \end{cases} \longleftrightarrow \left(\begin{array}{ccc|c} 1 & 1 & 1 & 6 \\ 0 & -3 & -1 & -9 \\ 0 & 1 & -2 & -4 \end{array} \right)$$

交换： $E_2 \leftrightarrow E_3$ 对应 $R_2 \leftrightarrow R_3$ 。

$$\begin{cases} x_1 + x_2 + x_3 = 6, \\ x_2 - 2x_3 = -4, \\ -3x_2 - x_3 = -9 \end{cases} \longleftrightarrow \left(\begin{array}{ccc|c} 1 & 1 & 1 & 6 \\ 0 & 1 & -2 & -4 \\ 0 & -3 & -1 & -9 \end{array} \right)$$

继续倍加： $E_3 \leftarrow E_3 + 3E_2$ 对应 $R_3 \leftarrow R_3 + 3R_2$ 。

$$\begin{cases} x_1 + x_2 + x_3 = 6, \\ x_2 - 2x_3 = -4, \\ -7x_3 = -21 \end{cases} \longleftrightarrow \left(\begin{array}{ccc|c} 1 & 1 & 1 & 6 \\ 0 & 1 & -2 & -4 \\ 0 & 0 & -7 & -21 \end{array} \right) \quad (2.5)$$

每一步的全部数值都来自前一行的方程操作。矩阵行变换没有增加新的求解原理，只是使同一个原理更便于书写与实现。

行阶梯形矩阵

定义 2.17 (主元位置与行阶梯形矩阵)

矩阵非零行的第一个非零元素称为该行的主元；它所在的位置称为主元位置 (Pivot Position)，所在列称为主元列 (Pivot Column)。

满足以下条件的矩阵称为行阶梯形矩阵 (Row Echelon Form)：

零行在底：所有元素都为 0 的行位于所有非零行的下方。

主元右移：每个非零行的主元位置，都在上一非零行的主元位置右边。

因此，每个主元下方的元素都为 0。所有元素均为 0 的零矩阵 (Zero Matrix) 也视为行阶梯形矩阵。

$$\begin{bmatrix} \blacksquare & * & * & * & * & * \\ 0 & 0 & \blacksquare & * & * & * \\ 0 & 0 & 0 & 0 & \blacksquare & * \\ 0 & 0 & 0 & 0 & 0 & 0 \end{bmatrix}$$

图 2.7: 一般阶梯形矩阵的结构示意。■ 表示主元, * 表示任意非零元, 0 表示零。主元逐行右移, 主元下方为零, 零行位于底部。

图中展示一种可能的非零分布, 并不要求主元右侧的元素全部非零; 主元之间也可以跳过没有主元的列。

例如

$$H = \left(\begin{array}{cccc|c} 2 & -1 & 3 & 0 & 4 \\ 0 & 0 & -5 & 2 & 1 \\ 0 & 0 & 0 & 0 & 0 \end{array} \right)$$

是行阶梯形矩阵。主元为 2, -5, 对应第 1、3 列, 主元之间可以跳过某些列。如果将它看作四元方程组的增广矩阵, 则 x_2, x_4 是自由变量。

又如

$$\left(\begin{array}{cc|c} 1 & 2 & 3 \\ 0 & 0 & 1 \end{array} \right)$$

也是行阶梯形, 但其末行的主元落在**常数项列**, 代表 $0 = 1$, 原方程组无解。讨论解时, 必须区分系数部分的主元与增广列中的主元。

推论 2.18 (行阶梯形的存在)

任意矩阵都可以通过有限次初等行变换化成行阶梯形。其具体数值形式可以因选取的行变换不同而不同。

这直接来自高斯消元的过程: 每次选定的主元向下、向右推进, 行数和列数有限, 所以过程最终停止。对增广矩阵消元时, 如果常数项列出现主元, 就已经足以判断无解。

2.4 行最简形与高斯-若尔当消元法

把主元上方也消成 0

行阶梯形消去了主元下方的元素，但其上方通常仍有非零元素，所以要回代。若再把每个主元化为 1，并把它上方的元素也消为 0，就能够从结果中直接读出主元变量。

定义 2.19 (行最简形矩阵)

一个行阶梯形矩阵，如果还满足：

主元为 1： 每个非零行的主元均为 1；

主元列其余元素为 0： 每个主元所在列中，除该主元外的所有元素都为 0，就称为**行最简形矩阵 (Reduced Row Echelon Form)**，也称简化行阶梯形矩阵。

$$\begin{bmatrix} \blacksquare & * & 0 & * & 0 & * \\ 0 & 0 & \blacksquare & * & 0 & * \\ 0 & 0 & 0 & 0 & \blacksquare & * \\ 0 & 0 & 0 & 0 & 0 & 0 \end{bmatrix}$$

图 2.8: 简化阶梯形矩阵的结构示意。■ 表示主元，* 表示任意非零元，0 表示零。此图中的主元均取值为 1，且主元所在列的其余元素全部为零。

例如

$$\left(\begin{array}{cccc|c} 1 & 2 & 0 & -1 & 3 \\ 0 & 0 & 1 & 4 & 2 \\ 0 & 0 & 0 & 0 & 0 \end{array} \right)$$

已经是行最简形。第 2、4 列没有主元，其中仍可有非零元素。**行最简形不要求所有非主元元素都为 0，只要求主元所在列满足这一条件。**

定理 2.20 (行最简形的存在与唯一性)

每个矩阵都可以用初等行变换化为行最简形；虽然化简步骤可以不同，最终的行最简形是唯一的。

存在性可由行阶梯形继续消元得到。唯一性是行化简的基本结论，本章先使用这一

结论，不展开其一般证明。它使不同计算路径的结果能够相互核对；不能把不同的行阶梯形误认为求解结果必然不同。

用高斯-若尔当法重做三元例题

在高斯消元得到行阶梯形后，从最后一个主元向上处理：先把主元化为 1，再消去同列上方的元素。这一过程称为**高斯-若尔当消元法 (Gauss-Jordan Elimination)**。

例题 2.21 (从行阶梯形到直接读解)

将式(2.3)的增广矩阵化为行最简形，求出方程组的解。

解：由式(2.5)继续作行变换：

$$\left(\begin{array}{ccc|c} 1 & 1 & 1 & 6 \\ 0 & 1 & -2 & -4 \\ 0 & 0 & -7 & -21 \end{array} \right) \xrightarrow{R_3 \leftarrow -\frac{1}{7}R_3} \left(\begin{array}{ccc|c} 1 & 1 & 1 & 6 \\ 0 & 1 & -2 & -4 \\ 0 & 0 & 1 & 3 \end{array} \right).$$

用第三行消去它上方第 3 列的非零元素：

$$\xrightarrow{R_2 \leftarrow R_2 + 2R_3} \left(\begin{array}{ccc|c} 1 & 1 & 1 & 6 \\ 0 & 1 & 0 & 2 \\ 0 & 0 & 1 & 3 \end{array} \right) \xrightarrow{R_1 \leftarrow R_1 - R_3} \left(\begin{array}{ccc|c} 1 & 1 & 0 & 3 \\ 0 & 1 & 0 & 2 \\ 0 & 0 & 1 & 3 \end{array} \right).$$

最后用第二行消去第 1 行中的 x_2 系数：

$$\xrightarrow{R_1 \leftarrow R_1 - R_2} \left(\begin{array}{ccc|c} 1 & 0 & 0 & 1 \\ 0 & 1 & 0 & 2 \\ 0 & 0 & 1 & 3 \end{array} \right).$$

现在可以直接读出 $x_1 = 1$ 、 $x_2 = 2$ 、 $x_3 = 3$ ，不必另作回代。

有自由变量时，直接读出的是参数关系

例题 2.22 (由行最简形写出全部解)

对四元方程组

$$\begin{cases} x_1 + 2x_2 - x_3 + x_4 = 3, \\ 2x_1 + 4x_2 + x_3 + 5x_4 = 12, \end{cases}$$

作 $R_2 \leftarrow R_2 - 2R_1$ ，再作 $R_2 \leftarrow \frac{1}{3}R_2$ ，最后作 $R_1 \leftarrow R_1 + R_2$ ：

$$\begin{aligned} & \left(\begin{array}{cccc|c} 1 & 2 & -1 & 1 & 3 \\ 2 & 4 & 1 & 5 & 12 \end{array} \right) \xrightarrow{R_2 \leftarrow R_2 - 2R_1} \left(\begin{array}{cccc|c} 1 & 2 & -1 & 1 & 3 \\ 0 & 0 & 3 & 3 & 6 \end{array} \right) \\ & \xrightarrow{R_2 \leftarrow \frac{1}{3}R_2} \left(\begin{array}{cccc|c} 1 & 2 & -1 & 1 & 3 \\ 0 & 0 & 1 & 1 & 2 \end{array} \right) \xrightarrow{R_1 \leftarrow R_1 + R_2} \left(\begin{array}{cccc|c} 1 & 2 & 0 & 2 & 5 \\ 0 & 0 & 1 & 1 & 2 \end{array} \right). \end{aligned}$$

读回方程为 $x_1 + 2x_2 + 2x_4 = 5$ 、 $x_3 + x_4 = 2$ 。令 $x_2 = s$ 、 $x_4 = t$ ，得

$$x = (5 - 2s - 2t, s, 2 - t, t)^T, \quad s, t \in \mathbb{R}.$$

因此，“无需回代即可读解”并不意味着每个未知数都已经变成一个固定数。方程组有解但解不唯一时，行最简形直接给出的是主元变量关于自由变量的表达式。

两种消元法怎样选择

	高斯消元法	高斯-若尔当消元法
化简目标	行阶梯形	行最简形
读取解	指定自由变量后回代	直接读取主元变量的表达式
手工特点	通常少做一些行运算	结果更整齐，便于比较与讨论
实现方式	可以按列组织为程序	也可以按主元列组织为程序

若只需求出某个方程组的解，手工计算通常采用高斯消元加回代；若希望把参数关系清楚地列出，行最简形更方便。两种方法都可程序化，行最简形更便于直接读解，不代表它在大型数值计算中总是更快。本章着重掌握两者共同的行变换原理。

$$\left[A \mid \boldsymbol{b} \right] \sim \cdots \sim \underbrace{\left[\begin{array}{cccccc|c} \blacksquare & * & * & * & * & * & * \\ 0 & 0 & \blacksquare & * & * & * & * \\ 0 & 0 & 0 & 0 & \blacksquare & * & * \\ 0 & 0 & 0 & 0 & 0 & 0 & 0 \end{array} \right]}_{\left[U \mid \boldsymbol{d} \right]}$$

图 2.9: 增广矩阵的行化简示意。■ 表示主元, * 表示任意非零元, 0 表示零; ~ 表示经过初等行变换。竖线左侧为系数部分, 右侧为常数项列, 二者始终一起变换。

这里 U 是行阶梯形的系数部分, $\boldsymbol{d}$ 是随行变换一起得到的常数项列。图示为方程组有解时的一种结构, 各符号只标记对应位置的性质, 不代表化简前后的数值保持不变。

2.5 向量方程与标准形式 $A\boldsymbol{x} = \boldsymbol{b}$

按列观察同一个方程组

到目前为止, 我们主要按行看方程: 每一行是一条约束。现在换一个方向, 观察同一个未知数在各个方程中的系数, 把它们按次序收集成一个列向量。

对于三元例题(2.3), 令

$$\boldsymbol{a}_1 = \begin{pmatrix} 1 \\ 2 \\ 1 \end{pmatrix}, \quad \boldsymbol{a}_2 = \begin{pmatrix} 1 \\ -1 \\ 2 \end{pmatrix}, \quad \boldsymbol{a}_3 = \begin{pmatrix} 1 \\ 1 \\ -1 \end{pmatrix}, \quad \boldsymbol{b} = \begin{pmatrix} 6 \\ 3 \\ 2 \end{pmatrix}.$$

则原方程组恰好可以写成

$$x_1 \begin{pmatrix} 1 \\ 2 \\ 1 \end{pmatrix} + x_2 \begin{pmatrix} 1 \\ -1 \\ 2 \end{pmatrix} + x_3 \begin{pmatrix} 1 \\ 1 \\ -1 \end{pmatrix} = \begin{pmatrix} 6 \\ 3 \\ 2 \end{pmatrix}, \quad (2.6)$$

即 $x_1 \boldsymbol{a}_1 + x_2 \boldsymbol{a}_2 + x_3 \boldsymbol{a}_3 = \boldsymbol{b}$ 。两个列向量相等, 当且仅当各分量分别相等; 把式(2.6)逐个分量展开, 就回到了原来的三个方程。

已经求出的解 $(1, 2, 3)^T$ 表明

$$\boldsymbol{b} = \boldsymbol{a}_1 + 2\boldsymbol{a}_2 + 3\boldsymbol{a}_3.$$

消元得到的三个数，正是把目标向量表示为给定列向量线性组合时的系数。这与第 1 章的线性表示问题完全一致。

定义 2.23 (线性方程组的向量方程)

对于一个 m 个方程、 n 个未知数的线性方程组，把第 j 个未知数的系数收集为

$$\mathbf{a}_j = (a_{1j}, a_{2j}, \dots, a_{mj})^T \in \mathbb{R}^m, \quad \mathbf{b} = (b_1, \dots, b_m)^T \in \mathbb{R}^m.$$

则方程组等价于**向量方程 (Vector Equation)**

$$x_1 \mathbf{a}_1 + x_2 \mathbf{a}_2 + \dots + x_n \mathbf{a}_n = \mathbf{b}.$$

有 n 个待定系数，并不表示这些列向量属于 $\mathbb{R}^n$ 。每个列向量有 m 个分量，属于 $\mathbb{R}^m$ ；解向量有 n 个分量，属于 $\mathbb{R}^n$ 。当方程数与未知数个数不同，两种空间尤其不能混淆。

定理 2.24 (有解等价于能够线性表示)

线性方程组有解，当且仅当其常数项向量 $\mathbf{b}$ 能由系数矩阵的列向量组 $\mathbf{a}_1, \dots, \mathbf{a}_n$ 线性表示，也就是

$$\mathbf{b} \in \text{Span}\{\mathbf{a}_1, \dots, \mathbf{a}_n\}.$$

若已有表示，且列向量组线性无关，则表示系数唯一；若列向量组线性相关，则表示系数不唯一。

这里最后一句以**已有表示**为前提。相关只说明存在冗余方向，不能保证任意目标向量都在张成空间内。无关也只保证其张成空间中的向量表示唯一，并不保证它们张成整个环境空间。

例题 2.25 (同一组列向量，目标不同，结果不同)

取 $\mathbf{a}_1 = (1, 1)^T$ 、 $\mathbf{a}_2 = (2, 2)^T$ 。

对于 $\mathbf{b} = (3, 3)^T$ ，有

$$x_1 \mathbf{a}_1 + x_2 \mathbf{a}_2 = \mathbf{b} \iff x_1 + 2x_2 = 3.$$

令 $x_2 = t$ ，得 $x_1 = 3 - 2t$ ，表示不唯一。

若改为 $\mathbf{c} = (1, 2)^T$ ，则两个分量分别要求 $x_1 + 2x_2 = 1$ 、 $x_1 + 2x_2 = 2$ ，互相矛盾，因而不能表示。




图 2.10: 从列向量的张成范围理解有解与无解。两个给定向量共线，张成直线 $y = x$ ； b 在直线上，可以表示， c 不在直线上，不能表示。图中的点属于目标向量所在的空间，并非解系数所在的空间。

秩的几何意义：列向量能够张成多大的空间

第 1 章已经说明，向量组的秩等于其张成空间的维数。把向量按列排成矩阵 $A = (a_1, \dots, a_n)$ ，这一结论就写成

$$r(A) = r(a_1, \dots, a_n) = \dim(\text{Span}\{a_1, \dots, a_n\}).$$

因此，**矩阵的秩 (Rank of a Matrix)**，就是它的列向量张成的子空间的维数。这不是一套新的概念，只是把第 1 章的向量组放进矩阵这一数表，仍然讨论同一组向量的秩、张成空间与维数。

以两列都属于 $\mathbb{R}^2$ 的 2×2 矩阵为例：两列共线且至少有一列非零时， $r(A) = 1$ ，张成一条过原点的直线；两列不共线时， $r(A) = 2$ ，张成整个 $\mathbb{R}^2$ 平面。如果两列都是零向量，张成空间只有原点，此时 $r(A) = 0$ 。




图 2.11: 矩阵秩的几何意义。矩阵的秩等于其列向量张成的子空间的维数。右图的浅色区域仅表示整个平面的一部分。

当组合系数遍取所有实数时，所有可能得到的向量恰好填满这些列向量的张成空间。**解的存在性**，就是看目标向量 b 是否落在这个子空间里：秩为 1 时，可表示的目标

限于一条直线；上面的秩为 2 的例子中，每个二维目标向量都能表示。第 2.6 节将把这一几何认识与消元结果对应起来。

从列向量的线性组合到标准形式

把列向量按次序拼成数表 $A = (a_1, \dots, a_n)$ ，把系数收集为 $x = (x_1, \dots, x_n)^T$ 。给定 A 后，每一组输入系数都确定一个输出向量，这种给每个输入指定唯一输出的对应称为映射 (Mapping)。对于正在求解的目标 b ，我们希望找到这样的输入：

$$x \xrightarrow{A} b.$$

于是把对应的向量方程简写为标准形式

$$\boxed{Ax = b}. \quad (2.7)$$

定义 2.26 (本章中 Ax 的含义)

本章把 Ax 用作按列作线性组合的简化记号：

$$Ax \text{ 表示 } x_1 a_1 + \dots + x_n a_n.$$

这里输入 $x \in \mathbb{R}^n$ ，输出属于 $\mathbb{R}^m$ 。矩阵与向量的乘法将在下一章正式定义，本章不使用一般矩阵乘法的规则。




图 2.12: 输入向量、系数数表与输出向量。方程 $Ax = b$ 的任务，是在 A 与目标 b 已知时寻找输入 x 。

对一个任意输入 x ，输出是它所决定的列向量线性组合；**只有满足方程的输入，输出才等于指定的 b** 。固定 A 后，“输入一个向量、得到另一个向量”的对应关系，是后续线性变换概念的雏形。这里先保留这一认识，不展开其正式定义与性质。

例如贯穿例题中，输入 $(1, 2, 3)^T$ ，按列组合得到 $(6, 3, 2)^T$ 。我们先前所做的消元，是从已知输出反过来寻找输入，而不是改变这个输出的含义。

线性变换的几何直观

用平面向量可以直观理解这个映射：给定一个 2×2 矩阵 A ，输入二维向量 $\mathbf{x}$ ，按它的分量对 A 的列向量作线性组合，得到二维输出 $\mathbf{b}$ 。这种“把一个向量变成另一个向量”的对应关系，就是**线性变换的直观形态**。

例如，取

$$A = \begin{pmatrix} 2 & -1 \\ 1 & 2 \end{pmatrix}, \quad \mathbf{x} = \begin{pmatrix} 1 \\ 0 \end{pmatrix}.$$

输入的两个分量是 1 和 0，因此输出为

$$\mathbf{b} = 1 \begin{pmatrix} 2 \\ 1 \end{pmatrix} + 0 \begin{pmatrix} -1 \\ 2 \end{pmatrix} = \begin{pmatrix} 2 \\ 1 \end{pmatrix}.$$

这仍然只是列向量的线性组合。把输入和输出画在同一平面坐标系中，就能直观看到这个向量的方向与长度发生了怎样的改变。




图 2.13: 线性变换的几何直观。输入向量 $\mathbf{x}$ 经过矩阵 A 所表示的线性作用，得到输出向量 $\mathbf{b}$ 。弧形箭头仅指示输入与输出的对应关系。

它**保持向量的线性组合关系**：先组合输入再求输出，与先分别求输出、再按相同系数组合，结果一致。这一点来自列向量组合规则及分配律。这里仅建立直观认识，不正式定义矩阵乘法；线性变换的系统定义与性质留待后续章节展开。

同一个问题的三个视角

代数视角：逐个方程列出未知数必须满足的约束，利用消元求解。

向量视角：用给定列向量线性表示目标向量，询问表示是否存在、是否唯一。

映射视角：固定数表 A ，把输入系数变成输出向量，寻找能够产生指定输出的输入。下一章将进一步研究这一对应关系。

因此，标准形式并没有把问题变得更抽象而失去联系。它把第 1 章的线性表示和本章的消元计算放到同一套记号之中。

2.6 解的存在性与唯一性判定

行变换为什么能判断列向量之间的关系

第 1 章把向量组的秩定义为它的极大线性无关组所含的向量个数。对矩阵 A ，我们只需把这一概念用于它的各列，而不另起一个无关的定义。

定义 2.27 (本章的秩记号)

设 $A = (a_1, \dots, a_n)$ ，记

$$r(A) = r(a_1, \dots, a_n).$$

也就是说， $r(A)$ 是矩阵列向量组的秩。对于增广矩阵 $\bar{A} = (A | b)$ ，则

$$r(\bar{A}) = r(a_1, \dots, a_n, b).$$

本节只通过初等行变换计算这一秩，不引入其他求法。

定理 2.28 (行变换保持列向量的线性关系)

设 A 经初等行变换成为 H ，两者的对应列分别为 $a_1, \dots, a_n$ 与 $h_1, \dots, h_n$ 。对同一组实数 $c_1, \dots, c_n$ ，有

$$c_1 a_1 + \dots + c_n a_n = 0 \iff c_1 h_1 + \dots + c_n h_n = 0.$$

因此，对应的列向量组具有相同的线性相关性和相同的秩，特别地 $r(A) = r(H)$ 。

证明： 把左侧向量等式逐分量展开，是一个以 $c_1, \dots, c_n$ 为未知数、右端全为 0 的方程组。对系数数表作初等行变换，恰好是对这个方程组作同解变换，右端的零经过变换仍为零。因此同一组系数在变换前后同时成立。

把某一列用其他列表示，也可以移到同一边成为上述零向量关系。于是某些列是否无关、能否表示其余各列，在变换前后完全对应，极大无关组的列数也相同。 ■

注意，保持的是对应列之间的线性关系，不是说每一列的数值保持不变。若要从原矩阵中取出一个极大无关列组，应先确定化简后主元所在的列号，再取原矩阵相同列号的列向量。

回到第 1.5 节的定义：极大无关组必须自身无关，并且能够表示原组的全部向量。因此，要说明主元列的作用，就应分别回答：它们为什么“没有多余”，又为什么“已经够用”？

定理 2.29 (主元列给出极大无关组)

设 $m \times n$ 矩阵 A 经初等行变换成为行阶梯形 $H = (h_{ij})$, 其 p 个主元所在列的列号为 $j_1 < \cdots < j_p$. 则

- (1) $h_{j_1}, \dots, h_{j_p}$ 是 H 的列向量组的一个极大线性无关组;
- (2) $a_{j_1}, \dots, a_{j_p}$ 是原矩阵 A 的列向量组的一个极大线性无关组。

因此, $r(A) = r(H) = p$, 即主元个数就是列向量组的秩。

证明: 若 $p = 0$, H 的所有列均为零; 由行变换保持列关系, A 的所有列也为零。两者的极大无关组均取空组, 秩均为 0。以下设 $p \geq 1$ 。

(1) 自身无关: 每个主元列提供一个新的独立方向。第 i 个主元位于第 i 行、第 j_i 列。由阶梯形结构,

$$h_{ij_i} \neq 0, \quad h_{ij_\ell} = 0 \quad (\ell < i).$$

也就是说, 新的主元列在这一行出现非零元素, 而此前的主元列在这一行都是零。因此, 新列不能由此前的主元列表示。严格地, 若

$$c_1 h_{j_1} + \cdots + c_p h_{j_p} = \mathbf{0},$$

比较第 p 个分量, 得 $h_{pj_p} c_p = 0$, 故 $c_p = 0$ 。再依次比较第 $p-1, \dots, 1$ 个分量, 得到

$$c_p = c_{p-1} = \cdots = c_1 = 0.$$

所以这些主元列线性无关。

(2) 能够表示全体: 任意一列都能由主元列组合出来。任取 H 的第 j 列 h_j , 考虑表示式

$$c_1 h_{j_1} + \cdots + c_p h_{j_p} = h_j.$$

按前 p 个分量展开, 便得到阶梯形方程组

$$\begin{cases} h_{1j_1} c_1 + h_{1j_2} c_2 + \cdots + h_{1j_p} c_p = h_{1j}, \\ \vdots \\ h_{pj_p} c_p = h_{pj}. \end{cases}$$

上式按 $p \geq 2$ 示意; $p = 1$ 时只有 $h_{1j_1} c_1 = h_{1j}$ 。每个主元 h_{ij_i} 都非零, 因此从最后一式向上回代, 总能唯一确定 $c_p, \dots, c_1$ 。其余 $m - p$ 个分量在等式两边均为 0, 自动满足。故每一列都可由主元列线性表示。

结合 (1)、(2), 主元列正好满足第 1 章极大无关组的两个条件。

(3) 回到原矩阵：保留列号，也保留表示系数。行变换保持对应列之间的零向量关系，故 $a_{j_1}, \dots, a_{j_p}$ 同样线性无关。对任意列号 j ，还有

$$h_j = \sum_{\ell=1}^p c_{\ell} h_{j_{\ell}} \iff a_j = \sum_{\ell=1}^p c_{\ell} a_{j_{\ell}}.$$

所以这些原列向量也能表示 A 的全部列，构成原列组的一个极大无关组。它们共有 p 个，按秩的定义即得 $r(A) = r(H) = p$ 。■

消元负责显露关系，列号负责指认原向量。在阶梯形中找主元列，再按列号回到原矩阵取列：这些原列向量既没有多余，又能表示全体。因此，数主元才成为求秩的方法。不能直接数原矩阵的非零行；未经消元的非零行可能重复。

例题 2.30 (寻找原向量组的极大无关组)

对

$$A = \begin{bmatrix} 1 & 2 & -1 & 1 \\ 2 & 4 & 1 & 5 \end{bmatrix} \xrightarrow{R_2 \leftarrow R_2 - 2R_1} H = \begin{bmatrix} 1 & 2 & -1 & 1 \\ 0 & 0 & 3 & 3 \end{bmatrix}.$$

主元在第 1、3 列。 h_1 与 h_3 线性无关，并且

$$\begin{aligned} h_2 &= 2h_1 & \iff & a_2 = 2a_1, \\ h_4 &= 2h_1 + h_3 & \iff & a_4 = 2a_1 + a_3. \end{aligned}$$

两组表示使用完全相同的系数。因此，返回原矩阵取第 1、3 列，得到

$$a_1 = (1, 2)^T, \quad a_3 = (-1, 1)^T$$

组成的极大无关组，故 $r(A) = 2$ 。注意选取的是 a_1, a_3 ，而不是化简后数值已经改变的 h_1, h_3 。

非齐次方程组：先判断是否有解，再判断解是否唯一

定义 2.31 (齐次与非齐次方程组)

常数项全部为 0，即 $b = 0$ 的方程组 $Ax = 0$ ，称为**齐次线性方程组 (Homogeneous Linear System)**。

至少有一个常数项不为 0，即 $b \neq 0$ 的方程组 $Ax = b$ ，称为**非齐次线性方程组 (Nonhomogeneous Linear System)**。

方程组**有解**，是指存在一组数同时满足其中所有方程；若不存在这样的公共解，则方程组**无解**。

把 $\mathbf{b}$ 附加到 A 的各列之后, 若它已经能由原列组表示, 秩不增加; 若它不能被表示, 就增加一个独立方向。因此

$$r(A) \leq r(\overline{A}) \leq r(A) + 1.$$

这个不等式来自第 1 章向量组的秩: 只增加一个向量, 秩至多增加 1。

定理 2.32 (线性方程组的秩判定)

设 $Ax = \mathbf{b}$ 有 n 个未知数, 增广矩阵为 $\overline{A} = (A \mid \mathbf{b})$ 。

无解:

$$r(A) < r(\overline{A}).$$

此时 $\mathbf{b}$ 不能由 A 的列向量线性表示, 增广矩阵的行阶梯形中出现常数项列的主元, 即矛盾方程。

唯一解:

$$r(A) = r(\overline{A}) = n.$$

此时 $\mathbf{b}$ 可以表示, 且 n 个系数列线性无关, 所以表示系数唯一。

无穷多解:

$$r(A) = r(\overline{A}) < n.$$

此时 $\mathbf{b}$ 可以表示, 但系数列线性相关, 存在 $n - r(A)$ 个自由变量, 表示不唯一。

证明: 方程组有解, 当且仅当 $\mathbf{b}$ 属于系数列的张成空间, 也就是附加 $\mathbf{b}$ 后秩不增加。在方程组有解的前提下, 系数部分的主元数为 $r(A)$: 若它等于 n , 所有未知数均为主元变量; 若小于 n , 就留下 $n - r(A)$ 个自由变量。应用第 2.2 节的回代结论, 即得三种情形。

■

对增广矩阵一起消元, 通常可以同时读出两个秩: 数整个阶梯形的非零行, 得到 $r(\overline{A})$; 数其中系数部分非零的行, 得到 $r(A)$ 。末行若形如 $(0, \dots, 0 \mid c)$ 且 $c \neq 0$, 它只对增广矩阵的秩贡献 1。

例题 2.33 (把三种消元结果翻译为秩条件)

下面是第 2.2 节三个二元例题的增广矩阵化简：

$$\left(\begin{array}{cc|c} 1 & 1 & 2 \\ 2 & 2 & 5 \end{array} \right) \xrightarrow{R_2 \leftarrow R_2 - 2R_1} \left(\begin{array}{cc|c} 1 & 1 & 2 \\ 0 & 0 & 1 \end{array} \right),$$

$$\left(\begin{array}{cc|c} 1 & 1 & 2 \\ 1 & -1 & 0 \end{array} \right) \xrightarrow{R_2 \leftarrow R_2 - R_1} \left(\begin{array}{cc|c} 1 & 1 & 2 \\ 0 & -2 & -2 \end{array} \right),$$

$$\left(\begin{array}{cc|c} 1 & 1 & 2 \\ 2 & 2 & 4 \end{array} \right) \xrightarrow{R_2 \leftarrow R_2 - 2R_1} \left(\begin{array}{cc|c} 1 & 1 & 2 \\ 0 & 0 & 0 \end{array} \right).$$

第一组： $r(A) = 1 < 2 = r(\bar{A})$ ，无解。

第二组： $r(A) = r(\bar{A}) = 2 = n$ ，唯一解为 $(1, 1)^T$ 。

第三组： $r(A) = r(\bar{A}) = 1 < 2 = n$ ，有一个自由变量，全部解为 $(2 - t, t)^T$ 。

推论 2.34 (方程数与未知数个数)

对于 m 个方程、 n 个未知数，恒有 $r(A) \leq \min\{m, n\}$ 。

若 $m < n$ ，非齐次方程组不可能有唯一解：它或者无解，或者有无穷多解。

若 $r(A) = m$ ，则对**每一个** $b \in \mathbb{R}^m$ ，方程组都有解。若 $r(A) = n$ ，则对每个**能够表示的** b ，其解唯一。

最后两句话分别回答“能否表示任意目标”和“已有表示是否唯一”。当 $m = n = r(A)$ 时，二者同时成立；当 m, n 不同时，不可互相代替。

含参数的方程组：先分类，再作除法

例题 2.35 (参数改变时，解的情形如何变化)

讨论实参数 λ, μ 下的方程组

$$\begin{cases} x_1 + x_2 + x_3 = 1, \\ x_1 + \lambda x_2 + x_3 = 2, \\ x_1 + x_2 + (\lambda - 1)x_3 = \mu. \end{cases}$$

对增广矩阵依次作 $R_2 \leftarrow R_2 - R_1$ 、 $R_3 \leftarrow R_3 - R_1$ ，得到

$$\left(\begin{array}{ccc|c} 1 & 1 & 1 & 1 \\ 1 & \lambda & 1 & 2 \\ 1 & 1 & \lambda-1 & \mu \end{array} \right) \xrightarrow{\substack{R_2 \leftarrow R_2 - R_1 \\ R_3 \leftarrow R_3 - R_1}} \left(\begin{array}{ccc|c} 1 & 1 & 1 & 1 \\ 0 & \lambda-1 & 0 & 1 \\ 0 & 0 & \lambda-2 & \mu-1 \end{array} \right).$$

现在不能立即除以 $\lambda-1$ 或 $\lambda-2$ ，必须先判断它们是否为 0。

情形一： $\lambda \neq 1, 2$ 。两个系数均非零， $r(A) = r(\bar{A}) = 3$ ，有唯一解

$$x_2 = \frac{1}{\lambda-1}, \quad x_3 = \frac{\mu-1}{\lambda-2}, \quad x_1 = 1 - \frac{1}{\lambda-1} - \frac{\mu-1}{\lambda-2}.$$

情形二： $\lambda = 1$ 。第二行变成 $(0, 0, 0 | 1)$ ，即 $0 = 1$ ，不论 μ 为何值都无解。若继续整理，交换第 2、3 行后，再作 $R_2 \leftarrow R_2 - (\mu-1)R_3$ ，可得阶梯形

$$\left(\begin{array}{ccc|c} 1 & 1 & 1 & 1 \\ 0 & 0 & -1 & 0 \\ 0 & 0 & 0 & 1 \end{array} \right),$$

故 $r(A) = 2$ 、 $r(\bar{A}) = 3$ 。

情形三： $\lambda = 2$ 。末行变为 $(0, 0, 0 | \mu-1)$ 。若 $\mu \neq 1$ ，则无解；若 $\mu = 1$ ，则

$$r(A) = r(\bar{A}) = 2 < 3, \quad x_2 = 1, \quad x_3 = t, \quad x_1 = -t,$$

有无穷多解 $x = (-t, 1, t)^T$ 。

这个例题给出含参数问题的基本做法：**先把可能为 0 的表达式保留下来，再按主元是否消失、常数项是否矛盾分类。**未经分类就约去含参数的因子，会丢掉某些情形。

齐次方程组与线性相关性

定理 2.36 (齐次线性方程组的解判定)

齐次方程组 $Ax = 0$ 总有零解 $x = 0$ ，因此一定有解，且 $r(\bar{A}) = r(A)$ 。

只有零解的充要条件是

$$r(A) = n \iff A \text{ 的列向量组线性无关.}$$

有非零解的充要条件是

$$r(A) < n \iff A \text{ 的列向量组线性相关.}$$

这里“非零解”指解向量**不全为 0**，并不要求每个分量都非零。

这直接呼应第 1 章： $x_1 a_1 + \cdots + x_n a_n = \mathbf{0}$ 是否存在不全为 0 的系数，就是线性相关与无关的定义。齐次方程组没有“无解”情形；一旦有非零解，就有无穷多解。

例题 2.37 (三个主元，只有零解)

把贯穿例题的常数项都改为 0，按原来的操作消元：

$$\begin{aligned} & \left(\begin{array}{ccc|c} 1 & 1 & 1 & 0 \\ 2 & -1 & 1 & 0 \\ 1 & 2 & -1 & 0 \end{array} \right) \xrightarrow{\substack{R_2 \leftarrow R_2 - 2R_1 \\ R_3 \leftarrow R_3 - R_1}} \left(\begin{array}{ccc|c} 1 & 1 & 1 & 0 \\ 0 & -3 & -1 & 0 \\ 0 & 1 & -2 & 0 \end{array} \right) \\ & \xrightarrow{R_2 \leftrightarrow R_3} \left(\begin{array}{ccc|c} 1 & 1 & 1 & 0 \\ 0 & 1 & -2 & 0 \\ 0 & -3 & -1 & 0 \end{array} \right) \xrightarrow{R_3 \leftarrow R_3 + 3R_2} \left(\begin{array}{ccc|c} 1 & 1 & 1 & 0 \\ 0 & 1 & -2 & 0 \\ 0 & 0 & -7 & 0 \end{array} \right). \end{aligned}$$

有 $r(A) = 3 = n$ 。由 $-7x_3 = 0$ 向上回代，得 $x_3 = x_2 = x_1 = 0$ ，因此只有零解，三个系数列线性无关。

例题 2.38 (有自由变量，得到非零解)

对齐次方程组

$$\begin{cases} x_1 + 2x_2 - x_3 + x_4 = 0, \\ 2x_1 + 4x_2 + x_3 + 5x_4 = 0, \end{cases}$$

作与第 2.4 节相同的行操作：

$$\begin{aligned} & \left(\begin{array}{cccc|c} 1 & 2 & -1 & 1 & 0 \\ 2 & 4 & 1 & 5 & 0 \end{array} \right) \xrightarrow{R_2 \leftarrow R_2 - 2R_1} \left(\begin{array}{cccc|c} 1 & 2 & -1 & 1 & 0 \\ 0 & 0 & 3 & 3 & 0 \end{array} \right) \\ & \xrightarrow{R_2 \leftarrow \frac{1}{3}R_2} \left(\begin{array}{cccc|c} 1 & 2 & -1 & 1 & 0 \\ 0 & 0 & 1 & 1 & 0 \end{array} \right) \xrightarrow{R_1 \leftarrow R_1 + R_2} \left(\begin{array}{cccc|c} 1 & 2 & 0 & 2 & 0 \\ 0 & 0 & 1 & 1 & 0 \end{array} \right). \end{aligned}$$

有 $r(A) = 2 < 4$ 。令 $x_2 = s$ 、 $x_4 = t$ ，全部解为

$$\mathbf{x} = (-2s - 2t, s, -t, t)^T, \quad s, t \in \mathbb{R}.$$

例如取 $s = 1, t = 0$ ，得到非零解 $(-2, 1, 0, 0)^T$ 。它同时给出系数列的一条相关关系 $-2a_1 + a_2 = \mathbf{0}$ 。

推论 2.39 (未知数多于方程时的齐次系统)

若齐次线性方程组的未知数个数 n 大于方程个数 m ，则一定有非零解。

因为 $r(A) \leq m < n$, 至少留下一个自由变量。这是**充分条件, 不是必要条件**: 即使方程数不少于未知数个数, 只要 $r(A) < n$, 仍有非零解。例如 $x_1 + x_2 = 0$ 、 $2x_1 + 2x_2 = 0$ 就有解 $(-t, t)^T$ 。

还可检查一个极端情形: 若 A 的所有元素为 0, 则 $r(A) = 0$ 。当 $\mathbf{b} = \mathbf{0}$ 时, 任意 $\mathbf{x} \in \mathbb{R}^n$ 都是解; 当 $\mathbf{b} \neq \mathbf{0}$ 时, 至少有一行要求 $0 = b_i \neq 0$, 因而无解。这说明零系数并不妨碍判定方法, 只要把常数项一起考虑即可。

完成一道题的检查顺序

先确认未知数个数与排列顺序, 写出增广矩阵; 再标注每一步行操作, 把它化为行阶梯形。**先查矛盾, 再数主元, 最后写解**: 无解时指出具体矛盾行; 唯一解时逐项列出; 无穷多解时明确自由变量及参数范围, 给出全部解, 而不是随意取一个特解 (Particular Solution) 就停止。

最后把所得解代回原方程验证。含参数时, 检查所有被用作除数的表达式是否已经排除 0。秩的比较、主元的计数和向量的表示关系, 应当给出一致的判断。

2.7 【应用案例】抖音视频推荐：从用户偏好反求组合权重

刷短视频时，用户会停留、划走、点赞，也会关注新的内容。推荐系统根据这些反馈，从大量候选视频中筛选、排序，再通过新的反馈继续调整。对于学习线性代数的我们，可以先把注意力放在一个具体问题上：**用户的偏好已经给定，现有的视频能够以怎样的权重组合，恰好满足这份偏好？**

第 0 章把视频表示成向量，第 1 章说明视频向量之间存在张成、相关、秩与基的关系。本例沿用第 1 章的前三条视频及其偏好数据，把“已知权重，合成偏好”反过来，讨论“已知偏好，反求权重”。**四个特征、全部数值及组合规则都是教学简化，不代表抖音真实算法。**实际推荐包含多轮筛选和排序；这里抽出一个可以用线性方程组精确说明的内容组合问题，权重不直接等同于平台曝光概率。



视频 1：搞笑美食

视频 2：科技游戏

视频 3：混合日常

图 2.14: 三条示例视频的内容场景：搞笑美食、科技游戏与混合日常。画面为 AI 生成的教学插画，并非平台视频截图；向量分值由本例人为设定。

本例暂把候选视频库与用户偏好看作已经获得的数据，不讨论它们怎样从真实行为中学习出来。我们要观察的是，**将内容按比例组合时，四项特征要求怎样共同约束这几个比例。**



图 2.15: 从真实推荐场景中抽取一个教学问题。上方概括用户反馈与内容推荐的联系；下方是本例单独建立的线性模型，不表示平台内部存在同样的求解模块。

固定四个特征的顺序为“搞笑、科技、美食、游戏”。视频 1 侧重搞笑与美食，视频 2 侧重科技与游戏，视频 3 在四项特征上都有中等强度。用户的偏好向量为 $\mathbf{b} = (0.35, 0.65, 0.35, 0.65)^T$ 。图中条形的长度表示特征强度，**同一行始终比较同一种特征**。




图 2.16: 把视频和用户偏好放进同一个四维特征空间。三个视频向量及偏好向量均沿用第 1 章；下方括号中的分量顺序与条形图一致。

设三条视频的权重为 x_1, x_2, x_3 。要求组合恰好得到用户偏好，就是要求

$$x_1 \mathbf{a}_1 + x_2 \mathbf{a}_2 + x_3 \mathbf{a}_3 = \mathbf{b}.$$

展开四个分量，得到

$$\begin{cases} x_1 + \frac{1}{2}x_3 = 0.35, & \text{搞笑,} \\ x_2 + \frac{1}{2}x_3 = 0.65, & \text{科技,} \\ x_1 + \frac{1}{2}x_3 = 0.35, & \text{美食,} \\ x_2 + \frac{1}{2}x_3 = 0.65, & \text{游戏.} \end{cases}$$

每一行方程都是一次特征核对。例如，搞笑特征由视频 1 和视频 3 贡献，视频 2 在这一项的贡献为 0；它们的加权结果必须等于 0.35。我们求的是三条视频怎样共同构成一份内容组合，而不只是从中挑出某一条视频。

记 $A = (\mathbf{a}_1, \mathbf{a}_2, \mathbf{a}_3)$ ，则向量方程简写为 $A\mathbf{x} = \mathbf{b}$ 。增广矩阵把四项要求放在一起；只需两次初等行变换，就能看清其中重复的约束：

$$\bar{A} = \left(\begin{array}{ccc|c} 1 & 0 & \frac{1}{2} & 0.35 \\ 0 & 1 & \frac{1}{2} & 0.65 \\ 1 & 0 & \frac{1}{2} & 0.35 \\ 0 & 1 & \frac{1}{2} & 0.65 \end{array} \right) \xrightarrow[R_4 \leftarrow R_4 - R_2]{R_3 \leftarrow R_3 - R_1} \left(\begin{array}{ccc|c} 1 & 0 & \frac{1}{2} & 0.35 \\ 0 & 1 & \frac{1}{2} & 0.65 \\ 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 \end{array} \right).$$

这就是本例的高斯消元。所得矩阵是行阶梯形，第 1、2 列各有一个主元，第 3 列没有主元。后两行成为 $0 = 0$ ，表示美食要求与搞笑要求重复、游戏要求与科技要求重复，四个特征分量只给出了两条独立约束。

主元变量是 x_1, x_2 ，自由变量是 x_3 。令 $x_3 = t$ ，便可直接回代得到

$$\mathbf{x} = (0.35 - 0.5t, 0.65 - 0.5t, t)^T.$$

这条式子可以读成一条组合规则：增加混合视频 3 的权重时，视频 1 和视频 2 的权重各减少它的一半，最终的四项特征不变。第 1 章的关系 $\mathbf{a}_3 = \frac{1}{2}\mathbf{a}_1 + \frac{1}{2}\mathbf{a}_2$ ，现在变成了可以实际计算的权重调整方式。




图 2.17: 同一用户偏好，三种视频组合。每条长条表示三个视频的权重；三种不同配方都生成同一个四维向量 $\mathbf{b}$ 。颜色在后续特征贡献图中保持一致。

图中的中间方案恰好是第 1 章已经用过的 $(0.2, 0.5, 0.3)^T$ 。把它按特征拆开，可以看到：视频 3 在每项上贡献 $0.3 \times 0.5 = 0.15$ ；视频 1 补上搞笑与美食，视频 2 补上科技与游戏。四条合成后的特征条形与目标逐项相等。




图 2.18: 检查一组权重是否满足方程组，就是检查四项特征的加权贡献是否分别达到目标。图中采用权重 $(0.2, 0.5, 0.3)^T$ ；右端数字是对应的目标分量。

两个主元意味着 $r(A) = r(\bar{A}) = 2$ ，未知数却有 3 个，所以这是有无穷多解的非齐次方程组。自由变量不是计算遗漏，而是这些视频在特征表示上存在冗余，偏好条件不足以唯一确定每一条视频的权重。

代数解允许 t 取任意实数；若要求权重非负，就限制为 $0 \leq t \leq 0.7$ 。这些权重的和恰好为 1，因此条形图也能表示一份内容组合的比例。这仍只是本例的组合规则，不能据此推断真实平台将按这些比例展示视频。

如果候选库只保留视频 1 和视频 2, 同一用户偏好就只有一种组合: 权重分别为 0.35 与 0.65。记 $A_{12} = (a_1, a_2)$, 此时

$$r(A_{12}) = r(A_{12} | b) = 2 = n,$$

两个未知数都对应主元, 没有自由变量。这说明**唯一解与无穷多解的区别**, 在于当前视频库是否为同一目标留下了额外的组合方式。



图 2.19: 在权重空间中看唯一解与无穷多解。左图只有两个权重, 满足要求的点唯一; 右图有三个权重, 全部实数解形成一条直线, 深色线段是其中权重非负的部分。

再把用户的美食偏好从 0.35 提高到 0.50, 其余分量保持不变, 得到

$$c = (0.35, 0.65, 0.50, 0.65)^T.$$

这个小变化却使精确组合变得不可能: 三条视频各自的搞笑分量都等于美食分量, 因此任何线性组合也必须满足“搞笑 = 美食”。目标 c 要求两者不同, 已经超出了现有视频库的表示范围。

在增广矩阵中, 仍作 $R_3 \leftarrow R_3 - R_1$, 就会得到矛盾方程 $0 = 0.15$ 。系数部分仍只有两个主元, 增广矩阵却多出一个常数项列的主元:

$$r(A) = 2 < 3 = r(A | c).$$

无解在这里有明确的内容含义: 现有视频把某些特征绑定在一起, 不能独立调高美食而不改变搞笑。这不是消元方法失效, 而是当前表示模型无法满足新的目标。




图 2.20: 用户偏好是否在可表示范围内。省去始终与科技分量相等的游戏分量后，用搞笑、科技、美食作三个坐标；平面“美食 = 搞笑”表示内容空间。 b 在平面上， c 在平面外。

回头看那些不同的可行组合，它们之间的差别还能用齐次方程组解释。取

$$d = (-\frac{1}{2}, -\frac{1}{2}, 1)^T, \quad Ad = -\frac{1}{2}a_1 - \frac{1}{2}a_2 + a_3 = 0.$$

这是 $Ax = 0$ 的一个非零解，也就是视频向量线性相关的证据：增加一份视频 3 的权重，同时各减少半份视频 1 和视频 2，四项特征的净变化恰好都是 0。




图 2.21: 齐次方程组描述“不改变偏好的调整方向”。左边是三条视频权重的增减，右边是四项特征的净变化。负数表示权重减少，并非负数量的视频。

例如，从权重 $(0.35, 0.65, 0)^T$ 出发，沿着上述方向调整 0.3 倍，就得到 $(0.2, 0.5, 0.3)^T$ ，用户偏好仍然是同一个 b 。齐次方程组回答“哪些调整可以相互抵消”，非齐次方程组回答“哪些组合能够产生指定偏好”；主元、自由变量和秩把这两个问题联系起来。

这个案例中，方程组的作用不是给出一个神秘的推荐分数，而是把每项特征要求变成可以同时核对的约束。唯一解表示权重被这些约束完全确定，无穷多解表示还有可调整的组合，无解则提示目标超出了视频库的张成范围。下一章，我们将继续把矩阵理解为从输入权重到输出特征向量的线性映射。

本章小结

本章从鸡兔同笼问题出发，建立了如下联系：

消元思想 $\rightarrow$ 高斯消元法 $\rightarrow$ 矩阵与初等行变换
 $\rightarrow$ 向量方程与标准形式 $A\mathbf{x} = \mathbf{b}$ $\rightarrow$ 解的判定.

同解变换是计算的依据。交换方程、非零倍乘、倍加都可以逆向恢复，所以保持解集不变。矩阵的三种初等行变换只是这些操作的紧凑记录，常数项列必须一起变换。

行阶梯形揭示未知数之间的先后关系。高斯消元法向下消元，再向上回代；高斯-若尔当法继续把主元化为 1，并消去其所在列的其他元素，得到行最简形。主元变量由自由变量确定，不能把所有未知数都任意取值。

线性方程组本质上是向量的线性表示问题。系数矩阵的列是给定向量，未知数是待求的组合系数，常数项列是目标向量。是否有解取决于目标向量能否由系数矩阵的列向量线性表示；在方程组有解的前提下，解是否唯一取决于系数列是否线性无关。

消元把秩的定义变成了系统算法。初等行变换保持对应列的线性关系；化为行阶梯形之后，非零行数就是列向量组的秩。若从原列组中选极大无关组，应按主元列号返回原矩阵取列。

设未知数个数为 n ， $\overline{A} = (A \mid \mathbf{b})$ ，解的判定可汇总为：

秩条件	行阶梯形的表现	解的情形
$r(A) < r(\overline{A})$	出现矛盾行	无解
$r(A) = r(\overline{A}) = n$	无矛盾，无自由变量	唯一解
$r(A) = r(\overline{A}) < n$	无矛盾，有自由变量	无穷多解

齐次方程组必有零解： $r(A) = n$ 时只有零解， $r(A) < n$ 时有非零解。后一结论也就是系数列线性相关的判定；未知数多于方程的齐次系统一定属于后一情形。

本章中的矩阵首先是一种组织方程与消元的工具，同时又记录了“输入系数、输出线性组合”的向量对应关系。下一章将正式研究矩阵的运算与性质，进一步理解矩阵怎样表示线性映射。更深入的解集结构将在第 6 章继续讨论。

第 3 章

矩阵：线性映射的代数表示

介绍性实例 AI 时代的线性骨架

——ChatGPT 如何用矩阵“读懂”人类语言

上一章我们看到，1942 年的曼哈顿计划里，上百个未知数组成的线性方程组，撑起了人类第一次掌握核能的时代。矩阵从诞生之初，就站在人类技术革命的最底层。

八十多年后的今天，另一项重塑了人类文明的技术，依然把矩阵作为它最核心的运算单元。

2022 年底，ChatGPT 横空出世。人类第一次真切地感受到，机器可以像人一样理解语言、推理、写作，甚至编写代码。很少有人会把这个划时代的人工智能，和我们正在学的线性代数联系在一起。但剥开所有酷炫的技术包装，ChatGPT 最核心的 Transformer 架构，从头到尾都在做同一件事：矩阵运算。

在 Transformer 出现之前，机器处理语言像个刚识字的孩子：用手指着字，从左到右一个一个读，读到后面就忘了前面。它只能看见局部，看不见整句话的关联。而 Transformer 最革命性的地方，就是让机器第一次能「一眼看完一整句话」，同时判断每个词和其他所有词的关联——这就是我们常说的「注意力机制」。

而实现这一切的工具，正是我们本章即将深入研究的对象：矩阵。

在把一句话写成矩阵之前，先浅浅提一个后面会反复出现的概念：**词元 (Token)**。

你可以把它理解成大模型处理文本的基本单位。我们习惯把一句话拆成字、拆成词，机器则先按分词器的规则，把文字切成一个个它能识别的片段。一个 Token 可能是一个完整的词，也可能只是词的一部分；在中文中，一个汉字也可能被分成多个 Token。

你暂时不用深究分词的规则，也不用纠结它和“词”的区别。对我们本章来说，最重要的只有一件事：**每一个 Token，都会先被映射成一个 d 维向量**。有了这些向量，我们就能把一句话组织成矩阵。

机器不认识文字，只认识数字。第一步，是把每个 Token 映射成一个 d 维向量。一句话切分后有 N 个 Token，把它们的向量按顺序排成 N 行，就得到了一个 $N \times d$ 的输入矩阵 X 。




图 3-导 1: 从文字到矩阵：信息如何变成数表。

读图说明：为了看清排列方式，图中假设“AI / 改变 / 世界”是三个 Token，并非某个实际分词器的切分结果。每个 Token 的初始向量先竖排，再转置后逐行放入 X ，因此 X 有 N 行、 d 列。后面的注意力计算会更新这些表示、融入上下文。

到此，文字消失了，剩下的是一张数表，和当年曼哈顿计划里的中子通量数表，在数学上没有本质区别。

接下来的操作，是理解注意力机制的第一道门。Transformer 用三个可训练的权重矩阵 W_Q, W_K, W_V ，分别作用于输入矩阵 X ，得到三个全新的矩阵：




图 3-导 2: 三副眼镜与三次线性投影： Q 、 K 、 V 的诞生。

读图说明：权重矩阵 (Weight Matrix) 由训练调整；这里采用单头、等维的简化模型；一般注意力头的查询、键和值维度可以不同，三个权重矩阵不一定是 $d \times d$ 。本例图示依据：Vaswani 等，*Attention Is All You Need* (2017)，第 3 节与第 5 节。

看到这里，你可能会问：“两个矩阵放在一起，到底意味着什么？它们是怎么算出来的？”这正是本章的核心任务，我们暂时不需要知道具体的计算规则。但我们可以知道的是：这三个权重矩阵的维度都是 $d \times d$ 。当它们作用于 $N \times d$ 的输入矩阵 X 时，产生的新矩阵 Q 、 K 、 V ，维度仍然是 $N \times d$ 。

这意味着什么？意味着这三个矩阵，把同一句话里的每一个 Token，分别投射到了三个不同的语义空间：

Q (Query, 查询)：代表当前这个 Token “正在寻找什么信息”。

K (Key, 键)：代表每个 Token “包含什么信息”。

V (Value, 值)：代表每个 Token “实际携带的信息是什么”。


用更通俗的话说，这就好比让同一个 Token，分别戴上三副不同的眼镜去看自己。每一副眼镜，都让它看到自己不同侧面的意义。而这三副眼镜，就是那三个权重矩阵。

接下来，Transformer 要把这句话里所有 Token 之间的关联找出来。它用 Q 和 K 做了一次矩阵运算：

$$S = QK^T$$

这里的 K^T 是转置矩阵（一个我们即将在本章正式见面的概念）。 Q 是 $N \times d$ ， K^T 是 $d \times N$ ，它们作用之后，生成了一个 $N \times N$ 的方阵 S 。

请你仔细体会这个 $N \times N$ 矩阵的含义。它的第 i 行第 j 列的元素，衡量的是第 i 个 Token 和第 j 个 Token 之间的语义关联强度。



原本孤立的 N 个 Token，变成了一张全连接的关系网

图 3-导 3: 全局关联矩阵 S ：从 Token 向量到 Token 之间的关系。

读图说明：这里画的是未加掩码的关联分数 $S = QK^T$ ，它一般不对称；归一化前先作尺度调整， $A = \text{softmax}(S/\sqrt{d})$ 。注意力机制 (Attention Mechanism) 早于 Transformer；自回归语言模型还使用因果掩码，使每个位置不能读取后续位置。本图仅用于解释矩阵的行列对应。

也就是说，这个 S 矩阵，把原本孤立的 N 个 Token，变成了一张全连接的关系网。每个 Token 都在问：我和其他每一个 Token，到底有多大的关系？

随后，对这个矩阵的每一行做一种归一化处理（记为 Softmax），把原本可能很大或很小的数值，压缩到 0 到 1 之间，并且保证每一行的数值加起来等于 1。处理完之后，我们得到了一个权重矩阵 A 。这个 A 的每一行，就是一组“注意力权重”——它告诉机器，在生成第 i 个 Token 的新表示时，应该从其他 Token 那里分别获取多少比例的信息。

最后，用这个权重矩阵去作用值矩阵 V ，得到最终输出：

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d}}\right) V$$

这一步，是理解注意力机制的第二道门。 A 是 $N \times N$ ， V 是 $N \times d$ ，作用之后，输出仍然是一个 $N \times d$ 的矩阵。从第 1 章的视角来看，这一步的本质，就是对 V 的每一列做了一次线性组合：用 A 的每一行作为系数，把 V 中所有 Token 的向量加权求和，最终得到第 i 个 Token 融合了全局上下文之后的新向量。





图 3-导 4: 注意力权重的分配与线性组合： AV 的本质。

读图说明：图中取 $N = 3$ ， $0.2 + 0.5 + 0.3 = 1$ ，数字仅为示例。Token 向量在 V 中按行存放，所以输出第 i 行是 V 各行的线性组合；逐列看，则是同一个 A 分别左乘 V 的每一列，并非把 V 的各列彼此组合。只有固定 A 时， $V \mapsto AV$ 才是线性映射；完整注意力还含依赖输入的权重与非线性归一化。

你看，整个看似神秘的注意力机制，拆开来核心只有三件事：

1. 用权重矩阵做三次线性投影，把每个 Token 分别映射到查询、键、值三个不同的语义空间；
2. 用矩阵间的乘法计算全局关联，把孤立的 Token 变成一张全连接的语义关系网，并转化为注意力权重；
3. 用权重对值向量做线性组合，让每个 Token 吸收全局上下文，输出全新的向量表示。

而训练 ChatGPT 的过程，某种意义上就是反过来解一个巨型的线性方程组：已知海量的文本输入和期望输出，反求那上亿个矩阵元素的最优值。它和第 2 章我们解的 $Ax = b$ 底层逻辑完全相通，只是规模从几个未知数，变成了千亿级的参数。



同一套数学骨架：矩阵

图 3-导 5: 正向计算与反向求解：连接第 2 章与第 3 章。

读图说明：右半环保留正文与 $Ax = b$ 的类比，表示“由已知结果反求参数”的思路。实际训练同时需要输入与训练目标，通过损失函数、反向传播和优化方法迭代调整权重；它通常是非线性优化问题，不是直接求解一个巨型线性方程组，也不保证得到唯一或全局最优的权重。

从劈开原子核的核反应堆，到能对话的大语言模型；从计算物理世界的中子通量，到理解人类语言的语义关联。领域天差地别，时代相隔近百年，支撑它们的却是同一套数学骨架——矩阵。

矩阵从来不是一张冰冷的数表，也不只是方程组的简写。它是一种通用的语言，用来描述「输入如何被线性地映射为输出」。物理世界的变化、信息的变换、智能的生成，剥到最底层，都可以用矩阵来刻画。

本章我们就正式学习矩阵的运算，理解矩阵为什么可以表示线性映射。当你学完矩阵乘法、转置这些基础运算，再回头看 Transformer 的注意力公式，你会发现那些看似复杂的符号，不过是最基础的矩阵运算的组合。

3.1 线性映射：矩阵的本质

上一章我们反复见到这样的操作：给一个 n 维向量 $\mathbf{x}$ ，乘上一个 $m \times n$ 矩阵 A ，就得到一个 m 维向量 $\mathbf{b}$ 。这里的“乘上”，仍然是把 A 的各列按照 $\mathbf{x}$ 的分量作线性组合。

这其实是一种对应关系：输入一个向量，输出一个向量。这和我们初中熟悉的函数 (Function) $f(x) = y$ 本质完全相同——只不过以前是数到数的对应，现在是向量到向量的对应。

我们把这种向量空间之间的对应关系，称为**映射 (Mapping)**。确切地说，映射必须为每一个允许的输入指定**唯一的输出**。一个矩阵 A ，就定义了一个从 $\mathbb{R}^n$ 到 $\mathbb{R}^m$ 的映射：

$$f(\mathbf{x}) = A\mathbf{x}.$$




图 3.1: 函数与映射的本质。二者都是输入到输出的对应关系：左图是数到数的函数，右图是向量到向量的映射。

读图说明：函数与映射使用的是同一种对应思想；这里比较的是输入、输出的对象。向量到向量的映射未必线性，还须检验它是否保持加法与数乘。

在 $T: \mathbb{R}^n \rightarrow \mathbb{R}^m$ 中， $\mathbb{R}^n$ 是定义域 (Domain)， $\mathbb{R}^m$ 是预先指定的目标空间，称为陪域 (Codomain)。给定输入 $\mathbf{x}$ ，对应的输出称为它在映射下的像 (Image)。目标空间中的向量不一定都能成为实际输出。

矩阵给出的对应关系有什么特别之处？ 设 A 的各列是 $\mathbf{a}_1, \dots, \mathbf{a}_n$ 。沿用第 2 章的含义， $f(\mathbf{x}) = \sum_{k=1}^n x_k \mathbf{a}_k$ 。于是

$$\begin{aligned} f(\mathbf{x} + \mathbf{y}) &= \sum_{k=1}^n (x_k + y_k) \mathbf{a}_k = f(\mathbf{x}) + f(\mathbf{y}), \\ f(c\mathbf{x}) &= \sum_{k=1}^n (cx_k) \mathbf{a}_k = cf(\mathbf{x}) \quad (c \in \mathbb{R}). \end{aligned}$$

第一条是**可加性 (Additivity)**，第二条是**齐次性 (Homogeneity)**。两者合起来说明：先作线性组合再映射，与先映射再作同样的线性组合，结果相同。

定义 3.1 (线性映射)

若映射 $T: \mathbb{R}^n \rightarrow \mathbb{R}^m$ 对任意 $\mathbf{x}, \mathbf{y} \in \mathbb{R}^n$ 和任意 $c \in \mathbb{R}$ 满足

$$T(\mathbf{x} + \mathbf{y}) = T(\mathbf{x}) + T(\mathbf{y}), \quad T(c\mathbf{x}) = cT(\mathbf{x}),$$

则称 T 为**线性映射 (Linear Map)**。等价地, 对任意实数 k, l , 有

$$T(k\mathbf{x} + l\mathbf{y}) = kT(\mathbf{x}) + lT(\mathbf{y}).$$

本节统一用 T 表示线性映射。把同样的规则反复用于有限个向量, 就得到

$$T\left(\sum_{k=1}^n c_k \mathbf{v}_k\right) = \sum_{k=1}^n c_k T(\mathbf{v}_k).$$

把齐次性中的系数取为 0, 就得到

$$T(\mathbf{0}) = T(0\mathbf{x}) = 0T(\mathbf{x}) = \mathbf{0}.$$

因此, **线性映射必须把零向量送到零向量**。这是线性的必要条件 (Necessary Condition): 不满足它的映射, 一定不是线性映射; 但满足它, 并不能保证线性。它不是判定线性的充分条件 (Sufficient Condition)。例如, $S: \mathbb{R} \rightarrow \mathbb{R}$, $S(x) = x^2$ 虽然满足 $S(0) = 0$, 却有 $S(2) = 4 \neq 2S(1) = 2$, 不满足齐次性。判断一个映射是否线性, 仍须检查它对**任意输入、任意实数系数**是否保持加法与数乘。

再看平移。固定一个非零向量 $\mathbf{a} \in \mathbb{R}^n$, 定义 $S(\mathbf{x}) = \mathbf{x} + \mathbf{a}$ 。这个规则确实给每个输入指定了唯一的输出, 所以它是映射; 但是 $S(\mathbf{0}) = \mathbf{a} \neq \mathbf{0}$, 连上述必要条件都不满足, 因而不是线性映射。这里应当检查的是**零向量的像**, 而不是含糊地说映射是否“过原点”。

很多学生在刚接触线性映射时, 会产生一种可爱的错觉。他们写下 $\cos 2x = 2 \cos x$ 和 $\cos(x+y) = \cos x + \cos y$, 满心欢喜地以为 $\cos$ 是从 $\mathbb{R}$ 到 $\mathbb{R}$ 的线性映射。可惜, 公式不会因为写得整齐就成为事实。令 $x = y = 0$, 这两条所谓的等式都变成了 $1 = 2$; 再看 $\cos 0 = 1 \neq 0$, 零点这一关也没过, 余弦函数就在入口处被淘汰了。**线性条件是用来检验映射的, 不是给函数套上去就会自动成立的。**

与这些反例相对, 熟悉的导数 (Derivative) 给出了一个真正的线性映射。回忆第 1.7 节的多项式空间 P_n : 它由次数不超过 n 的实系数多项式以及零多项式组成。固定 $n \geq 1$, 定义求导映射

$$D: P_n \longrightarrow P_n, \quad D(f) = f'.$$

求导后所得多项式仍在 P_n 中，所以这个映射的输入与输出属于同一个空间。对任意 $f, g \in P_n$ 与 $c \in \mathbb{R}$ ，求导法则给出

$$\begin{aligned} D(f+g) &= (f+g)' = f' + g' = D(f) + D(g), \\ D(cf) &= (cf)' = cf' = cD(f). \end{aligned}$$

它保持加法与数乘，因而是线性映射。从一个向量空间到它自身的线性映射，称为线性算子 (Linear Operator)；这里的 D 就是求导算子。例如，在 P_2 中， $D(t^2) = 2t$ ， $D(3t) = 3$ ，而 $D(t^2 + 3t) = 2t + 3$ 。直观地说，输入是一条变化规律，输出是它在各处的瞬时变化率：两条规律叠加，变化率也相加；把规律同乘一个常数，变化率也同乘这个常数。这个例子也呼应了第1章的认识：向量可以是函数，线性所要求的是运算关系，而不是对象的外形。

基的像，决定整个映射

现在反过来思考：如果事先只给定一个线性映射，而没有给出矩阵，我们应当记录哪些信息？第1章告诉我们，任意 $\mathbf{x} = (x_1, \dots, x_n)^T$ 都有唯一的标准基展开

$$\mathbf{x} = x_1 \mathbf{e}_1 + \dots + x_n \mathbf{e}_n.$$

线性映射保持这组组合系数，因此没有必要逐个记录无穷多个输入的输出。

引理 3.2 (线性映射由基的像唯一决定)

设 $\mathbf{e}_1, \dots, \mathbf{e}_n$ 是 $\mathbb{R}^n$ 的标准基。线性映射 $T: \mathbb{R}^n \rightarrow \mathbb{R}^m$ 完全由

$$T(\mathbf{e}_1), \dots, T(\mathbf{e}_n)$$

唯一决定。具体地，对任意 $\mathbf{x} = (x_1, \dots, x_n)^T$ ，

$$T(\mathbf{x}) = x_1 T(\mathbf{e}_1) + \dots + x_n T(\mathbf{e}_n).$$




图 3.2: 线性映射的确定性。只要确定了每个基向量的像，整个空间中任意向量的像都随之唯一确定。

读图说明：上下的箭头表示配对关系，长度与方向不代表实际坐标。关键是组合系数 $x_1, \dots, x_n$ 保持不变；各个基的像不必互不相同，也可以是零向量。

证明：由标准基展开及线性性，

$$T(\mathbf{x}) = T\left(\sum_{k=1}^n x_k \mathbf{e}_k\right) = \sum_{k=1}^n x_k T(\mathbf{e}_k).$$

右端只用到了 $\mathbf{x}$ 的分量和已知的基向量的像，所以 $T(\mathbf{x})$ 已被确定。若另一个线性映射 S 在每个标准基向量上与 T 相同，则对每个 $\mathbf{x}$ 都有

$$S(\mathbf{x}) = \sum_{k=1}^n x_k S(\mathbf{e}_k) = \sum_{k=1}^n x_k T(\mathbf{e}_k) = T(\mathbf{x}),$$

故 $S = T$ 。 ■

这个结论还有一个自然的反向说明：**可以任意指定基向量的像**。任取 $\mathbf{a}_1, \dots, \mathbf{a}_n \in \mathbb{R}^m$ ，定义

$$T(\mathbf{x}) = \sum_{k=1}^n x_k \mathbf{a}_k.$$

由于标准基坐标唯一，上式给每个输入唯一的输出；由向量运算法则，它满足可加性与齐次性，且 $T(\mathbf{e}_k) = \mathbf{a}_k$ 。因此任意这样一组指定都给出唯一的线性映射。

只要知道每个基向量被映射到哪里，整个空间中任意向量的像就可以通过线性组合唯一确定。这正是有限大小的矩阵能够表示整个线性映射的根本原因。

把基的像按列记录，得到矩阵

下面不再把矩阵仅看成方程的系数数表，而是从映射本身得到它。为区别输入与输出，记 $\mathbb{R}^n$ 的标准基为 $\mathbf{e}_1, \dots, \mathbf{e}_n$ ， $\mathbb{R}^m$ 的标准基为 $\boldsymbol{\varepsilon}_1, \dots, \boldsymbol{\varepsilon}_m$ 。

定义 3.3 (线性映射在标准基下的矩阵)

设 $T: \mathbb{R}^n \rightarrow \mathbb{R}^m$ 是线性映射。对每个 $k = 1, \dots, n$, 把 $T(\mathbf{e}_k)$ 唯一展开为

$$T(\mathbf{e}_k) = A_{1,k}\mathbf{e}_1 + A_{2,k}\mathbf{e}_2 + \cdots + A_{m,k}\mathbf{e}_m.$$

将这 n 组系数按列依次排列, 所得 $m \times n$ 矩阵

$$M(T) = A = \begin{bmatrix} A_{1,1} & A_{1,2} & \cdots & A_{1,n} \\ A_{2,1} & A_{2,2} & \cdots & A_{2,n} \\ \vdots & \vdots & & \vdots \\ A_{m,1} & A_{m,2} & \cdots & A_{m,n} \end{bmatrix}$$

称为 T 在标准基下的**矩阵表示 (Matrix Representation)**, 也称 T 在标准基下的矩阵, 记为 $M(T)$ 。

有时用 $\mathcal{L}(\mathbb{R}^n, \mathbb{R}^m)$ 记所有从 $\mathbb{R}^n$ 到 $\mathbb{R}^m$ 的线性映射组成的集合。于是上述条件也可简写为 $T \in \mathcal{L}(\mathbb{R}^n, \mathbb{R}^m)$; 这里它只是一种集合记号。

怎样读一个元素? 第 j 行、第 k 列的 $A_{j,k}$, 是第 k 个定义域基向量的像 $T(\mathbf{e}_k)$ 在第 j 个目标空间基向量 $\mathbf{e}_j$ 上的坐标。先选第 k 个输入, 再读它输出的第 j 个分量。

怎样读一整列? 由于使用标准基, 坐标就是向量的分量, 因此

$$\text{第 } k \text{ 列} = \begin{pmatrix} A_{1,k} \\ \vdots \\ A_{m,k} \end{pmatrix} = T(\mathbf{e}_k), \quad A = [T(\mathbf{e}_1) \cdots T(\mathbf{e}_n)].$$

注意, **基的像按列放置, 不是按行放置**。定义域有 n 个标准基向量, 所以矩阵有 n 列; 每个像有 m 个分量, 所以矩阵有 m 行。即

$$\boxed{\text{列数} = \dim \mathbb{R}^n = n, \quad \text{行数} = \dim \mathbb{R}^m = m.}$$

这里的行数由预先指定的目标空间决定, 不表示输出一定遍及该空间。




图 3.3: 线性映射的矩阵表示。矩阵的第 k 列，就是第 k 个标准基向量在映射下的像。

读图说明：蓝色始终对应第 1 个基向量，红色始终对应第 2 个基向量。右图与矩阵记录的是同一组输出：图形显示方向与长度，数表记录各个分量。

从映射到矩阵，再从矩阵回到映射

对于任意 $x = (x_1, \dots, x_n)^T$ ，核心引理给出

$$T(x) = x_1 T(e_1) + \dots + x_n T(e_n) = x_1 a_1 + \dots + x_n a_n = Ax.$$

这里 a_k 正是矩阵 $A = M(T)$ 的第 k 列。第 2 章中“按输入系数作列向量的线性组合”，现在有了明确的映射解释。

定理 3.4 (标准基下的双向对应)

每个线性映射 $T: \mathbb{R}^n \rightarrow \mathbb{R}^m$ 都唯一对应一个 $m \times n$ 矩阵 $A = M(T)$ ，并满足 $T(x) = Ax$ 。

反过来，每个 $m \times n$ 矩阵 A 都按 $T_A(x) = Ax$ 唯一确定一个线性映射，而且 $M(T_A) = A$ 。因此，固定两端的标准基之后，线性映射与这种大小的矩阵构成一一对应 (One-to-One Correspondence)。

证明：从映射到矩阵，每个 $T(e_k)$ 的标准基坐标唯一，所以各列唯一。从矩阵到映射，列向量的线性组合满足可加性和齐次性，因而 T_A 线性；又因 e_k 仅第 k 个分量为 1，有 $T_A(e_k) = a_k$ ，按列记录便重新得到 A 。两种构造互相还原。 ■

接下来的三个算例都使用同一条路径：**求标准基向量的像，再按原有次序拼成各列。**图形、公式与数表只是这条路径的不同表达。

例题 3.5 (二维平面旋转：从方向读出两列)

设 $T: \mathbb{R}^2 \rightarrow \mathbb{R}^2$ 把平面向量绕原点逆时针旋转 θ 角，求 $M(T)$ 。

解 标准基为 $e_1 = (1, 0)^T$ 、 $e_2 = (0, 1)^T$ 。旋转保持向量的加法与数乘：把向量相加的整个平行四边形同时旋转，所得对角线就是两条旋转后向量的和；同样，数乘造成的伸缩及反向与旋转的先后次序无关。因此 T 是线性映射。

先求两个基向量的像。 e_1 原来沿横轴正向，旋转后仍长为 1，与横轴正向的有向角为 θ ，故


$$T(e_1) = \begin{pmatrix} \cos \theta \\ \sin \theta \end{pmatrix}.$$

e_2 原来的方向角是 $\pi/2$ ，旋转后为 $\pi/2 + \theta$ ，故

$$T(e_2) = \begin{pmatrix} \cos(\pi/2 + \theta) \\ \sin(\pi/2 + \theta) \end{pmatrix} = \begin{pmatrix} -\sin \theta \\ \cos \theta \end{pmatrix}.$$

按列排列，便得到**旋转矩阵 (Rotation Matrix)**：

$$M(T) = \begin{bmatrix} \cos \theta & -\sin \theta \\ \sin \theta & \cos \theta \end{bmatrix}.$$



第 1 列：横轴单位向量的像

$$T(e_1) = (\cos \theta, \sin \theta)^T$$

第 2 列：纵轴单位向量的像

$$T(e_2) = (-\sin \theta, \cos \theta)^T$$

虚线为旋转前，实线为旋转后。

图 3.4: 旋转标准基，就能读出旋转矩阵的两列。图中取 $\theta = 35^\circ$ ，公式对任意实数 θ 成立。

读图说明：两支基向量同时转过相同的角度。第 2 列的负号来自 $\cos(\pi/2 + \theta) = -\sin \theta$ ，不是另行规定的运算规则。

最后检验一个熟悉的角度：当 $\theta = \pi/2$ 时，两列分别为 $(0, 1)^T$ 与 $(-1, 0)^T$ 。于是

$$M(T) = \begin{bmatrix} 0 & -1 \\ 1 & 0 \end{bmatrix}, \quad T\left(\begin{pmatrix} x \\ y \end{pmatrix}\right) = x \begin{pmatrix} 0 \\ 1 \end{pmatrix} + y \begin{pmatrix} -1 \\ 0 \end{pmatrix} = \begin{pmatrix} -y \\ x \end{pmatrix}.$$

例如 $(2, 1)^T$ 变为 $(-1, 2)^T$ ，与逆时针转过直角的几何结果一致。

例题 3.6 (二维到三维：输入两项，输出三项)

设线性映射 $T: \mathbb{R}^2 \rightarrow \mathbb{R}^3$ 为

$$T((x, y)^T) = (x + 3y, 2x + 5y, 7x + 9y)^T.$$

求 $M(T)$ ，并计算 $T((2, -1)^T)$ 。

解 每个输出分量都是输入分量的线性组合，代入向量加法与数乘即可验证两条线性性质。定义域是 $\mathbb{R}^2$ ，只需计算它的两个标准基向量的像：

$$T(e_1) = T((1, 0)^T) = (1 + 3 \cdot 0, 2 + 5 \cdot 0, 7 + 9 \cdot 0)^T = (1, 2, 7)^T,$$

$$T(e_2) = T((0, 1)^T) = (0 + 3, 0 + 5, 0 + 9)^T = (3, 5, 9)^T.$$

把这两个三维列向量依次放入第 1 列和第 2 列，得到

$$M(T) = \begin{bmatrix} 1 & 3 \\ 2 & 5 \\ 7 & 9 \end{bmatrix}.$$

它有 2 列，是因为输入空间有 2 个标准基向量；它有 3 行，是因为每个输出有 3 个分量。




图 3.5: 从两个二维标准基向量，得到两个三维的像。右侧浅色四边形由这两个像向量构成，表示左侧单位正方形的对应结果。

读图说明： 输出虽然有 3 个分量，映射仍由 2 个基的像决定。对应四边形上的点为 $sT(e_1) + tT(e_2)$ ，其中 $0 \leq s, t \leq 1$ ；图中坐标轴采用空间示意投影。

不必再逐项代入原式，由 $(2, -1)^T = 2e_1 - e_2$ 可直接得到

$$\begin{aligned} T((2, -1)^T) &= 2T(e_1) - T(e_2) \\ &= 2(1, 2, 7)^T - (3, 5, 9)^T = (-1, -1, 5)^T. \end{aligned}$$

这正是 $M(T)x$ 的含义：用输入分量 2 与 -1 ，组合矩阵已经记录的两个基的像。

例题 3.7 (三维到二维：投影后保留平面坐标)

把空间向量正交投影到 xy 平面，再用该平面的两个坐标表示结果，得到映射

$$T: \mathbb{R}^3 \rightarrow \mathbb{R}^2, \quad T((x, y, z)^T) = (x, y)^T.$$

求 $M(T)$ ，并说明它的每一列表示什么。

解 正交投影 (Orthogonal Projection) 在这里表示沿垂直于 xy 平面的方向落到该平面。三维投影结果为 $(x, y, 0)^T$ ；本例用平面坐标记录为 $(x, y)^T$ ，舍去 z 分量。由分量运算可见， T 保持加法与数乘。

定义域有三个标准基向量，必须分别计算三个像：

$$T(e_1) = T((1, 0, 0)^T) = (1, 0)^T,$$

$$T(e_2) = T((0, 1, 0)^T) = (0, 1)^T,$$

$$T(e_3) = T((0, 0, 1)^T) = (0, 0)^T.$$

按列排列，得到一个 2 行 3 列的矩阵：

$$M(T) = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \end{bmatrix}.$$

第 1 列记录 e_1 的像，第 2 列记录 e_2 的像，第 3 列记录 e_3 的像。第三列为零并非缺少信息，而是准确记录了第三个标准基向量被送到零向量。




图 3.6: 三维到二维的投影。先沿竖直虚线落到 xy 平面，再用两个平面坐标记录结果； e_3 的像是零向量。

读图说明：垂直方向的分量改变，平面上的输出不变。例如 $(2, 1, 3)^T$ 与 $(2, 1, -4)^T$ 都被送到 $(2, 1)^T$ 。一个映射允许不同输入得到相同输出。

对任意输入，由基的像可还原整个规则：

$$T((x, y, z)^T) = x(1, 0)^T + y(0, 1)^T + z(0, 0)^T = (x, y)^T.$$

这与一开始给定的投影规则完全相同。

矩阵，就是线性映射在标准基下的代数表示；矩阵乘向量 Ax ，本质就是计算线性映射 T 在 x 处的像。三个算例的共同路径，都是先求基的像，再按列记录；输入的组合系数，决定了输出怎样由这些列组合而成。

3.2 矩阵的线性运算：映射的加法与数乘

第 3.1 节已经说明，矩阵是线性映射在标准基下的代数表示。如果把同一个输入交给两个线性映射，再把它们的输出相加，就得到一个新的对应规则；如果把每个输出都放大同样的倍数，也得到一个新的对应规则。矩阵的加法与数乘，正是这两种映射运算的记录。

定义 3.8 (映射的加法与数乘)

设 $S, T: \mathbb{R}^n \rightarrow \mathbb{R}^m$ 为线性映射， $\lambda \in \mathbb{R}$ 。定义

$$(S + T)(x) = S(x) + T(x), \quad (\lambda T)(x) = \lambda T(x).$$

这分别称为映射的加法 (Addition of Maps) 与映射的数乘 (Scalar Multiplication of a Map)。

两种运算的结果仍然线性。例如，把 $u + v$ 代入和映射，利用 S, T 的可加性，将四个输出重新分组，就得到

$$(S + T)(u + v) = (S + T)(u) + (S + T)(v).$$

数乘性质同理； λT 的两条线性性质也直接来自输出向量的运算法则。

设 $A = M(S)$, $B = M(T)$ 。根据“第 k 列记录第 k 个基向量的像”，和映射的第 k 列必为

$$(S + T)(e_k) = S(e_k) + T(e_k) = a_k + b_k.$$

把这件事在每一列上重复一次，便自然得到如下数表规则。

定义 3.9 (矩阵的加法与数乘)

同为 $m \times n$ 的矩阵 A, B 可以相加，矩阵加法 (Matrix Addition) 按对应位置进行；矩阵数乘 (Matrix Scalar Multiplication) 把每个元素乘同一个数：

$$(A + B)_{j,k} = A_{j,k} + B_{j,k}, \quad (\lambda A)_{j,k} = \lambda A_{j,k}.$$

因此 $M(S + T) = M(S) + M(T)$, $M(\lambda T) = \lambda M(T)$ 。

同型才能相加。这并非单纯为了让格子对齐：两个映射只有面对相同的输入空间、输出到相同的目标空间，才能把对应输出相加。

例题 3.10 (同一位置, 合并同类贡献)

取 $A = \begin{bmatrix} 1 & -2 \\ 3 & 0 \end{bmatrix}$, $B = \begin{bmatrix} 2 & 1 \\ -1 & 4 \end{bmatrix}$, 则

$$A + B = \begin{bmatrix} 1+2 & -2+1 \\ 3-1 & 0+4 \end{bmatrix} = \begin{bmatrix} 3 & -1 \\ 2 & 4 \end{bmatrix}, \quad 2A = \begin{bmatrix} 2 & -4 \\ 6 & 0 \end{bmatrix}.$$

负矩阵 $-B$ 把 B 的元素逐一变号, 于是

$$A - B = A + (-B) = \begin{bmatrix} -1 & -3 \\ 4 & -4 \end{bmatrix}.$$

把所有输入都送到零向量的映射, 对应零矩阵 (Zero Matrix), 记作 $0_{m \times n}$ 或简写为 0 。把 T 的每个输出取相反向量, 对应负矩阵 (Negative Matrix) $-A$ 。由映射的逐点运算, 立即得到下列性质。

性质 3.11 (矩阵线性运算的法则)

对同型矩阵 A, B, C 与实数 λ, μ , 有

$$A + B = B + A, \quad (A + B) + C = A + (B + C),$$

$$A + 0 = A, \quad A + (-A) = 0,$$

$$\lambda(A + B) = \lambda A + \lambda B, \quad (\lambda + \mu)A = \lambda A + \mu A,$$

$$\lambda(\mu A) = (\lambda\mu)A, \quad 1A = A.$$

例如, 矩阵加法的交换律来自 $S(x) + T(x) = T(x) + S(x)$; 两个和映射对每个输入的结果一致, 其表示矩阵就一致。其余性质也有同样的来源。

例题 3.12 (叠加两个缩放映射)

设 $S((x, y)^T) = (2x, y)^T$, $T((x, y)^T) = (x, 3y)^T$ 。它们分别沿横向、纵向拉伸, 矩阵为

$$A = \begin{bmatrix} 2 & 0 \\ 0 & 1 \end{bmatrix}, \quad B = \begin{bmatrix} 1 & 0 \\ 0 & 3 \end{bmatrix}.$$

和映射把同一个输入的两个输出相加:

$$(S + T)((x, y)^T) = (3x, 4y)^T, \quad A + B = \begin{bmatrix} 3 & 0 \\ 0 & 4 \end{bmatrix}.$$




图 3.7: 映射的加法对应矩阵的加法。左图以输入 $x = (1, 1)^T$ 为例，两个输出按平行四边形法则相加；右图记录相应矩阵。

读图说明：和映射得到 $(3, 4)^T$ ，不是“先横向伸长再纵向伸长”得到的 $(2, 3)^T$ 。叠加输出与先后作用是两种不同的运算。

矩阵的线性运算并不是任意规定的数字规则，而是映射的逐点加法与数乘落在各个基的像上。加法与数乘解决了输出的叠加；如果让一次映射的输出成为下一次映射的输入，又会得到什么？这便引出了映射的复合，以及矩阵的乘法。

3.3 矩阵乘法：映射的复合

本节采用“元素、列、行、外积”四种互相对应的读图方式。图解思路参考平锅健儿整理、Gilbert Strang 协助的图解笔记 [23]；下面所有数表与图示统一使用本讲义的算例。

在计算程序中，一份数据往往要先经过一次处理，再进入下一次处理。线性映射也可以这样连接：先做 T ，再做 S ，把结果写为

$$(S \circ T)(x) = S(T(x)).$$

这称为映射的复合 (Composition)。顺序必须读清：写在右边的 T 先作用。若 $T: \mathbb{R}^n \rightarrow \mathbb{R}^p$ ， $S: \mathbb{R}^p \rightarrow \mathbb{R}^m$ ，则它们能够衔接，复合映射从 $\mathbb{R}^n$ 到 $\mathbb{R}^m$ 。由于两次作用都保持线性组合，复合后仍保持线性组合。




图 3.8: 先经过 T ，再经过 S ，对应先用 B ，再用 A ，整个映射记为乘积 AB 。相邻的输入、输出维数必须一致。

读图说明：中间空间 $\mathbb{R}^p$ 既是第一次作用的目标空间，也是第二次作用的定义域。因此乘积的中间两个尺寸相等，而最终矩阵的大小为 $m \times n$ 。

追踪一个基向量，导出行乘列

设 $B = M(T)$ ， $A = M(S)$ 。用 e_k 表示输入空间的第 k 个标准基向量，用 ε_ℓ 表示中间空间的第 ℓ 个标准基向量。第 3.1 节告诉我们

$$T(e_k) = \sum_{\ell=1}^p B_{\ell,k} \varepsilon_\ell.$$

再施加 S 。由线性性，原来的组合系数 $B_{\ell,k}$ 保持不变：

$$(S \circ T)(e_k) = S\left(\sum_{\ell=1}^p B_{\ell,k} \varepsilon_\ell\right) = \sum_{\ell=1}^p B_{\ell,k} S(\varepsilon_\ell).$$

$S(\varepsilon_\ell)$ 是 A 的第 ℓ 列，其第 j 个分量为 $A_{j,\ell}$ 。所以最终输出的第 j 个分量是

$$A_{j,1}B_{1,k} + A_{j,2}B_{2,k} + \cdots + A_{j,p}B_{p,k}.$$

它恰好是 A 的第 j 行与 B 的第 k 列，对应元素相乘后相加。**矩阵乘法为什么是行乘列？不是任意约定，而是线性映射复合的必然结果。**

定义 3.13 (矩阵乘法)

若 A 为 $m \times p$ 矩阵， B 为 $p \times n$ 矩阵，则矩阵乘法 (Matrix Multiplication) AB 为 $m \times n$ 矩阵，其中

$$(AB)_{j,k} = \sum_{\ell=1}^p A_{j,\ell} B_{\ell,k}.$$

在标准基下， $M(S \circ T) = M(S)M(T)$ 。

第 2 章使用的 Ax 现在也有了正式的乘法含义：把 x 看成一列，所得结果仍然是以 $x_1, \dots, x_n$ 为系数对 A 的各列作线性组合，含义与此前完全一致。

$$\begin{array}{c} A \\ \begin{bmatrix} 1 & 2 \\ 0 & -1 \\ 3 & 1 \end{bmatrix} \end{array} \times \begin{array}{c} B \\ \begin{bmatrix} 1 & 0 & 2 & -1 \\ 2 & 1 & 0 & 3 \end{bmatrix} \end{array} = \begin{array}{c} AB \\ \begin{bmatrix} 5 & 2 & 2 & 5 \\ -2 & -1 & 0 & -3 \\ 5 & 1 & 6 & 0 \end{bmatrix} \end{array}$$

$$[3 \quad 1] \begin{bmatrix} -1 \\ 3 \end{bmatrix} = 3(-1) + 1(3) = 0$$

图 3.9: 看一个元素：一行与一列相遇，确定结果中的一个位置。

读图说明：玫红色是左矩阵的第 3 行，蓝色是右矩阵的第 4 列；绿色格子因此位于乘积的第 3 行、第 4 列。

例题 3.14 (三行两列乘两行四列)

取

$$A = \begin{bmatrix} 1 & 2 \\ 0 & -1 \\ 3 & 1 \end{bmatrix}, \quad B = \begin{bmatrix} 1 & 0 & 2 & -1 \\ 2 & 1 & 0 & 3 \end{bmatrix}.$$

中间尺寸都是 2，因此 AB 存在，大小为 3×4 。逐行乘列，有

$$AB = \begin{bmatrix} 1 \cdot 1 + 2 \cdot 2 & 1 \cdot 0 + 2 \cdot 1 & 1 \cdot 2 + 2 \cdot 0 & 1 \cdot (-1) + 2 \cdot 3 \\ 0 \cdot 1 - 1 \cdot 2 & 0 \cdot 0 - 1 \cdot 1 & 0 \cdot 2 - 1 \cdot 0 & 0 \cdot (-1) - 1 \cdot 3 \\ 3 \cdot 1 + 1 \cdot 2 & 3 \cdot 0 + 1 \cdot 1 & 3 \cdot 2 + 1 \cdot 0 & 3 \cdot (-1) + 1 \cdot 3 \end{bmatrix}.$$

整理为

$$AB = \begin{bmatrix} 5 & 2 & 2 & 5 \\ -2 & -1 & 0 & -3 \\ 5 & 1 & 6 & 0 \end{bmatrix}.$$

例如 $(AB)_{3,4} = 3 \cdot (-1) + 1 \cdot 3 = 0$ 。本例的 BA 无法相乘，因为其相邻尺寸为 4 与 3，并不匹配。

一列一列看，一行一行看

将 B 写成列向量的排列 $B = [b_1 \cdots b_n]$ 。由刚才的基向量推导，

$$AB = [Ab_1 \cdots Ab_n].$$

乘积的第 k 列，是 A 作用于 B 的第 k 列所得的结果，也就是 A 各列以 $B_{1,k}, \dots, B_{p,k}$ 为系数的线性组合。这其实就是第 1 章的向量线性组合，现在换成了矩阵的语言。例如上例的第 1 列为

$$1(1, 0, 3)^T + 2(2, -1, 1)^T = (5, -2, 5)^T.$$

$$\begin{array}{c} A \\ \begin{bmatrix} 1 & 2 \\ 0 & -1 \\ 3 & 1 \end{bmatrix} \end{array} \times \begin{array}{c} B \\ \begin{bmatrix} 1 & 0 & 2 & -1 \\ 2 & 1 & 0 & 3 \end{bmatrix} \end{array} = \begin{array}{c} AB \\ \begin{bmatrix} 5 & 2 & 2 & 5 \\ -2 & -1 & 0 & -3 \\ 5 & 1 & 6 & 0 \end{bmatrix} \end{array}$$

$$1a_1 + 2a_2 = \begin{bmatrix} 5 \\ -2 \\ 5 \end{bmatrix}$$

图 3.10: 看一整列: 右矩阵的一列给出系数, 左矩阵的各列参与组合。

读图说明: 本图只追踪第 1 列。把右矩阵的 4 列分别代入同一个映射, 就会一次得到乘积的 4 列。

从行的方向看, 设 B 的各行为 $\beta_1^T, \dots, \beta_p^T$, 则 AB 的第 j 行为

$$A_{j,1}\beta_1^T + \dots + A_{j,p}\beta_p^T.$$

即乘积的第 j 行, 是 B 各行以 A 的第 j 行元素为系数的线性组合。例如上例的第 2 行是 0 倍第 1 行加 -1 倍第 2 行, 得到 $(-2, -1, 0, -3)$ 。这两个视角分别解释了右侧系数怎样组织列、左侧系数怎样组织行。

$$\begin{array}{c} A \\ \begin{bmatrix} 1 & 2 \\ 0 & -1 \\ 3 & 1 \end{bmatrix} \end{array} \times \begin{array}{c} B \\ \begin{bmatrix} 1 & 0 & 2 & -1 \\ 2 & 1 & 0 & 3 \end{bmatrix} \end{array} = \begin{array}{c} AB \\ \begin{bmatrix} 5 & 2 & 2 & 5 \\ -2 & -1 & 0 & -3 \\ 5 & 1 & 6 & 0 \end{bmatrix} \end{array}$$

$$3[1 \ 0 \ 2 \ -1] + [2 \ 1 \ 0 \ 3] = [5 \ 1 \ 6 \ 0]$$

图 3.11: 看一整行: 左矩阵的一行给出系数, 右矩阵的各行参与组合。

读图说明: 追踪第 3 行: 3 倍蓝色行加 1 倍玫红色行, 得到绿色结果行。行视角与列视角使用完全相同的数值。

列乘行: 两个向量怎样生成一张矩阵

还有一种与“行乘列”相反的观察方式。先让输入 $x \in \mathbb{R}^n$ 经由一个行向量, 变成一个数 $t = v^T x$; 再把这个数作为倍数, 输出 $tu \in \mathbb{R}^m$ 。这仍是两个线性映射的复合, 其矩阵自然是

$$\underbrace{u}_{m \times 1} \underbrace{v^T}_{1 \times n} = \begin{bmatrix} u_1 v_1 & \cdots & u_1 v_n \\ \vdots & & \vdots \\ u_m v_1 & \cdots & u_m v_n \end{bmatrix}.$$

这种列向量乘行向量称为外积 (Outer Product)。它输出一张 $m \times n$ 数表, 而不是一个数。第 j 列是 $v_j u$, 第 i 行是 $u_i v^T$: 同一对向量, 同时组织了所有行与所有列。

例题 3.15 (一个方向，生成整张数表)

取 $\mathbf{u} = (1, 2, 3)^T$ 、 $\mathbf{v} = (2, -1)^T$ ，则

$$\mathbf{u}\mathbf{v}^T = \begin{bmatrix} 1 \\ 2 \\ 3 \end{bmatrix} \begin{bmatrix} 2 & -1 \end{bmatrix} = \begin{bmatrix} 2 & -1 \\ 4 & -2 \\ 6 & -3 \end{bmatrix}.$$

它把 $(x_1, x_2)^T$ 送到 $(2x_1 - x_2)\mathbf{u}$ 。无论怎样输入，输出都沿着 $\mathbf{u}$ 所在的直线。因此当两个向量均非零时，外积是秩一矩阵 (Rank-One Matrix)；若其中一个为零向量，所得矩阵的秩为 0。

$$\begin{array}{c} \mathbf{u} \\ \begin{bmatrix} 1 \\ 2 \\ 3 \end{bmatrix} \end{array} \times \begin{array}{c} \mathbf{v}^T \\ \begin{bmatrix} 2 & -1 \end{bmatrix} \end{array} = \begin{array}{c} \mathbf{u}\mathbf{v}^T \\ \begin{bmatrix} 2 & -1 \\ 4 & -2 \\ 6 & -3 \end{bmatrix} \end{array} \quad \begin{array}{l} \text{第 1 列} = 2\mathbf{u} \\ \text{第 2 列} = -\mathbf{u} \end{array}$$

$$(3 \times 1)(1 \times 2) = 3 \times 2$$

图 3.12: 列向量铺成列，行向量给出每一列的倍数。

读图说明：蓝色的竖条与玫红色的横条相乘，生成整块矩形数表；图中的每个格子都是对应两个分量的乘积。

注意：“向量乘向量”必须说明摆放方式。长度均为 n 时，行乘列 $\mathbf{u}^T\mathbf{v}$ 得到 1×1 的数；列乘行 $\mathbf{u}\mathbf{v}^T$ 得到 $n \times n$ 的矩阵。两个列向量不能直接按矩阵乘法相乘。这里的外积也不是三维向量的叉乘。

一整块地看：矩阵乘法是外积之和

把中间空间的各个坐标通道分开。第 ℓ 个通道先用 B 的第 ℓ 行产生一个数，再用 A 的第 ℓ 列产生输出方向。将所有通道的输出相加，得到

$$AB = \sum_{\ell=1}^p \mathbf{a}_\ell \mathbf{\beta}_\ell^T.$$

这与行乘列不是两种不同的乘法，只是组织同一批乘加的不同方式。行乘列一次看一个格子；列乘行一次生成整张数表，然后把这数表相加。

$$\begin{array}{c} a_1 \beta_1^T \\ \begin{bmatrix} 1 & 0 & 2 & -1 \\ 0 & 0 & 0 & 0 \\ 3 & 0 & 6 & -3 \end{bmatrix} \end{array} + \begin{array}{c} a_2 \beta_2^T \\ \begin{bmatrix} 4 & 2 & 0 & 6 \\ -2 & -1 & 0 & -3 \\ 2 & 1 & 0 & 3 \end{bmatrix} \end{array} = \begin{array}{c} AB \\ \begin{bmatrix} 5 & 2 & 2 & 5 \\ -2 & -1 & 0 & -3 \\ 5 & 1 & 6 & 0 \end{bmatrix} \end{array}$$

每一块均为 3×4 ；对应位置相加

图 3.13: 同一个乘积的第四个视角：两张外积数表叠加为 AB 。

读图说明：中间尺寸为 2，所以这里有两个通道、两张数表。第一个通道对应左矩阵第 1 列与右矩阵第 1 行，第二个通道同理。

工程小景：一组灯带，不同时刻

例如，控制三条 LED 灯带，让它们按同一时间曲线明暗变化，但各自亮度比例为 $1, \frac{1}{2}, \frac{1}{4}$ 。在不考虑饱和、量化与器件非线性的教学模型中，取四个时刻的驱动强度为 $(0, 1, 2, 1)$ 。全部亮度便由一个外积生成：

$$D = \begin{bmatrix} 1 \\ 1/2 \\ 1/4 \end{bmatrix} [0 \quad 1 \quad 2 \quad 1].$$

一列记录一个时刻的三条灯带，一行记录一条灯带的时间变化。只需保存 3 个比例和 4 个时刻值，就能生成 12 个亮度数值；关键是这些数值原本共享同一种变化模式。

	t_1	t_2	t_3	t_4	
灯带 1	0	1	2	1	纵向：灯带的固定比例 横向：共同的时间曲线
灯带 2	0	0.5	1	0.5	
灯带 3	0	0.25	0.5	0.25	

图 3.14: 外积生成一张“灯带—时刻”亮度图。

读图说明：颜色越深表示教学模型中的亮度数值越大。所有行成比例，因而这张表只有一个独立变化模式。

顺序不能交换，分组可以改变


例题 3.16 (先旋转后缩放，与先缩放后旋转)

设 $R = \begin{bmatrix} 0 & -1 \\ 1 & 0 \end{bmatrix}$ 表示逆时针旋转 90° ， $D = \begin{bmatrix} 2 & 0 \\ 0 & 1 \end{bmatrix}$ 表示横向伸长为两倍。直接计算，

$$DR = \begin{bmatrix} 0 & -2 \\ 1 & 0 \end{bmatrix}, \quad RD = \begin{bmatrix} 0 & -1 \\ 2 & 0 \end{bmatrix}.$$

对于 $e_1 = (1, 0)^T$ ，先旋转后缩放得到 $DR e_1 = (0, 1)^T$ ；先缩放后旋转得到 $RD e_1 = (0, 2)^T$ 。两者不同，所以 $DR \neq RD$ 。

先旋转，再横向缩放



先横向缩放，再旋转




图 3.15: 交换复合的先后次序，会改变结果。两条路线从同一个输入出发，最终的纵向长度不同。

读图说明：左图旋转后已沿纵轴，横向缩放不再改变它；右图先把长度变为 2，再旋转到纵轴。虚线弧箭头只表示作用的先后，不表示额外的向量。

注意：矩阵乘法一般不满足交换律。即使 AB 、 BA 都有意义，也不能互换；即使某一对矩阵恰好可交换，也不能把它推广到任意矩阵。

性质 3.17 (乘法的基本运算律)

只要各项尺寸匹配，就有

$$(AB)C = A(BC), \quad A(B + C) = AB + AC, \quad (A + B)C = AC + BC,$$

以及 $\lambda(AB) = (\lambda A)B = A(\lambda B)$ 。

证明：复合三个映射时，无论把前两次还是后两次先合成一组，对每个输入而言都是“先第三个、再第二个、最后第一个”，结果不变。因此映射复合具有结合性，它的矩阵表示也满足结合律。分配律则来自线性映射保持输出的加法；数乘的关系同理。 ■

用一个小例子核对：取 $P = \begin{bmatrix} 1 & 1 \\ 0 & 1 \end{bmatrix}$, $Q = \begin{bmatrix} 2 & 0 \\ 0 & 1 \end{bmatrix}$, $C = \begin{bmatrix} 1 & 0 \\ 1 & 1 \end{bmatrix}$, 则

$$(PQ)C = \begin{bmatrix} 2 & 1 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} 1 & 0 \\ 1 & 1 \end{bmatrix} = \begin{bmatrix} 3 & 1 \\ 1 & 1 \end{bmatrix}, \quad P(QC) = \begin{bmatrix} 1 & 1 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} 2 & 0 \\ 1 & 1 \end{bmatrix} = \begin{bmatrix} 3 & 1 \\ 1 & 1 \end{bmatrix}.$$

例子只用于核对规则；一般结论来自上面的复合解释。

把每个向量原样输出的恒等映射 (Identity Map) $I(\mathbf{x}) = \mathbf{x}$, 保持每个标准基向量不变。因此它对应的单位矩阵 (Identity Matrix) 为

$$E_n = \begin{bmatrix} 1 & 0 & \cdots & 0 \\ 0 & 1 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & 1 \end{bmatrix}.$$

矩阵中行、列下标相等的位置构成主对角线 (Main Diagonal), 单位矩阵就在这些位置上取 1, 其余位置取 0。若 A 为 $m \times n$, 则 $E_m A = A = A E_n$ 。下标在尺寸明确时可省略。行数与列数相同的矩阵称为方阵 (Square Matrix); $n \times n$ 方阵称为 n 阶方阵。

对方阵还可以反复复合其映射, 得到矩阵的幂 (Matrix Power) $A^q = \underbrace{A \cdots A}_{q \uparrow}$, 其中 q 为正整数, 并约定 $A^0 = E$ 。结合律保证对非负整数 p, q 有 $A^p A^q = A^{p+q}$ 。但展开 $(A+B)^2$ 必须保留顺序:

$$(A+B)^2 = A^2 + AB + BA + B^2,$$

只有 $AB = BA$ 时才可把中间两项合为 $2AB$ 。

注意: 非零矩阵的乘积也可能是零矩阵。例如 $\text{diag}(1,0) \text{diag}(0,1) = 0$; 这里 $\text{diag}(a,b)$ 简记 $\begin{bmatrix} a & 0 \\ 0 & b \end{bmatrix}$ 。因此 $AB = AC$ 不能直接约去 A 。何时可以“撤销”左侧的作用, 需要下一节的逆映射。

矩阵乘法把先后进行的线性处理合成一次运算, 也把“能否恢复输入”的问题提到了面前。既然矩阵能够描述一个映射, 那么什么时候还能用另一个矩阵把它的作用完全撤销?

3.4 逆矩阵：逆映射

先回想熟悉的函数：在指定的定义域与目标集合之间，一一对应的函数才有反函数 (Inverse Function)。例如， $y = 2x$ 的反函数是 $y = \frac{1}{2}x$ ，它撤销“乘 2”，把输出还原为输入；两个方向的复合都等于恒等映射。

线性映射是向量空间之间的函数。若它既是单射又是满射，即双射，也有这样的逆映射。与反函数一样，逆映射关心的是能否唯一找回输入。一维数乘对应矩阵 [2]，其逆为 $[\frac{1}{2}]$ ；二维逆时针旋转 θ 的逆，则是顺时针旋转 θ 。下面把这种往返关系写成准确的定义。




图 3.16: 从反函数到逆映射：原作用与撤销作用复合，都回到出发点。

读图说明：上图作用于数，下图作用于向量；往返关系的前提都是指定两端集合之间的双射。




图 3.17: 一维伸缩与二维旋转：反向作用恢复原来的输入。

读图说明：右图以 R_θ 表示逆时针旋转 θ 的矩阵；蓝弧表示正向作用，红弧表示撤销作用。恢复后的向量与红色原向量重合。

旋转之后可以反向旋转，非零倍伸缩之后可以按倒数伸缩；但把三维向量投影到平面后，单凭输出无法知道原来的第三个分量。能否撤销一个映射，取决于输出是否保留了区分输入所需的信息，以及指定的目标是否都能达到。

若不同输入总有不同输出，映射称为单射 (Injection)；若目标空间中的每个向量都能得到，映射称为满射 (Surjection)。两者同时成立称为双射 (Bijection)。满足 $T(x) = y$

的输入 x ，称为 y 的一个原像 (Preimage)。对双射，每个输出都能反查到唯一的输入，这个反查规则就是逆映射 (Inverse Map)，记作 T^{-1} 。

对双射线性映射，逆映射也线性。事实上，若 $u = T(x)$ 、 $v = T(y)$ ，则

$$T(kx + ly) = ku + lv.$$

因为原像唯一， $T^{-1}(ku + lv) = kx + ly$ 。由第 3.1 节，逆映射仍可用矩阵表示。两次相反作用都回到原向量，于是两个方向的复合都应对应单位矩阵。

定义 3.18 (逆矩阵)

设 A 为 n 阶方阵。若存在 n 阶矩阵 B 使

$$AB = BA = E_n,$$

则称 A 为可逆矩阵 (Invertible Matrix)， B 为 A 的逆矩阵 (Inverse Matrix)，记为 A^{-1} 。不存在逆矩阵的方阵称为奇异矩阵 (Singular Matrix)。

在本书的双侧逆意义下，只有方阵可能可逆。原因仍在映射：双射把输入的一组基送到目标空间的一组基。像向量既能表示全部目标，又没有多余向量，因此两端维数相同。这里没有使用行列式。

定理 3.19 (逆矩阵的基本性质)

若 A, B 为同阶可逆方阵，则逆矩阵唯一，且

$$(A^{-1})^{-1} = A, \quad (AB)^{-1} = B^{-1}A^{-1}.$$

若 $\lambda \neq 0$ ，则 $(\lambda A)^{-1} = \lambda^{-1}A^{-1}$ 。

证明：唯一性来自逆映射对每个输出只能指定一个输入；代数上，若 B, C 都是 A 的逆，则 $B = B(AC) = (BA)C = C$ 。

乘积 AB 先做 B 再做 A 。恢复时，先撤销最后做的 A ，再撤销 B ，所以逆矩阵的顺序反过来。核对两个方向：

$$(AB)(B^{-1}A^{-1}) = A(BB^{-1})A^{-1} = E,$$

$$(B^{-1}A^{-1})(AB) = B^{-1}(A^{-1}A)B = E.$$

对逆再取逆恢复原作用；非零数乘用倒数撤销，即得其余结论。 ■

注意：求乘积的逆，务必先反序，再分别求逆： $(AB)^{-1} = B^{-1}A^{-1}$ 。如果 A 可逆， $AB = AC$ 才能通过左乘 A^{-1} 推出 $B = C$ ；右侧的消去也必须从右侧乘相应的逆。

例题 3.20 (求逆, 就是寻找各个标准基向量的原像)

设 $A = \begin{bmatrix} 2 & 1 \\ 1 & 1 \end{bmatrix}$, 求 A^{-1} 。为了确定逆映射的第 1 列, 先求哪个向量被 A 送到 e_1 :

$$\begin{cases} 2u + v = 1, \\ u + v = 0, \end{cases} \implies (u, v) = (1, -1).$$

同样, 求第 2 列时解

$$\begin{cases} 2u + v = 0, \\ u + v = 1, \end{cases} \implies (u, v) = (-1, 2).$$

把两个原像按列记录, 得到候选矩阵 $B = \begin{bmatrix} 1 & -1 \\ -1 & 2 \end{bmatrix}$ 。核对可得

$$AB = \begin{bmatrix} 2-1 & -2+2 \\ 1-1 & -1+2 \end{bmatrix} = E_2, \quad BA = \begin{bmatrix} 2-1 & 1-1 \\ -2+2 & -1+2 \end{bmatrix} = E_2.$$

因此 $A^{-1} = B$ 。

对一般二阶矩阵, 依照同样的方法求两个标准基向量的原像, 可得常用计算式:

$$A = \begin{bmatrix} a & b \\ c & d \end{bmatrix}, \quad ad - bc \neq 0 \implies A^{-1} = \frac{1}{ad - bc} \begin{bmatrix} d & -b \\ -c & a \end{bmatrix}.$$

这里 $ad - bc$ 只是消元中出现的一个数。若它为零, 两列线性相关, 映射不能为每个输出提供唯一输入, 所以没有双侧逆; 其行列式解释留到第 6 章。

例题 3.21 (反向旋转恢复输入)

设 $A = \begin{bmatrix} \cos \theta & -\sin \theta \\ \sin \theta & \cos \theta \end{bmatrix}$, 它对应逆时针旋转 θ 。逆映射为旋转 $-\theta$, 故

$$A^{-1} = \begin{bmatrix} \cos \theta & \sin \theta \\ -\sin \theta & \cos \theta \end{bmatrix}.$$

由 $\cos^2 \theta + \sin^2 \theta = 1$, 两个方向的乘积均为 E_2 。




图 3.18: 逆映射把变换后的向量送回原向量。两幅图使用相同坐标尺度, 左图逆时针转动, 右图沿相反方向恢复。

读图说明: 逆矩阵描述的是撤销整个映射的规则, 不是把原矩阵的每个元素分别取倒数。旋转矩阵的逆还恰好等于它的转置, 这一点将在下一节的转置语言中再次出现。

定理 3.22 (方阵可逆与方程组的唯一解)

对 n 阶方阵 A , 下列说法等价: A 可逆; 映射 $T(x) = Ax$ 是双射; 对每个 $b \in \mathbb{R}^n$, 方程 $Ax = b$ 有唯一解。此时

$$x = A^{-1}b.$$

每个目标都能达到, 对应满射; 每个目标只对应一个输入, 对应单射。因此这正是第2章“存在性与唯一性”的映射解释。结合第2章的结论, 也可把可逆性识别为: A 的每一列都有主元, 或 A 能由行变换化为 E_n 。系统的行变换求逆方法将在第3.6节给出。

注意: 上述结论要带上“方阵”及“对每个右端项”的条件。一个非方阵方程组对某个给定右端项有唯一解, 并不意味着该矩阵有双侧逆。

逆矩阵用于表达撤销作用的理论关系; 实际求解大型方程组时, 通常直接消元或使用分解, 不必先把整个逆矩阵算出来。下一节先整理两种重要的数表工具: 转置怎样交换输入、输出的系数角色, 分块怎样组织大型映射的计算。

3.5 转置与分块矩阵

矩阵记录了输入分量怎样影响输出分量。有时我们需要换一个方向整理这些系数: 从“每个输入造成什么输出”, 改看“某种输出汇总依赖哪些输入”。有时我们需要把许多输入、输出分成若干组。转置与分块分别解决这两种组织问题。

3.5.1 矩阵的转置

第2章的推荐案例，把每条视频写成“搞笑、科技、美食、游戏”四维特征向量，再按列排成矩阵 A 。输入视频权重 x ，便得到特征得分 $b = Ax$ ；当时的问题是反求一份能产生指定偏好的内容配方。第3.1节又把这件事解释为线性映射：输入的线性组合，决定基向量的像怎样组合成输出。

现在平台还想解释这份配方的评分。给四项输出特征一组评价权重 y ，总评分为 $y \cdot b$ 。能否把评分折算到视频一侧，得到每条视频的单位贡献分 d ，使 $d \cdot x$ 给出同一总分？这一次要传回来的，是评价的系数。例如，沿用三条视频的教学模型，取配方 $(0.35, 0.65, 0)^T$ ，以 $(1, 2, 0, 1)^T$ 评价四项特征，三条视频的单位贡献分就是 $(1, 3, 2)^T$ ，总分为 2.30。第二条视频实际贡献 0.65×3 ；单位贡献分与曝光权重不能混为一谈。所有评分与权重仍是教学简化设定，不代表抖音的实际推荐规则。




图 3.19: 正向映射与反向折算。蓝色正向路径把视频权重组合成红色特征得分，橙色反向路径把特征评价折算为各视频的单位贡献分，两侧计算同一总评分。转置不是把输出还原成输入，而是评价的反向传递。

读图说明：上方传递状态，下方传递评价系数。 y 是另外选定的评分权重，并不是正向输出 b ；反向折算并不反求原来的配方。

线性泛函：给向量打分的尺子。“向量到数”的规则，其实并不陌生。读取 x 的第 j 个坐标，是一种测量；用固定权重对 b 做点积，是一种评分；在第1章的多项式空间中，读取多项式在固定位置 t_0 的取值，也是一种测量：

$$\rho_j(x) = x_j, \quad \varphi_y(b) = y \cdot b, \quad \varepsilon_{t_0}(p) = p(t_0). \quad (3.1)$$

三种规则都把一个向量送到一个数，而且保持加法与数乘。例如，先把两个多项式相加再取值，与分别取值再相加相同；把多项式同乘一个常数，取值也乘这个常数。这里 t_0 必须固定，评分的对象是整个多项式 p ，不是把 t_0 当作随意变化的输入。




图 3.20: 线性泛函是向量的线性评分器。左侧蓝色向量 $v = (2, 1)^T$, 经评分规则 $\varphi(v) = 2v_1 + v_2$, 得到右侧橙色数值 5; 尺子表示一种固定的线性测量。下方两条关系说明评分保持加法与数乘, 这为评价的反向传递提供了基础。

读图说明: 右侧输出是一个实数, 不是另一支向量。尺子固定以后, 只要改变输入, 便能读取相应的分数; 所有这样的线性尺子组成对偶空间。

定义 3.23 (线性泛函与对偶空间)

设 V 是实向量空间。若映射 $\varphi: V \rightarrow \mathbb{R}$ 对任意 $u, v \in V$ 与 $c \in \mathbb{R}$ 满足

$$\varphi(u + v) = \varphi(u) + \varphi(v), \quad \varphi(cv) = c\varphi(v), \quad (3.2)$$

就称 φ 为 V 上的一个线性泛函 (Linear Functional)。 V 上全体线性泛函组成的向量空间称为对偶空间 (Dual Space), 记作 V' 。

这里的“泛函”可以理解为**线性评分器**，“对偶空间”则是**所有线性测量尺子的集合**。尺子也能相加、数乘：对同一个对象把两把尺子的读数相加，或把一把尺子的读数同倍缩放，就得到新的尺子。相应运算为

$$(\varphi + \psi)(v) = \varphi(v) + \psi(v), \quad (c\varphi)(v) = c\varphi(v). \quad (3.3)$$

零评分器对所有向量都给出 0 分。这些规则沿用第 1 章的加法与数乘，因而全体线性评分器确实组成向量空间。

有限维情形下， $\dim V' = \dim V$ ： n 维空间恰好需要 n 把独立的坐标尺子。在 $\mathbb{R}^n$ 中，取 $\alpha_j(x) = x_j$ ，每个线性泛函都有唯一的表示

$$\psi = d_1\alpha_1 + \cdots + d_n\alpha_n \iff \psi(x) = d_1x_1 + \cdots + d_nx_n. \quad (3.4)$$

这里 d_j 是固定的评分系数， x_j 才是输入分量。把系数排成向量 d ，就得到

$$\psi(x) = d \cdot x, \quad d_j = \psi(e_j). \quad (3.5)$$

一把尺子在各标准基上的读数，便记录了它的全部规则。这又回到第 3.1 节的核心：线

性映射由基的像唯一决定。坐标尺子 $\alpha_1, \dots, \alpha_n$ 称为标准基的对偶基 (Dual Basis)；本节只用这组最熟悉的尺子，不展开一般对偶空间的理论。

对偶映射：让评价沿映射往回传。 给定正向映射 $T: V \rightarrow W$ ，假如输出端已经选定一把尺子 $\varphi \in W'$ ，那么不必另造输入端的评分器：把输入先送入 T ，再交给 φ 评分，就得到输入上的规则 $\varphi \circ T$ 。在推荐模型里，这正是“先生成内容特征，再计算综合评价”；同一规则也可以在输入端直接记成视频的贡献评分。

定义 3.24 (对偶映射)

设 $T: V \rightarrow W$ 为线性映射。它的对偶映射 (Dual Map) 是从 W' 到 V' 的映射 T' ，定义为

$$T': W' \rightarrow V', \quad T'(\varphi) = \varphi \circ T, \quad (T'(\varphi))(x) = \varphi(T(x)). \quad (3.6)$$

它把输出空间的评分器拉回为输入空间的评分器，箭头与 T 相反。

复合后的规则仍保持输入的法与数乘，所以确实属于 V' 。而对评分器本身作线性组合，也有

$$T'(c\varphi + d\psi) = cT'(\varphi) + dT'(\psi). \quad (3.7)$$

也就是说，先组合输出评分再传回，与分别传回再组合相同； T' 本身也是线性映射。它作用的对象是**评分规则**，不是原来的输出状态。这种反向结构不需要 T 可逆。




图 3.21: 正向映射与对偶映射的对应关系。上层 $T: V \rightarrow W$ 传递向量，下层 $T': W' \rightarrow V'$ 沿相反方向传递线性评分。用标准基及其对应的坐标尺子基记录这两种作用，所得矩阵分别为 A 与 A^T ；行列互换是对偶作用的坐标表现。

读图说明：上下两层的对象不同：上层是状态，下层是线性泛函。竖直虚线只标示同一侧的状态与评分空间的位置对应，不是额外的向量映射；下层反向箭头也不是 T^{-1} 。

从对偶映射，到转置矩阵。 以下取 $V = \mathbb{R}^n$ 、 $W = \mathbb{R}^m$ ， $T(x) = Ax$ 。输出评分器 φ_y 的

系数是 $\mathbf{y}$ ；拉回后的评分器 $T'(\varphi_{\mathbf{y}})$ 的系数记为 $\mathbf{d}$ 。由定义，

$$(T'(\varphi_{\mathbf{y}}))(\mathbf{x}) = \varphi_{\mathbf{y}}(A\mathbf{x}) = \mathbf{y} \cdot (A\mathbf{x}) = \mathbf{d} \cdot \mathbf{x}. \quad (3.8)$$

“评分反向传递”的抽象对应，就这样落成“评分系数反向换算”的矩阵作用。评分器与它的系数向量是两种对象，式 (3.5) 使我们在标准坐标下能够一一对应地记录它们。

定义 3.25 (矩阵的转置：对偶映射的坐标表示)

设 $T: \mathbb{R}^n \rightarrow \mathbb{R}^m$ 的标准基矩阵为 A 。对偶映射 T' 在这两组标准基所对应的对偶基下的矩阵，称为 A 的转置 (Transpose)，记作 A^T 。它由下式唯一确定：

$$\boxed{\mathbf{y} \cdot (A\mathbf{x}) = (A^T\mathbf{y}) \cdot \mathbf{x}}, \quad \mathbf{x} \in \mathbb{R}^n, \quad \mathbf{y} \in \mathbb{R}^m. \quad (3.9)$$

因此 $\mathbf{d} = A^T\mathbf{y}$ ：输出评分与拉回后的输入评分完全相同。

为什么这个矩阵表现为行列互换？依旧用第 3.1 节的方法，先看基的像，再按列记录。输出端的第 i 把坐标尺子 β_i 只读取第 i 个输出：

$$\beta_i(\mathbf{b}) = b_i, \quad (T'(\beta_i))(\mathbf{x}) = \beta_i(A\mathbf{x}) = \mathbf{r}_i \cdot \mathbf{x}, \quad (3.10)$$

其中 $\mathbf{r}_i$ 是 A 的第 i 行竖排后的向量。这表明，第 i 把输出尺子被拉回后，其坐标就是原矩阵第 i 行的系数。将这些基的像按列排列，便得到

$$A^T = [\mathbf{r}_1 \cdots \mathbf{r}_m], \quad (A^T)_{ij} = A_{ji}. \quad (3.11)$$

最后一个等式是坐标计算规则：把原矩阵的各行竖排成新矩阵的各列，尺寸由 $m \times n$ 变为 $n \times m$ 。它来自对偶基的像，不是先规定一个数字换位游戏，再赋予它含义。简言之，对偶映射是转置的本质，行列互换是标准坐标下的表现。

正向 A 按列组合输出；反向 A^T 的每一行，对评价权重作一次汇总，给出一条输入的单位贡献。推荐模型中， A^T 的一行对应一条视频，一列对应一项特征。把这两个角色认清，既能理解评价怎样传递，也能正确计算转置。

例题 3.26 (二阶矩阵：两侧评分相同)

取 $A = \begin{bmatrix} 1 & 2 \\ 3 & 4 \end{bmatrix}$, $\mathbf{x} = (1, 2)^T$, $\mathbf{y} = (2, -1)^T$ ，比较输出端与输入端的评分。

解 由对偶作用的坐标形式，

$$A^T = \begin{bmatrix} 1 & 3 \\ 2 & 4 \end{bmatrix}, \quad A\mathbf{x} = \begin{pmatrix} 5 \\ 11 \end{pmatrix}, \quad A^T\mathbf{y} = \begin{pmatrix} -1 \\ 0 \end{pmatrix}. \quad (3.12)$$

输出端的评分与输入端的评分分别为

$$\mathbf{y} \cdot (A\mathbf{x}) = 2 \times 5 - 11 = -1, \quad (A^T \mathbf{y}) \cdot \mathbf{x} = -1 \times 1 + 0 \times 2 = -1. \quad (3.13)$$

两边读数相同。 $\mathbf{x}$ 与 $A^T \mathbf{y}$ 却不是同一个向量：后者是评分系数，不是恢复出的输入。

例题 3.27 (三阶矩阵：仍是同一评价的两种算法)

$$\text{取 } B = \begin{bmatrix} 1 & 0 & 2 \\ -1 & 3 & 0 \\ 0 & 1 & 1 \end{bmatrix}, \quad \mathbf{u} = (1, 2, -1)^T, \quad \mathbf{v} = (2, -1, 1)^T.$$

解 把基的反向像按列记录，得到

$$B^T = \begin{bmatrix} 1 & -1 & 0 \\ 0 & 3 & 1 \\ 2 & 0 & 1 \end{bmatrix}, \quad B\mathbf{u} = \begin{pmatrix} -1 \\ 5 \\ 1 \end{pmatrix}, \quad B^T \mathbf{v} = \begin{pmatrix} 3 \\ -2 \\ 5 \end{pmatrix}. \quad (3.14)$$

于是

$$\mathbf{v} \cdot (B\mathbf{u}) = -2 - 5 + 1 = -6, \quad (B^T \mathbf{v}) \cdot \mathbf{u} = 3 - 4 - 5 = -6. \quad (3.15)$$

尺寸增加，评分逻辑没有改变。两个算例展示了本质定义与坐标规则的一致性；规则对任意尺寸成立的理由，是前面对基的反向像所作的推导，而不只是这两次数值检验。

注意：转置传回评价，逆映射还原输入，两者不能混淆。转置对任意矩阵都有定义；逆矩阵只对可逆方阵存在。即便 A 可逆，一般也没有 $A^T = A^{-1}$ 。

转置的工程视角：特征探测器与响应读数。同一个评分回传，还可以从“探测器”来理解。设 $A = [\mathbf{a}_1 \cdots \mathbf{a}_n]$ ，每一列都是一个固定的特征方向。正向 $A\mathbf{x}$ 用权重把这些方向组合成输出，像一个**组合器**；反向 $A^T \mathbf{y}$ 则把这些固定方向当作**特征探测器**，对待扫描向量 $\mathbf{y}$ 逐一读数。标准坐标下，评价系数也可以画成向量；第 i 个探测器读到的，正是它与 $\mathbf{y}$ 的点积：

$$A^T \mathbf{y} = \begin{bmatrix} \mathbf{a}_1 \cdot \mathbf{y} \\ \mathbf{a}_2 \cdot \mathbf{y} \\ \vdots \\ \mathbf{a}_n \cdot \mathbf{y} \end{bmatrix} = \begin{bmatrix} c_1 \\ c_2 \\ \vdots \\ c_n \end{bmatrix}, \quad c_i = \mathbf{a}_i \cdot \mathbf{y}. \quad (3.16)$$

所以转置乘向量得到的是一组**响应读数**：对每个视频特征方向，各读一次同一评价向量。


第 0 章的几何公式现在有了工程含义。若两个向量非零，夹角为 θ ，则

$$c_i = |\mathbf{a}_i| |\mathbf{y}| \cos \theta. \quad (3.17)$$

夹角为锐角时读数为正，越接近同向，同样长度下的响应越强；夹角为 90° 时读数为 0，探测器读不到这个方向的分量；夹角为钝角时读数为负，表示该方向上的响应与探测器相反。若探测器固定，读数同时反映待扫描向量的长度与方向；不同探测器的自身长度也会影响读数大小，不能只把它当作夹角评分。将非零探测器除以自身长度，取 $q_i = a_i/|a_i|$ ，才有

$$q_i \cdot y = |y| \cos \theta. \quad (3.18)$$

这是沿单位方向的有符号投影长度 (Scalar Projection)：同向一侧为正，反向一侧为负。这里仅借用高中的方向分量解释点积，不展开后面的投影理论；原始读数 c_i 还额外乘了探测器的长度。



非正交探测器：响应读数 $\neq$ 真实组合系数

图 3.22: 转置的探测器视角。左侧蓝色、红色特征方向分别为 $a_1 = (1, 0)^T$ 、 $a_2 = (1, 1)^T$ ，中间橙色待扫描向量为 $y = (2, 1)^T$ ，右侧柱状条记录点积响应 2 与 3。这个二维示意中， $y = a_1 + a_2$ 的组合系数是 1 与 1；探测器不正交，响应有串扰，读数不等于真实组合系数。

读图说明：每根色条是一个点积读数，条长按同一尺度绘制。两个探测器互有响应，因此不能把右侧的 2、3 直接送回组合器来还原 y ；向量在列空间内，也可能发生这种差别。

这里有一个重要区别：**读数不等于组合系数**。若列向量都是单位向量、两两垂直，并构成所讨论空间的一组基，那么每个探测器只响应自己的方向，读数才对该空间中的任意向量都恰好等于组合系数。一般情况下，各列可能相互响应，读数便出现“串扰”。例如图 3.22 中，待扫描向量由两列各取 1 份组成，第二个探测器还读到了第一列的贡献，得到的 2 与 3 都不能直接当作配方。即便列向量线性无关，“能够唯一组合”也不等于“原始读数就是系数”。

这些特征方向能够组合出的范围，就是各列的张成空间，称为列空间 (Column Space)，记作 $\text{Col}(A)$ 。若 $y \in \text{Col}(A)$ ，存在组合系数 x_0 使 $y = Ax_0$ 。原始读数于是满足

$$c = A^T y = A^T A x_0. \quad (3.19)$$

先组合，再扫描，就把探测器之间的相互响应叠加到了读数里； $A^T A$ 记录的正是这种重叠关系。这为第 5 章的最小二乘埋下伏笔：必须分清响应与系数，并处理探测器之间的重叠。如果 y 不在列空间里，读数照样存在，但没有配方能够精确还原它，后文将寻找

合适的近似；如果各列相关，即使目标可达，组合系数也可能不唯一，不能指望一次转置就消除全部自由度。这里先看清问题，不展开求解过程。

用对偶逻辑，读出转置的运算性质。先看两次转置。原向量 x 本身可以看作“读取评分器在 x 上的读数”的规则，即 $\psi \mapsto \psi(x)$ 。在有限维空间中，这种对应使原空间与对偶空间的自然一一对应。对偶两次之后，对任意输出评分器 φ 所读到的是

$$(T'(\varphi))(x) = \varphi(T(x)). \quad (3.20)$$

这正是原输出 $T(x)$ 的评分，因此在上述自然对应下，两次对偶回到原映射。写成标准坐标，就是把式 (3.9) 两侧的点积交换次序：

$$x \cdot (A^T y) = (Ax) \cdot y, \quad (A^T)^T = A. \quad (3.21)$$

还原的是**映射规则**。这里没有让同一个状态先乘 A 再乘 A^T ，更没有把后者当作前者的逆。

再看叠加。设 $S, T: V \rightarrow W$ ，把两个正向输出相加之后评分，与分别评分再相加相同。对任意 $\varphi \in W'$ ，

$$((S + T)'(\varphi))(x) = \varphi(S(x) + T(x)) = (S'(\varphi) + T'(\varphi))(x). \quad (3.22)$$

所以两个正向作用相加，它们的反向评价也相加。记录到同型矩阵的加法上，便得到

$$(A + B)^T = A^T + B^T. \quad (3.23)$$

正向输出整体缩放时，线性尺子的读数也同倍缩放：

$$((\lambda T)'(\varphi))(x) = \varphi(\lambda T(x)) = \lambda(T'(\varphi))(x), \quad (\lambda A)^T = \lambda A^T. \quad (3.24)$$

这两条法则来自评分器的线性，完全不需要检查各个元素的位置。

乘积的反序则来自评价传递的路线。设 $T: V \rightarrow U$ ， $S: U \rightarrow W$ ，矩阵分别为 B, A 。正向先做 B ，再做 A ；对最终输出的评价，必须先经过 S' 拉回中间空间，再经过 T' 拉回原输入空间。正向先穿袜子再穿鞋，撤销这两层作用时先脱鞋再脱袜子；评分的回传次序同样从最后一层开始。




图 3.23: 复合映射的评价, 按相反次序传回。蓝色路径先经 B 再经 A , 橙色路径先经 A^T 再经 B^T , 紫色框表示中间空间。下方袜子与鞋子的简笔图只帮助记忆顺序: 反序来自对偶映射的复合逻辑, 不是另行规定的符号规则。

读图说明: 实际回传的是评价系数, 而不是把数据依次倒放。尺寸也按路线匹配: 先把 m 维输出评价送回 p 维, 再送回 n 维。

对任意 $\varphi \in W'$, 由函数复合的结合律,

$$(S \circ T)'(\varphi) = \varphi \circ S \circ T = T'(S'(\varphi)). \quad (3.25)$$

因此 $(S \circ T)' = T' \circ S'$ 。用它在标准对偶基下的矩阵记录, 就得到

$$(AB)^T = B^T A^T. \quad (3.26)$$

式子的次序, 正是图 3.23 中评价所走的次序。我们推导的是整个评分规则, 而不是逐位核对数字。

性质 3.28 (转置的运算法则)

对维数匹配的矩阵及实数 λ ,

$$\begin{aligned} (A^T)^T &= A, & (A+B)^T &= A^T + B^T, \\ (\lambda A)^T &= \lambda A^T, & (AB)^T &= B^T A^T. \end{aligned} \quad (3.27)$$

若 A 可逆, 则 $(A^T)^{-1} = (A^{-1})^T$ 。

恒等映射不改变评分, 其对偶仍是恒等映射。因此, 对 $AA^{-1} = A^{-1}A = E$ 反向传递评价, 有

$$(A^{-1})^T A^T = A^T (A^{-1})^T = E. \quad (3.28)$$

这说明 $(A^{-1})^T$ 恰好是 A^T 的逆, 也解释了最后一条性质。

注意：乘积转置必须反序：先处理最后一层的评价，再处理前一层。一般不能写成 $(AB)^T = A^T B^T$ ；两次转置还原与矩阵互为逆也不是同一件事。

这些法则还保留了几类常用矩阵的清楚含义。各标准坐标方向独立伸缩，对应对角矩阵 (Diagonal Matrix) $\text{diag}(d_1, \dots, d_n)$ ；反向评分仍使用同样的倍数，所以它等于自身的转置。满足 $A^T = A$ 的方阵称为对称矩阵 (Symmetric Matrix)，满足 $A^T = -A$ 的方阵称为反对称矩阵 (Skew-Symmetric Matrix)。前者正向作用与反向评分采用同一规则，后者相差一个负号：

$$\begin{aligned} A^T = A &\iff \mathbf{y} \cdot (A\mathbf{x}) = \mathbf{x} \cdot (A\mathbf{y}), \\ A^T = -A &\iff \mathbf{y} \cdot (A\mathbf{x}) = -\mathbf{x} \cdot (A\mathbf{y}) \quad \text{对所有 } \mathbf{x}, \mathbf{y}. \end{aligned} \quad (3.29)$$

反对称情形取 $\mathbf{y} = \mathbf{x}$ ，得到 $\mathbf{x} \cdot (A\mathbf{x}) = 0$ ；再取标准基，便知主对角线元素都是 0。例如

$$\begin{bmatrix} 2 & -1 \\ -1 & 3 \end{bmatrix} \quad \text{是对称矩阵}, \quad \begin{bmatrix} 0 & -2 \\ 2 & 0 \end{bmatrix} \quad \text{是反对称矩阵}. \quad (3.30)$$

任意实方阵还可以分成对称与反对称两部分：

$$A = S + K, \quad S = \frac{A + A^T}{2}, \quad K = \frac{A - A^T}{2}, \quad S^T = S, \quad K^T = -K. \quad (3.31)$$

对两部分分别取转置，上面的线性运算法则就给出最后两个等式。这里仍是在拆分映射的作用方式。

四个基本子空间：状态与评价，各有两种方向。正向能产生哪些输出，反向能传回哪些评价？哪些输入会消失，哪些评分始终读不到正向输出？这四个问题自然引出四个基本子空间 (Four Fundamental Subspaces)。此处先认清它们的位置与作用，完整的维数、正交直和及解集理论留到第 5 章。

A 的列空间 $\text{Col}(A) \subseteq \mathbb{R}^m$ ，是各列张成的空间，也就是所有 $A\mathbf{x}$ 所成的可达输出范围。输出端有些评分器对这个范围中的每个向量都给出 0 分；由转置恒等式，它们的系数满足

$$\mathbf{y} \cdot (A\mathbf{x}) = 0 \text{ 对所有 } \mathbf{x} \iff A^T \mathbf{y} = \mathbf{0}. \quad (3.32)$$

这些**评分系数向量**组成左零空间 (Left Null Space) $\text{Null}(A^T) \subseteq \mathbb{R}^m$ 。严格地说，评分器属于输出对偶空间，系数属于 $\mathbb{R}^m$ ；通过标准坐标的对应，我们把它们画在同一侧。左零空间与列空间正交，表达的是“这组评价读不到任何可达输出”。例如，视频库中某两项特征总以固定比例出现，就有一把尺子检查这个恒成立的约束。

反向可达的贡献系数组成行空间 (Row Space)：

$$\text{Row}(A) = \{A^T \mathbf{y} : \mathbf{y} \in \mathbb{R}^m\} = \text{Col}(A^T) \subseteq \mathbb{R}^n, \quad \text{Row}(A^T) = \text{Col}(A). \quad (3.33)$$

它既由原矩阵的各行竖排后张成，也记录所有能从输出端拉回的输入评分。两把输出尺

子如果在列空间上的读数完全相同，拉回后的输入评分就相同：输入只能产生列空间里的向量，不会读到这两把尺子在其外的差别。所以，**列空间上的有效评分，与行空间中的贡献系数一一对应**。在这个意义下，行空间是列空间的对偶的一种坐标实现；两者不是字面上同一个集合，前者是输入侧的系数向量，后者是列空间上的评分规则。

输入端也有评分看不见的部分： $Ax = 0$ 的全部输入构成零空间 (Null Space) $\text{Null}(A) \subseteq \mathbb{R}^n$ 。这样的输入对每个输出评价都贡献 0 分，因此与每个拉回的行空间向量正交。在推荐场景中，某些权重置换恰好互相抵消，便属于这个零空间；输入变了，特征输出没有变。




图 3.24: 四个基本子空间的对偶视角。输入侧蓝色行空间与绿色零空间正交，输出侧红色列空间与土黄色左零空间正交，图中分区仅表示角色，不表示维数相等。 A 联系可起作用的输入与可达输出， A^T 联系输出评价与输入评分；两条虚线分别表示被对应映射消去的方向。

读图说明：两条实线联系行空间与列空间，但一般不互为逆映射。正交互补的完整结论还需结合维数，第 5 章将说明两侧怎样铺满各自的整个空间；此处的箭头只帮助辨认作用与评价的对应。

这张图把“状态怎样变化”与“评价怎样传递”放在一起。行空间与零空间位于输入侧，列空间与左零空间位于输出侧；对偶映射使两端的的关系可以沿同一条评分恒等式理解。第 4 章会研究零空间与值域，第 5 章再证明这两组空间的正交直和结构，并用它们解释解的存在性与自由度。本节先记住：**转置把输出评价拉回输入，矩阵的行列互换只是记录这件事的坐标形式**。

沿正向与对偶两个方向，同一组作用系数已有了两种读法。工程中还需要按设备、区域或功能把输入、输出分组；把整张矩阵分成若干块，能否继续沿映射的流向计算？这就是下面的分块矩阵所要回答的问题。

3.5.2 分块矩阵

大规模计算往往按子系统组织。例如结构模型中可以把不同构件的未知量分组，电路模型中可以把不同模块的输入分组。把输入写为 $x = (x_1^T, x_2^T)^T$ ，把输出也分成两组，

则一个线性映射可以记录为

$$\begin{cases} y_1 = A_{11}x_1 + A_{12}x_2, \\ y_2 = A_{21}x_1 + A_{22}x_2. \end{cases}$$

每个 A_{ij} 记录一组输入对一组输出的影响。将原矩阵按这些行、列边界划开，便得到分块矩阵 (Block Matrix)：

$$A = \left[\begin{array}{c|c} A_{11} & A_{12} \\ \hline A_{21} & A_{22} \end{array} \right].$$

这里 A_{ij} 表示一个子矩阵，与标量元素 $A_{j,k}$ 的逗号下标相区别。若输入两组大小为 n_1, n_2 ，输出两组大小为 m_1, m_2 ，则 A_{ij} 的大小为 $m_i \times n_j$ 。

输入组 x_1	输入组 x_2	
$A_{11} : m_1 \times n_1$	$A_{12} : m_1 \times n_2$	输出组 y_1
$A_{21} : m_2 \times n_1$	$A_{22} : m_2 \times n_2$	输出组 y_2

图 3.25: 按输入组与输出组划分矩阵。每一块对应一组输入到一组输出的线性作用；分块没有改变原来的映射。

读图说明：块可以大小不同。分块加法要求对应块同型；分块乘法则要求前一个映射的输出分组与后一个映射的输入分组相匹配。

映射叠加时，对应块直接相加；映射整体数乘时，每块同乘标量。映射复合时，把中间变量的表达式代入，即得

$$\begin{bmatrix} A_{11} & A_{12} \\ A_{21} & A_{22} \end{bmatrix} \begin{bmatrix} B_{11} & B_{12} \\ B_{21} & B_{22} \end{bmatrix} = \begin{bmatrix} A_{11}B_{11} + A_{12}B_{21} & A_{11}B_{12} + A_{12}B_{22} \\ A_{21}B_{11} + A_{22}B_{21} & A_{21}B_{12} + A_{22}B_{22} \end{bmatrix}.$$

例如第一组输出的第一组输入贡献，来自两条路径：经中间第 1 组的 $A_{11}B_{11}$ ，与经中间第 2 组的 $A_{12}B_{21}$ 。按路径相加，就得到左上块。

注意：分块乘法看起来像普通乘法，但每一个块乘积都必须有意义，相加的块还必须同型。仅仅“都是两行两列的块”并不够；相邻的分组尺寸必须一致，块内的乘法次序也不能交换。

例题 3.29 (让零块省去整组计算)

将输入分为前两项与后一项, 取

$$A = \left[\begin{array}{cc|c} 1 & 2 & 0 \\ 0 & 1 & 0 \\ \hline 0 & 0 & 3 \end{array} \right] = \begin{bmatrix} D & 0 \\ 0 & 3 \end{bmatrix}, \quad B = \left[\begin{array}{cc|c} 1 & 0 & 1 \\ 2 & 1 & 2 \\ \hline 0 & 1 & 4 \end{array} \right] = \begin{bmatrix} B_{11} & B_{12} \\ B_{21} & 4 \end{bmatrix},$$

其中 $D = \begin{bmatrix} 1 & 2 \\ 0 & 1 \end{bmatrix}$ 。直接按块计算,

$$DB_{11} = \begin{bmatrix} 5 & 2 \\ 2 & 1 \end{bmatrix}, \quad DB_{12} = \begin{pmatrix} 5 \\ 2 \end{pmatrix}, \quad 3B_{21} = [0 \quad 3], \quad 3 \cdot 4 = 12.$$

所以

$$AB = \left[\begin{array}{cc|c} 5 & 2 & 5 \\ 2 & 1 & 2 \\ \hline 0 & 3 & 12 \end{array} \right].$$

零块使跨组贡献整块消失, 不必逐个计算其中的零项。

若方阵只在主对角块上有非零块, 称为分块对角矩阵 (Block Diagonal Matrix); 若主对角块下方全为零, 称为分块上三角矩阵 (Block Upper Triangular Matrix)。在各对角块都是方阵时, 常用结论是

$$\begin{bmatrix} D_1 & 0 \\ 0 & D_2 \end{bmatrix} \text{可逆} \iff D_1, D_2 \text{都可逆}, \quad \begin{bmatrix} D_1 & 0 \\ 0 & D_2 \end{bmatrix}^{-1} = \begin{bmatrix} D_1^{-1} & 0 \\ 0 & D_2^{-1} \end{bmatrix}.$$

这是因为两组输入分别独立恢复。对上三角分块矩阵, 右上角还存在跨组作用, 逆矩阵中的这一块应当怎样求? 直接从逆矩阵的定义出发即可。

用四个待定分块推导逆矩阵。设 D_1 是 $p \times p$ 可逆矩阵, D_2 是 $q \times q$ 可逆矩阵, C 是 $p \times q$ 矩阵。记

$$K = \begin{bmatrix} D_1 & C \\ 0 & D_2 \end{bmatrix}, \quad B = \begin{bmatrix} B_1 & B_2 \\ B_3 & B_4 \end{bmatrix}.$$

我们要寻找满足 $KB = BK = E_{p+q}$ 的 B 。其中 B_1, B_2, B_3, B_4 的大小依次为 $p \times p, p \times q, q \times p, q \times q$ 。此时不预先假定 $B_3 = 0$, 而让方程把它确定出来。

先按定义要求 $KB = E_{p+q}$ ，利用分块乘法得到

$$\begin{aligned} KB &= \begin{bmatrix} D_1 & C \\ 0 & D_2 \end{bmatrix} \begin{bmatrix} B_1 & B_2 \\ B_3 & B_4 \end{bmatrix} \\ &= \begin{bmatrix} D_1 B_1 + C B_3 & D_1 B_2 + C B_4 \\ D_2 B_3 & D_2 B_4 \end{bmatrix} = \begin{bmatrix} E_p & 0 \\ 0 & E_q \end{bmatrix}. \end{aligned}$$

对应块相等，便得到四个矩阵方程：

$$\begin{cases} D_1 B_1 + C B_3 = E_p, & \text{左上块,} \\ D_1 B_2 + C B_4 = 0, & \text{右上块,} \\ D_2 B_3 = 0, & \text{左下块,} \\ D_2 B_4 = E_q, & \text{右下块.} \end{cases}$$

先解下面两式。左乘 D_2^{-1} ，得到 $B_3 = 0$ 、 $B_4 = D_2^{-1}$ ；再代入上面两式，得到

$$D_1 B_1 = E_p, \quad D_1 B_2 + C D_2^{-1} = 0.$$

最后左乘 D_1^{-1} ，就有

$$B_1 = D_1^{-1}, \quad B_2 = -D_1^{-1} C D_2^{-1}.$$

四块都已确定。还可以反向乘回，直接核对逆矩阵定义的另一个等式：

$$\begin{aligned} BK &= \begin{bmatrix} D_1^{-1} & -D_1^{-1} C D_2^{-1} \\ 0 & D_2^{-1} \end{bmatrix} \begin{bmatrix} D_1 & C \\ 0 & D_2 \end{bmatrix} \\ &= \begin{bmatrix} E_p & D_1^{-1} C - D_1^{-1} C D_2^{-1} D_2 \\ 0 & E_q \end{bmatrix} = E_{p+q}. \end{aligned}$$

因此

$$K^{-1} = \begin{bmatrix} D_1^{-1} & -D_1^{-1} C D_2^{-1} \\ 0 & D_2^{-1} \end{bmatrix}.$$

右上块的负号来自移项；三个因子的顺序来自两次左乘，不能按标量运算随意交换。这个结果也对应逐组恢复输入：先由 $y_2 = D_2 x_2$ 求出 x_2 ，再从 y_1 中减去 $C x_2$ ，最后用 D_1^{-1} 恢复 x_1 。

例如取

$$D_1 = \begin{bmatrix} 1 & 1 \\ 0 & 1 \end{bmatrix}, \quad C = \begin{pmatrix} 1 \\ 2 \end{pmatrix}, \quad D_2 = [2].$$

先计算右上块：

$$-D_1^{-1}CD_2^{-1} = -\begin{bmatrix} 1 & -1 \\ 0 & 1 \end{bmatrix} \begin{pmatrix} 1 \\ 2 \end{pmatrix} \cdot \frac{1}{2} = \begin{pmatrix} \frac{1}{2} \\ -1 \end{pmatrix}.$$

于是

$$K = \left[\begin{array}{cc|c} 1 & 1 & 1 \\ 0 & 1 & 2 \\ \hline 0 & 0 & 2 \end{array} \right], \quad K^{-1} = \left[\begin{array}{cc|c} 1 & -1 & \frac{1}{2} \\ 0 & 1 & -1 \\ \hline 0 & 0 & \frac{1}{2} \end{array} \right].$$

例如乘积 KK^{-1} 的右上角元素为 $\frac{1}{2} - 1 + \frac{1}{2} = 0$ ，正是跨组作用被抵消的结果。

在对角块均为方阵的前提下， K 可逆当且仅当 D_1, D_2 都可逆。刚才的构造证明了充分性。反过来，若 K 可逆，则 $D_1 \mathbf{u} = 0$ 必须只有零解，否则非零向量 $(\mathbf{u}^T, \mathbf{0}^T)^T$ 会被 K 送到零，与可逆性矛盾；同时，任意第二组输出都必须能由 $D_2 \mathbf{x}_2$ 得到。根据前一节对方阵可逆性的判定，前者保证 D_1 可逆，后者保证 D_2 可逆。

分块把一个大映射拆成若干相互连接的小映射，零块和三角结构则把“同时求解”变成“分组依次求解”。第2章的消元法正是在制造这样的简化结构。下一节将把每一步消元本身也写成矩阵，为把整个过程保存下来作准备。

3.6 初等变换与初等矩阵：消元的矩阵形式

第2章使用交换两行、非零倍乘一行、把一行的倍数加到另一行这三种操作完成消元。现在从映射看：如果 $A\mathbf{x} = \mathbf{y}$ ，在输出向量 $\mathbf{y}$ 的分量之间作一次这样的线性调整，相当于在原映射之后再接一个简单映射。复合对应左乘，于是行变换应当能写成某个矩阵 F 乘在 A 的左侧。

定义 3.30 (初等矩阵)

对单位矩阵 E_m 作一次初等行变换，所得矩阵称为初等矩阵 (Elementary Matrix)。三类常用记号为：

$$D_i(c) : r_i \leftarrow cr_i \ (c \neq 0), \quad H_{ij}(c) : r_i \leftarrow r_i + cr_j \ (i \neq j), \quad P_{ij} : r_i \leftrightarrow r_j.$$

在 $H_{ij}(c)$ 中，除对角线的 1 外，第 (i, j) 位置为 c ，其余非对角元均为 0。通常取 $c \neq 0$ ； $c = 0$ 时只是单位矩阵。

为什么从单位矩阵出发？因为它原样记录输出空间的标准基。将那次简单的输出调整作用于单位矩阵的各列，恰好得到这个调整映射自身的表示矩阵。

$$D_2(c) = \begin{bmatrix} 1 & 0 & 0 \\ 0 & c & 0 \\ 0 & 0 & 1 \end{bmatrix} \quad H_{31}(c) = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ c & 0 & 1 \end{bmatrix} \quad P_{12} = \begin{bmatrix} 0 & 1 & 0 \\ 1 & 0 & 0 \\ 0 & 0 & 1 \end{bmatrix}$$

倍乘第 2 行
 $r_2 \leftarrow cr_2, c \neq 0$

倍加到第 3 行
 $r_3 \leftarrow r_3 + cr_1$

交换第 1、2 行
 $r_1 \leftrightarrow r_2$

图 3.26: 三类初等矩阵的结构。图中以三阶矩阵为例，彩色元素显示相对于单位矩阵的改变。

读图说明：倍加矩阵中 $(3,1)$ 的 c 表示“把第 1 行的 c 倍加到第 3 行”。第一个下标是接受改变的行，第二个下标是提供倍数的行。

定理 3.31 (初等行变换就是左乘初等矩阵)

设 A 是 $m \times n$ 矩阵， F 由 E_m 经过某次初等行变换得到，则 FA 就是对 A 作同一次行变换的结果。

证明： F 调整的是输出向量的分量。因此 $F(Ae_k)$ 把 A 第 k 列的分量作同一次调整；对所有列同时这样做，正是对整个矩阵作相应的行变换。也可用乘法的行视角核对： F 的第 i 行指定了 A 的各行应按什么系数组合。 ■

例题 3.32 (把第 1 行的两倍加到第 3 行)

取

$$A = \begin{bmatrix} 1 & 2 & 0 \\ 0 & 1 & 3 \\ 2 & -1 & 1 \end{bmatrix}, \quad F = H_{31}(2) = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 2 & 0 & 1 \end{bmatrix}.$$

F 的前两行原样取出 A 的前两行，第 3 行取 $2r_1 + r_3$ ，所以

$$FA = \begin{bmatrix} 1 & 2 & 0 \\ 0 & 1 & 3 \\ 2 \cdot 1 + 2 & 2 \cdot 2 - 1 & 2 \cdot 0 + 1 \end{bmatrix} = \begin{bmatrix} 1 & 2 & 0 \\ 0 & 1 & 3 \\ 4 & 3 & 1 \end{bmatrix}.$$

这与直接执行 $r_3 \leftarrow r_3 + 2r_1$ 完全相同。

三类输出调整都能撤销，故初等矩阵都可逆，而且

$$D_i(c)^{-1} = D_i(1/c), \quad H_{ij}(c)^{-1} = H_{ij}(-c), \quad P_{ij}^{-1} = P_{ij}.$$

这也是第 2 章三类方程变换同解的矩阵解释：从 $Ax = b$ 到 $FAx = Fb$ 可以反向恢复，必须把系数与右端项一起变换。




图 3.27: 把行变换看成接在输出端的简单映射。原来的输入不变，输出分量按 F 重新组合，整个映射的矩阵变为 FA 。

读图说明: 左乘 F 调整的是输出坐标，不是改变输入的个数。可逆的行调整保留方程组的解，却通常会改变各列向量具体的坐标。

从行变换求逆，并与列变换区分

若一系列初等行变换把 A 化为单位矩阵，即

$$F_q \cdots F_2 F_1 A = E,$$

则 $A^{-1} = F_q \cdots F_2 F_1$ 。把同样的变换施加到 E 上，就能记录这个乘积。于是得到求逆算法

$$[A | E] \longrightarrow [E | A^{-1}].$$

可逆矩阵也因此可以写成有限个初等矩阵的乘积。反过来，初等矩阵的乘积一定可逆。若 A 无法化为 E ，就不能把右半边当作逆矩阵。

例题 3.33 (在同一张增广数表中记录逆映射)

对第 3.4 节的 $A = \begin{bmatrix} 2 & 1 \\ 1 & 1 \end{bmatrix}$ ，作

$$\begin{aligned} \left[\begin{array}{cc|cc} 2 & 1 & 1 & 0 \\ 1 & 1 & 0 & 1 \end{array} \right] &\xrightarrow{r_1 \leftrightarrow r_2} \left[\begin{array}{cc|cc} 1 & 1 & 0 & 1 \\ 2 & 1 & 1 & 0 \end{array} \right] \xrightarrow{r_2 \leftarrow r_2 - 2r_1} \left[\begin{array}{cc|cc} 1 & 1 & 0 & 1 \\ 0 & -1 & 1 & -2 \end{array} \right], \\ &\xrightarrow{r_2 \leftarrow -r_2} \left[\begin{array}{cc|cc} 1 & 1 & 0 & 1 \\ 0 & 1 & -1 & 2 \end{array} \right] \xrightarrow{r_1 \leftarrow r_1 - r_2} \left[\begin{array}{cc|cc} 1 & 0 & 1 & -1 \\ 0 & 1 & -1 & 2 \end{array} \right]. \end{aligned}$$

右半边正是 $A^{-1} = \begin{bmatrix} 1 & -1 \\ -1 & 2 \end{bmatrix}$ 。

类似地，交换两列、非零倍乘一列、把一列的倍数加到另一列称为初等列变换 (Elementary Column Operations)。列变换对应右乘合适的初等矩阵：它把输入先作一次调整，再送进原映射。特别是

$$AH_{ij}(c): \text{第 } j \text{ 列} \leftarrow \text{第 } j \text{ 列} + c \text{ 第 } i \text{ 列}.$$

这个方向与 $H_{ij}(c)A$ 的行操作不同。因为右乘时，第 j 列为 $A(ce_i + e_j)$ ，接受改变的是第 j 列。

注意：行变换在左侧乘，列变换在右侧乘。解方程时可以对整个增广矩阵作同解行变换；若随意改变系数列却不相应处理未知数，通常会改变原问题。

现在，一次消元对应一个初等矩阵，一连串消元对应一连串矩阵乘法。若每遇到一个新的右端项，都从头重做这串操作，就浪费了已经完成的工作。下一节将把它们整理为两个三角矩阵，让一次消元服务于多次求解。

3.7 LU 分解：把一个方程组拆成两次三角求解

3.7.1 为什么要做 LU 分解？

面对 $Ax = b$ ，我们要找的是未知向量 x 。一般方程组中，每一行都可能牵涉好几个未知数；消元的作用，是把这些联系整理出先后次序。等最后一行只剩一个未知数，就能先解它，再一行一行向上回代。**容易求解的关键，是三角结构让下一步的未知数只剩一个。**

现在把问题再往前推一步：如果 A 不变， b 却不断改变，还需要每次从头消元吗？桥梁在同一个线性模型下承受不同荷载，就是这样的任务。结构连接与刚度不变，系数矩阵不变；车辆或其他外力改变，右端项随之改变。对同一张系数表反复进行相同的行运算，显然有许多工作可以保存。

LU 分解正是把这部分工作保存下来。**它的求解意义，是 把一个复杂的方程组转化为两个容易求解的三角方程组：先从上往下算出一个中间向量，再从下往上算回所求的解。**我们先看这条路线，再用一个三元方程组把每一步走完；最后回到桥梁，看看怎样复用已经算好的结果。

本节先讨论可逆方阵，且按当前行次序进行高斯消元时，每一步所需的主元都非零。需要交换行的情况放在第 3.8 节选读中讨论。

3.7.2 图解 LU 分解的结构

主对角线下方全为零的方阵称为上三角矩阵 (Upper Triangular Matrix)，它适合从最后一行往上求解；主对角线上方全为零的方阵称为下三角矩阵 (Lower Triangular Matrix)，它适合从第一行往下求解。下三角矩阵的对角线若全为 1，就称为单位下三角矩阵 (Unit Lower Triangular Matrix)。这里的“单位”只限定对角线，下面仍然可以有非零元素。

消元结束后，上三角矩阵 U 记录整理好的方程系数；另用单位下三角矩阵 L 记录每一步用了主元行的多少倍。两份记录一起保留了原来的系数关系，得到

$$A = LU.$$

这种写法称为 LU 分解 (LU Factorization)。先不要急着把它当成一个需要背诵的恒等式： L 从哪里来、为什么乘回去就是 A ，会在下面的消元实例中直接看见。

$$\begin{array}{ccc}
 A & L & U \\
 \begin{bmatrix} a_{11} & a_{12} & a_{13} \\ a_{21} & a_{22} & a_{23} \\ a_{31} & a_{32} & a_{33} \end{bmatrix} & = & \begin{bmatrix} 1 & 0 & 0 \\ \ell_{21} & 1 & 0 \\ \ell_{31} & \ell_{32} & 1 \end{bmatrix} \times \begin{bmatrix} u_{11} & u_{12} & u_{13} \\ 0 & u_{22} & u_{23} \\ 0 & 0 & u_{33} \end{bmatrix} \\
 \text{原来的系数矩阵} & \text{单位下三角} & \text{上三角} \\
 & \text{对角线为 1, 记录乘数} & \text{消元后的方程系数}
 \end{array}$$

图 3.28: 一份系数矩阵, 分成两份可复用的记录: L 保存乘数, U 保存三角方程。

读图说明: L 主对角线上方、 U 主对角线下方的浅色区域固定为零; 蓝、绿色区域保留各自的三角结构。本节讨论可逆方阵的无换行消元, 因而 U 的各个对角元都非零。

把这个分解代回原方程, 利用矩阵乘法的结合律,

$$Ax = b \iff L(Ux) = b.$$

令 $y = Ux$ 。虽然此时还不知道 x , 却能先把 y 当作未知量, 因为 L 和 b 都已知。于是求解变成两步:

$$\boxed{\text{第一步: } Ly = b} \implies \boxed{\text{第二步: } Ux = y}.$$

第一步称为前代 (Forward Substitution): L 的第一行只有 y_1 , 算出后代入第二行求 y_2 , 再往下推进。第二步是回代 (Back Substitution): U 的最后一行只有 x_n , 算出后代入上一行, 再向上推进。先把中间向量 y 算完整, 第二个方程组的右端项才有了具体数值。




图 3.29: 先解下三角方程, 再解上三角方程; 箭头同时标出求解顺序与逐行计算方向。

读图说明: 把 $y = Ux$ 看作待求的中间量。先由已知的 b 求出 y , 才能把它放到第二个方程组的右端。

请分清“作用的顺序”和“求解的顺序”: 给定 x 计算 Ax , 是先乘 U 、再乘 L ; 已知最终结果 b 去寻找 x , 则先解含 L 的方程, 再解含 U 的方程。这里直接逐行求解, 不必先计算 L^{-1} 、 U^{-1} 或 A^{-1} 。

3.7.3 具体方程组的演练

先把要解决的问题写出来。考虑

$$\begin{cases} 2x_1 - x_2 = 1, \\ -x_1 + 2x_2 - x_3 = 0, \\ -x_2 + 2x_3 = 0, \end{cases} \quad A = \begin{bmatrix} 2 & -1 & 0 \\ -1 & 2 & -1 \\ 0 & -1 & 2 \end{bmatrix}, \quad \mathbf{b} = \begin{pmatrix} 1 \\ 0 \\ 0 \end{pmatrix}.$$

这就是本节桥梁教学模型的系数矩阵，稍后记为 K 。此处统一用 $\mathbf{x}$ 表示未知量，先把注意力放在求解顺序上。以下数值均为三节点线性教学模型，不是实桥设计参数或测量数据。

从 A 到 U ：消掉一个数，保存一个乘数。用主元所在行消去它下面的元素时，统一写成

$$r_i \leftarrow r_i - \ell_{ik} r_k, \quad \ell_{ik} = \frac{\text{本步要消去的元素}}{\text{本步主元}}.$$

这个比值称为消元乘数 (Elimination Multiplier)，也叫消元倍数。 L 保存的是 ℓ_{ik} 本身，不是行变换中另加的负号。

第一列的主元是 2。要消去下面的 -1 ，所用乘数为 $\ell_{21} = \boxed{-\frac{1}{2}}$ ；第 3 行本来就是 0，所以 $\ell_{31} = \boxed{0}$ 。执行 $r_2 \leftarrow r_2 - (-\frac{1}{2})r_1$ 后，第 2 行变为 $(0, \frac{3}{2}, -1)$ 。我们看到，减去负倍数也就是加上正倍数，但写入 L 的仍是 $-\frac{1}{2}$ 。

第二列必须看更新后的矩阵。新主元是 $\frac{3}{2}$ ，下面的元素为 -1 ，所以

$$\ell_{32} = \frac{-1}{3/2} = \boxed{-\frac{2}{3}}, \quad r_3 \leftarrow r_3 - (-\frac{2}{3})r_2.$$

这次第 3 行变为 $(0, 0, \frac{4}{3})$ ，上三角矩阵 U 就形成了。图中把当前主元列着色，并将乘数沿箭头记入下方的 L ；这种“阶梯形演进、逐列记录”的组织方式也见于 Lay 教材的矩阵分解一节 [3]，这里全部使用本讲义的三节点算例重新绘制。




图 3.30: 上方阶梯形逐步形成, 下方同步记录乘数; 同色数字沿箭头“落入” L 的对应列。

读图说明: 细框标出本步主元。 $\ell_{21}, \ell_{31}, \ell_{32}$ 分别填入 L 的 $(2, 1), (3, 1), (3, 2)$ 位置。问号表示尚未计算, 已知的零照常记录; 原矩阵的元素与消元乘数不是同一个数。

怎样把“主元列除以主元”读准确? 每一轮只取当前主元及其下方的列段, 除以当前主元; 主元上方的位置补零。本例中三个列段依次来自 $A, A^{(1)}, U$, 因此

$$L = \begin{bmatrix} \frac{2}{2} & 0 & 0 \\ -\frac{1}{2} & \frac{3/2}{3/2} & 0 \\ 0 & \frac{-1}{3/2} & \frac{4/3}{4/3} \end{bmatrix} = \begin{bmatrix} 1 & 0 & 0 \\ -\frac{1}{2} & 1 & 0 \\ 0 & -\frac{2}{3} & 1 \end{bmatrix}.$$

这就解释了为什么 L 的对角线是 1, 以及乘数为什么在对应的主元下方。不能把原矩阵的每一列都直接除以原主元; 第 2 轮使用的是已经更新过的系数。

乘回去也能看见这些记录的作用。设 U 的三行为 U_1, U_2, U_3 , 则 LU 的三行分别为

$$U_1 = (2, -1, 0), \quad -\frac{1}{2}U_1 + U_2 = (-1, 2, -1), \quad -\frac{2}{3}U_2 + U_3 = (0, -1, 2).$$

它们恰好是 A 的三行。消元把某行减去主元行的相应倍数, L 又把这些倍数加回去, 因而 $LU = A$ 。下面用第 3.6 节的初等矩阵, 把这种“撤销消元”的解释完整写出来。

从初等矩阵看: L 怎样撤销整串消元? 每做一次初等行变换, 就相当于在左侧乘一个初等矩阵。设我们按顺序执行 k 次消元, 对应的初等矩阵依次为 $E_1, E_2, \dots, E_k$ 。先做的变换紧挨着 A , 后做的变换继续乘在左边, 因此

$$A \xrightarrow{E_1} E_1 A \xrightarrow{E_2} E_2 E_1 A \xrightarrow{\cdots} \underbrace{E_k \cdots E_2 E_1 A}_U.$$

我们看到， U 是对 A 实施整串消元后的结果。要从 U 恢复 A ，就把这串操作倒着撤销：先撤销最后一步，再撤销倒数第二步，直到撤销第一步。于是

$$\begin{aligned} E_k \cdots E_2 E_1 A &= U, \\ A &= (E_k \cdots E_2 E_1)^{-1} U \\ &= \underbrace{E_1^{-1} E_2^{-1} \cdots E_k^{-1}}_L U. \end{aligned}$$

这就是 $A = LU$ 的矩阵代数解释：

$$L = (E_k \cdots E_2 E_1)^{-1} = E_1^{-1} E_2^{-1} \cdots E_k^{-1}.$$

这里同时用到了第 3.4 节的乘积求逆法则：乘积求逆时，因子的书写顺序要反过来。在 L 作用于 U 时，最右边的 E_k^{-1} 先作用，恰好先撤销最后一次消元；不能任意调换这些因子。

本节消元不交换行，也不将主元行缩放为 1，只用主元行消去其下方的元素。因而每个 E_i 都是单位下三角矩阵，它的逆矩阵仍是单位下三角矩阵，这些逆矩阵的乘积 L 也保持这一结构。一次消元是 $r_i \leftarrow r_i - \ell_{ij} r_j$ ，它的逆操作就是 $r_i \leftarrow r_i + \ell_{ij} r_j$ 。这说明消元矩阵中的相应位置是 $-\ell_{ij}$ ，撤销它的矩阵中则是 ℓ_{ij} ；按照消元顺序逐列整理，就得到前面记录乘数的 L 。

在同一个算例中，把这两个初等矩阵真正乘出来。本例只需执行两次消元：先做 $r_2 \leftarrow r_2 + \frac{1}{2}r_1$ ，再做 $r_3 \leftarrow r_3 + \frac{2}{3}r_2$ ，所以

$$E_1 = \begin{bmatrix} 1 & 0 & 0 \\ \frac{1}{2} & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix}, \quad E_2 = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & \frac{2}{3} & 1 \end{bmatrix}, \quad E_2 E_1 A = U.$$

撤销它们时，相应倍数改号。按照刚才推出的顺序相乘，

$$\begin{aligned} L = E_1^{-1} E_2^{-1} &= \begin{bmatrix} 1 & 0 & 0 \\ -\frac{1}{2} & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & -\frac{2}{3} & 1 \end{bmatrix} \\ &= \begin{bmatrix} 1 & 0 & 0 \\ -\frac{1}{2} & 1 & 0 \\ 0 & -\frac{2}{3} & 1 \end{bmatrix}. \end{aligned}$$

这正是图中由乘数 $-\frac{1}{2}$ 、 $-\frac{2}{3}$ 填出的 L 。读这个乘积时，先由右边的 E_2^{-1} 撤销第 2 列消元，再由 E_1^{-1} 撤销第 1 列消元，原来的 A 就恢复了。所以， U 是消元的结果， L 是整串消元操作的逆；两者相乘，便还原原矩阵。

这也解释了前代为什么能替右端项完成消元。将同一串初等变换施加到增广矩阵的两侧，便有

$$Ax = b \implies Ux = \underbrace{E_k \cdots E_1 b}_y, \quad Ly = b.$$

因此，先解 $Ly = b$ ，就是算出消元后的右端项；再解 $Ux = y$ ，就是熟悉的回代。初等矩阵解释了分解怎样产生，两次三角求解则说明分解怎样拿来解方程组。

第一步，前代：先求 y ，从上到下。现在正式使用保存好的 L, U 。先解

$$\underbrace{\begin{bmatrix} 1 & 0 & 0 \\ -\frac{1}{2} & 1 & 0 \\ 0 & -\frac{2}{3} & 1 \end{bmatrix}}_L \begin{pmatrix} y_1 \\ y_2 \\ y_3 \end{pmatrix} = \begin{pmatrix} 1 \\ 0 \\ 0 \end{pmatrix}, \quad \begin{cases} y_1 = 1, \\ -\frac{1}{2}y_1 + y_2 = 0, \\ -\frac{2}{3}y_2 + y_3 = 0. \end{cases}$$

第一行直接给出 y_1 ；把这个数放进第二行，就只剩 y_2 ；再把 y_2 放进第三行：

$$\begin{aligned} y_1 &= 1, \\ y_2 &= 0 + \frac{1}{2}y_1 = \frac{1}{2}, \\ y_3 &= 0 + \frac{2}{3}y_2 = \frac{1}{3}. \end{aligned} \quad \boxed{y = \begin{pmatrix} 1 \\ \frac{1}{2} \\ \frac{1}{3} \end{pmatrix}}.$$

这组 y 也正是对右端项做相同行消元得到的结果：先把第一行右端的 $\frac{1}{2}$ 倍加到第二行，得到 $\frac{1}{2}$ ；再把新第二行右端的 $\frac{2}{3}$ 倍加到第三行，得到 $\frac{1}{3}$ 。前代把“右端项跟着消元”这件事重新做了一遍，系数矩阵则不必再消元。

第二步，回代：再求 x ，从下到上。把刚算出的 y 放到右端，解

$$\underbrace{\begin{bmatrix} 2 & -1 & 0 \\ 0 & \frac{3}{2} & -1 \\ 0 & 0 & \frac{4}{3} \end{bmatrix}}_U \begin{pmatrix} x_1 \\ x_2 \\ x_3 \end{pmatrix} = \begin{pmatrix} 1 \\ \frac{1}{2} \\ \frac{1}{3} \end{pmatrix}, \quad \begin{cases} 2x_1 - x_2 = 1, \\ \frac{3}{2}x_2 - x_3 = \frac{1}{2}, \\ \frac{4}{3}x_3 = \frac{1}{3}. \end{cases}$$

这一次，请从最后一行开始读。先求 x_3 ，再把它代入上一行求 x_2 ，最后求 x_1 ：

$$\begin{aligned} x_3 &= \frac{1/3}{4/3} = \frac{1}{4}, \\ x_2 &= \frac{\frac{1}{2} + x_3}{3/2} = \frac{\frac{1}{2} + \frac{1}{4}}{3/2} = \frac{1}{2}, \\ x_1 &= \frac{1 + x_2}{2} = \frac{3}{4}. \end{aligned} \quad \boxed{x = \begin{pmatrix} \frac{3}{4} \\ \frac{1}{2} \\ \frac{1}{4} \end{pmatrix}}.$$

代回最初的三条方程，左端分别是 $2 \cdot \frac{3}{4} - \frac{1}{2} = 1$ 、 $-\frac{3}{4} + 2 \cdot \frac{1}{2} - \frac{1}{4} = 0$ 、 $-\frac{1}{2} + 2 \cdot \frac{1}{4} = 0$ ，

与原右端项完全相同。我们没有直接“求出一个逆矩阵”，而是按两条清楚的逐行路线得到了原方程组的解。

回看消元：剩余方程的系数怎样更新？ 可以把第一轮画成一幅块状图。第一行暂时保留，下面两行各自减去主元行的相应倍数；因此右下角的 2×2 系数块，从 B 变成“ B 减去乘数列与主元行右侧的乘积”。这就是外积消元的局部图景。

$$\begin{array}{ccc} \text{原来的剩余块 } B & \text{乘数列} \times \text{主元行的右侧} & \text{更新后的剩余块} \\ \left[\begin{array}{cc} 2 & -1 \\ -1 & 2 \end{array} \right] & - \left(-\frac{1}{2} \right) \begin{bmatrix} -1 & 0 \end{bmatrix} = \begin{bmatrix} \frac{1}{2} & 0 \\ 0 & 0 \end{bmatrix} & = \left[\begin{array}{cc} \frac{3}{2} & -1 \\ -1 & 2 \end{array} \right] \end{array}$$

下一轮只需在这个更小的方程组里继续消元

图 3.31: 一次消元怎样更新右下角：从剩余系数块中，减去“乘数列乘主元行右侧”生成的数表。

读图说明： 本图只拆开第一轮的更新。 $\frac{3}{2} = 2 - (-\frac{1}{2})(-1)$ ；第二轮就应使用这个新主元。列乘行是第 3.3 节的外积，这里只用它说明后续方程的系数为何改变。

接下来只需处理更小的剩余块。这样的图解帮助我们看清**每轮消元都在缩小尚未处理的方程组**；真正求解时，仍然使用刚才的两步：前代求 y ，回代求 x 。

3.7.4 为什么工程上喜欢 LU 分解？

回到桥梁：固定同一个线性结构模型，换一种荷载，就相当于换一个 b 。港珠澳大桥香港连接路的工程论文展示了有限元模型，并讨论不同荷载作用下的设计检查 [24]。这里借这一背景说明重复求解的需要，不把下面的小矩阵当成实桥的设计计算。




图 3.32: 港珠澳大桥西段实景。大型桥梁的分析需要比较多种作用情形，本节关注其中“相同系数、多个右端项”的计算任务。

读图说明：摄影：N509FZ，2018 年 9 月 2 日；Wikimedia Commons，CC BY-SA 4.0。照片未修改，仅按比例排印，来源与许可链接见文献 [25]。照片展示真实工程；以下数值均为教学自拟。

把复杂结构简化为三个沿同一方向移动的节点，两端固定，四段连接刚度都取 1。记位移为 u 、外力为 f ，中间节点的平衡是 $(u_2 - u_1) + (u_2 - u_3) = f_2$ ；两侧节点同理：

$$Ku = f, \quad K = \begin{bmatrix} 2 & -1 & 0 \\ -1 & 2 & -1 \\ 0 & -1 & 2 \end{bmatrix} = A.$$

K 是这个无量纲教学模型的刚度矩阵 (Stiffness Matrix)，每种指定荷载是一个荷载工况 (Load Case)。它与前面的 A 完全相同，所以原来的 L, U 可以直接使用；只需把 x, b 分别读作位移 u 与荷载 f 。



所有位移与力均以向右为正；模型不按实桥比例绘制

图 3.33: 从真实桥梁的多工况问题，抽取一个可手算的三节点连接模型。

读图说明：连接力取决于相对位移。例如中间节点的平衡为 $(u_2 - u_1) + (u_2 - u_3) = f_2$ ，所以系数自然成为 $-1, 2, -1$ 。

刚才算的就是节点 1 承受单位荷载。若把单位荷载移到节点 2，不用再计算任何消

元乘数，只将 $f^{(2)} = (0, 1, 0)^T$ 代入两次三角求解：

$$Ly = f^{(2)} \implies y = (0, 1, \frac{2}{3})^T, \quad Uu^{(2)} = y \implies u^{(2)} = (\frac{1}{2}, 1, \frac{1}{2})^T.$$

同理，荷载移到节点 3 时， $y = (0, 0, 1)^T$ ，解为 $u^{(3)} = (\frac{1}{4}, \frac{1}{2}, \frac{3}{4})^T$ 。三次计算的系数矩阵相同，分解也相同，改变的只有前代的输入及随后算出的数值。




图 3.34: 同一个连接模型，三种荷载位置，三组位移响应。

读图说明：每个工况中，三行依次对应三个节点。蓝色箭头长度与位移大小成比例，向右为正，与三节点模型的方向约定一致。

如果一次处理许多荷载，可以把它们并排成矩阵 B ，把各组解并排成 X ，就得到

$$AX = B \implies LY = B \implies UX = Y.$$

每一列仍按同样的顺序求解。对一般稠密 n 阶矩阵，分解的工作量大致随 n^3 增长，每组前代与回代的工作量大致随 n^2 增长；保存分解的收益，在右端项很多时尤其明显。通用数值库也将分解与随后求解组织为可分别调用的步骤 [27]。对本例这种带状矩阵还可利用更多零元素减少计算，不能把稠密估计当成所有工程模型的精确成本。

同样的思路也适用于电路和导热：三个节点由四个单位电阻依次连接、两端接地时，节点电压满足 $Kv = j$ ；均匀细杆取三个内部温度未知量、连接导热系数归一化为 1 时，相对于端点的温升满足 $Kt = q$ 。这些都是教学简化模型；电路软件实际也会组织并求解矩阵系统 [26]。固定元件或导热系数，改变输入，就能复用已经完成的分解。

一次分解、多次求解的前提，是系数矩阵确实没有改变。若材料刚度、连接方式或边界条件改变，就应重新检查并通常重新分解矩阵；不能只换右端项继续使用。对于本节固定的 A ，无论 b 怎样改变，都按“先 $Ly = b$ ，后 $Ux = y$ ”重复求解。

我们现在可以把 LU 的意义连成一句话：**消元把方程组整理成三角形， L 留下整理时的乘数， U 留下整理后的系数；新问题沿着前代、回代两条路线就能得到解。**若消元中遇到零主元，或过小的主元使数值计算不稳，就需要改变行次序。下一节选读将用同一个桥梁模型说明 PLU 如何处理这件事。

3.8 【选读】PLU 分解：选主元与数值稳定性

本小节为拓展内容，不做考核要求。主线中只要掌握 LU 怎样记录消元、怎样复用求解即可。本节进一步说明，计算机保存有限位数字时，为什么还要认真选择主元。

回到港珠澳大桥背景下的三节点教学模型。桥梁结构本身没有改变，但程序装配方程时，节点记录的读取次序可能不同。只要把方程和右端项一起重排，物理问题仍然相同；消元所见到的“第一个元素”却可能改变。因此，**固定结构值得复用分解，实际求解还要选择合适的主元顺序**。本节用重排后的同一个 K 展示这一点，随后用小主元例子说明有限精度的影响。

考虑矩阵 $\begin{bmatrix} 0 & 1 \\ 1 & 1 \end{bmatrix}$ 。它的映射可逆，但第 1 个位置为 0，无法直接用它消去下方的 1。交换两行后便可继续。这个例子说明：**可逆矩阵也未必能按原行次序进行无换行的 LU 消元**。

即使主元非零，过小的主元也可能产生过大的消元倍数，放大只保留有限位数字造成的舍入误差 (Rounding Error)。这属于数值稳定性 (Numerical Stability) 问题：算法应尽量避免把有限精度计算中的小误差放大成结果中的大偏差。

例题 3.34 (一个过小的主元)

考虑

$$\begin{cases} 10^{-4}x + y = 1, \\ x + y = 2. \end{cases}$$

精确解为 $x = 1/(1 - 10^{-4})$ 、 $y = (1 - 2 \cdot 10^{-4})/(1 - 10^{-4})$ ，两者都接近 1。

若每步只保留 3 位有效数字，用第 1 行直接消元，需要减去它的 10^4 倍。第 2 行变为 $-9999y = -9998$ ，舍入后却成为 $-10000y = -10000$ ，给出 $y = 1$ ；代回第 1 行得到 $x = 0$ ，偏差很大。

若先交换两行，消元倍数只有 10^{-4} ，由 $(1 - 10^{-4})y = 1 - 2 \cdot 10^{-4}$ 得到舍入结果 $y = 1$ ，再由 $x + y = 2$ 得到 $x = 1$ ，更接近精确解。

常用的部分选主元 (Partial Pivoting) 是在第 k 步，从**尚未处理的第 k 行及其下方**寻找当前列绝对值最大的元素，把它所在行交换到主元行，再消元。这使该步用于消去下方元素的倍数绝对值不超过 1。它通常能改善数值表现，但不是对所有矩阵都绝对无误差的保证。

一次行交换对应一个交换矩阵，多次交换合起来仍是置换矩阵 (Permutation Matrix)：它的每行、每列恰有一个 1，其余元素为 0，用来重新排列向量分量。把所有行交

换汇总为 P ，得到 PLU 分解 (PLU Factorization) 的常用写法

$$PA = LU.$$

本书始终采用这个约定。写成 $A = P^{-1}LU$ 与它等价；不同资料对置换矩阵的命名可能相差一个逆。对置换矩阵， $P^{-1} = P^T$ 。

例题 3.35 (同一桥梁模型，先读入节点 2 的方程)

把 $Ku = f$ 的前两条方程交换后，程序看到的矩阵和右端项变为

$$A = \begin{bmatrix} -1 & 2 & -1 \\ 2 & -1 & 0 \\ 0 & -1 & 2 \end{bmatrix}, \quad \mathbf{b} = (f_2, f_1, f_3)^T.$$

第 1 列的候选主元绝对值为 1, 2, 0。选择第 2 行的 2，交换前两行，取

$$P = \begin{bmatrix} 0 & 1 & 0 \\ 1 & 0 & 0 \\ 0 & 0 & 1 \end{bmatrix}, \quad PA = K, \quad P\mathbf{b} = \mathbf{f}.$$

于是第 3.7 节保存的 L, U 立即给出 $PA = LU$ 。第 2 轮中，剩余候选值为 $3/2, -1$ ，不再需要换行。

例如荷载在节点 1 时，读入的右端项为 $\mathbf{b} = (0, 1, 0)^T$ 。同步换行后恢复 $P\mathbf{b} = (1, 0, 0)^T$ ，解得的物理位移仍为 $(3/4, 1/2, 1/4)^T$ 。换的是方程的排列，不是节点的物理位置，也不是未知量的列次序。

装配次序：2、1、3

$$\begin{array}{cc} A & \mathbf{b} \\ \left[\begin{array}{ccc|c} -1 & 2 & -1 & 0 \\ 2 & -1 & 0 & 1 \\ 0 & -1 & 2 & 0 \end{array} \right] & \xrightarrow{\text{同乘 } P} \left[\begin{array}{ccc|c} 2 & -1 & 0 & 1 \\ -1 & 2 & -1 & 0 \\ 0 & -1 & 2 & 0 \end{array} \right] \end{array} \xrightarrow{\text{复用同一组 } L, U}$$

一条方程的系数与右端项必须作为一个整体移动

图 3.35: 从 LU 到 PLU：给同一个工程模型选择更合适的消元顺序。

读图说明：蓝色行与其右端项始终成对移动，玫红色行亦然。本例选主元后回到上一节的 K ，可以逐项核对分解和位移。

注意：本例只在开头换行。如果在后续消元步骤中交换行， L 前面各列已经保存的对应行元素，也必须随之交换，才能始终保持 $PA = LU$ 。

解 $Ax = b$ 时，先把右端项按同样的顺序排列，解 $Ly = Pb$ ，再解 $Ux = y$ 。若选主元时发现当前列剩余部分全为零，则不能继续除以这个主元，应按第2章的解判定处理，而不能把换行当作总能使矩阵可逆的办法。

处理一般矩阵的数值软件中，带部分选主元的 LU 是常见方案，例如 LAPACK 的 DGETRF 就采用换行选主元 [28]。无换行 LU 并非只适用于某一种矩阵。严格对角占优 (Strict Diagonal Dominance) 条件

$$|A_{i,i}| > \sum_{j \neq i} |A_{i,j}| \quad (i = 1, \dots, n)$$

是保证无换行消元可以进行的一类充分条件，却不是必要条件。例如 $\begin{bmatrix} 1 & 2 \\ 1 & 3 \end{bmatrix}$ 不满足这一条件，但减去第1行后主元为1，仍能顺利得到 LU。实际算法还会结合矩阵的具体结构选择方案。

LU 与 PLU 保存的是“怎样消元”的信息。下一节选读换一个问题：如果若干列本来就可以由少数核心列表示，能否把矩阵拆成“核心列”与“组合系数”两部分？这将把本章的矩阵分解与第1章的基、线性表示重新连接起来。

3.9 【选读】列秩分解 (CR 分解)

本小节为拓展内容，不做考核要求。这里仍只使用第1章向量组的秩、第2章的行化简和本章的矩阵乘法，不讨论下一章的映射结构定理。

设 A 的秩为 $r > 0$ 。从它的原列中选一组极大无关组，按次序排成矩阵 C 。第2章已证明：可先看梯形的主元列号，再返回原矩阵取出这些列。其余每一列都能由 C 的列唯一线性表示，把各列的表示系数也按列记录成矩阵 R ，就得到

$$A = CR.$$

从映射看，输入 x 先经过 R ，被整理成 r 个核心方向的组合系数；再经过 C ，将这些系数组合为实际输出。分解来自这个复合过程。

定义 3.36 (列秩分解)

若 A 是秩为 $r > 0$ 的 $m \times n$ 矩阵，分解

$$A = CR, \quad C : m \times r, \quad R : r \times n$$

中 C 的 r 列线性无关， R 的 r 行线性无关，则称为列秩分解 (Rank Factorization)，简称 CR 分解。列向量全部无关称为列满秩 (Full Column Rank)；行向量全部无关称为行满秩 (Full Row Rank)。

零矩阵无需寻找核心列。若允许空矩阵，也可令 C 为 $m \times 0$ 、 R 为 $0 \times n$ ，按空和为零的约定写成 $A = CR$ ；后面的算例均取 $r > 0$ 。

从行最简形读出组合系数

把 A 化为行最简形 U ，设主元列号为 $k_1, \dots, k_r$ 。取原矩阵的这些列组成 C ，再取 U 的前 r 个非零行组成 R 。为什么这些行恰好给出所需的系数？

在 U 中，主元列的前 r 个分量依次是标准基。于是第 j 列前 r 个元素本身，就是它关于主元列的组合系数。行变换保持**对应列之间的线性关系及其系数**，因此同样的系数也把原矩阵的第 j 列表示为 C 的各列之和。逐列写出，正好是 $A = CR$ 。

另外， R 的第 $k_1, \dots, k_r$ 列组成 E_r ，所以它的 r 行无关：若若干行的线性组合为零，只看这些列，就立即得到各个系数全为零。这说明上面的构造同时满足两个无关条件。

注意： C 必须由原矩阵的主元对应列构成，不能从行最简形中直接拿列来代替。行化简保留的是列之间的表示关系，不是各列的坐标。只有 R 取自行最简形的非零行。

例题 3.37 (两条核心列, 组织四条列向量)

取

$$A = \begin{bmatrix} 1 & 2 & 0 & 1 \\ 0 & 0 & 1 & 1 \\ 1 & 2 & 1 & 2 \end{bmatrix}.$$

先后作 $r_3 \leftarrow r_3 - r_1$ 、 $r_3 \leftarrow r_3 - r_2$, 得到

$$A \sim \begin{bmatrix} 1 & 2 & 0 & 1 \\ 0 & 0 & 1 & 1 \\ 0 & 0 & 1 & 1 \end{bmatrix} \sim U = \begin{bmatrix} 1 & 2 & 0 & 1 \\ 0 & 0 & 1 & 1 \\ 0 & 0 & 0 & 0 \end{bmatrix}.$$

这已是行最简形, 主元在第 1、3 列, 故 $r(A) = 2$ 。返回原矩阵取列, 并保留 U 的非零行, 得

$$C = \begin{bmatrix} 1 & 0 \\ 0 & 1 \\ 1 & 1 \end{bmatrix}, \quad R = \begin{bmatrix} 1 & 2 & 0 & 1 \\ 0 & 0 & 1 & 1 \end{bmatrix}.$$

于是

$$A = CR = \begin{bmatrix} 1 & 0 \\ 0 & 1 \\ 1 & 1 \end{bmatrix} \begin{bmatrix} 1 & 2 & 0 & 1 \\ 0 & 0 & 1 & 1 \end{bmatrix}.$$

逐列看, 四组系数为 $(1,0)^T$ 、 $(2,0)^T$ 、 $(0,1)^T$ 、 $(1,1)^T$, 分别说明原列为 $\mathbf{a}_1$ 、 $2\mathbf{a}_1$ 、 $\mathbf{a}_3$ 、 $\mathbf{a}_1 + \mathbf{a}_3$, 与原数表一致。

先看取列, 再看重建

把算例中的数表染成两种颜色, 便能看清 C 与 R 各自保留了什么。 C 中的两条竖向色带来自原矩阵; R 中的两条横向色带来自行最简形。不要把这两个来源混在一起。





图 3.36: CR 的两条取材路线：原矩阵给出方向，行最简形给出系数。

读图说明：行化简后的第 1、3 列只负责提示主元位置；真正放进 C 的仍是原矩阵的第 1、3 列。



右侧两格是 R 的对应列：上格乘 c_1 ，下格乘 c_2

图 3.37: 逐列重建：R 的每一列都是一张“两种方向如何配比”的记录。

读图说明：例如最后一列的系数为 $(1, 1)^T$ ，因此原矩阵最后一列是两个核心列之和。

也可以采用第 3.3 节的外积视角，把两条核心列各自的贡献铺成整张数表：

$$A = c_1 \begin{bmatrix} 1 & 2 & 0 & 1 \end{bmatrix} + c_2 \begin{bmatrix} 0 & 0 & 1 & 1 \end{bmatrix}.$$

方向 1 的贡献

$$\begin{bmatrix} 1 & 2 & 0 & 1 \\ 0 & 0 & 0 & 0 \\ 1 & 2 & 0 & 1 \end{bmatrix}$$

方向 2 的贡献

$$\begin{bmatrix} 0 & 0 & 0 & 0 \\ 0 & 0 & 1 & 1 \\ 0 & 0 & 1 & 1 \end{bmatrix}$$

A

$$= \begin{bmatrix} 1 & 2 & 0 & 1 \\ 0 & 0 & 1 & 1 \\ 1 & 2 & 1 & 2 \end{bmatrix}$$

图 3.38: 两张外积数表叠加，恢复整个矩阵。

读图说明：LU 的每一块记录一次消元贡献；CR 的每一块记录一个核心列方向的贡献。二者都通过“列乘行、再求和”恢复原矩阵。




图 3.39: CR 分解先提取核心方向的组合系数，再把系数还原为输出。例题中两个核心列张成三维空间内的平面 $z = x + y$ 。

读图说明：四个输入分量先变成两个组合系数，再变成三个输出分量。C 保留核心方向，R 保存各原列如何由核心列组成，二者各自记录不同的信息。

第 3.5 节已经从转置引入列空间与行空间：它们分别由矩阵的列与行张成，分别位于 $\mathbb{R}^m$ 与 $\mathbb{R}^n$ ，不应混在一起。在本节的构造中，C 与 A 的列空间相同：C 的列取自 A，而 A 的每列又由 C 的列表示。R 与 A 的行空间也相同：可逆的行变换不改变各行能够张成的范围，去掉零行也不改变它。

因此，CR 分解没有把一个矩阵任意切成两块，而是把“可用的输出方向”与“生成这些输出的系数关系”分开记录。核心列可以有不同的选择，所以分解一般不唯一；按行最简形的主元列来选取，是一种明确且便于计算的办法。

回到桥梁：四种荷载，只解两种核心工况

沿用第 3.7 节的连接矩阵 K，现在考虑一个含四种荷载的教学资料库：外侧两节点同时受力、该荷载加倍、右侧两节点同时受力，以及两种基本荷载叠加。把四个荷载向量并排放入 F，恰好得到刚才的数表：

$$F = \begin{bmatrix} 1 & 2 & 0 & 1 \\ 0 & 0 & 1 & 1 \\ 1 & 2 & 1 & 2 \end{bmatrix} = CR.$$

这里 C 记录两种独立荷载图样，R 记录每种工况如何组合。这只是本例选定的荷载库具有秩 2，并不表示真实桥梁只需要检查两种荷载。

用已保存的 LU 或 PLU 分解，只求两组核心响应 $Ku_{c_1} = c_1$ 、 $Ku_{c_2} = c_2$ ，得到

$$U_C = [u_{c_1} \quad u_{c_2}] = \begin{bmatrix} 1 & 3/4 \\ 1 & 3/2 \\ 1 & 5/4 \end{bmatrix}.$$

全部四组位移可以直接组合为 $X = U_C R$ 。因为

$$KX = K(U_C R) = (KU_C)R = CR = F,$$

所以第二组响应是第一组的 2 倍，第四组响应是两组核心响应之和。这是线性叠加与矩阵结合律的直接应用。




图 3.40: 从 CR 的列关系，读出工程工况之间的组合关系。

读图说明：虚线把荷载箭头连到相应节点。箭头向右，与第 3.7 节的模型一致；长度和旁边数值表示归一化荷载大小。

至此，三种分解服务于同一项计算：LU 保存固定结构的消元，PLU 为消元安排主元次序，CR 识别输入工况中可以复用的组合关系。真实工程背景带来重复求解的需要，而我们已经能用小矩阵完整展示这种需要怎样被数学回应。

从 LU 保存消元过程，到 CR 保存线性表示关系，矩阵分解都在做同一件事：把一项复杂作用组织成若干更易理解、也更易使用的作用。这种组织计算的方法，也会出现在每天与我们相遇的推荐系统中。下面用一个贯穿案例，把本章的运算重新连起来。

3.10 【应用案例】抖音推荐系统：从数据到预测

第 0 章把一条视频写成向量，第 1 章辨认视频向量之间的关系，第 2 章由偏好数据反求组合权重。现在，我们把许多用户和许多视频同时放到桌面上：过去发生过哪些互动？怎样据此估计下一次选择？当数据越来越多时，又怎样把计算分开、把已经做过的工作保存下来？这些问题，恰好把本章的矩阵运算连成一条线。

这个背景来自公开资料。抖音于 2025 年 3 月 30 日上线安全与信任中心，集中介绍推荐算法的原理与运行机制。官方《从零开始了解推荐系统》介绍了双塔召回与 Wide&Deep 模型；互动页面《什么是推荐系统》进一步把它们分别放在召回和排序环节中说明。这里讨论的是这些资料公开的基本原理，而不是一份完整的线上系统设计图。[9, 10, 8]

本节算例中的全部数值、权重、隐因子和矩阵均为教学简化模型，基于抖音公开的推荐算法原理进行简化，不代表抖音真实系统的内部实现。双塔的表征匹配、经典矩阵

分解的训练方法与后面的 CR 选读，各自回答不同的问题；我们会在它们相接的地方说明条件。




图 3.41: 推荐系统的公开流程，与本章五组矩阵运算的联系。

读图说明：上排概括官方公开的使用流程；下排依次列出五组数学联系。参数求解用本节的 ALS 小模型说明，虚线连接的 CR 是选读分析，二者都不是对抖音线上训练或去重流程的披露。

当你看完一条视频，却没有点赞；或者先收藏一段做菜教程，周末再回来照着做，这些行为传达的并不是同一条信息。官方《抖音算法的多目标平衡》说明，早期重点关注的完播等目标，已经扩展到收藏以及“收藏 + 复访”“关注 + 追更”“打开 + 搜索”等组合目标，以更好地刻画长期需求。《用户行为背后的算法推荐逻辑》也说明，行为价值要综合用户、作者与平台生态等因素，并随反馈调整。因而不能只看一个信号，也不能把某个行为的权重当作永久不变的常数。[12, 11]

先约定，矩阵的行对应用户，列对应视频。把完播、点赞、评论、分享、收藏分别记入同型矩阵 W, L, C_0, H_0, F ，就得到了五张用户—物品交互矩阵 (User-Item Interaction Matrix)。下标 ui 总指向同一对“用户 u —视频 i ”，因此可以逐个位置叠加：

$$R = w_W W + w_L L + w_C C_0 + w_H H_0 + w_F F.$$

这就是第 3.2 节的矩阵加法与数乘。权重决定每张数表在综合兴趣记录 R 中的贡献；相加之前，用户与视频的排列必须相同，各信号的量纲和记录方式也必须先作约定。

取 3 位用户、3 条视频，用 1 表示在观察期内记录到相应行为，用 0 表示没有记录到，构造如下小表：

$$W = \begin{pmatrix} 1 & 1 & 1 \\ 1 & 1 & 1 \\ 1 & 1 & 0 \end{pmatrix}, \quad L = \begin{pmatrix} 0 & 1 & 0 \\ 1 & 0 & 0 \\ 0 & 0 & 0 \end{pmatrix}, \quad C_0 = \begin{pmatrix} 0 & 0 & 0 \\ 0 & 0 & 0 \\ 0 & 0 & 1 \end{pmatrix},$$

$$H_0 = \begin{pmatrix} 0 & 0 & 0 \\ 0 & 0 & 1 \\ 0 & 0 & 0 \end{pmatrix}, \quad F = \begin{pmatrix} 0 & 0 & 1 \\ 0 & 0 & 0 \\ 0 & 0 & 0 \end{pmatrix}.$$

为方便手算，给五种信号的权重依次取 1,1,2,2,2，于是

$$R = W + L + 2C_0 + 2H_0 + 2F = \begin{pmatrix} 1 & 2 & 3 \\ 2 & 1 & 3 \\ 1 & 1 & 2 \end{pmatrix}.$$

例如， $r_{13} = 1 + 0 + 2 \times 0 + 2 \times 0 + 2 \times 1 = 3$ ，记录了用户 1 对视频 3 的完播和收藏。这里的 0 不表示“不喜欢”，3 也不是概率。**历史行为的加权记录，与未来行为概率的加权预测，是两个不同的对象。**

官方将推荐优先级概括为“综合预测用户行为概率 $\times$ 行为价值权重”。对多个行为，把这种思想写成一个便于理解的教学表达式，就是

$$\text{优先级}(u, i) = \sum_t w_t \hat{p}_t(u, i),$$

其中 $\hat{p}_t(u, i)$ 是预估的第 t 种行为发生概率；实际的权重与组合方式还有更多条件。这个式子解释了为什么要融合多种反馈，并不意味着只要把上面的 R 排序，就得到了抖音的推荐结果。[11]

要在海量视频中先找出值得进一步评估的一批候选，官方介绍了双塔召回模型 (Two-Tower Retrieval Model)：用户特征与内容特征分别经过两个模型，得到处于同一向量空间的表征，再按距离或相似程度匹配。把对象表示成供模型计算的向量，称为向量嵌入 (Embedding)；其中用于刻画潜在联系的分量，在本节模型中称为隐因子 (Latent Factor)。它们不必各自对应“美食”“篮球”等人为标签。[10]

双塔模型通常包含非线性层，不能把整座用户塔或内容塔直接认作线性映射。**本章抽取的是表征已经确定以后，怎样用矩阵完成匹配。**若暂时把两座塔简化成线性映射，它们也是从两端分别进入同一个空间的两条并行路线，并不是把用户塔接到内容塔后面。

把 m 位用户的表征逐行放入 $P \in \mathbb{R}^{m \times k}$ ，把 n 条视频的表征逐行放入 $Q \in \mathbb{R}^{n \times k}$ 。为了沿用第 3.3 节“先看复合，再看乘法”的思路，考虑下面两个确实线性的作用：

$$\mathbb{R}^n \xrightarrow{Q^T} \mathbb{R}^k \xrightarrow{P} \mathbb{R}^m.$$

前一个作用把视频的组合系数变为隐空间向量，后一个作用把这个隐向量变为对所有用

户的匹配分数。先作 Q^T ，再作 P ，复合的矩阵就是

$$\hat{R} = PQ^T, \quad (m \times k)(k \times n) = m \times n.$$

这是简化模型的原始匹配分数表，尚不是完整排序系统输出的概率表。用两塔输出的对应分量乘积之和打分，也是 TensorFlow Recommenders 官方双塔示例采用的基本做法。[14]

对于视频 i 的标准基向量 $e_i \in \mathbb{R}^n$ ，设 $q_i = (q_{i1}, \dots, q_{ik})^T$ ，则

$$Q^T e_i = q_i, \quad \hat{R} e_i = P q_i = q_{i1} P_{:,1} + \dots + q_{ik} P_{:,k}.$$

这正是矩阵乘法的列视角：视频 i 对所有用户的预测分数组成一列，这一列由 P 的各列线性组合而成。这里复合的是“选择视频的表征”和“计算各用户分数”两个作用。

现在取两个隐因子，仍使用 3 位用户、3 条视频：

$$P = \begin{pmatrix} 1 & 2 \\ 2 & 1 \\ 1 & 1 \end{pmatrix}, \quad Q = \begin{pmatrix} 1 & 0 \\ 0 & 1 \\ 1 & 1 \end{pmatrix}, \quad Q^T = \begin{pmatrix} 1 & 0 & 1 \\ 0 & 1 & 1 \end{pmatrix}.$$

逐行乘逐列，把每一个位置的计算都展开，就得到

$$\hat{R} = \begin{pmatrix} 1 \times 1 + 2 \times 0 & 1 \times 0 + 2 \times 1 & 1 \times 1 + 2 \times 1 \\ 2 \times 1 + 1 \times 0 & 2 \times 0 + 1 \times 1 & 2 \times 1 + 1 \times 1 \\ 1 \times 1 + 1 \times 0 & 1 \times 0 + 1 \times 1 & 1 \times 1 + 1 \times 1 \end{pmatrix} = \begin{pmatrix} 1 & 2 & 3 \\ 2 & 1 & 3 \\ 1 & 1 & 2 \end{pmatrix}.$$

这一组数特意构造成 $\hat{R} = R$ ，便于前后核对。真实数据通常只能被近似拟合，不能由这张小表推断真实推荐可以做到无误差预测。




图 3.42: 两端分别产生表征，一次矩阵乘法汇集全部配对分数。

读图说明：两座塔的内部用简洁方框表示；它们通常含非线性运算。图中精确展开的是固定输出表征后的矩阵乘法。全部数值为教学简化。

一般地，记用户和内容的列向量为 $\mathbf{u}, \mathbf{v}$ ，一种点积评分模型写作

$$s(\mathbf{u}, \mathbf{v}) = f(\mathbf{u}^T \mathbf{v}), \quad \mathbf{u}^T \mathbf{v} = \sum_{\ell=1}^k u_{\ell} v_{\ell}.$$

右边的和就是“对应分量乘积之和”，属于第7章将正式讨论的内积 (Inner Product)。本例取 $f(t) = t$ ；若希望把分数压到0与1之间，可以选 Sigmoid 函数 (Sigmoid Function) $f(t) = 1/(1 + e^{-t})$ ，但得到一个0到1之间的数，并不自动保证它就是准确的行为概率。

另一种常见匹配量是余弦相似度 (Cosine Similarity)。对非零向量，它等于

$$\frac{\mathbf{u}^T \mathbf{v}}{\sqrt{\sum_{\ell} u_{\ell}^2} \sqrt{\sum_{\ell} v_{\ell}^2}}.$$

它先考虑两个向量各自的长度，不能简单说成“对内积应用一个固定的单变量函数 f ”。若先把两向量分别除以各自长度，余弦相似度才成为归一化后向量的内积。官方资料介绍了距离匹配和余弦相似度，但没有把某一个固定的 f 公布为所有抖音双塔模型的统一公式。[10] 对当前的二维教学向量 $\mathbf{p}_u = (a, b)^T$ 、 $\mathbf{q}_i = (c, d)^T$ ，我们只需会算 $ac + bd$ 。

乘法的次序在这里也有了具体含义。本例中 PQ^T 是 3×3 的用户—视频分数表，而

$$Q^T P = \begin{pmatrix} 2 & 3 \\ 3 & 2 \end{pmatrix}$$

是隐空间上的一个 2×2 复合，已经不是同一张表；它把同序号的用户与视频行按这份人为排列配在一起求和，这种编号配对没有自动获得推荐意义。如果用户数与视频数不同， $Q^T P$ 甚至可能无法相乘。**交换次序之前，先检查空间、维度与数据所指的对象。**

召回只负责初筛。接下来的排序还要利用更多特征预估行为并综合其价值。抖音公开的 Wide&Deep 模型把两种能力结合起来：Wide 部分利用历史中已经出现的特征关联，Deep 部分学习更复杂的联系，以便推广到较少出现的组合。其“记忆与泛化”的分工，也与原始 Wide&Deep 论文的说明一致。[10, 13] 因此，上面算出的一个内积分数，可以帮助理解召回中的匹配，却不能代替整个排序模型。

换一个观察方向，同一张历史记录还有另一种用途。 R 的一行回答“这位用户怎样与各条视频互动”，而

$$R^T = \begin{pmatrix} 1 & 2 & 1 \\ 2 & 1 & 1 \\ 3 & 3 & 2 \end{pmatrix}$$


的一行回答“这条视频怎样被各位用户回应”。例如， R 的第3列 $(3, 3, 2)^T$ ，在 R^T 中成为第3行。转置没有产生新行为，只交换了整理数据的视角，这正是第3.5节的含义。

规模更大时，分块便不只是纸上的画线。抖音的官方体验页面说明，每天有上亿条内容产生，而进入一次推荐的只是其中很小的一部分；官方技术介绍也以亿级用户说明计算规模。[8, 10] 不应把全体用户与全部内容的所有配对永久铺成一张稠密大表。实际系统会利用稀疏记录、候选筛选与分布式计算；下面的分块乘法只说明**需要计算的那部分分数怎样拆开**。

设按用户行把 P 分为 P_1, P_2 ，按视频行把 Q 分为 Q_1, Q_2 ，则

$$P = \begin{pmatrix} P_1 \\ P_2 \end{pmatrix}, \quad Q = \begin{pmatrix} Q_1 \\ Q_2 \end{pmatrix}, \quad PQ^T = \begin{pmatrix} P_1 Q_1^T & P_1 Q_2^T \\ P_2 Q_1^T & P_2 Q_2^T \end{pmatrix}.$$

若 P_a 有 m_a 行、 Q_b 有 n_b 行，每个块都按 $(m_a \times k)(k \times n_b) = m_a \times n_b$ 计算。内侧的 k 个分量不仅数量要相同，排列与含义也必须对齐；否则数值能够相乘，得到的却不是所需分数。



教学划分：前两位用户、前两条视频各成一块；其余各成一块

图 3.43: 按用户和视频分块，各块可以分别计算，再按原位置拼接。

读图说明：图中块的面积不表示实际数据量。任务 A、B 展示同一用户块与两个视频块的计算，其余两个块同理；实际候选筛选可以使许多配对根本不必计算。

表征确定后，分数可以手算出来；更深一层的问题是，这些表征怎样从数据中得到？真实双塔可以通过深度学习训练。为了看清第3.4节的逆矩阵和第3.7节的分解怎样参与求解，我们另取一种经典的矩阵分解方法：交替最小二乘法 (Alternating Least Squares)，简称 ALS。它反复固定 Q 求 P ，再固定 P 求 Q 。Hu、Koren 与 Volinsky 的隐式反馈推荐论文给出了带置信权重的 ALS 方法；**这里用它解释矩阵求解，并不声称抖音公开的双塔或 Monolith 采用了本例的 ALS 训练**。[15]

所谓最小二乘法 (Least Squares)，就是让预测与目标的误差平方和尽量小。固定 Q

后，取一个所有位置都已给定目标值、且置信权重相同的教学数表，考虑

$$\sum_{u=1}^m \sum_{i=1}^n \left(r_{ui} - \sum_{\ell=1}^k p_{u\ell} q_{i\ell} \right)^2 + \lambda \sum_{u=1}^m \sum_{\ell=1}^k p_{u\ell}^2, \quad \lambda \geq 0.$$

后面的项称为正则化 (Regularization)：它抑制参数单纯为了贴合已有数据而变得过大。这个优化问题的推导留待后续学习；这里接受它得到的线性方程组，集中观察已经学过的矩阵结构：

$$(Q^T Q + \lambda I_k) P^T = Q^T R^T.$$

左边的系数矩阵是 $k \times k$ ，右边是 $k \times m$ ，每一列对应一位用户的求解任务。隐因子数 k 与用户、视频总量不是同一个量；例如上述论文讨论的典型因子数在 20 到 200 之间。这是论文所述模型的范围，不是抖音公开的参数。[15]

如果 $\lambda = 0$ 且 Q 的列线性无关，就可写出

$$P^T = (Q^T Q)^{-1} Q^T R^T.$$

逆矩阵作用在隐因子组成的小空间里，而不是去求一张亿级用户—视频表的逆。列不独立时，不能直接使用这个逆；若 $\lambda > 0$ ，则对任意非零 x ，

$$x^T (Q^T Q + \lambda I_k) x = \sum_i (Qx)_i^2 + \lambda \sum_{\ell} x_{\ell}^2 > 0,$$

从而系数矩阵的齐次方程只有零解，矩阵一定可逆。这个结论把“能写出一个逆”所需要的条件补全了。

在计算机中，**写成逆矩阵公式，并不意味着必须先把逆矩阵的所有元素算出来**。沿用本例的 Q, R ，取教学参数 $\lambda = 1$ ，记

$$H = Q^T Q + I_2 = \begin{pmatrix} 3 & 1 \\ 1 & 3 \end{pmatrix}, \quad B = Q^T R^T = \begin{pmatrix} 4 & 5 & 3 \\ 5 & 4 & 3 \end{pmatrix}.$$

求新一轮的用户参数，就是解 $HZ = B$ ，其中 $Z = (P^{\text{new}})^T$ 。对增广矩阵作一次初等行变换，三组右端项同时得到处理：

$$\left(\begin{array}{cc|ccc} 3 & 1 & 4 & 5 & 3 \\ 1 & 3 & 5 & 4 & 3 \end{array} \right) \xrightarrow{r_2 \leftarrow r_2 - \frac{1}{3}r_1} \left(\begin{array}{cc|ccc} 3 & 1 & 4 & 5 & 3 \\ 0 & 8/3 & 11/3 & 7/3 & 2 \end{array} \right).$$

第 3.6 节的倍加变换，在这里就是对所有用户复用同一个消元动作。把倍数保存下来，便

得到

$$H = \underbrace{\begin{pmatrix} 1 & 0 \\ 1/3 & 1 \end{pmatrix}}_{L_H} \underbrace{\begin{pmatrix} 3 & 1 \\ 0 & 8/3 \end{pmatrix}}_{U_H}.$$

这里给两个因子加下标 H ，以免与前面表示点赞的矩阵 L 混淆。先前代、再回代：

$$L_H Y = B, \quad U_H Z = Y, \quad Y = \begin{pmatrix} 4 & 5 & 3 \\ 11/3 & 7/3 & 2 \end{pmatrix}, \quad Z = \begin{pmatrix} 7/8 & 11/8 & 3/4 \\ 11/8 & 7/8 & 3/4 \end{pmatrix}.$$

例如第一列先由 $(8/3)z_{21} = 11/3$ 得 $z_{21} = 11/8$ ，再由 $3z_{11} + z_{21} = 4$ 得 $z_{11} = 7/8$ 。同一份 LU 分解处理了三位用户；只要 Q, λ 以及观测权重结构不变，就可以继续复用。正则化使新参数与前面特意设定的 P 不同，这是模型目标改变后的正常结果。

真实行为数据常有缺失，各位置的可信程度也不同。Hu 等人的方法给不同用户配置相应的置信权重，此时各用户的系数矩阵一般不同，不能无条件共用一份 LU 分解；“没有观看”也不能直接当作零分评价。[15] 本例采用完整小表和相同权重，正是为了单独呈现“一次分解、多个右端项”的结构。

若通用消元中出现很小的主元，可以按第 3.8 节的选读方法换行，写成 $\Pi H = L_H U_H$ ，同时把右端项换成 ΠB ；这里用 Π 表示置换矩阵，以免与用户表征矩阵 P 混淆。选主元有助于控制消元中的数值误差，但**换行不能消除矩阵本身接近奇异的问题**。仍需检查数据与正则化参数，不能把 PLU 看作所有不稳定问题的自动补救。[28]

除了怎样更新数值，实时推荐还要解决怎样迅速找到这些数值。字节跳动研究者于 2022 年发表的 Monolith 论文，重点介绍了无冲突的嵌入表 (Embedding Table) 及在线训练架构：用能区分不同特征 ID 的哈希表保存嵌入，通过频率过滤和过期机制控制内存，并将新反馈训练得到的参数增量同步到服务端。论文报告了在 BytePlus Recommend 的落地，也讨论了 DeepFM 与多塔实验模型；它并没有把整个系统规定成一个用户—视频内积公式。[20]

从数学上看，一张有限的嵌入表可以记成 $E \in \mathbb{R}^{N \times d}$ ，每个已登记的 ID 对应一个行向量。实际的 ID 可以表示用户、视频以及其他特征，系统也可以有多张表。**下面只取两位用户、两条视频，所以教学表中才有 $N = 4$ 。取 $d = 2$ ，抽取前面表征中的前两位**

用户与前两条视频，按“用户 1、用户 2、视频 1、视频 2”的行次序得到

$$E = \begin{pmatrix} 1 & 2 \\ 2 & 1 \\ 1 & 0 \\ 0 & 1 \end{pmatrix}.$$

行号只是这张教学表的排列。实际的用户 ID 与视频 ID 还要区分类别，例如“用户:1”和“视频:1”不能因为都带一个 1 就共享同一项。所谓无冲突，所要避免的正是不同特征 ID 被迫共用同一个嵌入所造成的信息混淆。



图 3.44: 按 ID 查到行向量，再把取得的向量交给评分模型。

读图说明：这是一张受 Monolith 嵌入表思想启发的 4 行教学表，不是其真实哈希表布局。数值与内积评分头均为教学设定，查表和评分是两个不同的操作。

把取出的行转成列向量，记作 $e_u = (E_{u,:})^T$ 、 $e_i = (E_{i,:})^T$ 。沿用本例的内积评分，便有 $\hat{r}_{ui} = e_u^T e_i$ 。四个配对可以全部算完：

$$\begin{aligned} \hat{r}_{11} &= 1 \times 1 + 2 \times 0 = 1, & \hat{r}_{12} &= 1 \times 0 + 2 \times 1 = 2, \\ \hat{r}_{21} &= 2 \times 1 + 1 \times 0 = 2, & \hat{r}_{22} &= 2 \times 0 + 1 \times 1 = 1. \end{aligned}$$

这里 u, i 在表中分别按用户类、视频类 ID 索引；右下标 11, 12, 21, 22 则沿用用户—视频分数表的编号。一次更新可以改变表中的少数行，后续查表就能用到新向量。小表所展示的，是“按 ID 取参数，再参与计算”的组织方式；Monolith 的贡献还包括如何让这种组织方式在大规模在线训练中可靠地运行。

最后，把目光从下一次预测收回到已经形成的数表：哪些列带来了新的方向，哪些列能够由已有的列表示？本小节对应的 CR 分解为选读内容，不做考核要求，仅作为理解矩阵秩与列空间的直观工具。我们仍用同一张 R ，不展开第 3.9 节已经讲过的完整消

元流程，只观察其结构：

$$R = \begin{pmatrix} 1 & 2 & 3 \\ 2 & 1 & 3 \\ 1 & 1 & 2 \end{pmatrix} \longrightarrow \begin{pmatrix} 1 & 0 & 1 \\ 0 & 1 & 1 \\ 0 & 0 & 0 \end{pmatrix}.$$

行最简形的主元在第 1、2 列。必须回到原矩阵取出这两列，组成 C ；把行最简形的非零行组成右因子。为了不与交互矩阵 R 重名，将 CR 分解的右因子记为 Γ ，于是

$$R = C\Gamma, \quad C = \begin{pmatrix} 1 & 2 \\ 2 & 1 \\ 1 & 1 \end{pmatrix}, \quad \Gamma = \begin{pmatrix} 1 & 0 & 1 \\ 0 & 1 & 1 \end{pmatrix}.$$

第 3 列等于前两列之和，所以 C 的列空间就是 R 的列空间。两条主元列对应的“代表性视频”，代表的是这份用户交互数表中的独立列方向，不是内容质量的评奖，也不表示两条基础视频可以替代其他视频本身。

$$\begin{array}{ccc} \boxed{C = \begin{pmatrix} 1 & 2 \\ 2 & 1 \\ 1 & 1 \end{pmatrix}} & \times & \boxed{\Gamma = \begin{pmatrix} 1 & 0 & 1 \\ 0 & 1 & 1 \end{pmatrix}} & = & R = \begin{pmatrix} 1 & 2 & 3 \\ 2 & 1 & 3 \\ 1 & 1 & 2 \end{pmatrix} \\ \text{原表中的两列} & & \text{三列各自的配比} & & \text{原交互数表} \end{array}$$

$r_3 = 1r_1 + 1r_2$ ：复用的是列关系

图 3.45: CR 把独立列方向与各列的组合系数分开保存。

读图说明：本例恰好有 $C = P$ 、 $\Gamma = Q^T$ ，因为教学数据被特意构造秩 2；一般的学习所得隐因子并不必由原矩阵的主元列构成。此图仅为选读，不作考核要求。

这给“去掉重复信息”一个准确的数学切口：在该教学数表内，保存基础列和组合系数，就能重建其余列。但两段不同视频可能恰好得到相似互动，近似相关也不等于精确的线性相关，因此不能据此宣称平台不必保存每条视频的特征，或已经用 CR 完成内容去重。**CR 保存的是数表的线性关系；召回与排序则是先筛候选、再综合打分的两个任务。**前者有助于理解表示与复用，不能与后者逐一等同。

从几张行为表相加，到两组表征相乘；从转置改变观察方向，到分块安排并行计算；从初等变换求解参数，到用 LU 保存消元、用 CR 辨认可复用的列关系，本章的运算都有了具体的工作对象。真实推荐还需要非线性模型、统计学习和工程系统，但我们已经能够把其中的线性部分讲清、算清。带着这条“数据怎样组织、映射怎样复合、计算怎样分解”的线索，再回看本章小结，矩阵便不再是一串孤立的规则。

本章小结

在第 2 章，矩阵首先是一张整理方程组的数表：把系数排好，便能有次序地消元。本章则从这张数表背后追问：它究竟记录了什么，又为什么能够参与加法、乘法与分解？从章首的语言模型，到章末的视频推荐；从平面上的旋转，到桥梁模型的重复求解，我们始终围绕同一条主线展开：**矩阵是线性映射在标准基下的代数表示，矩阵运算应当回到映射的作用中理解。**

这条主线的起点，是“基的像决定整个映射”。任意输入都能唯一地展开为标准基的线性组合，而线性映射保持组合系数。因此，只要知道每个基向量被送到哪里，就知道全部输入会得到什么输出。把这些像按列排好，便得到矩阵。它的第 k 列记录 $T(e_k)$ ，列数对应输入空间的维数，行数对应目标空间的维数。一张有限大小的数表能够描述无穷多个输入的作用，依靠的正是这份线性结构；计算 Ax ，就是用输入分量组合已经记录好的各列。

沿着这个解释，矩阵的运算便各有来由。同一个输入交给两个映射，把输出相加，得到矩阵加法；把输出统一放大，得到矩阵数乘；把前一次的输出交给后一次处理，得到矩阵乘法。 AB 表示先用 B 、再用 A ，中间尺寸相等，是因为两个作用必须接得起来。行乘列的规则由此产生，交换次序却可能改变结果。结合律允许我们改变计算的分组，不允许任意调换因子的顺序；这些区别都能在“先旋转还是先伸缩”的图形中看见。

乘法还教会了我们从不同尺度读同一张数表。看一个元素，是一行与一列对应相乘再相加；看一整列，是左矩阵各列的线性组合；看一整行，是右矩阵各行的线性组合。再换成外积的眼光，一列乘一行便生成一整张矩阵，各张外积数表相加又恢复原来的乘积。灯带案例中的亮度表，正是一个方向与一组时间系数共同生成的结果。**这些不是四套彼此分离的算法，而是同一线性作用的四种组织方式**，也为后面理解 LU 与 CR 怎样重建矩阵准备了共同语言。

复合之后，自然要问能否撤销。逆矩阵记录恢复输入的规则；对方阵而言，它存在，意味着每个目标都恰好对应一个输入。复合的撤销必须反序，所以 $(AB)^{-1} = B^{-1}A^{-1}$ 。转置则把同一组系数按行列互换重新组织，并不等于恢复输入。分块进一步把输入、输出分组，让大矩阵中的局部联系显露出来。无论按元素还是按块计算，都要先检查维数，再辨认顺序；矩阵的形状、每一行列所指的对象，与其中的数字同样重要。

初等矩阵把这些认识重新接回消元。交换、倍乘、倍加，都可以看成接在原映射之后的可逆调整，因而初等行变换对应左乘。对系数矩阵与右端项同步施加调整，才保留原方程组的解。把同样的操作作用于 $[A | E]$ ，可以记录逆矩阵；把一连串消元的倍数与最终结果分别保存，就走到了 LU 分解。至此，第 2 章写在方程旁边的操作，已经成为能够相乘、能够撤销、也能够存储的数学对象。

港珠澳大桥的工程背景，让“为什么要保存消元”有了具体落点。在本章自拟的三节点模型中，连接关系固定，荷载改变，只会改变 $Ku = f$ 的右端项。于是一次分解 $K = LU$ ，可以服务于多个工况：先解下三角方程，再解上三角方程，而不必每次从头消元。电阻网络与稳态导热的简化模型，又把不同的物理量带到了同一种数表面前。**LU 的价值，在于分清哪些工作随输入改变，哪些工作值得保存和复用。**写出逆矩阵可以说明解的理论形式，实际求解却往往直接使用分解，更贴近计算任务本身。

两节选读从不同方向延伸了这一思想。PLU 通过换行选择主元，把消元顺序也纳入计算设计；方程怎样排列，右端项就怎样同步排列。它提醒我们，纸面上的精确运算进入计算机之后，还要面对有限精度。CR 则回到第1章的线性表示：从原矩阵取出独立的核心列，用另一张矩阵记录各列的组合系数。LU 保存消元，CR 保存列关系，二者回答的问题不同，却都让复杂数表的内部组织变得可见。这部分拓展不增加主线的考核要求，但能帮助我们理解，矩阵分解为何不只是一种形式上的拆写。

章末的推荐案例把运算重新放回数据之中。同型行为表的加权叠加对应加法与数乘，固定用户和视频表征后的配对评分对应矩阵乘法，转置与分块改变数据的观察和计算方式，参数求解中的多个右端项又呼应了分解复用。真实系统还包含非线性模型与统计学习，不能被一张小矩阵替代；但借助这些教学模型，我们已经能够辨认其中明确的线性部分，说明每个乘积在计算什么、每组系数从哪里来。这也回应了章首的疑问：宏大的应用之所以能够进入数学课堂，是因为其中一部分复杂联系可以被抽取为清楚的线性关系。

从手算消元到保存分解，从逐个求值到成批组织数据，计算能力的进步既来自工具，也来自对结构的理解。学完本章，应当留下的不只是几条运算公式，更是一种追问的习惯：这个矩阵表示什么作用，这次运算对应什么过程，哪些信息可以重用，哪些条件不能省略？下一章，我们将沿着这些问题深入线性映射本身，考察哪些输入得到相同输出、哪些方向被送到零、哪些目标能够达到，再讨论更换基以后同一个作用如何改变表示。**从会计算一个映射，到看清一个映射的结构，是我们接下来要走的一步。**

第 4 章

线性变换与基变换：矩阵背后的变换

介绍性实例 阿波罗制导计算机： 人类最伟大的航行，靠两类矩阵运算完成

1969 年 7 月 20 日，阿波罗 11 号的制导计算机（AGC）正在以每秒约 2000 次的频率，反复执行着两类最基础的运算。

这台计算机的运算能力，还不如今天一部最便宜的手机。它的内存只有约 4KB，主频约 0.043MHz，所有的程序都靠手工编织的磁芯存储器运行。但就是这样一台机器，要把三名宇航员从地球轨道送到月球，再精准地送回地球。

在它每秒执行的成千上万条指令中，有两类运算从未停止过。

第一类，是姿态控制运算。

当飞船需要调整方向时，姿态发动机点火，飞船绕某个轴精确转过一个角度。飞船的姿态向量——描述它当前朝向的那组数——真实地发生了改变。从原姿态到新姿态，这个变化本身，就是一个线性变换。

旋转、缩放、投影，所有真实发生的向量演化，都可以用线性变换来精准描述。而矩阵，就是它的代数载体。给定一个矩阵 A ，它就代表了一种确定的变换规则：输入一个向量 x ，输出一个新的向量 Ax 。AGC 里存储的每一个姿态控制矩阵，都对应着一次真实的物理动作。

第二类，是参考系切换运算。

飞船在飞行过程中，需要不断在不同参考系之间切换：从地心惯性系切换到近地轨道系，从飞船本体系切换到月心着陆系。每一次切换，飞船本身的运动状态没有任何改变——它没有加速，没有旋转，没有受到任何新的力。改变的只是我们用来描述它的那组基。

同一个物理量，换一组基，坐标就变了。这就是基变换。

基变换不是向量真的变了，而是我们的观察视角变了。它回答的问题是：同一个向量，在不同的坐标系下，分别长什么样？这两组坐标之间，又该怎样互相换算？

读图准备：把坐标轴想成几把尺子 转动桌上的箭头，而把尺子留在原处，箭头本身就变了；把箭头留在原处，只转动用来测量的尺子，同一支箭头就会有另一组读数。前者帮助我们理解线性变换 (Linear Transformation)，后者帮助我们理解基变换 (Change of Basis)。两幅数学图分别只讲一件事：先在三维空间看箭头绕轴旋转，再在平面上看一支不动的箭头怎样有两组坐标。

史实说明：存储容量、时钟与运算速度 上文的性能数字须区别口径阅读。阿波罗 Block II 制导计算机有 2048 个字的可擦写存储器（按每字 16 位计约 4KB），另有 36864 个字的固定磁芯绳存储器；手工编织主要对应后者。其内部时钟约为 1MHz，0.043MHz 不能作为其主频；不同指令耗时不同，“每秒约 2000 次”也不能作为统一的指令执行速度。参见文献 [22] 第 2.3.1.1 节。

AGC 的导航程序里，大量运算都在做这件事。它把同一个位置向量，在多个参考系之间反复转换，确保无论从哪个角度看，飞船都在正确的位置上。




图 4.0a: 从地球到月球：航行背后的数学与手艺。复古线描插画为教学创作，飞行轨迹、天体大小与距离均为示意。

一、旋转：坐标轴不动，箭头真的转过去了。




图 4.0b: 固定同一组 $\mathbb{R}^3$ 坐标轴，向量绕 z 轴旋转。浅色虚线只保留原方向作比较；实线箭头的终点发生了改变。

$$A = \begin{pmatrix} 0 & -1 & 0 \\ 1 & 0 & 0 \\ 0 & 0 & 1 \end{pmatrix}, \quad v' = Av.$$

读图说明 这里用方向向量代表飞船朝向的一部分。旋转中心取作原点，观察用的坐标轴固定；随船转动的本体系不能同时说成“固定不动”。向量的长度保持不变， z 分量也保持不变。

二、换基：箭头没动，只换一组“尺子”。

下面两幅图画的是同一支向量 r 。请先看起点 O 和终点 R ：它们在两个小图中的位置完全相同。右图只把坐标轴转过 45° ，因此沿新轴量出的两个分量变了。




图 4.0c: 同一向量，两组坐标。两幅图中的实线箭头完全相同；虚线表示沿各自坐标轴的分量分解。右图沿 m_2 的反方向走，所以第二个坐标为负。

在左图，沿 e_1 走 3 个单位，再沿 e_2 走 1 个单位，就到达 R 。在右图，先沿 m_1 走 $2\sqrt{2}$ 个单位，再沿 m_2 的反方向走 $\sqrt{2}$ 个单位，仍到达同一个 R 。换的是分解方式，箭头并没有跟着坐标轴转动。

把新基向量在旧基下的坐标按列排在一起，就得到矩阵 P ：

$$P = \frac{1}{\sqrt{2}} \begin{pmatrix} 1 & -1 \\ 1 & 1 \end{pmatrix}, \quad [r]_E = P[r]_M, \quad \boxed{[r]_M = P^{-1}[r]_E}.$$

同样的方法也适用于三维空间：把两组平面坐标轴换成两组三维坐标轴， P 就相应成为一个三阶矩阵。

从换基到真实参考系 图中的两组基共用原点。地心与月心则是两个不同的原点；若把飞船的地心位置改写为月心位置，还须先减去月心的地心位置 c_E ，再换基，即 $r_M = P^{-1}(r_E - c_E)$ 。因此，“同一自由向量的分量换算”与“同一点相对于不同原点的位置坐标换算”要分清。

线性变换：基不动，向量动。 基变换：向量不动，基动。

两类运算，同一套语言——矩阵。

载人登月这种人类工程巅峰里最底层的操作，本质就是线性代数最核心的两类操作：线性变换描述「向量本身的变化」。基变换描述「观察视角的变化」。

这两件事，看起来相似，实则完全不同。混淆它们，是学习线性代数时最容易犯的错误之一。而区分它们，恰恰是理解矩阵、理解线性代数的关键一步。

更值得深思的是：阿波罗 11 号的导航计算机，从来没有“看见”过月球。它只看见矩阵。它只知道，当前的状态向量，经过某个矩阵作用后，变成了新的状态向量。它只知道，同一个向量，在不同的基下，对应着不同的坐标。但它就是靠这些矩阵运算，把人类送上了月球。

这引出了一个更根本的问题：我们究竟是在变换向量，还是在变换我们描述向量的方式？

在阿波罗 11 号之前，这个问题是哲学家的。在阿波罗 11 号之后，它成了工程师每天都要面对的问题。

本章我们就从几何直观出发，先讲线性变换的定义、矩阵表示与运算对应，再讲基变换的原理与相似矩阵。我们会看到，同一个线性变换，在不同基下对应着不同的矩阵；而这些矩阵之间，又由相似变换联系起来。它们描述的是同一个变换，只是穿了不同的“坐标系外衣”。

完成这一章，你对矩阵的理解将从“解方程的工具”，升级为“描述世界的框架”。

矩阵背后的人 当我们说“矩阵把人类送上月球”，也应看见矩阵背后的人：设计轨道、编写程序、编织存储器、校核数据，以及在关键时刻作出判断的人。一个正负号、一个单位、一组基的约定，都需要被清楚地表达并反复核对。数学的严谨，在这里成为人与人之间能够协作、能够信任的一种语言。

本章路线

屏幕上的图形转过一个角度，或被拉长、压扁，我们看到的是形状，计算机处理的却是顶点的坐标。第三章已经说明：知道标准基向量的像，就能写出线性映射的矩阵；矩阵的乘法，则把连续发生的作用接起来。本章从这些可见的变化出发，追问两个更深的问题：**哪些输入的差别会在变换中消失？哪些输出是这项变换能够产生的？**

这两个问题将分别引出零空间与值域。它们把第二章的消元计算接到第五章的解的结构：求解 $Ax = b$ ，既要问目标 b 能否到达，也要问到达它的输入是否唯一。第 4.1 至 4.4 节是本章主线，依次走向映射的内部结构、换基与相似矩阵；第 4.5 至 4.6 节为选读，分别讨论坐标变换的工程语言（以钱学森弹道为例）、秩与零度的严格证明；第 4.7 节以图像压缩作为选读应用案例。

本章始终在实数空间中讨论。矩阵作用于列向量， $A_{j,k}$ 的第一个下标表示行，第二个下标表示列； E_n 表示 n 阶单位矩阵，尺寸明确时简记为 E 。

4.1 线性变换的几何直观与零空间

4.1.1 计算机图形学中的线性变换

把图形看成一组顶点

在计算机图形学中，绕原点旋转、按坐标方向缩放，以及剪切等基本形变，都可以逐个顶点实施矩阵乘法。例如，一张平面图形有四个顶点，就把四个位置向量并排放进矩阵 X ，用同一个矩阵 A 左乘： AX 的四列便是变换后的顶点。这种统一处理之所以可行，依靠的是线性映射保持线性组合的性质。平移需要稍后的齐次坐标；任意非线性形变与整个渲染过程，则不能一概归结为同一个线性映射。

先取单位正方形，按绕边界的顺序记录顶点：

$$X = \begin{pmatrix} 0 & 1 & 1 & 0 \\ 0 & 0 & 1 & 1 \end{pmatrix}.$$

顶点之间的边也会随之移动。因为线段上的点可写成 $(1-t)u + tv$ ，其中 $0 \leq t \leq 1$ ，由线性性质可得

$$T((1-t)u + tv) = (1-t)T(u) + tT(v).$$

因此，一条边仍被送成连接两端点像的线段；如果两端点的像重合，整条边就缩成一个点。**保持线性组合，并不保证不同的点仍然分开。**下面五类变换，正好让我们看见这两种可能。

缩放：沿两个方向分别改变尺度

屏幕上的同一个图标，可能需要单独拉宽或拉高。我们先把横、纵两个方向分开处理，再看它们怎样共同作用于整个图形；这正是对角矩阵最直接的几何含义。

缩放变换 (Scaling Transformation) 把横坐标乘 s_x ，纵坐标乘 s_y 。标准基向量的像为

$$T(e_1) = (s_x, 0)^T, \quad T(e_2) = (0, s_y)^T.$$

利用 $x = xe_1 + ye_2$ 与线性组合的保持性，所需规则及矩阵便是

$$T(x, y) = (s_x x, s_y y)^T, \quad A = \text{diag}(s_x, s_y) = \begin{pmatrix} s_x & 0 \\ 0 & s_y \end{pmatrix}.$$




图 4.1: 缩放：两个方向分别伸长。

读图说明：灰色虚线为原图形，实线为变换后的像；两幅子图采用相同坐标比例。

这里以及下文的 $T(x, y)$ ，是 $T((x, y)^T)$ 的简写。对 $u = (u_1, u_2)^T$ 、 $v = (v_1, v_2)^T$ ，直接代入可得

$$\begin{aligned} T(u + v) &= \begin{pmatrix} s_x(u_1 + v_1) \\ s_y(u_2 + v_2) \end{pmatrix} \\ &= \begin{pmatrix} s_x u_1 \\ s_y u_2 \end{pmatrix} + \begin{pmatrix} s_x v_1 \\ s_y v_2 \end{pmatrix} = T(u) + T(v). \end{aligned}$$

数乘性质同理由分配律得到，因此这个坐标规则确实定义了线性映射，而不只是看起来像一个几何变形。

取 $s_x = 2, s_y = 3$ ，则

$$AX = \begin{pmatrix} 0 & 2 & 2 & 0 \\ 0 & 0 & 3 & 3 \end{pmatrix}.$$

原来横、纵边长都为 1 的正方形，变成横边长 2、纵边长 3 的矩形。比如 $(1,1)^T$ 被送到 $(2,3)^T$ ，而 $(1,0)^T + (0,1)^T$ 的像，恰好也是两条变换后边向量之和。

正的缩放因子表示同向伸缩，负的因子还会翻转相应坐标方向。因子为 0 时则发生完全压缩。例如 $s_x = 2, s_y = 0$ 把整个平面压到 x 轴上。只有 $s_x \neq 0$ 且 $s_y \neq 0$ 时，缩放才能用分别除以两个因子的办法恢复原输入。这个条件稍后会成为判断零空间的关键。

旋转：改变方向，保留长度和夹角

把平面绕原点逆时针转过 θ 。从单位圆看， e_1 的像为 $(\cos \theta, \sin \theta)^T$ ， e_2 的像为 $(-\sin \theta, \cos \theta)^T$ 。按第三章“基的像作列”的规则，得到

$$A_\theta = \begin{pmatrix} \cos \theta & -\sin \theta \\ \sin \theta & \cos \theta \end{pmatrix}, \quad T(x, y) = (x \cos \theta - y \sin \theta, x \sin \theta + y \cos \theta)^T.$$




图 4.2: 旋转：绕原点逆时针转过 60° 。

读图说明：灰色虚线为原图形，实线为变换后的像；两幅子图采用相同坐标比例。虚线弧从正 x 轴转向第一列的像。

这不是另背一套坐标口诀：第一列记录横向单位箭头转到哪里，第二列记录纵向单位箭头转到哪里，再用 x, y 组合两列。

把 cu 代入，两项中的 c 都能提出，因此

$$T(cu) = c \begin{pmatrix} u_1 \cos \theta - u_2 \sin \theta \\ u_1 \sin \theta + u_2 \cos \theta \end{pmatrix} = cT(u).$$

可加性同样来自各坐标表达式的分配律。又由 $\cos^2 \theta + \sin^2 \theta = 1$ ，展开两个输出分量的平方和，有

$$(x \cos \theta - y \sin \theta)^2 + (x \sin \theta + y \cos \theta)^2 = x^2 + y^2.$$

所以长度不变。将同样计算用于两个向量的差，可知两点间距离也不变；于是由三角形的边长关系，夹角也保持不变。

图 4.2 中取 $\theta = 60^\circ$ 。第一列的像为 $(\frac{1}{2}, \frac{\sqrt{3}}{2})^T$ ，小数 $(0.5, 0.866)^T$ 只是近似；图形的

边长仍为1。再取 $\theta = 90^\circ$, $A_\theta = \begin{pmatrix} 0 & -1 \\ 1 & 0 \end{pmatrix}$, 故


$$T(1,0) = (0,1)^T, \quad T(1,1) = (-1,1)^T.$$

正方形整体转动, 既没有拉长, 也没有压扁。将角度改为 $-\theta$ 就能转回去; 任意向量若旋转后为零, 原先也只能为零。

剪切: 高度不变, 横向偏移随高度改变

剪切变换 (Shear Transformation) 可以想成推动一叠纸的上部: 底边固定, 越高处横向移动得越多。令偏移量为原高度的 k 倍, 则

$$T(x,y) = (x + ky, y)^T, \quad T(e_1) = e_1, \quad T(e_2) = (k, 1)^T, \quad A = \begin{pmatrix} 1 & k \\ 0 & 1 \end{pmatrix}.$$



$$A = \begin{pmatrix} 1 & 1 \\ 0 & 1 \end{pmatrix}, \quad A \begin{pmatrix} 0 \\ 1 \end{pmatrix} = \begin{pmatrix} 1 \\ 1 \end{pmatrix}.$$

图 4.3: 剪切: 底边不动, 上边向右移动。

读图说明: 灰色虚线为原图形, 实线为变换后的像; 两幅子图采用相同坐标比例。

第二个分量没有改变; 第一个分量同时接收原来的横坐标和由高度带来的偏移。对任意 u, v ,

$$T(u+v) = \begin{pmatrix} u_1 + v_1 + k(u_2 + v_2) \\ u_2 + v_2 \end{pmatrix} = T(u) + T(v),$$


且 $T(cu) = cT(u)$, 所以剪切仍然线性。

取 $k = 1$, 单位正方形的四个顶点依次变成 $(0,0)$ 、 $(1,0)$ 、 $(2,1)$ 、 $(1,1)$, 围成平行四边形。例如 $T(0,1) = (1,1)^T$, 但底边上的每一点 $(x,0)$ 保持不动。图形虽然变斜, 信息却没有丢失: 从输出 (p,q) 先读出 $y = q$, 再算 $x = p - kq$, 就能唯一找回输入。相应的逆矩阵为 $\begin{pmatrix} 1 & -k \\ 0 & 1 \end{pmatrix}$, 对任意实数 k 都存在。

反射：把一侧翻到另一侧

反射变换 (Reflection) 保持镜面上的点不动，将垂直于镜面的方向反向。关于 x 轴、关于 y 轴、关于直线 $y = x$ 的反射，分别为

反射轴	$T(x, y)$	A
x 轴	$(x, -y)^T$	$\begin{pmatrix} 1 & 0 \\ 0 & -1 \end{pmatrix}$
y 轴	$(-x, y)^T$	$\begin{pmatrix} -1 & 0 \\ 0 & 1 \end{pmatrix}$
$y = x$	$(y, x)^T$	$\begin{pmatrix} 0 & 1 \\ 1 & 0 \end{pmatrix}$



$$A = \begin{pmatrix} 1 & 0 \\ 0 & -1 \end{pmatrix}, \quad A \begin{pmatrix} 2 \\ 3 \end{pmatrix} = \begin{pmatrix} 2 \\ -3 \end{pmatrix}.$$

图 4.4: 反射：正方形关于 x 轴翻到下方。

读图说明：灰色虚线为原图形，实线为变换后的像；两幅子图采用相同坐标比例。绿色虚线标出保持不动的镜像轴。

这些矩阵仍由两个标准基向量的像按列排出。以关于 x 轴反射为例，

$$T(\mathbf{u} + \mathbf{v}) = (u_1 + v_1, -u_2 - v_2)^T = T(\mathbf{u}) + T(\mathbf{v}),$$

数乘性质也成立。其余两种反射分别只改变一个分量的符号或交换两个分量，验证方法相同。

数值上， $(2, 3)^T$ 关于 x 轴的像是 $(2, -3)^T$ ；再反射一次便回到 $(2, 3)^T$ 。一般地，这三种反射均满足

$$T(T(\mathbf{u})) = \mathbf{u}, \quad A^2 = E_2,$$

所以逆变换就是自身。要分清两件事：可加性、齐次性说明它是线性映射；反射两次恢复原状说明它可逆，后一个性质不能单独替代线性检验。

正交投影：留下一个方向，舍去另一个方向

向 x 轴作正交投影 (Orthogonal Projection), 相当于从每一点沿竖直方向落到 x 轴。它保留横坐标、舍去纵坐标：

$$T(x, y) = (x, 0)^T, \quad T(e_1) = e_1, \quad T(e_2) = \mathbf{0}, \quad A = \begin{pmatrix} 1 & 0 \\ 0 & 0 \end{pmatrix}.$$




图 4.5: 投影：正方形被压成 x 轴上的线段。

读图说明：灰色虚线为原图形，实线为变换后的像；两幅子图采用相同坐标比例。竖直虚线箭头表示高度被舍去， y 轴上的输入都被送到原点。

相应地，向 y 轴的投影矩阵是 $\begin{pmatrix} 0 & 0 \\ 0 & 1 \end{pmatrix}$ 。直接检查，例如

$$T(u + v) = (u_1 + v_1, 0)^T = T(u) + T(v), \quad T(cu) = cT(u),$$

可知投影也完全符合线性性质。线性不等于可逆，投影正是最重要的提醒。

如果目标是与 x 轴夹角为 α 的过原点直线，取沿直线的单位方向 $d = (\cos \alpha, \sin \alpha)^T$ 。投影点形如 td ；由垂足条件，原向量减去投影后的剩余部分与直线垂直，即

$$(x - t \cos \alpha) \cos \alpha + (y - t \sin \alpha) \sin \alpha = 0.$$

利用单位方向的长度为 1，解得 $t = x \cos \alpha + y \sin \alpha$ ，所以

$$T(x, y) = (x \cos \alpha + y \sin \alpha) \begin{pmatrix} \cos \alpha \\ \sin \alpha \end{pmatrix}, \quad A = \begin{pmatrix} \cos^2 \alpha & \cos \alpha \sin \alpha \\ \cos \alpha \sin \alpha & \sin^2 \alpha \end{pmatrix}.$$

这里仅用到了高中平面向量的垂直条件，第 7 章会系统讨论这种正交关系。两分量都是 x, y 的固定线性组合，故仍保持加法与数乘。

现在回到 x 轴投影。 $(3, 4)^T$ 被送到 $(3, 0)^T$ ， $(3, -2)^T$ 也被送到同一个点。只看到输出 $(3, 0)^T$ ，就无法知道原来的高度。这是**信息丢失**：整条竖直直线上的输入，在输出中只留下一个点。

把它写成方程组，更能看清缺少了什么：

$$\begin{pmatrix} 1 & 0 \\ 0 & 0 \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \end{pmatrix} = \begin{pmatrix} b_1 \\ b_2 \end{pmatrix} \iff x_1 = b_1, \quad 0 = b_2.$$

若 $b_2 \neq 0$ ，方程组无解；若 $b_2 = 0$ ， x_2 任取，便有无穷多解。几何里的“压缩”，在方程组中留下了自由变量；几何里的“只能落在轴上”，在方程组中留下了对右端项的限制。

三维图形学中的线性变换

平面图形只记录横、纵坐标；三维模型还需要记录高度。给一个物体的所有顶点同时左乘同一个 3×3 矩阵，就能统一改变它的姿态和尺度。为了看清空间感，下面保留三根坐标轴，以浅色面区分立方体的朝向；所有图都先在 $\mathbb{R}^3$ 中计算顶点，再投影到纸面。

绕坐标轴旋转：一个方向不动，另两个方向配合转动

三维旋转先要回答“绕哪根轴”。绕 x 轴时， x 坐标不变， y, z 两个分量按二维旋转规则变化；绕其余两轴时同理。固定右手坐标系，正转角按右手法则规定，三个矩阵分别为




图 4.6: 三维旋转：轴上的点不动，其余点绕轴转动。

读图说明：灰色虚线为原单位立方体，蓝色为旋转后的立方体；蓝色虚线表示被遮挡的棱。红色标出旋转轴及正向转角，正向按右手法则规定。图中取 45° ，所列矩阵保留一般角度 θ 。

从高中三角公式推导平面旋转

下面说明图中三个矩阵怎样得到。我们仍采用列向量、右手直角坐标系；正角按右手法则 (Right-Hand Rule) 规定：右手拇指指向转轴正向，四指弯曲的方向为正。从转轴正半轴看向原点，正向旋转在面向我们的平面上表现为逆时针。先固定坐标系，真正转动向量；这称为主动旋转 (Active Rotation)。另一种“向量不动、坐标轴转动”的解释稍后再讨论。[37]

设平面非零向量 $\mathbf{u}$ 的长度为 ρ ，它与 x 轴正向的有向角为 φ 。旋转 θ 后得到 $\mathbf{u}'$ ，于是

$$x = \rho \cos \varphi, \quad y = \rho \sin \varphi, \quad (4.1)$$

$$x' = \rho \cos(\varphi + \theta) = x \cos \theta - y \sin \theta, \quad (4.2)$$

$$y' = \rho \sin(\varphi + \theta) = x \sin \theta + y \cos \theta. \quad (4.3)$$

这里只用了高中学过的两角和公式。零向量旋转后仍是零，上式也成立。把系数整理成矩阵，就是

$$\begin{pmatrix} x' \\ y' \end{pmatrix} = \underbrace{\begin{pmatrix} \cos \theta & -\sin \theta \\ \sin \theta & \cos \theta \end{pmatrix}}_{R(\theta)} \begin{pmatrix} x \\ y \end{pmatrix}. \quad (4.4)$$




图 4.6a: 平面旋转的推导：长度 ρ 不变，有向角从 φ 变成 $\varphi + \theta$ ，再用两角和公式展开坐标。

读图说明：蓝色是原向量，红色是旋转后的向量，灰色虚线为坐标辅助线。图中取锐角便于观察，推导对任意实数角成立。

还可以按第 3.1 节的办法读出同一个矩阵： $\mathbf{e}_1$ 变为 $(\cos \theta, \sin \theta)^T$ ， $\mathbf{e}_2$ 变为 $(-\sin \theta, \cos \theta)^T$ 。把这两个像按列放好，恰是 $R(\theta)$ 。三角公式给出分量，基的像解释列的含义；两条思路在这里相遇。

三维只多一根不动的轴：推导与助记

绕坐标轴旋转时，该轴方向的分量不变，垂直于它的坐标平面内发生二维旋转。因而三个基本矩阵不需要分别死记；只要认清“不动哪一轴、转动哪一个有序平面”。NASA 的 Henderson 报告也以单轴旋转建立三维坐标转换公式。[36]

绕 z 轴：把平面公式直接放进三维

此时 $z' = z$ ， (x, y) 按式(4.4)变化。基向量的像依次为

$$\mathbf{e}_1 \mapsto (\cos \theta, \sin \theta, 0)^T, \quad \mathbf{e}_2 \mapsto (-\sin \theta, \cos \theta, 0)^T, \quad \mathbf{e}_3 \mapsto \mathbf{e}_3. \quad (4.5)$$

按列排列，得到

$$R_z(\theta) = \begin{pmatrix} \cos \theta & -\sin \theta & 0 \\ \sin \theta & \cos \theta & 0 \\ 0 & 0 & 1 \end{pmatrix}. \quad (4.6)$$

绕 x 轴：在有序平面 (y, z) 中旋转

右手正向把 $+y$ 转向 $+z$ 。保持 $x' = x$ ，将平面公式中的 x, y 换为 y, z ，得到

$$\begin{aligned} y' &= y \cos \theta - z \sin \theta, & z' &= y \sin \theta + z \cos \theta, \end{aligned} \quad (4.7)$$

$$R_x(\theta) = \begin{pmatrix} 1 & 0 & 0 \\ 0 & \cos \theta & -\sin \theta \\ 0 & \sin \theta & \cos \theta \end{pmatrix}. \quad (4.8)$$

三列分别表示 $\mathbf{e}_1$ 不动、 $\mathbf{e}_2$ 转为 $(0, \cos \theta, \sin \theta)^T$ 、 $\mathbf{e}_3$ 转为 $(0, -\sin \theta, \cos \theta)^T$ 。

绕 y 轴：为什么负号换了位置

绕 $+y$ 轴的右手正向是从 $+z$ 转向 $+x$ ，所以与前面相同的二维模板应放在**有序平面** (z, x) 中，而不是直接放在 (x, z) 中。先写

$$\begin{pmatrix} z' \\ x' \end{pmatrix} = \begin{pmatrix} \cos \theta & -\sin \theta \\ \sin \theta & \cos \theta \end{pmatrix} \begin{pmatrix} z \\ x \end{pmatrix}, \quad y' = y. \quad (4.9)$$

再按全书统一的 (x, y, z) 顺序排回去：

$$x' = x \cos \theta + z \sin \theta, \quad z' = -x \sin \theta + z \cos \theta, \quad (4.10)$$

$$R_y(\theta) = \begin{pmatrix} \cos \theta & 0 & \sin \theta \\ 0 & 1 & 0 \\ -\sin \theta & 0 & \cos \theta \end{pmatrix}. \quad (4.11)$$

因此 $\mathbf{e}_1 \mapsto (\cos \theta, 0, -\sin \theta)^T$ ， $\mathbf{e}_2$ 不动， $\mathbf{e}_3 \mapsto (\sin \theta, 0, \cos \theta)^T$ 。 y 轴没有另一套旋转法则；看起来不同的符号，来自把 (z, x) 的顺序重新写成 (x, z) 。




图 4.6b: 三维旋转的三个二维截面。绕 x, y, z 轴时，分别在 (y, z) 、 (z, x) 、 (x, y) 有序平面中使用同一个二维旋转模板。

读图说明：每幅图的横、纵轴顺序已经写明，三幅不是同一个 xy 平面。红色箭头均由横轴正向逆时针转过同一示意角； $\odot$ 表示垂直纸面朝向读者的转轴。

助记不是背九个数，而是按几何重建

从 E_3 出发，绕哪根轴，就保留相应的行与列；其余四个位置填入正弦、余弦。要决定正弦的正负，记住右手循环

$$x \longrightarrow y \longrightarrow z \longrightarrow x: \quad \text{绕 } z: x \rightarrow y; \quad \text{绕 } x: y \rightarrow z; \quad \text{绕 } y: z \rightarrow x. \quad (4.12)$$

最后用 90° 自检： $R_z \mathbf{e}_1 = \mathbf{e}_2$, $R_x \mathbf{e}_2 = \mathbf{e}_3$, $R_y \mathbf{e}_3 = \mathbf{e}_1$ ；反过来的那个平面方向应带负号，例如 $R_y(90^\circ) \mathbf{e}_1 = -\mathbf{e}_3$ 。这比只记“ y 轴符号特殊”更可靠。

读公式时还要检查书写习惯。 本书用列向量左乘；若某资料用行向量，则 $\mathbf{u}' = R\mathbf{u}$ 转置后成为 $(\mathbf{u}')^T = \mathbf{u}^T R^T$ 。矩阵出现在右边，而且要转置。比较不同资料时，先统一列向量约定，再比较正负号。

向量转了，还是坐标轴转了

同样画一条弧形箭头，可能在说两件不同的事。固定坐标轴、把向量转过 θ ，得到的是一个新向量，按 $R(\theta)$ 计算；如果向量不动，只把坐标轴转过 θ ，改变的就是原向量的坐标记录。这称为被动旋转 (Passive Rotation)。新轴正转后，原来固定的箭头相对新轴退回了同样的角度，所以坐标用 $R(-\theta)$ 换算。由两角和公式或矩阵乘法，可以检验

$$R(-\theta)R(\theta) = E_2, \quad R(-\theta) = R(\theta)^{-1}. \quad (4.13)$$

向量正转，与坐标轴正转，不能使用同一个方向的坐标公式。 第 4.4 节会把后一种情形写成一般的换基关系；这里先借图辨认两种不同的动作。Zanetti 的论文也特别区分这两种解释。[37]




图 4.6c: 主动旋转与被动旋转。左图改变物理向量，右图保持向量不动、改变描述它的基。

读图说明：两边均从 $u = (2, 0)^T$ 出发。右图红色箭头仍在原处；负的第二个新坐标表示沿 c_2 的反方向分解，不表示向量已经向下旋转。

三个基本旋转矩阵还有一个方便的检查：把角度换为 $-\theta$ ，恰好得到原矩阵的转置。因此，对 $i = x, y, z$ 有

$$R_i(\theta)^{-1} = R_i(-\theta) = R_i(\theta)^T, \quad R_i(\theta)^T R_i(\theta) = E_3. \quad (4.14)$$

验证只需高中恒等式 $\cos^2 \theta + \sin^2 \theta = 1$ 。满足 $Q^T Q = E$ 的实方阵称为正交矩阵 (Orthogonal Matrix)；在这里，它表示矩阵各列仍是长度为 1、两两垂直的方向。注意，具有这一性质的矩阵未必都是旋转，例如只把 x 坐标变号的镜像也满足它。此处不展开一般理论，只把它作为检查旋转公式和求反向作用的工具。

从二维两角和公式出发，认清不动的轴，再用右手循环判断符号，就能够重新写出三维旋转矩阵。需要图解辅助时，可参阅《3 维旋转矩阵推导与助记》；比较外部资料时，应先统一列向量、右手系以及主动或被动的约定。[38]


图 4.6 中的三个旋转均取 45° ，方便比较三个轴各自怎样穿过物体。作为计算检验，另取绕 z 轴转 90° ：

$$\begin{pmatrix} 0 & -1 & 0 \\ 1 & 0 & 0 \\ 0 & 0 & 1 \end{pmatrix} \begin{pmatrix} 1 \\ 0 \\ 0 \end{pmatrix} = \begin{pmatrix} 0 \\ 1 \\ 0 \end{pmatrix}.$$

原来沿 x 轴的单位箭头转到了 y 轴，而沿 z 轴的箭头没有改变。对一般输入 $(x, y, z)^T$ ，第三个坐标仍为 z ；旋转不把非零向量压成零，也没有遗失任何空间方向。

三维缩放：看清“变扁”与“压成平面”的区别

取三个缩放因子为 $2, 1, \frac{1}{2}$ ，则输入的三个分量分别变为 $2x, y, z/2$ 。它们仍分别保持加法与数乘，所以是线性映射。立方体在纸面上看起来更扁，但高度并未消失。



横向伸长为 2 倍
另一水平方向不变
高度压缩为原来的一半

$$A = \begin{pmatrix} 2 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & \frac{1}{2} \end{pmatrix}, \quad A \begin{pmatrix} 1 \\ 1 \\ 1 \end{pmatrix} = \begin{pmatrix} 2 \\ 1 \\ \frac{1}{2} \end{pmatrix}.$$


图 4.7: 三维缩放: 单位立方体变成长方体。

读图说明: 灰色虚线为原立方体, 实线为变换后的可见棱; 三个缩放因子均非零, 所以这种“变扁”仍可恢复。

从输出 $(p, q, r)^T$ 可以唯一恢复输入 $(p/2, q, 2r)^T$ 。这与投影有本质区别: 缩放因子很小但非零时, 原高度仍能算回来; 只有因子恰好为 0 时, 这个方向的信息才被完全舍去。

向 xy 平面投影: 三维物体怎样只留下二维轮廓

若只关心每个顶点在水平面上的位置, 就采用 $T(x, y, z) = (x, y, 0)^T$ 。两个水平分量被保留, 竖直分量不再影响输出。图 4.8 把“舍去高度”画成顶点沿竖直方向落到平面上。



$$A = \begin{pmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 0 \end{pmatrix}, \quad A \begin{pmatrix} 2 \\ 1 \\ 3 \end{pmatrix} = \begin{pmatrix} 2 \\ 1 \\ 0 \end{pmatrix}.$$

图 4.8: 向 xy 平面投影: 只保留两个坐标方向。

读图说明: 左图立方体的高度在右图消失, 上下对应顶点合为一点; z 轴方向就是稍后要研究的零空间方向。

例如, $(2, 1, 3)^T$ 、 $(2, 1, -2)^T$ 与 $(2, 1, 0)^T$ 都有同一个像 $(2, 1, 0)^T$ 。它们并不是同一个输入, 只是输出已经无法分辨其高度。与此同时, 目标 $(2, 1, 1)^T$ 永远得不到, 因为任何输出的第三个分量都必须为 0。

把几何现象写成方程组，就是 $x = b_1, y = b_2, 0 = b_3$ 。当 $b_3 = 0$ 时， z 可以任取；当 $b_3 \neq 0$ 时，方程组无解。一个被舍去的输入方向，同时提醒我们去研究两件事：哪些输入会合并，哪些目标能够到达。下面的零空间与值域，就是为回答这两个问题而引入的。

平移为什么越过了线性的边界

屏幕上拖动一个图形，并没有改变它的形状，这很容易让人把平移也归在线性变换里。设固定平移量为 $\mathbf{a} \neq \mathbf{0}$ ，规则为

$$T(\mathbf{x}) = \mathbf{x} + \mathbf{a}.$$

先看原点。任何线性映射都满足 $T(\mathbf{0}) = T(0\mathbf{x}) = 0T(\mathbf{x}) = \mathbf{0}$ ，而这项平移满足

$$T(\mathbf{0}) = \mathbf{a} \neq \mathbf{0}.$$

仅此一项就能断定：**非零平移不是原空间中的线性变换。**

再检查可加性。先把两个输入相加，再平移，只加一次 $\mathbf{a}$ ；分别平移后再相加，却加了两次：

$$T(\mathbf{u} + \mathbf{v}) = \mathbf{u} + \mathbf{v} + \mathbf{a},$$

$$T(\mathbf{u}) + T(\mathbf{v}) = \mathbf{u} + \mathbf{v} + 2\mathbf{a}.$$

当 $\mathbf{a} \neq \mathbf{0}$ 时，两式不相等。例如 $\mathbf{a} = (2, 1)^T$ ，取 $\mathbf{u} = (1, 0)^T$ 、 $\mathbf{v} = (0, 1)^T$ ，前式得 $(3, 2)^T$ ，后式得 $(5, 3)^T$ 。这不是精度误差，而是运算结构不同。

平移仍将直线变为直线，也保留两点间的距离，但这些都不足以保证线性。线性所要求的是保留从原点出发的向量加法与数乘。若 $\mathbf{a} = \mathbf{0}$ ，平移才退化为恒等映射；此时当然线性。

齐次坐标：增加一个分量，让平移进入矩阵乘法

图形软件需要连续组合平移、旋转与缩放。为了统一运算格式，可以给二维点增加一个固定为 1 的分量，用齐次坐标 (Homogeneous Coordinates) 表示为 $(x, y, 1)^T$ 。令

$$T_h = \begin{pmatrix} 1 & 0 & a_1 \\ 0 & 1 & a_2 \\ 0 & 0 & 1 \end{pmatrix}, \quad T_h \begin{pmatrix} x \\ y \\ 1 \end{pmatrix} = \begin{pmatrix} x + a_1 \\ y + a_2 \\ 1 \end{pmatrix}.$$

这里沿用图形学中用 T_h 记齐次变换矩阵的写法；映射本身可写成 $\tilde{T}(\mathbf{z}) = T_h \mathbf{z}$ 。例如 $\mathbf{a} = (2, 1)^T$ 时， $(1, 3, 1)^T$ 被送到 $(3, 4, 1)^T$ ，读前两个分量便得到平移后的点。

一般的仿射映射 (Affine Map) 写成 $\mathbf{x} \mapsto A\mathbf{x} + \mathbf{a}$ 。它在二维原空间中只有 $\mathbf{a} = \mathbf{0}$ 时

才是线性的；增加一个分量以后，可以统一写成

$$\begin{pmatrix} A & \mathbf{a} \\ \mathbf{0}^T & 1 \end{pmatrix} \begin{pmatrix} \mathbf{x} \\ 1 \end{pmatrix} = \begin{pmatrix} A\mathbf{x} + \mathbf{a} \\ 1 \end{pmatrix}.$$

Khronos 的二维图形规范正是用这一形式把平移纳入矩阵表示。[29] 计算连续变换时，仍可沿用第三章的矩阵复合规则。

升维并没有推翻刚才的反例。在整个 $\mathbb{R}^3$ 上， $\tilde{T}$ 是线性映射；代表二维点的集合 $z_3 = 1$ 却不是子空间。两点的齐次坐标相加后，最后一个分量变成 2，已经离开这个截面；而三维零向量 $(0,0,0)^T$ 仍然被映到自身。原来二维原点的齐次表示是 $(0,0,1)^T$ ，它并非三维零向量，当然可以移动。




图 4.8a (自行添加)：升维后，二维原点与三维零向量是不同的点。

读图说明：示意平移量为 $(2,1)^T$ 。上方截面不经过三维原点，因而不是子空间；固定末分量为 1 是表示二维点的约定。

还有一个直观检查：两点坐标之差形如 $(u_1, u_2, 0)^T$ ，平移矩阵作用于它时，平移项不再起作用。这正对应“平移改变位置，但不改变两点之间的位移”。这里只借升维说明表示方式的扩展，不继续讨论透视投影；接下来要研究的零空间和值域，仍针对明确给定的线性映射。

例题 4.1 (同一张图形，操作次序改变后会怎样)

先沿两轴分别放大 2 倍、3 倍，再绕原点转 90° ；另一路线则先转 90° ，再沿固定的坐标轴缩放。比较顶点 $(1,1)^T$ 的结果。

解 设缩放矩阵为 $D = \begin{pmatrix} 2 & 0 \\ 0 & 3 \end{pmatrix}$ ，旋转矩阵为 $A = \begin{pmatrix} 0 & -1 \\ 1 & 0 \end{pmatrix}$ 。第一条路线把 $(1,1)^T$ 先送到 $(2,3)^T$ ，再送到 $(-3,2)^T$ ；第二条路线先送到 $(-1,1)^T$ ，再送到 $(-2,3)^T$ 。

对应矩阵分别为

$$AD = \begin{pmatrix} 0 & -3 \\ 2 & 0 \end{pmatrix}, \quad DA = \begin{pmatrix} 0 & -2 \\ 3 & 0 \end{pmatrix}.$$


前者使正方形最终占据横向长 3、纵向长 2 的矩形；后者最终占据横向长 2、纵向长 3 的矩形。区别来自缩放沿哪组固定方向发生。这是第三章复合次序的几何应用，并非计算中的偶然现象。

还有一种常见操作：让图形绕自己的中心转动。若中心 p 不是原点，坐标规则为

$$x \mapsto A(x - p) + p = Ax + (p - Ap).$$

先把中心移到原点，再旋转，最后移回原处，正是这个式子的三项含义。除非 $Ap = p$ ，它在原坐标中是仿射映射，不能仅因画面在“旋转”就忽略平移项。比如绕 $(2, 1)^T$ 转 90° ，规则为 $(x, y) \mapsto (3 - y, x - 1)^T$ ，会把原点送到 $(3, -1)^T$ 。齐次坐标可以统一组织这种复合，同时让我们清楚保留它与原空间线性变换的区别。

4.1.2 零空间与单射性



单射（一对一）：每个输出至多有一个原像。

图 4.8b: 不同的输入被送到不同的输出；没有两个输入共享同一个像。

读图说明：四条箭头分别到达四个不同的像，输出端没有合并。这里只强调单射的要求，不据这些示意点判断是否满射；椭圆表示集合，点不代表一组基。

如图 4.8b 所示，单射要求输出端保留输入之间的全部区别。

先寻找哪些向量被送到了零

在 x 轴投影中， $(0, 1)^T$ 、 $(0, -2)^T$ ，乃至整条 y 轴上的向量，都会被送到原点。它们共同构成一个方向：沿这个方向改变输入，不会改变输出。我们把这种“完全消失的输入”收集起来。

定义 4.2 (零空间)

设 $T: \mathbb{R}^n \rightarrow \mathbb{R}^m$ 是线性映射。它的零空间 (Null Space) 定义为

$$\text{null } T = \{x \in \mathbb{R}^n \mid T(x) = \mathbf{0}\}.$$

它由输入向量组成，位于定义域中；等式右边的零向量则位于目标空间中。

二维投影丢掉高度，三维投影同样会丢掉一整根方向。对 $T(x, y, z) = (x, y, 0)^T$ ，零输出要求 $x = y = 0$ ，却不限 z ，所以 $\text{null } T = \{(0, 0, t)^T : t \in \mathbb{R}\}$ 。图 4.9 把任意三个这样的输入放在一起比较。

零空间不是一个表示“什么都没有”的名字。它可能只有零向量，也可能是一条直线、一个平面，甚至整个定义域。它描述的是哪些输入的作用恰好为零。




图 4.9: 零空间是 z 轴，整条轴上的输入都被压缩为同一个零输出。

读图说明：红线属于输入空间，右边的红点属于输出空间。左图三个点的高度不同，但前两个分量均为 0。

定理 4.3 (零空间是子空间)

线性映射 $T: \mathbb{R}^n \rightarrow \mathbb{R}^m$ 的零空间是定义域 $\mathbb{R}^n$ 的子空间。

证明： 依据第 1 章的子空间判定，逐项验证。

零向量属于其中：由线性映射的齐次性， $T(\mathbf{0}) = \mathbf{0}$ ，所以 $\mathbf{0} \in \text{null } T$ 。

对加法封闭：若 $u, v \in \text{null } T$ ，则两者的像均为零。由可加性，

$$T(u + v) = T(u) + T(v) = \mathbf{0}.$$

故 $u + v \in \text{null } T$ 。

对数乘封闭：若 $u \in \text{null } T$ 、 $c \in \mathbb{R}$ ，由齐次性，

$$T(cu) = cT(u) = c\mathbf{0} = \mathbf{0}.$$

故 $cu \in \text{null } T$ 。三个条件均满足，结论成立。 ■

这份子空间证明在三维图里也能逐项看见：零点在红轴上，轴上两向量相加仍在轴上，沿轴向量作任意实数倍也不会离开轴。例如 $(0,0,1)^T + (0,0,2)^T = (0,0,3)^T$ ，而 $-2(0,0,1)^T = (0,0,-2)^T$ ，它们的像都为零。

零空间为什么能检测不同输入是否合并

只找零输出，似乎还没有检查所有输入。关键在于，线性映射把“两个输入有相同输出”转换成了“它们的差有零输出”：

$$T(x) = T(y) \iff T(x - y) = \mathbf{0} \iff x - y \in \text{null } T.$$

因此，零空间不仅告诉我们谁被送到了零，还告诉我们哪些方向上的差别在所有输出中都无法区分。

定理 4.4 (单射与零空间)

线性映射是单射，当且仅当它的零空间只含零向量：

$$T \text{ 是单射} \iff \text{null } T = \{\mathbf{0}\}.$$

证明：先设 T 是单射。若 $x \in \text{null } T$ ，则 $T(x) = \mathbf{0} = T(\mathbf{0})$ 。由单射的定义，两个输入必相同，即 $x = \mathbf{0}$ 。又因零向量确在零空间中，所以 $\text{null } T = \{\mathbf{0}\}$ 。

反过来，设 $\text{null } T = \{\mathbf{0}\}$ 。若 $T(x) = T(y)$ ，由可加性和齐次性， $T(x - y) = \mathbf{0}$ 。于是 $x - y \in \text{null } T$ ，只能有 $x - y = \mathbf{0}$ ，故 $x = y$ 。这就是单射。 ■

从几何上说，单射要求保留输入之间的所有区别。比如 $D = \text{diag}(2, 1, \frac{1}{2})$ 满足 $Dx = \mathbf{0}$ 只能有 $x = \mathbf{0}$ ，所以是单射； xy 平面投影却把 $(1, 2, 0)^T$ 与 $(1, 2, 3)^T$ 合并，它们的差 $(0, 0, 3)^T$ 正在零空间里。这给了双向证明一个可见的落点。

把“找零空间”落实为解齐次方程组

若 $T(x) = Ax$ ，其中 A 为 $m \times n$ 矩阵，就记

$$\text{null } A = \{x \in \mathbb{R}^n : Ax = \mathbf{0}\} = \text{null } T.$$

这正是齐次方程组的解空间 (Solution Space)。求零空间无需发明新的算法：照第二章的方法消元，再把全部解写成参数形式即可。

例题 4.5 (从自由变量读出零空间)

设 $T: \mathbb{R}^3 \rightarrow \mathbb{R}^2$ 的矩阵为

$$A = \begin{pmatrix} 1 & 2 & -1 \\ 2 & 4 & -2 \end{pmatrix}.$$

求 $\text{null } T$ 的一组基, 并判断 T 是否为单射。

解 齐次方程组的第二个方程是第一个的 2 倍。消元后只剩

$$x_1 + 2x_2 - x_3 = 0.$$

令自由变量 $x_2 = s, x_3 = t$, 得到

$$x = \begin{pmatrix} -2s + t \\ s \\ t \end{pmatrix} = s \begin{pmatrix} -2 \\ 1 \\ 0 \end{pmatrix} + t \begin{pmatrix} 1 \\ 0 \\ 1 \end{pmatrix}, \quad s, t \in \mathbb{R}.$$

两支向量都被 A 映为零; 它们张成全部解, 而且线性无关, 因为组合为零时, 第二个分量直接给出 $s = 0$, 第三个分量给出 $t = 0$ 。所以它们构成零空间的一组基, $\dim \text{null } T = 2$ 。零空间包含非零向量, 故 T 不是单射。

这个例子也说明**零空间的维数为什么等于自由变量的个数**。在一般的齐次方程组中, 把每个自由变量依次取 1、其余自由变量取 0, 会得到一组解向量。所有解都是这组向量的线性组合; 在自由变量所在的分量上检查, 又能立即证明它们线性无关。因此, 它们就是一组基。若没有自由变量, 齐次方程只有零解, 零空间的维数为 0。

回到五类变换, 再问一次有没有丢失输入

旋转的长度保持不变, 所以非零向量不能被转成零。剪切可用 $x = p - kq, y = q$ 恢复输入; 反射再做一次就恢复原状。它们的零空间都只有零向量, 因此都是单射。

缩放需要保留条件。对 $T(x, y) = (s_x x, s_y y)^T$, 零空间恰好由 $s_x x = 0, s_y y = 0$ 决定: 两因子都非零时只有零向量; 只有 s_x 为零时是 x 轴; 只有 s_y 为零时是 y 轴; 两因子都为零时是整个平面。沿哪个方向完全压缩, 哪个方向就进入零空间。

向 x 轴投影的零空间是 y 轴; 向 y 轴投影的零空间是 x 轴; 向过原点直线投影的零空间, 是与这条直线垂直的另一条过原点直线。投影保留了部分输入, 又合并了部分输入, 因此不是从整个平面到整个平面的单射。

例题 4.6 (零空间不一定沿坐标轴)

把平面正交投影到直线 $y = x$ 。求其零空间，并说明为什么 $(3,1)^T$ 与 $(2,2)^T$ 有相同的像。

解 在一般直线投影公式中取 $\alpha = 45^\circ$ ，得到

$$A = \frac{1}{2} \begin{pmatrix} 1 & 1 \\ 1 & 1 \end{pmatrix}, \quad T(x, y) = \left(\frac{x+y}{2}, \frac{x+y}{2} \right)^T.$$

零输出要求 $x + y = 0$ ，所以

$$\text{null } T = \{(t, -t)^T : t \in \mathbb{R}\} = \text{Span}\{(1, -1)^T\}.$$

这是直线 $y = -x$ ，恰好与目标直线垂直。两支给定向量的坐标和都是 4，故像都是 $(2, 2)^T$ ；它们的差为 $(1, -1)^T$ ，正落在零空间中。

这里没有把 x 分量或 y 分量单独抹掉，而是只留下两者的平均值。可见“丢失一个方向”不能总理解成“删除一个原坐标”。更准确的说法是：所有沿零空间方向的变化，都在输出中无法辨认。反过来，若输入向量限制在目标直线 $y = x$ 上，投影就是恒等作用，任何信息都不再丢失。单射性始终要针对完整给定的定义域判断。

三维零空间也可以斜穿原点

零空间的方向由映射决定，并不一定恰好沿坐标轴。考虑

$$A = \begin{pmatrix} 1 & 0 & -1 \\ 0 & 1 & -1 \\ 0 & 0 & 0 \end{pmatrix}, \quad T(x, y, z) = (x - z, y - z, 0)^T.$$

为了得到零输出，要同时有 $x - z = 0$ 、 $y - z = 0$ ，所以 $x = y = z = t$ 。零空间因此是由 $(1, 1, 1)^T$ 张成的直线。对任意目标 $(p, q, 0)^T$ ，输入 $(p, q, 0)^T$ 本身就能产生它，而轴外的第三分量永远无法产生。全部输出，也就是下一节要正式定义的值域，是 xy 平面。这个变换保持目标平面上的点不动，却沿不垂直于平面的方向投下，称为斜投影 (Oblique Projection)。




图 4.10: 零空间可以是一条不沿坐标轴的直线。

读图说明：变换 $(x,y,z) \mapsto (x-z, y-z, 0)$ 沿红色斜线方向压缩，输出仍是绿色平面；这是斜向投影，不是正交投影。

取 $(3,2,1)^T$ 与 $(4,3,2)^T$ ，二者都被送到 $(2,1,0)^T$ ；差向量 $(1,1,1)^T$ 在红色直线上。图中被压缩的方向有 1 维，输出平面有 2 维，数目恰好满足 $3 = 1 + 2$ 。这里先观察现象，第 4.3 节再用一个定理说明为什么这种维数平衡普遍成立。

记住这里与第五章的联系：**单射控制的是解的唯一性**。如果零空间只有零向量， $Ax = b$ 一旦有解就只能有一个；如果零空间含有非零向量，已有解便能沿零空间方向继续改变。至于右端项到底能不能得到，还要看另一块结构——值域。

4.2 值域与满射性




图 4.10b: 陪域中的每一点都能被某个输入到达；值域等于整个陪域。

读图说明：淡红色填满整个陪域，表示每一点都能到达；有限条箭头只展示其中的对应关系，并不是用几个点代替整个空间。满射允许多个输入得到同一个输出。

如图 4.10b 所示，满射要求陪域中不留任何空白。

零空间问“哪些输入被送到了零”，值域则问“哪些输出能够得到”。给定一个想要的结果，先研究所有可能的输出范围，可以避免为根本不可能到达的目标反复消元。我们要把“允许写在右端的向量”和“实际能够产生的向量”区分开来。投影到 x 轴时，所有输入虽然填满平面，输出却只能出现在 x 轴上。目标空间可以是整个平面，真正到达的部分却小得多。

定义 4.7 (值域)


设 $T: \mathbb{R}^n \rightarrow \mathbb{R}^m$ 是线性映射。它的值域 (Range) 为

$$\text{range } T = \{T(x) \mid x \in \mathbb{R}^n\}.$$

值域由输出向量组成，位于目标空间 $\mathbb{R}^m$ 中；它不一定等于目标空间。

三维投影更能体现“目标空间”与“值域”的区别。对 $T: \mathbb{R}^3 \rightarrow \mathbb{R}^3$ 、 $T(x, y, z) = (x, y, 0)^T$ ，目标空间仍然是三维的；图中不能擦掉输出端的 z 轴，否则容易误以为目标空间本来就只有二维。

定义域：可以输入任意三维向量



目标空间：只覆盖绿色平面




图 4.11: 值域是 xy 平面，不是整个 $\mathbb{R}^3$ ，所以映射不是满射。

读图说明：目标空间仍保留三根坐标轴。只有第三个分量为 0 的目标能够成为输出；特别地， z 轴上的非零点无法到达。

定理 4.8 (值域是子空间)

线性映射 $T: \mathbb{R}^n \rightarrow \mathbb{R}^m$ 的值域是目标空间 $\mathbb{R}^m$ 的子空间。

证明： 零向量属于值域：因为 $T(\mathbf{0}) = \mathbf{0}$ ，零输出有零输入作为原像。

对加法封闭：若 $a, b \in \text{range } T$ ，由值域的定义，可以找到输入 u, v ，使 $a = T(u)$ 、 $b = T(v)$ 。由可加性，

$$a + b = T(u + v) \in \text{range } T.$$

对数乘封闭：若 $\mathbf{a} = T(\mathbf{u}) \in \text{range } T$ 、 $c \in \mathbb{R}$ ，由齐次性，

$$c\mathbf{a} = cT(\mathbf{u}) = T(c\mathbf{u}) \in \text{range } T.$$

三个子空间条件均已验证。 ■

在图 4.11 中， $(1, 0, 0)^T$ 与 $(0, 2, 0)^T$ 都是输出，它们的和 $(1, 2, 0)^T$ 仍在绿面上；把后一个向量乘 -1 ，也仍在绿面上。数值计算与几何封闭性说的是同一件事。

这里的证明每次都先找输入，再用线性性质把输出的运算移到输入端。值域不是任意画出的一块区域，它有可以追溯的生成方式。

定理 4.9 (满射与值域)

线性映射是满射，当且仅当它的值域等于整个目标空间：

$$T : \mathbb{R}^n \rightarrow \mathbb{R}^m \text{ 是满射 } \iff \text{range } T = \mathbb{R}^m.$$

也就是说，每个目标向量都至少有一个原像。

证明： 若 T 是满射，则任意 $\mathbf{b} \in \mathbb{R}^m$ 都能写成 $T(\mathbf{x})$ ，因而属于值域；值域本来又包含于 $\mathbb{R}^m$ ，故二者相等。反过来，若二者相等，每个目标向量都在值域中，按值域定义就都有原像，所以 T 为满射。 ■

满射不要求“只出现一次”，只要求“至少能够出现”。例如三维恒等映射把任意 $(b_1, b_2, b_3)^T$ 原样输出，所以满射； xy 平面投影连 $(0, 0, 1)^T$ 都无法得到，所以不满射。若把目标空间直接规定为 xy 平面，这个投影又是满射。因此，判断必须连同目标空间一起说清楚。

列空间就是矩阵能够给出的全部输出

设 A 的列向量为 $\mathbf{a}_1, \dots, \mathbf{a}_n$ 。第三章已经把矩阵乘法解释为列的线性组合，因此

$$A\mathbf{x} = x_1\mathbf{a}_1 + \dots + x_n\mathbf{a}_n.$$

当 $\mathbf{x}$ 遍历 $\mathbb{R}^n$ ，组合系数就遍历所有实数选择，得到

$$\text{range } A = \text{range } T = \text{Span}\{\mathbf{a}_1, \dots, \mathbf{a}_n\}.$$

右边正是矩阵的列空间。因此第二章的有解判定可以重新读作

$$A\mathbf{x} = \mathbf{b} \text{ 有解 } \iff \mathbf{b} \in \text{range } A \iff \mathbf{b} \text{ 可由 } A \text{ 的列向量线性表示.}$$

若把 $\mathbf{b}$ 加到系数列后面没有增加张成空间的维数，就有解，即 $\text{rank}(A) = \text{rank}([A \mid \mathbf{b}])$ ；若增广后维数增加，目标向量就不在原列空间中，方程组无解。

例题 4.10 (同一矩阵, 哪些右端项能够得到)

仍取 $A = \begin{pmatrix} 1 & 2 & -1 \\ 2 & 4 & -2 \end{pmatrix}$ 。求它的值域, 并分别判断右端项 $\mathbf{b} = (3, 6)^T$ 与 $\mathbf{c} = (3, 5)^T$ 对应的方程组是否有解。

解 三列依次是 $(1, 2)^T$ 的 1 倍、2 倍与 -1 倍, 所以

$$\text{range } A = \text{Span}\{(1, 2)^T\} = \{(t, 2t)^T : t \in \mathbb{R}\}.$$

它是目标平面中的直线 $b_2 = 2b_1$ 。 $\mathbf{b}$ 在直线上, 比如 $A(3, 0, 0)^T = \mathbf{b}$, 所以有解; $\mathbf{c}$ 不在直线上, 所以无解。前一例中已经求出二维零空间, 故 $\mathbf{b}$ 的解并不唯一: 在 $(3, 0, 0)^T$ 上加任意零空间向量, 输出仍然是 $\mathbf{b}$ 。

三维输出空间里, 也可能只保留一条直线

现在把输出限制得更窄一些。考虑矩阵

$$A = \begin{pmatrix} 1 & 2 & 3 \\ 2 & 4 & 6 \\ 3 & 6 & 9 \end{pmatrix}.$$

它的第二列、第三列分别是第一列的 2 倍、3 倍。因而三个输入分量只通过一个数 $t = x + 2y + 3z$ 影响输出; 这个数变了, 输出就在同一条直线上前后移动。

输入: 三个数先合成一个参数

输出: 只到达绿色直线




图 4.12: 所有列成比例, 全部输出只能沿一个方向变化。

读图说明: 每个输出都是 $(1, 2, 3)^T$ 的倍数。绿色直线之外的点没有原像; 同一直线上的输出又对应多组输入。

例如 $A(1,0,0)^T = (1,2,3)^T$, $A(0,\frac{1}{2},0)^T$ 也等于它, 所以映射不是单射。目标 $(1,0,0)^T$ 不可能是 $(1,2,3)^T$ 的倍数, 因此没有原像, 映射也不是满射。

列空间由一个非零向量张成, 故秩为 1。零输出则要求 $x + 2y + 3z = 0$, 令 $y = s, z = t$ 得

$$x = s(-2, 1, 0)^T + t(-3, 0, 1)^T.$$

两支向量线性无关, 所以零空间是二维平面。输出只留下一个自由方向, 输入却有两个可以改变而不影响结果的方向; 这与刚才“零空间是直线、值域是平面”的例子恰好形成对照。

不要把“某个右端项有解”误读成满射

上例能够得到 $(3,6)^T$, 却不能得到 $(3,5)^T$, 所以不是到 $\mathbb{R}^2$ 的满射。满射要求的是每一个目标向量都能得到; 只找到一个有解的方程组, 还远远不够。

目标空间的约定同样重要。映射 $T: \mathbb{R}^2 \rightarrow \mathbb{R}^2$, $T(x,y) = (x,0)^T$ 不是满射, 因为到不了轴外的点; 若改用一个实数记录投影位置, 令 $S: \mathbb{R}^2 \rightarrow \mathbb{R}$, $S(x,y) = x$, 则 S 是满射。两者表达了相近的投影过程, 却给出了不同的目标空间, 判断自然不同。

五类变换的输出范围

下面都把目标空间固定为 $\mathbb{R}^2$ 。旋转、剪切与反射均可逆, 任意输出都能通过逆变换找到输入, 所以值域为整个平面, 都是满射。两缩放因子均非零时也如此; 只有一个因子为零时, 值域为另一坐标方向的整条轴; 两个因子均为零时, 值域仅为 $\{0\}$ 。

向过原点直线的正交投影, 其值域就是该直线。直线上任意向量本来就投影到自己, 轴外向量却永远不可能成为输出, 因此不是到整个平面的满射。把主要情形放在一起, 可以看得更清楚:

平面到平面的变换	$\text{null } T$	$\text{range } T$
两因子非零的缩放	$\{0\}$	$\mathbb{R}^2$
旋转、剪切、反射	$\{0\}$	$\mathbb{R}^2$
向 x 轴投影	y 轴	x 轴
向 y 轴投影	x 轴	y 轴
零映射	$\mathbb{R}^2$	$\{0\}$

这里的零映射把每个输入都送到零。零空间和值域, 一个记录输入端失去的区分, 一个记录输出端拥有的范围。下一节将看到, 两者的维数并不是各自独立的。

4.3 线性映射基本定理：秩与零度

为什么三维投影可以丢掉一个方向而保留两个方向，却不能在完全独立的意义下“丢掉两个、又保留两个”？要回答这个问题，就不能只盯着某一个点，而要数清输入空间、零空间和值域各有多少个独立方向。向 x 轴投影给出 $2 = 1 + 1$ ；向 xy 平面投影给出 $3 = 1 + 2$ ；上一节的秩一矩阵则给出 $3 = 2 + 1$ 。这些不是巧合，而是同一个维数定理的不同表现。

定理 4.11 (线性映射基本定理)

设 V 是 $\mathbb{R}^n$ 的有限维子空间， $T: V \rightarrow \mathbb{R}^m$ 为线性映射，则

$$\dim V = \dim \text{null } T + \dim \text{range } T.$$

特别地，对 $T: \mathbb{R}^n \rightarrow \mathbb{R}^m$ ，有

$$n = \dim \text{null } T + \dim \text{range } T.$$

零空间的维数称为零度 (Nullity)，因而本定理也称为秩与零度定理 (Rank-Nullity Theorem)。严格证明见选读第 4.6 节。

这里可以把等式读成“定义域的维数等于被压缩掉的维数加上输出保留的维数”。但这只是维数计数：一般情形下，零空间在输入端、值域在输出端，它们甚至位于不同的实数空间，不能直接写成 $\mathbb{R}^n = \text{null } T + \text{range } T$ ，更不能把它们向量任意相加。




图 4.13: 三维投影的维数平衡： $3 = 1 + 2$ 。

读图说明：等号与加号连接的是维数，不是把不同空间中的向量直接相加。中间红线在输入空间，右边绿面在输出空间。

以 $A = \text{diag}(1, 1, 0)$ 作数值检查：零空间的一组基是 $\{e_3\}$ ，值域的一组基是 $\{e_1, e_2\}$ ，所以 $3 = 1 + 2$ 。对右端项 $(2, 1, 0)^T$ ，全部解为 $(2, 1, t)^T$ ，恰好留下一个自由参数；右端

项改为 $(2, 1, 3)^T$ 时仍然无解。维数关系出了自由度，却不能把轴外的目标变成可到达的目标。

矩阵版本：多少个方向能够输出，多少个参数仍可自由变化

若 A 为 $m \times n$ 矩阵， $T(x) = Ax$ ，其值域就是列空间。这个空间的维数正是矩阵的秩，故

$$\text{rank}(A) = \dim \text{range } A, \quad \boxed{\dim \text{null } A = n - \text{rank}(A)}.$$

注意这里的 n 是列数，因为零空间位于 n 维输入空间。对前面讨论的 2×3 矩阵，列空间是一维，零空间是二维，故 $3 = 2 + 1$ ，与已经求出的基一致。

单射、满射与尺寸限制

若零空间维数为 0，映射就是单射，定理给出值域维数为 n 。由于值域包含在 $\mathbb{R}^m$ 中，必须有 $n \leq m$ 。所以从更高维空间线性地映入更低维空间，必然会合并某些不同输入。

若值域维数小于 n ，零空间就非平凡，即含有非零向量。另一端，若映射是满射，值域维数为 m ，于是 $n \geq m$ 。把这些关系写成矩阵语言：

$$T \text{ 是单射} \iff \text{rank}(A) = n,$$

$$T \text{ 是满射} \iff \text{rank}(A) = m.$$

当 $m = n$ 时，两条件相同，因而方阵对应的映射只要单射，就同时满射；只要满射，也同时单射。这与第三章的可逆矩阵结论一致。若 $m \neq n$ ，则必须分别判断，不能凭“看起来没有压缩”就断言所有目标都能到达。

例题 4.12 (单射与满射可以各自成立)

考虑

$$A = \begin{pmatrix} 1 & 0 & 1 \\ 0 & 1 & 1 \end{pmatrix}, \quad B = \begin{pmatrix} 1 & 0 \\ 0 & 1 \\ 1 & 1 \end{pmatrix}.$$

分别判断 $A: \mathbb{R}^3 \rightarrow \mathbb{R}^2$ 与 $B: \mathbb{R}^2 \rightarrow \mathbb{R}^3$ 的单射、满射性质。

解 A 的前两列已经张成 $\mathbb{R}^2$ ，故秩为 2，是满射；由 $3 - 2 = 1$ ，其零空间是一维。直接解得 $\text{null } A = \text{Span}\{(-1, -1, 1)^T\}$ ，所以不是单射。任意右端项 $(b_1, b_2)^T$ 都有解，但不唯一。

B 的两列线性无关，秩为 2，故由 $2 - 2 = 0$ 可知它是单射。输出形如 $(x, y, x + y)^T$ ，只能位于平面 $b_3 = b_1 + b_2$ ，不是整个 $\mathbb{R}^3$ ，所以不是满射。右端项在这个平面上时解唯一；不在平面上时无解。

提前看见第五章的问题

对一个给定的右端项 $\mathbf{b}$ ，先用值域判断能否到达；若能到达，任选一个解 $\mathbf{x}_0$ 。由线性性质，

$$A\mathbf{x} = \mathbf{b} \iff A(\mathbf{x} - \mathbf{x}_0) = \mathbf{0}.$$

因此全部解正是 $\mathbf{x}_0 + \mathbf{z}$ ，其中 $\mathbf{z} \in \text{null } A$ 。这里只先认清角色：值域决定存在性，零空间决定已有解能够沿哪些方向改变， $n - \text{rank}(A)$ 数出自由参数的个数。第五章将围绕这一结构系统展开。

两个端点也值得记住：零映射没有任何非零输出，全部输入都在零空间中，维数关系为 $n = n + 0$ ；恒等映射没有压缩任何方向，关系为 $n = 0 + n$ 。一般映射恰好处在这两端之间。这正是秩与零度定理把三种空间结构联系起来的桥梁。




图 4.13a: 单射、满射、双射的形态对照：单射要求输出端不合并，满射要求陪域不剩余，双射两者兼备。

读图说明：每格上方画对应关系，下方给出一个真实的线性映射例子。空心点表示未到达的目标，陪域整体着色表示全部覆盖。示意点的个数不是维数； n, m 分别是例子中定义域、陪域的维数，箭头交叉也不等于输出合并，应看它们是否落在同一个点。

把图 4.13a 与秩的判定放在一起看：单射对应 $\text{rank}(A) = n$ ，满射对应 $\text{rank}(A) = m$ ，当 $m = n$ 时两者等价。

4.4 基变换与相似矩阵

前面一直采用标准基，所以坐标列与向量本身看起来十分接近。现在换一个问题：同一个向量没有移动，只换一组基来分解它，坐标会怎样变化？同一个线性变换没有改变，只改用另一组基记录输入与输出，矩阵又会怎样变化？这就是基变换 (Change of Basis)，也是第三章“矩阵表示映射”向任意基的自然延伸。

先规定过渡矩阵的方向

设 $B = (b_1, \dots, b_n)$ 与 $C = (c_1, \dots, c_n)$ 是 $\mathbb{R}^n$ 的两组有序基。花体字母表示基，大写斜体字母表示矩阵； x 是向量本身， $[x]_B$ 与 $[x]_C$ 是它在两组基下的坐标列，不能混为一谈。

本节始终把从新基 C 坐标到旧基 B 坐标的过渡矩阵 (Change-of-Coordinates Matrix) 记作

$$P = P_{B \leftarrow C} = ([c_1]_B \cdots [c_n]_B). \quad (4.15)$$

第 j 列就是第 j 个新基向量 c_j 在旧基 B 下的坐标。若第 i 行、第 j 列为 p_{ij} ，则这列坐标的含义是

$$c_j = \sum_{i=1}^n p_{ij} b_i, \quad j = 1, \dots, n. \quad (4.16)$$

把新基展开代入向量，坐标公式就出现了

任取 $x \in \mathbb{R}^n$ ，设 $y = [x]_C = (y_1, \dots, y_n)^T$ 。坐标的定义告诉我们， $x = \sum_j y_j c_j$ 。逐个代入上式，再按旧基向量收集系数：

$$x = \sum_{j=1}^n y_j c_j = \sum_{j=1}^n y_j \left(\sum_{i=1}^n p_{ij} b_i \right) \quad (4.17)$$

$$= \sum_{i=1}^n \left(\sum_{j=1}^n p_{ij} y_j \right) b_i. \quad (4.18)$$

由于基下的坐标表示唯一，第 i 个旧坐标就是 $\sum_j p_{ij} y_j$ ；把这 n 个系数排成一列，得到

$$\boxed{[x]_B = P y = P [x]_C.} \quad (4.19)$$

这不是另行规定的换算规则，而是把一组基代入另一组基后，重新收集同一个向量的系数。

若将新基向量按标准坐标排成矩阵 $C = (c_1 \cdots c_n)$ ，同一展开式也可以写成 $x = C y$ 。这里 C 是数表， C 是有序基；仅当 B 为标准基时，才有 $P = C$ 、 $[x]_B = x$ 。对一般的旧基，应始终保留坐标下标。

反过来，把旧基向量用新基表示，得到 $Q = P_{C \leftarrow B}$ 。同样的推导给出 $[x]_C = Q [x]_B$ 。

连续换去再换回，对任意坐标列都有

$$QP\mathbf{y} = \mathbf{y}, \quad PQ\mathbf{u} = \mathbf{u}, \quad \mathbf{y}, \mathbf{u} \in \mathbb{R}^n. \quad (4.20)$$

坐标列可任意取值，故 $QP = PQ = E_n$ ，于是 $Q = P^{-1}$ ，并且

$$[\mathbf{x}]_C = P^{-1}[\mathbf{x}]_B. \quad (4.21)$$

过渡矩阵可逆不是额外假设，而是两组基能够互相表示、且坐标表示唯一的直接结果。

同一个变换，怎样得到两张矩阵

设 $T: \mathbb{R}^n \rightarrow \mathbb{R}^n$ 在基 B 下的矩阵为 A ，在基 C 下的矩阵为 B ，即

$$[T(\mathbf{x})]_B = A[\mathbf{x}]_B, \quad [T(\mathbf{x})]_C = B[\mathbf{x}]_C. \quad (4.22)$$

先用一张交换图 (Commutative Diagram) 把坐标与作用的位置放清楚：同一起终点之间，沿不同路径计算，结果一致。




图 4.16a: 换基与应用变换可以交换顺序：右上路径先换基再应用 T ，左下路径先应用 T 再换基，两条路径到达同一终点。这给出 $AP = PB$ ，即 $B = P^{-1}AP$ 。

读图说明：横向只改坐标，纵向才应用变换。这里的“交换”指两条相配路径的结果一致，并不表示 A 与 P 满足乘法交换律。一般情况下，右上角的坐标列 $\mathbf{u}$ 不能直接记作向量 $\mathbf{x}$ 。

如图 4.16a 所示， A 与 B 是同一个变换在两套坐标下的两个矩阵；换基只是观察方式变了，变换本身没有变。

换基、应用变换、换回来

给定新基坐标 $[\mathbf{x}]_C$ ，目标是得到同样用新基描述的输出 $[T(\mathbf{x})]_C$ 。先明确起点，再沿三次作用前进：

$$\text{起点: } [\mathbf{x}]_C;$$

$$\text{换到旧基: } [\mathbf{x}]_B = P[\mathbf{x}]_C; \quad (4.23)$$

$$\text{应用变换: } [T(\mathbf{x})]_B = A[\mathbf{x}]_B; \quad (4.24)$$

$$\text{换回新基: } [T(\mathbf{x})]_C = P^{-1}[T(\mathbf{x})]_B. \quad (4.25)$$

把三次左乘接起来，得到

$$[T(\mathbf{x})]_{\mathcal{C}} = P^{-1}AP[\mathbf{x}]_{\mathcal{C}} = B[\mathbf{x}]_{\mathcal{C}}. \quad (4.26)$$

这对任意输入坐标列成立；特别地，依次取每个标准单位列，就知道两矩阵的各列相同。因此

$$B = P^{-1}AP. \quad (4.27)$$

按作用顺序读，是先 P 、再 A 、最后 P^{-1} ；按矩阵乘积书写，则从右向左作用。路线绕回的是同一套坐标体系，不是同一个输入向量； $T(\mathbf{x})$ 通常不等于 $\mathbf{x}$ 。




图 4.16b: 相似变换是换基、应用变换、换回来的三步合成。合成矩阵 $B = P^{-1}AP$ 描述同一个变换在新坐标下的作用。

读图说明：四个坐标节点围成环形布局：实线沿外侧计算，灰色虚线直接使用 B ；两条路线都从新基输入走向新基输出。没有从输出指回输入的箭头，因为这里没有假设 T 可逆。

注意过渡方向。在当前 $P = P_{\mathcal{B} \leftarrow \mathcal{C}}$ 的约定下，不能把新矩阵写成 PAP^{-1} ：从旧坐标出发时，正确路线是先 P^{-1} 换到新坐标、再用 B 、最后用 P 换回，得到的是 $A = PBP^{-1}$ 。若改记 $Q = P_{\mathcal{C} \leftarrow \mathcal{B}} = P^{-1}$ ，才应把新矩阵写为 $B = QAQ^{-1}$ 。两种排列都可出现，但必须同时看清过渡矩阵的方向和中间作用的矩阵。

定义 4.13 (相似矩阵)

若两个同阶方阵 A, B 之间存在可逆矩阵 P ，使

$$B = P^{-1}AP,$$

就称它们为相似矩阵 (Similar Matrices)。这一关系称为相似变换 (Similarity Transformation)，表示同一个线性变换在两组基下的不同矩阵表示。

例题 4.14 (把同一投影写在另一组基下)

设 $T(x, y) = (x, 0)^T$, $\mathcal{B} = (\mathbf{e}_1, \mathbf{e}_2)$, $\mathcal{C} = ((1, 1)^T, (1, -1)^T)$ 。求 T 在 $\mathcal{C}$ 下的矩阵。

解 新基向量在旧基下的坐标按列排成

$$A = \begin{pmatrix} 1 & 0 \\ 0 & 0 \end{pmatrix}, \quad P = \begin{pmatrix} 1 & 1 \\ 1 & -1 \end{pmatrix}, \quad P^{-1} = \frac{1}{2} \begin{pmatrix} 1 & 1 \\ 1 & -1 \end{pmatrix}.$$

于是

$$B = P^{-1}AP = \frac{1}{2} \begin{pmatrix} 1 & 1 \\ 1 & 1 \end{pmatrix}.$$

从基的像也能核对：两个新基向量都投影为 $(1, 0)^T$ ，而 $(1, 0)^T = \frac{1}{2}(1, 1)^T + \frac{1}{2}(1, -1)^T$ ，因此 B 的两列都是 $(1/2, 1/2)^T$ 。

跟着数字走一遍：同一投影的两条路线

继续使用例题中的两组基，取 $\mathbf{x} = (3, 1)^T$ 。由于旧基是标准基， $[\mathbf{x}]_{\mathcal{B}} = (3, 1)^T$ 。先换到新基：

$$[\mathbf{x}]_{\mathcal{C}} = \frac{1}{2} \begin{pmatrix} 1 & 1 \\ 1 & -1 \end{pmatrix} \begin{pmatrix} 3 \\ 1 \end{pmatrix} = \begin{pmatrix} 2 \\ 1 \end{pmatrix}, \quad \mathbf{x} = 2\mathbf{c}_1 + \mathbf{c}_2. \quad (4.28)$$

这里的新基向量长度都是 $\sqrt{2}$ ，并非单位向量。“沿 $\mathbf{c}_1$ 走 2 个单位”是取 $2\mathbf{c}_1$ ，其实际长度为 $2\sqrt{2}$ ；坐标系数不等于沿斜轴的通常长度。




图 4.16c: 同一个向量 $\mathbf{x}$ ，在标准基下坐标是 $(3, 1)^T$ ，在新基下坐标是 $(2, 1)^T$ 。红色箭头本身没有移动，改变的是描述它的基。

读图说明：两幅图保持相同尺度与相同的物理方向，终点相对原点的位置一致。虚线表示按基向量首尾相接的分解；蓝色斜轴上的两个小点分别标出 $\mathbf{c}_1$ 与 $\mathbf{c}_2$ 的一个单位。

把相似公式中的每个矩阵写出来，可以看见新矩阵从哪里来：

$$B = P^{-1}AP = \frac{1}{2} \begin{pmatrix} 1 & 1 \\ 1 & -1 \end{pmatrix} \begin{pmatrix} 1 & 0 \\ 0 & 0 \end{pmatrix} \begin{pmatrix} 1 & 1 \\ 1 & -1 \end{pmatrix} \quad (4.29)$$

$$= \frac{1}{2} \begin{pmatrix} 1 & 1 \\ 1 & 1 \end{pmatrix}, \quad B[x]_C = \frac{1}{2} \begin{pmatrix} 1 & 1 \\ 1 & 1 \end{pmatrix} \begin{pmatrix} 2 \\ 1 \end{pmatrix} = \begin{pmatrix} 3/2 \\ 3/2 \end{pmatrix}. \quad (4.30)$$

也可以暂时不用 B ，沿旧坐标绕行：

$$\underbrace{\begin{pmatrix} 2 \\ 1 \end{pmatrix}}_{[x]_C} \xrightarrow{P} \underbrace{\begin{pmatrix} 3 \\ 1 \end{pmatrix}}_{[x]_B} \xrightarrow{A} \underbrace{\begin{pmatrix} 3 \\ 0 \end{pmatrix}}_{[T(x)]_B} \xrightarrow{P^{-1}} \underbrace{\begin{pmatrix} 3/2 \\ 3/2 \end{pmatrix}}_{[T(x)]_C}. \quad (4.31)$$




图 4.16d: 换基、投影、换回来：从 C 坐标出发，经过 P 、 A 、 P^{-1} 三步，在 C 坐标下得到同一投影的输出。合成矩阵就是 $B = P^{-1}AP$ 。

读图说明：按左上、右上、右下、左下的顺序读图。换基时物理箭头不变，只有中间的投影改变了它；灰色虚线表示直接在新基下使用 B 的另一条路线，终点相同。

若从标准基坐标开始，完整过程则是“换到新基、应用 B 、换回标准基”：

$$\begin{pmatrix} 3 \\ 1 \end{pmatrix} \xrightarrow{P^{-1}} \begin{pmatrix} 2 \\ 1 \end{pmatrix} \xrightarrow{B} \begin{pmatrix} 3/2 \\ 3/2 \end{pmatrix} \xrightarrow{P} \begin{pmatrix} 3 \\ 0 \end{pmatrix}. \quad (4.32)$$

直接使用 A 也得到 $(3, 0)^T$ 。两条路线得到同一个终点，这正是相似矩阵的几何含义。




图 4.16e: 两套坐标描述同一个投影。两幅图中的红色终点是同一个几何点； A 与 B 的差别来自坐标表示，实际的投影方向并未改变。

读图说明：两幅图都画在同一物理平面上，长度比例一致，蓝色为输入、红色为输出。投影的实际轨迹均平行于标准基的 y 轴，不平行于 $c_2 = (1, -1)^T$ ；换一组基不会改变几何作用。

区分几何方向与坐标列的变化。在标准坐标数表中，轨迹从 $(3, 1)^T$ 到 $(3, 0)^T$ ，坐标差为 $(0, -1)^T$ ；在新坐标数表中，从 $(2, 1)^T$ 到 $(3/2, 3/2)^T$ ，坐标差是 $(-1/2, 1/2)^T$ ，两个分量都改变了。它描述的仍是同一个竖直位移，因为

$$-\frac{1}{2}c_1 + \frac{1}{2}c_2 = (0, -1)^T. \quad (4.33)$$

若另在坐标数对的平面中把两个分量画成横纵轴，新坐标的轨迹会沿 $(-1, 1)^T$ 方向斜行；那是坐标图上的形状变化，不是物理投影方向改变。图 4.16e 保留真实的两组基方向，因而两幅图的投影线仍然平行。

相似矩阵的秩相同。因为换基没有改变 T 的零空间和值域，只改变它们的坐标表示，这两个空间的维数当然不变。以后还会看到，相似矩阵具有相同的行列式、特征值与迹；这里仅作预告，不用这些尚未展开的概念推导当前结论。

4.5 【选读】坐标变换的工程语言：以钱学森弹道为例

本小节为拓展内容，不做考核要求。第 4.1.1 节已经说明三维旋转怎样用矩阵表示。这里把目光转向工程现场：一架飞行器的运动，怎样同时成为地面人员、试验设备和计算机能够读懂的记录？

钱学森曾研究将火箭助推与滑翔飞行结合的构想，后来相关文献把再入后持续滑翔的这类方案称为“钱学森弹道”。关世义的论文以这一构想为背景，讨论了助推与滑翔两种飞行方式的结合。[34] 图 4.17a 把几种常见的轨迹形态并置：常规弹道以较高的弧线示意，巡航形态贴近地面，桑格尔方案突出反复起伏，钱学森方案则突出再入后的较平滑滑翔。工程师看到的却不只是一条曲线：助推时，飞行器逐渐离开发射点；再入和

滑翔时，周围空气的作用成为必须面对的问题；而不论飞到哪里，机体的朝向都未必与运动方向一致。于是，“它在哪里”“它朝向哪里”“它往哪里运动”成为三个彼此关联、却不能混为一谈的问题。这正是多组坐标同时出现的原因。图中的同一起终点只便于比较形态，约 100 km 的虚线是边界参照，不是大气突然终止的墙，更不是实际滑翔高度；本节全部轨迹、姿态与向量均为教学示意。




图 4.17a: 五种轨迹形态的教学对照。五条曲线共享示意起终点；钱学森弹道突出再入后的持续平滑滑翔，桑格尔弹道突出反复起伏。

读图说明：图为原创形态示意，不提供高度、速度、射程或气动计算模型；浅色区域只帮助辨认边界参照下方，曲线不可作为实际飞行数据读取。

设想同一次飞行在几处工作台上被同时观察。地面显示屏需要把飞行器放回地面的地图，便于辨认它与发射点的位置关系；固定在机体上的测量设备则有自己的安装方向，记录首先依附于机体；研究空气作用的人员还会关心运动方向，希望把“沿运动方向”和“偏离运动方向”的作用分开说明。图 4.17b 中的发射系、机体系 and 速度系，分别回应了这些工作需求。[33] 它们不是按飞行阶段轮流上岗的三套坐标，同一时刻就可能一起使用。一个方向在地面看来朝上，在机体记录中却未必沿某一根轴；这并不意味着测量互相矛盾，而是设备和人员站在不同的参照下说话。所谓把数据“接起来”，首先就是让这些记录能够互相解释。




图 4.17b: 一条轨迹，多组坐标。上方示意助推、再入与滑翔，下方分别画出地面参考架、机体参考架与速度参考架。

读图说明：下方坐标架已移到空白处单独展示，图上位置不代表它们的实际原点。三维坐标架在纸上以斜视图表示；阅读坐标数据时，要分别说明原点在哪里、轴向怎样规定。

这种分工在风洞中尤其容易看见。把飞行器模型固定在试验装置上，让空气流过模型，测力设备便可记录空气对它的作用。NASA Glenn 的风洞教学资料指出：装在模型内部的测力天平通常按机体轴记录力，外部天平则按风洞的风轴记录力。[39] 两种设备面对的是同一个模型，却未必直接交出同一种坐标记录。模型在装置上换一个朝向，机体轴跟着模型改变，风洞轴仍由试验装置确定；若把两份数据中同一位置上的数直接相减，就可能把坐标约定的差异误认为试验结果的差异。对负责数据处理的同学而言，工作的起点不是套一个更复杂的算法，而是读清楚“这几个数沿哪几根轴记录”。设同一个力向量为 f ，机体基为 C ，风洞基为 B ，统一记录只需用第 4.4 节已经认识的关系

$$[f]_B = P_{B \leftarrow C} [f]_C. \quad (4.34)$$

过渡矩阵的每一列告诉我们一根机体轴怎样用风洞轴描述。两组基都由单位且两两垂直的轴组成时，这种矩阵在工程文献中称为方向余弦矩阵 (Direction Cosine Matrix)；它把设备的记录翻译成可以一起比较的数据，力本身没有因此改变。对于位置，还须多看一项：两套坐标是否使用同一个原点。机体质心在自身坐标中的位置是零，并不意味着它位于发射点；若原点不同，还要计入原点之间的位移。这是第 4.1 节中“线性作用加平移”的工程含义。




图 4.17c: 风洞中的两份记录。模型和受力相同，机体轴与风洞轴却可能不同；比较数据之前，要先统一坐标。

读图说明：图按 NASA Glenn 对内、外部天平记录轴的说明原创绘制，并非设备结构图。绿色箭头始终表示同一个示意力；仅画侧视平面内的两根轴，第三根轴省略，箭头大小不代表试验测量值。

把视野从风洞移回长距离飞行，参考系的选择还关系到整套软件怎样组织数据。Chen 等人的论文在讨论助推—滑翔飞行器的导航计算背景时，比较了发射惯性系、当地水平系等参考系的使用需求：适合描述发射初期运动的参照，未必也最便于表述后续运动与地面的关系。[40] 这里值得初学者留意的，是选择背后的工作任务，而不是某一套专门算法。地面试验人员希望把试验结果放回装置的轴向，机上设备首先保留自身的测量约定，地面显示又要让人看清运动与地面的关系；同一组数据流经这些环节时，需要明确的转换接口。NASA/JPL 的 SPICE 参考系文档把“从哪个参考系、到哪个参考系、在哪一时刻”作为转换的重要信息。[31] 参考架如果随时间改变，昨天或上一时刻的朝向便不能不加区分地沿用。矩阵提供了换算的形式，工程记录还必须告诉使用者这张矩阵属于哪一个场景。

工程软件传递的也不只是某一时刻的向量，还包括“怎样让模型转动”这样的作用。可以设想一个地面演示：同一架模型在转台上完成一次转动，试验界面与三维回放界面各用一套固定的坐标基记录全过程。两块屏幕上的输入坐标不同，描述转动的矩阵也可能不同，但它们必须重现同一姿态变化。若这一次转动在线性映射意义下记为 T ，在两套基下的矩阵分别为 M_B 与 M_C ，仍取 $P = P_{B \leftarrow C}$ ，则

$$M_C = P^{-1} M_B P. \quad (4.35)$$

不必再展开矩阵中的每一个数：右边先把输入送到试验界面使用的坐标，再应用那次转动，最后把输出送回回放界面使用的坐标。图 4.17d 把这件事画成同一动作的两份记录。这正是工程协作中有用的相似关系——换一套显示或计算坐标，不应换掉模型实际完成的动作。这里描述的是同一转动的输入、输出同时换基。若一张“姿态矩阵”仅记录机体轴在参考系中的分量，只更换参考系就只是转换链的一次连接，不能因为名称里有“姿态”就一律套用相似公式。[37]




图 4.17d: 一次转动，两套记录。两行中的模型做完全相同的动作；变的是观察坐标，以及记录同一作用的矩阵。

读图说明：绿色短箭头随模型一起转动。蓝、红两套三维观察基分别固定，使用同一斜视方式画在纸上；红色坐标架相对蓝色坐标架向空间中倾转。沿灰色辅助路线换基不使模型再转一次。这是地面演示场景，不是飞行器的控制流程。

对计算机专业的读者，这个案例还可以读成一次多系统协作。试验文件中的三列数据、三维软件中的三个坐标、地面显示中的一个箭头，看起来都只是数字和图形，但没有轴向、原点、时刻与转换方向的约定，它们便不能放心地放在一起使用。陈阳泉关于坐标转换矩阵程序化推导的论文，展示了把坐标关系交给程序处理的思路。[35] 程序能够重复完成换算，接口设计却必须先说明数据的含义。一个可追踪的工程记录，不仅保存算出的结果，还让后来接手的人知道：这个量来自哪套坐标，现在要交给哪套坐标；描述的是同一个向量，还是同一个动作。理解这些问题，才知道为什么看似简单的换基会反复出现在试验、仿真与数据处理之间。

从助推、再入到持续滑翔，直至最后下降，地面位置、机体朝向和运动方向始终需要彼此对照。我们不在这里展开飞行力学，而是看清贯穿这些工作的共同需求：**让来自不同设备、不同观察位置的记录，仍能描述同一个物理过程。**过渡矩阵使向量的记录相通，相似矩阵使同一作用的表示相通；前者帮助比较数据，后者帮助不同软件重现同一动作。三维旋转的公式在第 4.1.1 节已经推导，到了工程现场，它们承担的是连接测量、试验与计算的具体工作。至于怎样选择一组更便于研究问题的基，第 8 章和第 9 章还会继续回答。

4.6 【选读】秩与零度定理的证明及行秩性质

本小节为拓展内容，不做考核要求。

主线已经使用了秩与零度的维数等式。现在用第1章的基扩充定理给出证明，再说明为什么矩阵的行与列能够拥有相同的秩。本节讨论的仍是实数空间，不需要特征值、行列式或第7章的正交补理论。

把零空间的基扩充为整个定义域的基

设 $T: \mathbb{R}^n \rightarrow \mathbb{R}^m$ 是线性映射，取 $\text{null } T$ 的一组基

$$u_1, \dots, u_k, \quad k = \dim \text{null } T.$$

由第1章的基扩充定理，这组线性无关向量可以扩充为 $\mathbb{R}^n$ 的一组基：

$$u_1, \dots, u_k, w_1, \dots, w_{n-k}.$$

前 k 支向量被送到零。我们要证明，后面 $n-k$ 支向量的像恰好构成值域的一组基。只需分别证明张成性与线性无关性。

这些像张成整个值域

任取 $y \in \text{range } T$ 。根据值域定义，存在 $x \in \mathbb{R}^n$ 使 $T(x) = y$ 。由于扩充后的向量组是一组基， x 可以写成

$$x = \sum_{i=1}^k a_i u_i + \sum_{j=1}^{n-k} b_j w_j.$$

由线性性质，且每个 $T(u_i) = \mathbf{0}$ ，有

$$y = T(x) = \sum_{i=1}^k a_i T(u_i) + \sum_{j=1}^{n-k} b_j T(w_j) = \sum_{j=1}^{n-k} b_j T(w_j).$$

因此任意输出都在这些像的张成空间中；这些像本来又都属于值域，所以

$$\text{range } T = \text{Span}\{T(w_1), \dots, T(w_{n-k})\}.$$

这些像线性无关

设一组实数 $c_1, \dots, c_{n-k}$ 满足

$$\sum_{j=1}^{n-k} c_j T(w_j) = \mathbf{0}.$$

利用线性性质，将 T 提到组合之外，得到

$$T\left(\sum_{j=1}^{n-k} c_j w_j\right) = \mathbf{0}.$$

所以括号内的输入属于 $\text{null } T$ 。因为 $u_1, \dots, u_k$ 是零空间的一组基，存在实数 $d_1, \dots, d_k$ ，使

$$\sum_{j=1}^{n-k} c_j w_j = \sum_{i=1}^k d_i u_i.$$

移到同一边，就得到扩充基的一组线性组合为零：

$$\sum_{j=1}^{n-k} c_j w_j - \sum_{i=1}^k d_i u_i = 0.$$

这是一组基向量的线性组合，所以每个系数都必须为 0。特别地， $c_1 = \dots = c_{n-k} = 0$ ，这就证明了上述 $n-k$ 个像向量线性无关。

它们既张成值域又线性无关，故构成值域的一组基，因而

$$\dim \text{range } T = n - k, \quad n = \dim \text{null } T + \dim \text{range } T.$$

若 $k = 0$ 或 $k = n$ ，证明中的一组向量为空组，按空组张成零子空间、空和为零理解，结论依然成立。对实数空间的子空间 V ，只须把扩充基的总长度 n 改为 $\dim V$ ，同样得到一般版本。□

证明还说明了“保留方向”的准确含义：补进来的 w_j 可以有不同选法，但它们的像总能组成值域的一组基，数目固定为 $n-k$ 。维数定理没有要求存在某一组唯一的、天然指定的保留方向。

为什么行秩等于列秩

矩阵的行秩 (Row Rank) 是行向量组张成空间的维数，列秩 (Column Rank) 是列空间的维数。对 $m \times n$ 矩阵，行空间位于 $\mathbb{R}^n$ ，列空间位于 $\mathbb{R}^m$ ；二者通常不是同一个空间，却有相同的维数。

定理 4.15 (行秩等于列秩)

任意实矩阵 A 的行秩等于列秩。因而

$$\text{rank}(A^T) = \text{rank}(A).$$

证明： 设 A 为 $m \times n$ 矩阵。用第二章的初等行变换把 A 化为行阶梯形矩阵 U ，设 U 有 r 个非零行。

先看行空间。每次初等行变换得到的新行都是旧行的线性组合，因此新行空间包含于旧行空间；逆变换仍为初等行变换，反过来又得到旧行空间包含于新行空间。所以行空间实际上不变。阶梯形 U 的 r 个非零行线性无关：若它们的线性组合为零，按从左到右的主元列依次检查，便迫使组合系数逐个为零。因此 A 的行秩等于 r 。

再看齐次解。初等行变换保持方程组的解，故 $\text{null } A = \text{null } U$ 。 $Ux = \mathbf{0}$ 有 r 个主元变量、 $n - r$ 个自由变量；由第 4.1.2 小节已经证明的参数基构造，

$$\dim \text{null } A = n - r.$$

最后使用秩与零度定理。列秩就是值域维数，所以

$$\text{列秩}(A) = \text{rank}(A) = n - \dim \text{null } A = n - (n - r) = r.$$

行秩与列秩相等。 A^T 的列向量恰好是 A 的行向量改为列写，因此 $\text{rank}(A^T)$ 等于 A 的行秩，所需等式随即成立。■

这份证明没有先假定“消元保持列秩”，而是先用可逆的行组合说明行空间不变，再由齐次解与秩—零度定理读出列秩。因此逻辑没有绕回待证的结论。

例如，矩阵 $\begin{pmatrix} 1 & 2 & -1 \\ 2 & 4 & -2 \end{pmatrix}$ 的行空间是 $\mathbb{R}^3$ 中由 $(1, 2, -1)$ 张成的直线，列空间是 $\mathbb{R}^2$ 中由 $(1, 2)^T$ 张成的直线。两条直线所在的空间不同，坐标长度也不同，但维数都是 1。这才是“行秩等于列秩”的几何意思。

回到第三章的 CR 与第五章的消元

第 3.9 节选读的 CR 分解，把矩阵写成 $A = CR$ ： C 从原矩阵提取 r 个独立列方向，右因子 R 保存各列的组合系数。若按该节的行最简形构造， R 有 r 个独立行。行秩等于列秩说明，这两种记录所需的独立方向数恰好相同；这也是 CR 结构背后的维数依据。

初等行变换虽可能改变列空间在目标空间中的具体位置，却不改变矩阵的秩。可以用本节结论解释：行空间不变，所以行秩不变，列秩也就不变；也可以用齐次解不变和 $\text{rank}(A) = n - \dim \text{null } A$ 解释。第五章将再次用到这些理由，让“消元以后为什么仍能判断原方程组”的每一步都有清楚依据。

4.7 【应用案例】图像压缩：从像素到频率的基变换

把一张灰度图片放大，会看到许多小方格，每一格称为一个像素 (Pixel)。本例以 0 表示黑、255 表示白，中间数值表示不同的亮度。于是，一小块图片可以记录成矩阵；彩色图像也可以分成若干颜色分量分别记录。压缩要解决的问题是：能否用更少的存储，保留图像中我们关心的结构？

JPEG 提供了一个真实背景。JPEG 官方列出的 ISO/IEC 10918-1 与 ITU-T T.81 是对应标准；其常用的有损 DCT 流程以 8×8 图像块为单位，经过变换、量化和编码。标准附录 A.3 给出变换与量化定义，Wallace 的经典论文解释了这些环节的作用。[41, 42, 45] 这里抽出其中的换基思想，用更小的算例看清它。

教学模型约定：以下所有数值、算例、图像、配图与量化规则均为教学简化模型，不代表 JPEG 标准的具体实现细节。全节使用同一个自拟 4×4 灰度块，省略颜色处理、像素平移和文件编码；基模式由公式计算绘制。

按行依次读出 16 个像素，就得到一个向量。行列下标统一从 0 开始：

$$\mathbf{x} = (X_{00}, X_{01}, \dots, X_{03}, X_{10}, \dots, X_{33})^T \in \mathbb{R}^{16}.$$

只在某个位置放 1、其余位置放 0，就得到一幅单点模式 E_{ij} ；依次展开后，它们正是标准基向量。这组像素基 (Pixel Basis) 逐点记录亮度，像素值就是坐标。16 个坐标共同决定一块图像。




图 4.18: 换基可逆，量化丢失细节，再用逆变换重建。

读图说明：教学简化流程。中间已包含量化后的尺度恢复；存储时记录的是整数系数。文件编码环节未画出。

不过，在天空、墙面或平滑渐变中，相邻像素往往十分相近。逐点记录容易反复描述同一片亮度和同一种缓慢变化。这里的“相关”不表示任意像素都能由邻居精确推算，而是提示我们：换一种组织坐标的方式，可能更方便保留主要变化。

第 4.4 节已经说明，同一个向量可以有不同的坐标；换基不等于改变对象。本例要做的正是这件事：先把“每个位置多亮”，改写成“每一种变化模式占多少”；再决定哪些坐标值得保留。DCT 负责前一件事，量化负责后一件事。

让每个坐标对应一种变化模式

离散余弦变换 (Discrete Cosine Transform) 把图像写成一组余弦模式的线性组合。所谓频率，在这里就是亮暗变化的快慢：最低频模式处处相同，记录整体亮度；频率越高，亮暗交替越快。它描述的是空间中的变化，不是图像播放的速度。

本例采用规范化的二型 DCT。公开定义可见标准附录 A.3.3 及 SciPy 的 DCT-II 说明。[42, 43] 缩小到 4 个采样点，所需 4×4 矩阵 D 的元素为

$$D_{uj} = \alpha_u \cos \frac{(2j+1)u\pi}{8}, \quad \alpha_0 = \frac{1}{2}, \quad \alpha_1 = \alpha_2 = \alpha_3 = \frac{1}{\sqrt{2}}, \quad 0 \leq u, j \leq 3.$$

你无需背诵这个公式；它只是把基模式的来源说明白。例如第 0 行是 $(\frac{1}{2}, \frac{1}{2}, \frac{1}{2}, \frac{1}{2})$ ，第 1 行约为 $(0.6533, 0.2706, -0.2706, -0.6533)$ ：前者不变，后者缓慢地从正变负。

把两个方向的模式组合，得到基图案 B_{uv} ，其第 i, j 个位置为 $D_{ui}D_{vj}$ 。这 16 幅图案彼此独立，共同张成整个 16 维空间；任意 4×4 实数块都能由它们唯一表示。




图 4.19: 同一个 16 维空间，可以选择两组不同的基。

读图说明：自绘 4×4 教学模式，各侧只展示 16 幅基图案中的 4 幅。左侧白格为 1、灰格为 0；右侧统一以中灰表示 0，浅色为正、深色为负，并按同一尺度显示；这些有正负号的模式不是待压缩照片。

矩阵乘法把整个换基过程写得很短：

$$\boxed{C = DXD^T}, \quad \boxed{X = D^TCD}.$$

前式先后处理两个坐标方向；后式利用所选尺度下 $D^{-1} = D^T$ 恢复原块。这里直接使用这一可核验的性质，不展开正交理论。

C_{uv} 是模式 B_{uv} 的系数；把所有 $C_{uv}B_{uv}$ 相加，就重新得到 X 。若把展开后的基图案按列排成过渡矩阵，这仍是第 3 章的矩阵乘法、第 4.4 节的坐标转换。**16 个像素换成 16 个频率系数，空间的维数仍为 16，信息并没有减少。**

用同一个图像块，看见量化发生在哪里

图 4.20 的原图从左上向右下逐渐变亮。像素基下 16 个坐标都不为零；DCT 基下，却只有整体亮度和两个缓慢变化的系数较大。其余只有两项小系数，另外 11 项恰为零。这是本例的结构，并非对所有图像的保证。

最容易手算的是整体亮度系数。因为 D 的第 0 行全为 $1/2$ ， C_{00} 等于 16 个像素之和除以 4。本例平均亮度为 112，所以 $C_{00} = 4 \times 112 = 448$ 。系数不是像素值，超过 255 或取负数都很正常。

现在进行量化 (Quantization)：选定间隔 $\Delta > 0$ ，把系数除以它，再取最近的整数；重建前再乘回间隔。对每个位置分别做

$$K_{uv} = \text{round}(C_{uv}/\Delta), \quad \hat{C}_{uv} = \Delta K_{uv}, \quad \hat{X} = D^T \hat{C} D.$$

这里取教学步长 $\Delta = 32$ 。于是 $448 \mapsto 14 \mapsto 448$ ， $-107.061 \dots \mapsto -3 \mapsto -96$ ， $-7.608 \dots \mapsto 0 \mapsto 0$ 。取整恰逢半整数时，本模型约定向远离 0 的方向取整；本例没有这种边界值。




图 4.20: 同一 4×4 图像块：换基集中坐标，量化后只能近似恢复。

读图说明：全部为教学简化数据，量化步长为 32。左右图使用相同的 0—255 灰度标尺；系数与重建像素只为显示保留一位小数，计算使用未舍入数值。中间浅蓝色仅提示系数大小。

量化后只剩 $K_{00} = 14$ 、 $K_{01} = K_{10} = -3$ 三个非零坐标。逆变换保留了渐变，却不能恢复原来的每个像素：左上角由 40 变为约 49.3，右下角由 184 变为约 174.7。保留下来的大系数也经过舍入，误差不只来自置零。

换基本身不丢信息，量化才是这里有损压缩的关键。标准的量化表可以为不同频率选择不同间隔；本例统一取 32，只为便于手算。[42] 把整数和成串的零进一步编码，才会减少实际文件的字节数。不能把“三个非零系数”直接说成压缩比为 16 : 3，还要计入位置、参数等记录。

用值域与零空间，说明哪些方向被舍去了

系数为什么能集中？对这一平滑图像块，大部分变化已经能用整体亮度和两个低频模式描述；高频模式只作小幅修正。图 4.21 按频率指标排列同一组系数，可以直接比较大小。




图 4.21: 本例的大系数集中在左侧的三个低频位置。

读图说明：教学简化数据，柱高为系数绝对值，不是“信息量”或压缩比。最右边的 33 代表两个方向上均为最高频；复杂纹理图像可能有较大的高频系数。

现在暂不取整，只考察一个**固定的线性操作** L ：保留 C_{00}, C_{01}, C_{10} ，其余 13 个坐标置零，再换回像素基。把基图案按行展开为向量， L 的值域是 $\text{Span}\{B_{00}, B_{01}, B_{10}\}$ ；零空间由另外 13 幅基图案张成。这就回到了本章熟悉的 $\mathbb{R}^{16}$ 。

这 16 幅图案原本是一组基，因此被保留的三幅仍然独立，其余 13 幅也独立。由第 4.3 节的语言，

$$\underbrace{16}_{\text{输入维数}} = \underbrace{13}_{\text{零空间维数}} + \underbrace{3}_{\text{值域维数}}, \quad \text{rank}(L) = 3.$$

这里的 3 是**保留图案所张成空间的维数**，不是某幅 4×4 像素矩阵的秩。输出仍有 16 个像素，只是它们由三个系数共同决定；被丢弃方向上的差异，已经无法从输出中辨认。

本例量化后恰好只剩这三处非零系数，重建图像也落在上述三维子空间内。但**完整的量化不是线性映射**：12 和 12 各自量化为 0，它们的和 24 量化并恢复尺度后却为 32，加法不再保持。因此，秩—零度定理适用于固定保留位置的 L ，不能套用于整个量化过程。

如果图像包含细密纹理或清晰文字，高频坐标可能很重要；删得过多，边缘和细节就会改变。Wallace 把量化解释为舍去视觉上不那么重要的精度，而不是断言“高频没有用”。[45] 换基使可舍弃的坐标更容易辨认，是否舍弃仍取决于图像和质量要求。

由此，压缩与本章的主线连在一起：同一个对象先换坐标，再在较低维的子空间中近似，最后换回熟悉的像素表示。DCT 是一组固定的基，对所有同尺寸图像块使用相同的模式；有没有一组基能针对具体图像自动调整？这个问题留给第 7 章的内积和第 11 章的 SVD。

本章小结

本章从屏幕上可见的几何变换出发，走向线性映射看不见的内部结构。旋转、非退化缩放、剪切与反射能够恢复输入，投影则合并了一整类输入。平移的反例提醒我们，保持图形的外观或直线关系并不足以保证线性；齐次坐标通过增加一个分量，把平移也统一进高维的矩阵乘法，同时也要求我们严格分清原空间与升维空间。这套从图形学中提炼出的语言，为分析抽象的线性映射提供了第一层直观。

主线需要掌握的三个对象，可以沿求解 $Ax = b$ 的过程理解。**值域**由系数列的全部线性组合构成，决定目标 b 能否得到；**零空间**是 $Ax = 0$ 的解空间，决定两个输入之间哪些差别不会改变输出。把这两者联系起来的是**秩与零度定理**：

$$n = \dim \text{null } A + \text{rank}(A).$$

它把定义域的维数拆成“被压缩掉的维数”与“输出保留的维数”。零空间只有零向量意味着单射，即有解时解唯一；值域等于整个目标空间意味着满射，即每个右端项都有解。这两个判断各有对象，也各有条件，不能互相替代。

基变换进一步表明，换一组基会改变坐标和矩阵，却不会改变同一线性变换的秩与零度。相似矩阵 $B = P^{-1}AP$ 记录的正是这种“视角改变、结构不变”的关系。选读中的基扩充法解释了秩与零度等式从何而来，而行秩等于列秩则把矩阵的行与列两种观察方向接到一起。这些讨论说明，矩阵只是线性映射在特定基下的快照，换基并没有改变映射本身。

章末的图像压缩案例，把上述结构落到了真实的工程算法中。JPEG 把图像块从像素基换到 DCT 基，可逆的换基本身不丢信息；真正带来压缩的是随后的量化与舍弃，它把高频系数归零，相当于把图像投影到一个低维子空间里。这既呼应了值域与零空间的语言，也提醒我们：压缩之所以有效，是因为新基把重要信息集中到了少数坐标上。DCT 是一组固定的基，未来我们还会问，有没有一组基能针对具体数据自动调整？

从计算机图形的一次转动，到一组方程是否有解，我们始终在辨认同样的线性结构。下一章将带着零空间、值域与维数关系，重新审视线性方程组，把第二章已经会做的计算，组织成对解的存在性、唯一性与全部解的完整理解。

第 5 章

线性方程组的再研究: 解的结构

第二章教我们消元, 第四章引入零空间与值域. 本章把两条线索接起来: **列空间决定目标能否到达, 零空间决定到达同一目标的全部自由度**. 从电网实例出发, 我们将用基、维数和四个基本子空间解释方程组的全部解.

介绍性实例 当一张电网牵动千万人的生活 ——从北美大停电看方程、网络与状态

1882 年 9 月 4 日, 爱迪生的珍珠街电站在纽约开始供电, 将发电机、地下导线与街区电灯接成一个系统。[46] 此后一百多年, 地方电网逐渐互联, 城市能够获得远方的电能, 也能相互支援; 与此同时, 地区之间的依赖不断增加。

2003 年 8 月 14 日下午, 美国东北部、中西部部分地区及加拿大安大略省发生大面积停电, 影响约五千万人, 涉及约 6180 万千瓦的用电负荷。[47] 图 5.0a 中的灰色区域记录了事故范围。线路退出会改变其他线路上的电力分布, 因此局部扰动可能牵动整个网络。

- **1882**
珍珠街电站开始供电
从一片街区组织起电力系统
- **2003**
北美大停电
约五千万人受到影响



图 5.0a: 从街区供电到区域互联: 电网的规模, 也意味着联系的规模。

右图摘自美加联合调查报告第 100 页图 6.29[47], 保留原图。灰色表示事故影响区域, 其中仍有部分地区保持供电; 它不是逐条线路的故障传播图。

事后的联合调查涉及系统认识、运行态势感知、树木清障和可靠性协调等多方面问题。[48] 工程师需要知道的, 既包括哪台设备出了问题, 也包括这些设备怎样相连、哪些运行条件必须共同满足, 以及连接改变之后整个系统会怎样响应。要进入这些问题, 首先需要一种能够把“局部的连接”写成“整体的关系”的语言。我们在第二章学过的线性方程组, 正是其中最基础的一层。

为了看清这一层结构, 先把庞大的电网缩成图 5.0b 中的四个节点、五条线路, 并用理想直流电路的节点电流平衡作教学模型。这里不复原事故电网, 也暂不处理交流电网的完整运行条件。每条线路先规定一个参考方向, 电流按这个方向记正, 反向记负; 在不积累电荷的连接点, **外部注入的电流加上线路流入, 必须等于线路流出**。把各节点的这个关系分别写出来, 就得到一组线性方程。




图 5.0b: 从网络连接到节点方程: 每一条线路同时联系两个节点。

图中方向只是符号约定, 不预先限制电流的实际方向。放大图取 b_2 为外部净注入; 它为负时表示该节点向外取出电流。所有连接均为自拟教学示意。

例如节点 2 的关系是 $-f_1 + f_3 + f_4 = b_2$ 。设 f 收集五条线路的电流, b 收集四个节点的外部净注入, 把全网的节点方程合在一起, 就写成

$$Af = b. \quad (5.1)$$

这里的 A 是一个 4×5 的关联矩阵 (Incidence Matrix): 每列对应一条线路, 在流出节点所在行记 $+1$, 在流入节点所在行记 -1 , 其余位置记 0 。它只记录谁与谁相连, 以及我们怎样约定方向。设备的名称与地理位置暂时隐去, 网络的连接关系却完整地留在了数表中。电网络的这种组织方式, 也是用线性代数研究网络结构的经典入口。[49]

但是, 写出方程还不是问题的终点。给定一组外部供需, 每条线路的电流都能算出来吗? 如果能, 是否只有一种满足节点平衡的分配? 把所有节点方程相加, 会不会发现有些条件早已包含在其余条件之中? 第二章的消元法可以帮助我们作出判断; 本章则要继续解释: 这些判断为什么成立, 它们究竟反映了网络中的什么结构?

先看供需。并不是任意写下一组节点净注入，都能由内部线路实现；在这个连通的教学网络中，全网注入与取出必须平衡。能够实现的 b 组成 A 的列空间 (Column Space)。再看线路：沿一个闭合回路同时增加一股循环电流，各节点都多流入一份、也多流出一份，外部收支因而不变。这类满足 $Az = 0$ 的变化，属于 A 的零空间 (Null Space)。一个空间回答“什么目标能够达到”，另一个空间回答“达到同一目标还留下什么自由度”。




图 5.0c: 同一张网络引出的四个问题：四个基本子空间各有工程含义。

四幅图使用同一连接结构。上右图画的是相对于某个已有平衡方案的电流增量， $t > 0$ 时沿红色箭头循环；它不表示无电源的电阻回路会自行维持电流。此处只预览结构，严格定义与相互关系将在本章正文中展开。

还有另一种观察方式：把各节点的电势排成向量 v ，每条线路两端的电势差便组成 $A^T v$ 。这些能够由节点电势产生的线路记录，组成 A 的行空间 (Row Space)。而把全部节点方程相加，内部线路一进一出全部抵消，只留下 $b_1 + b_2 + b_3 + b_4 = 0$ ；这条整体约束来自 A 的左零空间 (Left Null Space)。甚至把所有节点电势同时加上一个相同的数，线路电势差也完全不变，这同样体现了转置矩阵的零空间。[49]

第三章从转置中引出的四个基本子空间 (Four Fundamental Subspaces)，现在各有具体的工程问题。列空间与左零空间联系节点端的“能够实现”与“必须满足”，行空间与零空间联系线路端的“电势差”与“循环自由度”。四个名称背后，是同一个工程系统的四种关系。节点守恒只给出了其中一层条件；线路实际怎样分配电流，还要结合元件关系。本章的目标，正是把“方程有没有解、解是否唯一、所有解如何组成”组织成对这些关系的整体认识。

真实电网也不会停在同一时刻。用电需求随时间变化, 设备会接入或退出; 在今天的电力系统中, 储能装置还会把某个时段充入的能量留到另一个时段使用, 以帮助调节供需。[50] 一张满足节点平衡的记录, 只说明此刻的关系。工程师还需要连续地记录状态, 追问下一时刻会怎样, 以及一次变化会怎样影响之后的运行。



图 5.0d: 从一张快照到连续记录: 平衡关系描述此刻, 更新规则联系前后。

这里仅示意状态记录的先后次序, 没有指定真实电网的参数或演化曲线。连接固定时, 状态仍可能变化; 连接改变时, 模型也需要随之更新。

例如, 储能装置下一时段的电量, 等于当前电量加上本时段的净充入量。把需要记住的量有序排成一列, 就得到状态向量 (State Vector)。若某个教学模型在所考察范围内可用固定的线性更新规则描述, 并暂不考虑外部输入, 状态之间便可以写成

$$\mathbf{x}_{k+1} = F\mathbf{x}_k. \quad (5.2)$$

这里 F 是状态转移矩阵 (State-Transition Matrix), 它记录从当前状态到下一状态的作用; 前面的 A 则记录节点与线路的连接。两种矩阵承担不同任务。真实系统的完整动态模型通常更复杂, 式(5.2)只为后面的离散递推选读打开入口: 同一个矩阵反复作用, 怎样把一个初始状态带向之后的一串状态?

于是, 从电网中提出的问题便有了次序: 先辨认哪些平衡可以实现, 再说明达到同一平衡可以保留哪些自由度, 进而把行与列、矩阵与转置联系起来; 在此基础上, 再观察状态怎样随时间更新。我们不会在本章用一个小矩阵重演北美大停电, 但可以开始读懂大型系统背后的基本关系。百余年来, 从街区里的电灯到跨地区的互连网络, 人类建造的不只是更多设备, 也是一套越来越复杂的相互联系。本章就从方程的全部解出发, 学习看清这份联系的结构。

从一个答案，到全部答案

为什么已经会解方程组，还要再研究一次？第二章中，我们学会了消元、辨认主元和自由变量，也会判断无解、唯一解与无穷多解；那时，方程组主要是一项计算任务。第四章中，我们又从线性映射出发，认识了零空间、值域以及秩与零度，开始看见矩阵内部的结构。两条线索现在可以合起来：消元得到的参数不只是待填写的数字，而是解集能够变化的方向；一个右端项也不只是常数项，而是映射需要到达的目标。

本章的任务，就是用映射的语言重新理解全部解。为什么若干自由变量能组成解空间的一组基？为什么非齐次解可以沿某些方向改变而输出不变？为什么行变换改了方程，却没有改解集？我们将先从熟悉的计算中找出这些问题，再用几何图像和四个基本子空间把答案组织起来。第 2 章的方法仍然是计算依据；这里的“再研究”，是把计算结果提升为对结构的认识。

列空间决定目标能否到达，零空间决定到达同一目标的全部自由度。这句话将贯穿全章。第 5.1 至 5.7 节为主线，其中第 5.7 节把解的结构延伸到无解时的最优近似；第 5.8、5.9 节为选读，把同样的线性结构放到随时间更新的状态中观察；第 5.10 节回到短视频推荐，用四个子空间解释精确匹配、方案自由与最优近似。

5.1 齐次方程组：从自由变量到基础解系

第 2 章我们已经会解齐次方程组了。今天仍从行最简形、主元和自由变量出发，但换一个角度看结果：每个自由变量在变化时，整个解向量沿什么方向移动？把所有这些方向放在一起，能否得到全部解？先看一个四元例子，把从方程到空间的每一环接起来。

例题 5.1 (从四个未知数中找出两个自由方向)

求齐次方程组

$$\begin{cases} x_1 + x_2 + x_3 = 0, \\ 2x_1 + 2x_2 + 3x_3 + x_4 = 0, \\ x_1 + x_2 + 2x_3 + x_4 = 0 \end{cases} \quad (5.3)$$

的通解，并找出描述全部解的独立方向。

解 用第 2 章的行变换方法，把系数与零常数项一起排列。先消去第一列，再消去

重复的第三行, 得到行阶梯形:

$$\left[\begin{array}{cccc|c} 1 & 1 & 1 & 0 & 0 \\ 2 & 2 & 3 & 1 & 0 \\ 1 & 1 & 2 & 1 & 0 \end{array} \right] \xrightarrow[r_3 \leftarrow r_3 - r_1]{r_2 \leftarrow r_2 - 2r_1} \left[\begin{array}{cccc|c} 1 & 1 & 1 & 0 & 0 \\ 0 & 0 & 1 & 1 & 0 \\ 0 & 0 & 1 & 1 & 0 \end{array} \right] \quad (5.4)$$

$$\xrightarrow{r_3 \leftarrow r_3 - r_2} \left[\begin{array}{cccc|c} 1 & 1 & 1 & 0 & 0 \\ 0 & 0 & 1 & 1 & 0 \\ 0 & 0 & 0 & 0 & 0 \end{array} \right]. \quad (5.5)$$

最后用 $r_1 \leftarrow r_1 - r_2$, 得到行最简形

$$\left[\begin{array}{cccc|c} 1 & 1 & 0 & -1 & 0 \\ 0 & 0 & 1 & 1 & 0 \\ 0 & 0 & 0 & 0 & 0 \end{array} \right]. \quad (5.6)$$

主元在第 1、3 列, 所以 x_1, x_3 是主元变量, x_2, x_4 是自由变量。行最简形直接给出 $x_1 = -x_2 + x_4$ 、 $x_3 = -x_4$ 。令 $x_2 = s$ 、 $x_4 = t$, 逐项写出并整理:

$$\mathbf{x} = (-s + t, s, -t, t)^T \quad (5.7)$$

$$= s(-1, 1, 0, 0)^T + t(1, 0, -1, 1)^T, \quad s, t \in \mathbb{R}. \quad (5.8)$$

先不要急着给这两支向量命名。我们已经看见, **所有解都能由它们线性组合出来**: s 控制第一个方向, t 控制第二个方向。取 $(s, t) = (1, 0)$ 、 $(0, 1)$, 得到的两支向量各自就是齐次解; 取任意 (s, t) , 就得到任意一个解。

还要排除“两个方向其实重复”的可能。若

$$c_1(-1, 1, 0, 0)^T + c_2(1, 0, -1, 1)^T = \mathbf{0}, \quad (5.9)$$

检查第 2 个分量得到 $c_1 = 0$, 检查第 4 个分量得到 $c_2 = 0$, 所以两支向量线性无关。它们既生成全部解, 又没有多余方向, 因而构成零空间的一组基。四个分量说明输入记录在 $\mathbb{R}^4$ 中, 两个自由参数说明解空间只有二维; **分量个数与解空间维数不是同一个概念**。

这个例子把三个观察连在了一起: 行最简形给出自由变量, 自由变量给出解向量, 独立的解向量张成整个零空间。为了在后面的几何图中把同样的结构画出来, 我们再保留一个三维的贯穿例子。

例题 5.2 (把参数解写成向量组合)

求矩阵

$$A = \begin{pmatrix} 1 & 1 & 0 \\ 2 & 2 & 0 \\ -1 & -1 & 0 \end{pmatrix} \quad (5.10)$$

对应的齐次方程组 $Ax = \mathbf{0}$ 的全部解，并说明解空间的基与维数。

解 按第二章的行变换, $r_2 \leftarrow r_2 - 2r_1, r_3 \leftarrow r_3 + r_1$, 只剩一个独立方程 $x_1 + x_2 = 0$ 。无需重复展开消元表: 主元变量是 x_1 , 自由变量是 x_2, x_3 。取 $x_2 = s, x_3 = t$, 得到

$$\mathbf{x} = (-s, s, t)^T = s\boldsymbol{\xi}_1 + t\boldsymbol{\xi}_2, \quad s, t \in \mathbb{R}, \quad (5.11)$$

$$\boldsymbol{\xi}_1 = (-1, 1, 0)^T, \quad \boldsymbol{\xi}_2 = (0, 0, 1)^T. \quad (5.12)$$

两支向量都满足齐次方程, 所有解也都由它们表示。若 $s\boldsymbol{\xi}_1 + t\boldsymbol{\xi}_2 = \mathbf{0}$, 检查第二个分量得 $s = 0$, 检查第三个分量得 $t = 0$, 因此它们线性无关。它们构成 $\text{Null}(A)$ 的一组基, 解空间是 $x_1 + x_2 = 0$ 的二维平面, 尽管这些解都用三个分量记录。

把全部解用任意参数一次写出的表达式, 称为通解 (General Solution)。参数必须遍历相应的全部实数值, 不能只代入几个值, 便把所得几个向量当成全部解。

定义 5.3 (基础解系)

齐次方程组 $Ax = \mathbf{0}$ 的解空间 $\text{Null}(A)$ 的一组基, 称为该方程组的基础解系 (Fundamental Set of Solutions)。它必须同时满足两个条件: 各解向量线性无关, 而且能够线性表示全部齐次解。

定义之所以放在这里, 是因为例题已经替它说明了两项要求的来源。只找几支满足方程的向量还不够, 它们可能漏掉某些解; 只要求能够表示所有解也不够, 其中可能有多余向量。基础解系把这两项要求同时满足。

每个自由变量, 贡献一个独立的解方向

一般地, 设自由变量为 $x_{j_1}, \dots, x_{j_k}$ 。把第 i 个自由变量取 1, 其余自由变量取 0, 再由主元方程确定其他分量, 得到解向量 $\boldsymbol{\xi}_i$ 。由于齐次方程的主元变量都是自由变量的线性组合, 任意解都能写成

$$\mathbf{x} = c_1\boldsymbol{\xi}_1 + \dots + c_k\boldsymbol{\xi}_k, \quad c_1, \dots, c_k \in \mathbb{R}. \quad (5.13)$$

在第 j_i 个分量上, $\boldsymbol{\xi}_i$ 为 1, 其余构造出的解向量为 0。因此, 若上述组合为零, 在这些

自由分量上依次检查, 便得到 $c_1 = \cdots = c_k = 0$ 。这同时证明了生成全部解与线性无关, 两项条件缺一不可。

定理 5.4 (基础解系的向量个数)

设 A 有 n 列, $r(A) = r$ 。齐次方程组的解空间维数为

$$\dim \text{Null}(A) = n - r. \quad (5.14)$$

当 $r < n$ 时, 任意基础解系含 $n - r$ 个向量; 当 $r = n$ 时, 只有零解, 没有非零基础解向量, 零空间维数为 0。

证明: 第四章的秩与零度定理给出 $n = \dim \text{Null}(A) + r(A)$ 。上一段的参数构造又说明, 每个自由变量对应一支基向量。因此基向量个数、自由变量个数与 $n - r$ 是同一个数字的三种解释。 ■

把这个计数重新放回消元过程: n 个变量中, r 个由主元方程确定, 其余 $n - r$ 个自由选择; 每个自由选择对应一个独立方向。因此

$$\text{基础解系向量个数} = \text{自由变量个数} = \dim \text{Null}(A) = n - r(A). \quad (5.15)$$

这不是三个碰巧相等的答案, 而是同一结构的算法、基与维数三种读法。在电网络的节点平衡模型中, 这些自由方向对应不改变节点收支的线路变化; 增加这样的变化, 方程的右端项仍是零。




图 5.1: 齐次解空间从原点开始: 零维是一个点, 一维是直线, 二维是平面。

读图说明: 三幅均在 $\mathbb{R}^3$ 中示意。左图可取单位矩阵; 中图可取约束 $x_1 - x_2 = 0, x_3 = 0$; 右图可取约束 $x_3 = 0$ 。图中的绿色集合只显示局部, 直线和平面没有画出的部分仍属于解空间。




图 5.2: 三维解空间：零映射的全部输入都是解。

读图说明：示例为三元零系数方程组。立方体只帮助辨认三个独立方向；解空间是整个 $\mathbb{R}^3$ ，并不被立方体边界限制。

基础解系可以改变，解空间不会改变

在例题 5.2 中， ξ_1, ξ_2 是一组基； $\eta_1 = \xi_1 + \xi_2$ 、 $\eta_2 = \xi_1 - \xi_2$ 也是一组基，因为原来的两支向量可以由它们反向表示。更熟悉的例子是 $\mathbb{R}^2$ ： $(1, 0)^T, (0, 1)^T$ 与 $(1, 1)^T, (1, -1)^T$ 都是基。改变的是描述方向的方式，所有能够表示的向量没有改变。




图 5.3: 同一个二维空间，可以由不同的两支独立向量描述。

读图说明：图中的两组向量都张成整个平面。基础解系的不唯一性来自空间可以选不同的基；固定变量顺序时，行最简形唯一，按自由变量标准取值构造出的基也随之确定。

例如，贯穿例子中的新基可以具体写为

$$\eta_1 = (-1, 1, 1)^T, \quad \eta_2 = (-1, 1, -1)^T, \quad (5.16)$$

$$\xi_1 = \frac{1}{2}(\eta_1 + \eta_2), \quad \xi_2 = \frac{1}{2}(\eta_1 - \eta_2). \quad (5.17)$$

两组方向互相线性表示，张成同一个平面。如果用 η_1, η_2 来写通解，参数的数值会改变，解的集合却不变。我们选择基，是为了描述这个空间，不是为了创造另一个空间。

还应分清：系数列的极大线性无关组，是从原列向量中选出的列空间的基，含 $r(A)$ 个向量；基础解系是零空间的基，含 $n - r(A)$ 个向量。前者解释输出能够张成多大范围，后者解释输入还留下多少自由方向。极大无关组这一概念并不限于系数列；若从全部齐次解中选出一组能够生成解空间的独立向量，它本身就是基础解系。

齐次方程把这些自由方向都放在原点处。若右端项不再为零，方向还会存在吗？下一节将说明：它们仍然存在，只是全部解从一个特解出发。

5.2 非齐次方程组：一个特解与全部解

仍使用式(5.10)中的矩阵, 把右端项改为 $\mathbf{b} = (3, 6, -3)^T$. 独立方程变为 $x_1 + x_2 = 3$, $\mathbf{x}_p = (3, 0, 0)^T$ 显然是一个特解 (Particular Solution). 但它只给出一个点: x_2, x_3 还可以自由变化。我们需要说明这些变化怎样生成全部解。

定理 5.5 (两个解的差与解的叠加)

若 $A\mathbf{x}_1 = A\mathbf{x}_2 = \mathbf{b}$, 则 $\mathbf{x}_1 - \mathbf{x}_2 \in \text{Null}(A)$. 反之, 若 $A\mathbf{x}_p = \mathbf{b}$ 且 $\mathbf{z} \in \text{Null}(A)$, 则 $\mathbf{x}_p + \mathbf{z}$ 仍是 $A\mathbf{x} = \mathbf{b}$ 的解。

证明: 两个输入产生相同输出, 它们之间的差别必被映射消去。代数上,

$$A(\mathbf{x}_1 - \mathbf{x}_2) = A\mathbf{x}_1 - A\mathbf{x}_2 = \mathbf{b} - \mathbf{b} = \mathbf{0}, \quad (5.18)$$

$$A(\mathbf{x}_p + \mathbf{z}) = A\mathbf{x}_p + A\mathbf{z} = \mathbf{b} + \mathbf{0} = \mathbf{b}. \quad (5.19)$$

后一式说明, 沿任何零空间方向改变已有解, 都不会改变它的输出。■

现在固定一个特解 $\mathbf{x}_p$, 再任取一个解 $\mathbf{x}$. 刚证明的结论告诉我们, $\mathbf{z} = \mathbf{x} - \mathbf{x}_p$ 是齐次解。于是把等式移项, 就得到 $\mathbf{x} = \mathbf{x}_p + \mathbf{z}$. 这条推导的作用, 是把“任意一个解”转成“一个已知点加上一种允许的变化”; 变化的全部范围, 就是上一节已经求出的零空间。

反过来, 任何零空间中的 $\mathbf{z}$ 都可以加入特解, 而不会改变右端项。这说明两种描述的范围完全相同: 每个原方程的解都包含在内, 包含在内的每个向量也确实满足原方程。

定理 5.6 (非齐次方程组的通解结构)

设 $A\mathbf{x} = \mathbf{b}$ 有解, $\mathbf{x}_p$ 为任意一个特解, $\xi_1, \dots, \xi_k$ 是相应齐次方程组的基础解系, 则全部解为

$$\mathbf{x} = \mathbf{x}_p + c_1\xi_1 + \dots + c_k\xi_k, \quad c_1, \dots, c_k \in \mathbb{R}. \quad (5.20)$$

用集合表示, 即

$$\{\mathbf{x} : A\mathbf{x} = \mathbf{b}\} = \mathbf{x}_p + \text{Null}(A) = \{\mathbf{x}_p + \mathbf{z} : \mathbf{z} \in \text{Null}(A)\}. \quad (5.21)$$

证明: 任意解 $\mathbf{x}$ 与特解之差都在零空间中, 所以能写成式(5.20)。反过来, 该式的每个向量都是特解与齐次解之和, 因而满足原方程。两个方向都成立, 才说明公式没有遗漏解, 也没有加入不满足方程的向量。■

例题 5.7 (同一矩阵, 改变右端项)

对式(5.10)中的 A , 写出 $Ax = (3, 6, -3)^T$ 的通解。

解 由例题 5.2 的基础解系, 直接得到

$$x = (3, 0, 0)^T + s(-1, 1, 0)^T + t(0, 0, 1)^T, \quad s, t \in \mathbb{R}. \quad (5.22)$$

特解也可以选成 $(2, 1, 0)^T$ 。两支特解相差 $(-1, 1, 0)^T$, 恰在零空间中, 所以换一个特解并不会改变解集。特解给出一个出发点, 基础解系给出全部可移动方向。




图 5.4: 零空间的平移: 绿色平面给出方向, 蓝色平面给出全部非齐次解。

读图说明: 用三维方程 $x_3 = 2$ 示意: 绿色平面为 $x_3 = 0$, 特解为 $(0, 0, 2)^T$, 蓝色平面为 $x_3 = 2$ 。若改成二维方程 $x_2 = 2$, 同样的平移把横轴变成上方的解直线。这里画的是结构, 不是前一例子的坐标重画。

定义 5.8 (仿射子空间)

设 $W \subseteq \mathbb{R}^n$ 是子空间, $p \in \mathbb{R}^n$ 。集合 $p + W$ 称为仿射子空间 (Affine Subspace), 它是 W 的一次平移, 其维数定义为 $\dim W$ 。

若 $p \in W$, 平移后仍是 W ; 若 $p \notin W$, 平移后的集合不含零向量, 因而不是子空间。特别地, 非齐次方程组在 $b \neq 0$ 且有解时, 其解集不经过原点, 是一个仿射子空间。无解时则是空集, 不能用“特解加零空间”表示。

为什么非齐次解集不能当作子空间? 以 $x_3 = 2$ 为例, 零向量不满足它; $(0, 0, 2)^T$ 是解, 数乘 2 得到的 $(0, 0, 4)^T$ 却不是解。一般地, 若 $Ax_p = b \neq 0$, 就有 $A(2x_p) = 2b \neq b$ 。它保存的是共同的变化方向, 而不是过原点的线性运算封闭性。齐次解可以任意线性组合; 非齐次解要从一个特解出发, 再加齐次解。

从工程上看, 一个已经满足节点收支的线路分配, 可以加上不改变收支的循环流; 但把整个线路分配扩大两倍, 通常也会把节点收支扩大两倍。前一种操作沿零空间移动, 后一种操作改变了目标, 两者不能混同。

自由度决定解集的几何形状

有解时, 设 $k = \dim \text{Null}(A) = n - r(A)$ 。当 $k = 0$, 没有可改变的方向, 解集是一个点; 当 $k = 1$, 是直线; 当 $k = 2$, 是平面; 一般是 k 维仿射子空间。维数描述的是解集内部独立的变化方向, 并不是记录一个解所需的分量个数。




图 5.5: 解集的四种形态: 点、直线、平面与空集。

读图说明: 图形只示意解集的维数。右下可由 $x_2 = 1, x_2 = 2$ 理解: 两个约束无法同时满足, 解集为空。灰色虚线表示平移之前的方向。

定义 5.9 (超平面)

在 $\mathbb{R}^n$ 中, 维数为 $n - 1$ 的仿射子空间称为超平面 (Hyperplane)。例如 $a_1x_1 + \cdots + a_nx_n = c$, 其中系数不全为零, 给出一个超平面。

因此, $\mathbb{R}^3$ 中的平面是超平面, 但一条直线不是; $\mathbb{R}^5$ 中二维解集也不能称为超平面。一个非零线性约束留出 $n - 1$ 个自由方向, 多个独立约束则可能进一步降低维数。

以贯穿例子为对照, 输入用三个分量记录, 但 $r(A) = 1$, 所以解集有两个自由方向, 是平面而非整个三维空间。再取二元方程 $x_1 + x_2 = 3$, 秩为 1、自由度为 1, 解集是一条直线; 若两条独立约束同时确定两个未知数, 自由度降为 0, 就只剩交点。这些形状都从同一公式 $n - r(A)$ 读出。空集这一情形必须先排除: 没有特解, 就谈不上把零空间平移到哪个位置。

独立自由参数的个数也称为解集的自由度 (Degrees of Freedom)。有解时, 它就是齐次解空间的维数; 改变特解只改变位置, 不改变这个数字。

我们已经看见了原方程的全部解。计算时却总会把原方程改写成更简单的方程，下一节就解释：为什么这些改写仍能保留同一解集。

5.3 行变换与原像：为什么消元保持解集

第二章把三种初等行变换称为同解变换，第三章又把它们写成左乘初等矩阵。现在可以把两种认识接起来：每个操作都可逆，所以它不仅保留已知解，还保留“哪些输入产生指定输出”这一完整关系。

例如，先做 $r_2 \leftarrow r_2 - 2r_1$ ，再做另一项行变换，对应的初等矩阵分别为 E_1, E_2 ，两项合起来左乘 E_2E_1 ，而不是把两个初等矩阵相加。一般地，若依次做 q 次变换，便有

$$G = E_q \cdots E_2 E_1, \quad G^{-1} = E_1^{-1} E_2^{-1} \cdots E_q^{-1}. \quad (5.23)$$

每一步都能撤销，整个过程也能撤销。正是这一点让消元可以来回改写方程，而不丢掉任何原来的条件。

设 G 是若干初等矩阵的乘积，它可逆。对系数矩阵与常数列同步变换，就是

$$[A \mid \mathbf{b}] \mapsto [GA \mid G\mathbf{b}]. \quad (5.24)$$

定理 5.10 (可逆的输出变换保持原像关系)

若 G 可逆，则

$$A\mathbf{x} = \mathbf{b} \iff GA\mathbf{x} = G\mathbf{b}. \quad (5.25)$$

因而两个方程组的解集完全相同。

证明： 正向在等式两边左乘 G ；反向在等式两边左乘 G^{-1} 。从映射看， G 不会合并不同输出，所以同时变换实际输出与指定目标，不会改变哪些输入满足方程。这里被保持的是目标的原像 (Preimage)。 ■

例题 5.11 (把两条方程改写成同一条有效约束)

设 $D = \begin{pmatrix} 1 & 1 \\ 2 & 2 \end{pmatrix}$ 、 $\mathbf{b} = (3, 6)^T$ 。用 $r_2 \leftarrow r_2 - 2r_1$ 化简，并比较变换前后的解。

解 此次行变换对应

$$G = \begin{pmatrix} 1 & 0 \\ -2 & 1 \end{pmatrix}, \quad GD = \begin{pmatrix} 1 & 1 \\ 0 & 0 \end{pmatrix}, \quad G\mathbf{b} = (3, 0)^T. \quad (5.26)$$

原方程为 $x_1 + x_2 = 3$ 、 $2x_1 + 2x_2 = 6$ ，变换后为 $x_1 + x_2 = 3$ 、 $0 = 0$ 。两者都给出

$$\mathbf{x} = (3, 0)^T + t(-1, 1)^T, \quad t \in \mathbb{R}. \quad (5.27)$$

变换前，所有输出位于 $y_2 = 2y_1$ ；变换后，所有输出位于横轴。可是目标也从 $(3, 6)^T$ 同步变成 $(3, 0)^T$ ，因此到达指定目标的输入一个也没有改变。**不能只变换 D 而保留旧的 $\mathbf{b}$ ：那将成为另一个方程组。**

固定坐标下的复合，与更换输出坐标

固定输入、输出的坐标时， $T(\mathbf{x}) = A\mathbf{x}$ 与 $T'(\mathbf{x}) = GA\mathbf{x}$ 是两个不同的映射，后者是 $G \circ T$ 。不能把左乘一个矩阵简单说成“映射没有变”。

这里可以把输出想成测量记录：原来分别记录两项数值，后来改为“第一项”与“第二项减去第一项的两倍”。因为这种记录可逆，旧记录能完整恢复。计算得到的数值发生变化，不等于输入与目标之间的关系丢失；但若坚持把新数值仍解释成旧坐标中的点，得到的确实就是另一个映射。这两种观察方式必须分清。

若改用坐标表示的观点，则可以让 G 把旧输出坐标换成新输出坐标。设旧输出基为 B 、新输出基为 C ，规定 $P_{B \leftarrow C} = G^{-1}$ 。由第四章的坐标公式，

$$[\mathbf{y}]_C = G[\mathbf{y}]_B, \quad [T(\mathbf{x})]_C = GA\mathbf{x}. \quad (5.28)$$

这时 A 与 GA 记录的是同一个抽象映射在两组输出基下的表示，目标也必须从 $\mathbf{b}$ 改记为 $G\mathbf{b}$ 。输入坐标始终不变。这是换基的解释，而非断言两个固定坐标中的函数相同。




图 5.6: 输入端保持不变，输出与目标同时经过可逆变换。

读图说明：取 $D = \begin{pmatrix} 1 & 1 \\ 2 & 2 \end{pmatrix}$ ， $G = \begin{pmatrix} 1 & 0 \\ -2 & 1 \end{pmatrix}$ 。解直线不变，列空间的坐标图像从斜线变成横轴；零空间仍是 $x_1 + x_2 = 0$ 。每幅小图的缩放只用于排版。

哪些空间不变，哪些空间改变位置

对于任意可逆 G ，有

$$\text{Null}(GA) = \text{Null}(A), \quad (5.29)$$

$$\text{Row}(GA) = \text{Row}(A), \quad (5.30)$$

$$\text{Col}(GA) = G \text{Col}(A). \quad (5.31)$$

第一式由 $G\mathbf{A}\mathbf{x} = \mathbf{0} \iff \mathbf{A}\mathbf{x} = \mathbf{0}$ 得到。第二式来自双向的行组合：新行都是旧行的组合，旧行又能经 G^{-1} 由新行表示。第三式把每个输出 $\mathbf{A}\mathbf{x}$ 送成 $G\mathbf{A}\mathbf{x}$ ；列空间的维数不变，但在固定坐标中的集合通常改变了。

注意：可逆并不意味着保持长度和夹角。例如 $G = \text{diag}(2, 1)$ 把原来正交的 $(1, 1)^T$ 、 $(1, -1)^T$ 变成 $(2, 1)^T$ 、 $(2, -1)^T$ ，它们的点积为 3。换到一般新基后，直接对坐标数组使用标准点积，也未必仍记录原物理向量的夹角。本章下面的正交关系，均针对给定矩阵在标准坐标中的四个子空间。

现在可以放心使用行变换了：它把输出端的条件重新组织，并将目标作同样的变换；可逆性保证哪些输入是解始终不变。输入侧的解集、零空间和行空间保留，输出侧的列空间则随 G 重新摆放。消元结果仍能告诉我们原矩阵的秩与自由度，却不能让我们把化简后的列向量原样搬回原坐标。带着这一分别看输入、看输出的习惯，下一节把两端的四个空间放到同一幅结构图中。

5.4 一个矩阵，四个基本子空间

第 3.5.1 节中，我们用“正向组合输出、反向回传评分”理解矩阵转置： A 把输入送到输出端， A^T 则把输出端的评价折算为输入端的评分。现在沿着这两条路径看，四个基本子空间就有了共同的来处：哪些状态能产生输出，哪些变化会被压成零；哪些评分能被回传，哪些评分对全部可达输出都读作零。它们分别属于输入、输出两侧，描述的却是同一个映射。

只看 $\mathbf{A}\mathbf{x} = \mathbf{b}$ ，容易把注意力集中在一组未知数上。换一个问题：矩阵允许哪些输出？哪些输入不起作用？各行又在检查哪些方向？转置矩阵检测哪些输出端约束？这四个问题分别落在输入与输出两端，不能混成一个空间。




图 5.4a: 四个子空间的对偶结构: 蓝色与绿色位于输入侧, 红色与土黄色位于输出侧。正向组合与反向评分把两端联系起来, 呼应第 3.5.1 节的转置解释。

读图说明: 每块色框代表一类方向, 不是把空间中的点分到不相交的区域。正向箭头在行空间与列空间之间作用, 反向箭头传递评价; 它们互不保证是对方的逆。左右各自的正交与维数关系将在本节证明。

5.4.1 四个子空间的定义与维数

设 A 为 $m \times n$ 矩阵, 列记为 $a_j \in \mathbb{R}^m$, 第 i 行记为 r_i^T , 其中 $r_i \in \mathbb{R}^n$ 。沿用本书的列向量习惯, 我们把各行竖排后讨论它们张成的空间。

先站在**输入侧** $\mathbb{R}^n$ 看。行空间 $\text{Row}(A)$ 由各行竖排后张成, 收集方程能够检查到的方向; 零空间 $\text{Null}(A)$ 则收集经过 A 后全被送到零的输入。前者与独立约束有关, 维数为 $r(A)$; 后者与自由变量有关, 维数为 $n - r(A)$ 。同一个输入可以同时包含这两类分量。

再站在**输出侧** $\mathbb{R}^m$ 看。列空间 $\text{Col}(A)$ 由各列张成, 是所有输入实际能够产生的范围, 维数为 $r(A)$; 左零空间 $\text{Null}(A^T)$ 由转置齐次方程确定, 给出输出必须避开的非零方向, 维数为 $m - r(A)$ 。两侧的分组取决于向量有多少个分量, 而不是名称中的“行”或“列”在纸上朝哪个方向。

把这两侧再用探测器语言读一遍。设输出端评价为 y , 第 3.5.1 节给出的总评分恒等式是

$$y \cdot (Ax) = (A^T y) \cdot x. \quad (5.32)$$

左边是在输出端打分, 右边是在输入端使用回传的评分器; 无论从哪端算, 总分相同。这个等式也提醒我们: 转置传回的是评价, 不是在撤销原来的映射。



图 5.4b: 一次组合、两端评分: 输出端的评价由转置拉回, 成为输入端的评分器。橙色两条路径算出的总分相同, 评价方向与状态传递方向相反。

读图说明: 每一个输出坐标就是一把原始评分尺: 若取 $y = e_i$, 回传后的 $A^T e_i = r_i$ 正是第 i 行竖排的向量。任意输出评价都是这些坐标评分的线性组合, 因而任意回传评分都落在行空间里。

先看**列空间**: Ax 把各列按权重组合, 所以它是第三章“组合器”的全部输出范围。这里的各列是特征方向, 未必线性无关, 不一定是一组基。再看**零空间**: $Az = 0$ 表示每一行探测器都有 $r_i \cdot z = 0$; 在这些输入方向上改变权重, 全部输出记录都不变。因此“探测死角”指的是各行在输入端的读数为零, 不是说输入向量本身不存在。

行空间则收集了所有可能的回传评分: $A^T y$ 随 y 改变, 得到的正是 $\text{Col}(A^T)$ 。每一行是输入端的一把特征探测器, 行空间是这些评分器能组合出的全部方向。从对偶观点说, 它是**列空间上全部线性评分的一个坐标实现**: 将可达输出上的评分沿 A 拉回, 便得到输入评分。这里不能把 $\text{Row}(A)$ 与 $\text{Col}(A)'$ 直接写成相等; 前者位于 $\mathbb{R}^n$, 后者由定义在列空间上的泛函组成, 二者通过评分回传建立对应。第 3.5.1 节已经解释了这种区别。

最后看**左零空间**: 若 $A^T y = 0$, 式(5.32)就说明, 对任何输入都有 $y \cdot (Ax) = 0$ 。它收集的是那些对全部可达输出都打 0 分的评价方向。准确说, y 是评分器的系数向量, 评分器本身是 $w \mapsto y \cdot w$; 借助标准点积, 我们把这些评分器画成输出端的向量。

下面的正式定义把这四种角色写成准确的集合; 读每一行时, 都先问它属于输入侧还是输出侧。

定义 5.12 (四个基本子空间)

矩阵 A 的四个基本子空间 (Four Fundamental Subspaces) 为

$$\text{Col}(A) = \text{Span}\{a_1, \dots, a_n\} = \{Ax : x \in \mathbb{R}^n\}, \quad (5.33)$$

$$\text{Null}(A) = \{x \in \mathbb{R}^n : Ax = 0\}, \quad (5.34)$$

$$\text{Row}(A) = \text{Span}\{r_1, \dots, r_m\} = \text{Col}(A^T), \quad (5.35)$$

$$\text{Null}(A^T) = \{y \in \mathbb{R}^m : A^T y = 0\}. \quad (5.36)$$

其中列空间与左零空间位于输出端 $\mathbb{R}^m$, 行空间与零空间位于输入端 $\mathbb{R}^n$ 。

列空间就是第四章的值域; 零空间就是第 5.1 节的齐次解空间; 行空间由转置的列

组织; 左零空间则是转置的齐次解空间。它们不是四套无关的新定义, 而是对同一矩阵同时采用列组合、行约束和转置观察。

定理 5.13 (四个子空间的维数)

若 $r(A) = r$, 则

$$\dim \text{Col}(A) = r, \quad \dim \text{Null}(A) = n - r, \quad (5.37)$$

$$\dim \text{Row}(A) = r, \quad \dim \text{Null}(A^T) = m - r. \quad (5.38)$$

证明: 列空间维数是矩阵秩的定义, 零空间维数由秩与零度定理给出。第四章已证明行秩等于列秩, 因而 $r(A^T) = r(A) = r$; 把秩与零度定理用于 $A^T: \mathbb{R}^m \rightarrow \mathbb{R}^n$, 就得到左零空间维数 $m - r$ 。注意, 两次计数所用的输入维数分别为 n 与 m 。■

两次秩与零度的计数, 也可以分别读成“状态”与“评分”的计数: 输入端有 r 个独立的有效方向, 另有 $n - r$ 个不改变输出的自由方向; 输出端有 r 个可达方向, 另有 $m - r$ 个对可达输出全给零分的评价方向。行空间与列空间维数相同, 是评分回传连接两侧的结果; 两个零空间的维数则不必相同, 不能因为箭头反向就把 $n - r$ 与 $m - r$ 混用。

例题 5.14 (贯穿矩阵的四个空间)

求式(5.10)中的矩阵 A 的四个基本子空间及其维数。

解 各列都是 $(1, 2, -1)^T$ 的倍数, 各行都是 $(1, 1, 0)$ 的倍数, 因此 $r(A) = 1$ 。结合已经求出的齐次解, 得到

$$\text{Col}(A) = \text{Span}\{(1, 2, -1)^T\}, \quad (5.39)$$

$$\text{Row}(A) = \text{Span}\{(1, 1, 0)^T\}, \quad (5.40)$$

$$\text{Null}(A) = \text{Span}\{(-1, 1, 0)^T, (0, 0, 1)^T\}, \quad (5.41)$$

$$\text{Null}(A^T) = \{\mathbf{y} : y_1 + 2y_2 - y_3 = 0\} = \text{Span}\{(-2, 1, 0)^T, (1, 0, 1)^T\}. \quad (5.42)$$

两个张成空间各为一维直线, 两个零空间各为二维平面, 维数分别配成 $1 + 2 = 3$ 。左右两端虽都用三个分量, 这两条直线却不是同一条, 两个平面也不是同一个。

可以逐项核对这个例子, 而不只记住四行结果。将行空间的方向 $(1, 1, 0)^T$ 输入 A , 得到 $2(1, 2, -1)^T$, 确实沿列空间变化; 将零空间的任一基向量输入 A , 则得到零。输出侧, 列空间的方向 $(1, 2, -1)^T$ 与左零空间的两支基向量点积都为零。这说明两端各是一条直线配一个平面, 而不是两条直线配对; 维数相加为 3, 但不必平均分成两部分。

在章首的网络模型中，输入端记录线路，输出端记录节点。零空间收集不改变节点收支的循环变化；左零空间则检查全网收支必须满足的限制。四个子空间的分组，让我们不会把“线路还可以怎样改”与“节点目标能否实现”混成同一个问题。

怎样从消元结果提取基

列空间的基要取原矩阵中对应主元列号的列；行空间的基可以取阶梯形的非零行，因为行变换不改变行空间。零空间的基由自由参数构造；左零空间的基对 $A^T \mathbf{y} = \mathbf{0}$ 使用同一构造。这样四种基仍由第二章的算法求得，只是读结果时所面对的空间不同。

5.4.2 正交与直和：拆开输入与输出

为什么正向的“看不见”，会对应反向的“读作零”？若 $\mathbf{z}$ 被 A 送到零，任意输出评分回传后都满足 $(A^T \mathbf{y}) \cdot \mathbf{z} = \mathbf{y} \cdot (A\mathbf{z}) = 0$ 。所以零空间中的输入，确实会让行空间里的每一把探测器都读作零。输出侧完全对称：左零空间里的评价，面对列空间中的任何结果，都读作零。正交不是额外添加的图形印象，而是总评分恒等式在两端留下的结构。

维数能够相加，还不足以说明两个空间不重叠。我们需要进一步辨认它们的方向关系。这里只使用第 0 章的标准点积：称两个子空间子空间正交 (Orthogonal Subspaces)，是指其中任取两支向量的点积都为零。这个表述包括零向量；只有在用夹角解释时，才要求参与夹角的向量非零。

定理 5.15 (四个基本子空间的正交直和)

对任意实矩阵 A ，有

$$\text{Row}(A) \perp \text{Null}(A), \quad \mathbb{R}^n = \text{Row}(A) \oplus \text{Null}(A), \quad (5.43)$$

$$\text{Col}(A) \perp \text{Null}(A^T), \quad \mathbb{R}^m = \text{Col}(A) \oplus \text{Null}(A^T). \quad (5.44)$$

这两项分解是正交直和 (Orthogonal Direct Sum)：每端任意向量都可以唯一分成两个互相正交的分量。

证明：先证输入端的正交。若 $\mathbf{z} \in \text{Null}(A)$ ，则 $A\mathbf{z} = \mathbf{0}$ 。逐行看，就是每个 $\mathbf{r}_i \cdot \mathbf{z} = 0$ 。任意行空间向量 $\mathbf{w} = \sum_i c_i \mathbf{r}_i$ 因而满足

$$\mathbf{w} \cdot \mathbf{z} = \sum_i c_i (\mathbf{r}_i \cdot \mathbf{z}) = 0. \quad (5.45)$$

再证交为零。若 $\mathbf{v}$ 同时属于行空间与零空间，便可以把它分别放在上式的两个位置，于是 $\mathbf{v} \cdot \mathbf{v} = 0$ 。点积与自身相乘是各分量平方和，故 $\mathbf{v} = \mathbf{0}$ 。

最后证铺满输入空间。由第 1 章的子空间维数公式和交为零,

$$\dim(\text{Row}(A) + \text{Null}(A)) = r + (n - r) = n. \quad (5.46)$$

它是 $\mathbb{R}^n$ 中的 n 维子空间, 因而等于整个空间; 交为零又保证和的分解唯一。这就得到输入端的直和。

输出端的论证完全平行: $A^T \mathbf{y} = \mathbf{0}$ 表示 $\mathbf{y}$ 与每一列正交, 因而与整个列空间正交; 同时属于列空间与左零空间的向量只能为零。维数之和为 $r + (m - r) = m$, 所以两者直和等于 $\mathbb{R}^m$, 分解也唯一。■

注意: 正交只说明方向互不重叠, 维数计数才保证没有遗漏方向。例如 $\mathbb{R}^3$ 中 x 轴与 y 轴正交, 合起来却只是一个平面。证明中“正交、交为零、维数足够”这三环不可省去任何一环。

回顾第 1 章: 交只有零向量, 就可以把两个子空间的和写成直和。正交能保证这种分解在它们的和空间中唯一, 却不能保证和空间就是整个环境空间。例如 $\mathbb{R}^3$ 的 x_1 轴与 x_2 轴互相正交, 交为零, 二者的和也确实是直和; 但是维数只有 $1 + 1 = 2$, 只能铺成 $x_1 x_2$ 平面, 遗漏了 x_3 方向。我们要得到 $\mathbb{R}^n$ 本身的分解, 还必须用 $r + (n - r) = n$ 补上最后一环。




图 5.7: 正交保证不重复, 维数保证不遗漏: 两条坐标轴还没有铺满三维空间。

读图说明: 这幅图区分“和是直和”与“直和等于整个空间”。四个基本子空间的每一对除了正交, 还恰好具有足够的维数, 才得到对输入端或输出端的完整分解。




图 5.8: 输入端的正交直和：行空间分量与零空间分量唯一相加。

读图说明：为便于画在平面，取 $D = \begin{pmatrix} 1 & 1 \\ 2 & 2 \end{pmatrix}$ 。示意 $x = (2, 0)^T = (1, 1)^T + (1, -1)^T$ ；整幅图采用统一放大比例。蓝色与绿色两条直线正交，合起来覆盖整个输入平面。




图 5.9: 输出端的正交直和：可产生的部分与左零空间部分分别记录。

读图说明：仍取上一图的 D 。这里 $b = (3, 1)^T = (1, 2)^T + (2, -1)^T$ ，第二部分非零，故整个 b 不在列空间中。分解只说明结构，本节不讨论投影算法或近似解。

于是任意输入唯一写成 $x = x_R + x_N$ ，其中 $x_R \in \text{Row}(A)$ 、 $x_N \in \text{Null}(A)$ ，并且 $Ax = Ax_R$ 。零空间分量不影响输出。输出端同样唯一写成 $b = b_C + b_L$ ；只有列空间中的向量能由 A 产生，非零的左零空间分量则使整个目标不可达。

四个空间现在各有维数，也各有相对方向。先把这些结论用两端的直观图重新读一遍，再将它们放回方程组，回答解的存在性和自由度。

5.4.3 直观总结：正交互补的两组子空间

以上我们用代数严格证明了四个子空间的正交与直和关系。我们也可以换一个更直观的视角，把这四个子空间的定位、意义和相互关系，用一句话、一张图总结清楚。所谓正交互补子空间 (Orthogonal Complementary Subspaces)，既要求两部分互相正交，也要求它们的直和等于整个空间；两部分的维数不必各占一半。

先把空间分到两侧：**行空间与零空间属于输入端，列空间与左零空间属于输出端。**表中的“方向”指非零方向；零向量仍共同属于每一对子空间。“消灭”则指映射后的输出为零，不是输入向量从空间中消失。

同一矩阵的两端：输入与输出				
空间名称	所在宇宙	维度	几何意义	工程直觉
行空间 Row(A)	输入空间 $\mathbb{R}^n$	$r(A)$	所有行向量张成的子空间	有效的输入评分方向 输出评价能回传到这里
零空间 Null(A)	输入空间 $\mathbb{R}^n$	$n - r(A)$	齐次方程的解空间	各行探测器的死角 全部输入响应读数为零
列空间 Col(A)	输出空间 $\mathbb{R}^m$	$r(A)$	所有列向量张成的子空间	组合器的可达输出 所有可能产生的结果都在这里
左零空间 Null(A^T)	输出空间 $\mathbb{R}^m$	$m - r(A)$	转置矩阵的零空间	对可达输出都打 0 分 非零分量使整个目标不可达

$\mathbb{R}^n = \text{Row}(A) \oplus \text{Null}(A) \quad \mathbb{R}^m = \text{Col}(A) \oplus \text{Null}(A^T)$

图 5.4c: 四个基本子空间总览：输入、输出两侧各有一组正交互补的子空间。评分方向与探测死角在输入端配对，可达输出与零评分方向在输出端配对。

读图说明：从输入端向输出端看，行空间与列空间配成“有效作用”的两端；从各自的环境空间看，每一端再与自己的零空间组成正交直和。

先看输入端。整个输入空间 $\mathbb{R}^n$ 分成两个互相正交的部分：行空间和零空间。它们没有重叠的非零方向，合起来刚好铺满整个 $\mathbb{R}^n$ 。这不是把空间中的点分到两个不相交的区域，而是把每一个向量唯一写成两部分之和。

任意输入 $\mathbf{x}$ 都可以拆成行空间分量 $\mathbf{x}_{\text{row}}$ 与零空间分量 $\mathbf{x}_{\text{null}}$ ，即前文的 $\mathbf{x}_R, \mathbf{x}_N$ 。行空间分量是“活下来”的部分，它被映向列空间，真正产生输出；零空间分量是“被消灭”的部分，无论怎样改变它，映射后的这一部分始终为零。因此

$$\mathbf{x} = \mathbf{x}_{\text{row}} + \mathbf{x}_{\text{null}}, \tag{5.47}$$

$$A\mathbf{x} = A\mathbf{x}_{\text{row}}, \quad A\mathbf{x}_{\text{null}} = \mathbf{0}. \tag{5.48}$$

零空间里的所有变动，当前输出都看不见。例如电网络中的循环流可以改变线路记录，却不改变节点收支；“看不见”是针对这个矩阵所记录的量而言的。




图 5.4d: 输入空间的正交分解：任意输入都可以拆成“有效分量+被消分量”。行空间里的任意评分器，对绿色零空间分量都读作零。

读图说明：图取 $A = \begin{pmatrix} 1 & 1 \\ 2 & 2 \end{pmatrix}$ ，故 $n = 2$ 、 $r(A) = 1$ 。这里 $x = (2.8, .8)^T = (1.8, 1.8)^T + (1, -1)^T$ 。两个分量均从原点出发，灰色虚线表示相加关系。高维情形仍有唯一分解，但两部分未必都是直线，维数也未必相等。

再看输出端，结构完全对称。整个输出空间 $\mathbb{R}^m$ 也有两个正交互补的部分：列空间和左零空间。**列空间是所有能到达的范围**：只要目标在其中，就存在输入能产生它。**左零空间给出不可到达的方向**：若目标带有非零的左零空间分量，就一定不在列空间中，方程组因而无解。

把前文的 b_C, b_L 分别记为 $b_{\text{col}}, b_{\text{left}}$ ，便得到

$$b = b_{\text{col}} + b_{\text{left}}, \quad b_{\text{col}} \in \text{Col}(A), \quad b_{\text{left}} \in \text{Null}(A^T), \quad (5.49)$$

$$Ax = b \text{ 有解} \iff b_{\text{left}} = 0. \quad (5.50)$$

所以，目标有没有“伸向盲区”，要看这一分量是否为零；它是方向上的判断，不是看图上的点落在哪一块颜色里。




图 5.4e: 输出空间的正交分解: 目标是否有解, 取决于它有没有非零的左零空间分量。土黄色方向对全部可达输出都给零分, 却可以检测目标是否超出了可达范围。

读图说明: 仍取上一图的 A 。红色目标为 $(3, 1)^T$, 深红色列空间分量为 $(1, 2)^T$, 土黄色左零空间分量为 $(2, -1)^T$ 。后一个分量非零, 所以目标不可达; 两个正交子空间仍共同含有原点。

回到解的问题。既然零空间分量会被映射消灭, 所有输入只要行空间分量相同, 输出就完全相同。反过来, 只要方程组有解, 行空间中就恰好有一个解: 它是所有解里不带零空间分量的那一个, 这就是这里所说的“干净”。其他解只是在它上面加入不同的零空间向量。列空间决定目标能否到达, 零空间决定到达同一目标的全部自由度。下一节将把这幅直观画面完整写成解的判定, 并证明行空间与列空间之间的一一对应。

5.5 四个子空间怎样共同决定解

前面我们分别看过解空间、平移后的解集, 以及矩阵两端的四个空间。现在回到求解者最关心的三个问题: 目标能达到吗? 达到它的输入唯一吗? 如果不唯一, 还能自由改变多少个方向? 四个子空间并没有增加一套求解步骤, 而是把这三个问题分配给不同的结构来回答。

有没有解: 先检查输出端

方程 $Ax = b$ 要求输出恰好是 b , 所以首先必须有 $b \in \text{Col}(A)$ 。左零空间提供同一条件的另一种检查: 目标必须与其中每支向量正交。若目标包含非零的左零空间分量, 再怎样调整输入也产生不了这一部分。

解唯一吗：再检查输入端

确认有解以后，任意两解之差都在零空间中。如果 $\text{Null}(A) = \{\mathbf{0}\}$ ，两解的差只能为零，解就唯一；若零空间有非零方向，已有解便能沿这个方向取任意实数倍，得到无穷多个解。**唯一性判断以存在性为前提：零空间为零不表示所有右端项都可达。**例如高而窄的矩阵可以没有非零齐次解，却仍不能覆盖整个输出空间。

自由度多大：数零空间的独立方向

有解时，零空间的一组基恰好给出通解中的全部自由参数。它含 $n - r(A)$ 支向量，因此

$$\text{解的自由度} = \dim \text{Null}(A) = n - r(A). \quad (5.51)$$

自由度不是“写出了几个解”，而是“从一个解出发，还可以独立改变几个方向”。在节点平衡模型中，不改变收支的循环变化可以有若干独立方向；它们共同张成的空间，决定了所有线路分配还留下多少自由度。下面把存在性与唯一性的结论严格归在一起。

定理 5.16 (存在性与唯一性的空间判定)

方程组 $Ax = b$ 有解，当且仅当

$$b \in \text{Col}(A) \iff b \perp \text{Null}(A^T). \quad (5.52)$$

这里后一条件是指 b 与左零空间中的每一支向量正交。若方程组有解，则解唯一当且仅当 $\text{Null}(A) = \{\mathbf{0}\}$ 。

证明：存在性与属于列空间等价，是向量线性表示的定义。若 b 在列空间中，前节的正交关系保证它与左零空间正交。反过来，把它唯一分解为 $b_C + b_L$ 。若 b 与左零空间中所有向量正交，特别取 b_L ，则

$$0 = b \cdot b_L = b_C \cdot b_L + b_L \cdot b_L = b_L \cdot b_L. \quad (5.53)$$

故 $b_L = \mathbf{0}$ ，即 b 属于列空间。

有解时，全部解为 $x_p + \text{Null}(A)$ 。零空间只有零向量时，这个集合只含一个点；含有非零向量时，沿它的所有实数倍改变特解，便得到无穷多个不同的解。■

左零空间也提供一种简短的**无解证据**：若找到 y 满足 $A^T y = \mathbf{0}$ 而 $y \cdot b \neq 0$ ，目标就不可能由 A 产生。因为对所有 x ，有 $y \cdot (Ax) = (A^T y) \cdot x = 0$ 。这与消元中出现的矛盾行是同一类约束的不同表达。

例题 5.17 (不用重复消元, 辨认一个不可达目标)

式(5.10)中的矩阵 A , 能否产生 $\mathbf{b} = (3, 6, -2)^T$?

解 其列空间是 $(1, 2, -1)^T$ 张成的直线, 给定目标不在直线上。也可以取左零空间向量 $\mathbf{y} = (1, 0, 1)^T$, 直接算得 $\mathbf{y} \cdot \mathbf{b} = 1 \neq 0$, 故无解。左零空间中的这支向量正在检查约束 $b_1 + b_3 = 0$ 。

产生输出的部分, 是否也会有重复

整个输入空间中可能有多个解, 但这些重复来自零空间。如果把输入限制在行空间, 零空间的方向已经被排除, 是否还会出现重复? 下面的结论把这项直观说成严格的一一对应。

这并不要求我们先算任何正交分解的算法。只用第 5.4 节已经证明的唯一分解: 每个解都能写成 $\mathbf{x}_R + \mathbf{x}_N$, 后一部分不产生输出。因此去掉 $\mathbf{x}_N$, 还会得到一个满足相同目标的解, 而且它位于行空间中。剩下的问题是: 行空间中会不会还藏着两个不同的解? 若有, 它们的差必须同时属于行空间和零空间; 而这两者没有共同的非零方向。这样, 存在与唯一两条路线恰好接到一起。

定理 5.18 (行空间到列空间的一一对应)

映射 $\mathbf{x} \mapsto A\mathbf{x}$ 限制在 $\text{Row}(A)$ 上, 是从 $\text{Row}(A)$ 到 $\text{Col}(A)$ 的一一对应线性映射。因此, 每个可达的目标 $\mathbf{b}$ 在行空间中恰好有一个解。

证明: 不合并不同的行空间输入。若 $\mathbf{u}, \mathbf{v} \in \text{Row}(A)$ 且 $A\mathbf{u} = A\mathbf{v}$, 则差 $\mathbf{u} - \mathbf{v}$ 同时属于行空间和零空间。两者交为零, 故 $\mathbf{u} = \mathbf{v}$, 这就证明单射。

覆盖全部列空间输出。任取 $\mathbf{b} \in \text{Col}(A)$, 存在 $\mathbf{x}$ 使 $A\mathbf{x} = \mathbf{b}$ 。将输入分解成 $\mathbf{x}_R + \mathbf{x}_N$, 得到

$$\mathbf{b} = A\mathbf{x}_R + A\mathbf{x}_N = A\mathbf{x}_R. \quad (5.54)$$

因此每个列空间输出都有行空间中的原像, 这就证明满射。限制后的映射仍保持线性组合, 所以它是一一对应的线性映射。 ■




图 5.10: 四个子空间共同决定解：行空间一一对应列空间，零空间送到零。

读图说明：取 $D = \begin{pmatrix} 1 & 1 \\ 2 & 2 \end{pmatrix}$ ，两端均可画在平面。红色点 x_R 表示行空间中的唯一解，经过它的灰色虚线表示同一目标的全部解。红色对应是映射限制后的作用，绿色弧线表示零空间中的所有输入都送到右端原点；两条作用并行，不是输入先经过零空间再产生输出的流程。

对贯穿例子的目标 $\mathbf{b} = (3, 6, -3)^T$ ，行空间中的输入形如 $(q, q, 0)^T$ ，代入 $A\mathbf{x} = \mathbf{b}$ 得 $2q = 3$ ，故这一唯一的行空间解为

$$\mathbf{x}_R = \left(\frac{3}{2}, \frac{3}{2}, 0\right)^T, \quad \mathbf{x} = \mathbf{x}_R + s(-1, 1, 0)^T + t(0, 0, 1)^T. \quad (5.55)$$

这里的数值可以跟着走一遍。 A 的每一行只检查 $x_1 + x_2$ ，所以任何解都满足 $x_1 + x_2 = 3$ ；行空间又要求 $x_1 = x_2$ 、 $x_3 = 0$ 。把这两种条件同时满足，便得到 $x_1 = x_2 = 3/2$ 。例如，下面两个解看上去不同，却输出同一个目标：

$$\mathbf{p} = (3, 0, 0)^T = \mathbf{x}_R - \frac{3}{2}\boldsymbol{\xi}_1, \quad (5.56)$$

$$\mathbf{q} = (0, 3, 2)^T = \mathbf{x}_R + \frac{3}{2}\boldsymbol{\xi}_1 + 2\boldsymbol{\xi}_2, \quad (5.57)$$

$$A\mathbf{p} = A\mathbf{q} = A\mathbf{x}_R = (3, 6, -3)^T. \quad (5.58)$$

它们的行空间分量都相同，差别全在零空间方向上。将零空间部分去掉后，留下的不是另一个目标的解，而是同一目标在行空间中唯一的解。这就是前节所说“没有多余零空间分量”的准确含义。

之前选择的特解 $(3, 0, 0)^T$ 只是这个集合中的另一个点。这里没有为它们比较“优劣”，只辨认其中哪一个属于行空间。

把结论回扣到章首电网络：可实现的节点注入位于关联矩阵的列空间，左零空间检查全网必须满足的收支条件；已实现的节点平衡允许沿零空间增加循环自由度。线路电势差由节点电势的转置作用组织在行空间中。真实线路电流还需服从元件关系，但这些关系所在的位置，已经由四个子空间明确区分。

我们现在能够同时解释“无解”与“多解”。下一节把这些空间变化放进含参数方程组，看看一个主元消失时，整幅结构图怎样改变。

5.6 解的判定：参数分类与结构反推

本节不重新教消元，而是用刚学到的子空间结构，重新解读含参数方程组的每一种情形。一个主元消失，不只是算式里少了一个非零数：秩可能下降，行空间与列空间的维数随之减少，两个零空间的维数则增加。可是自由方向增加以后，目标仍可能在列空间内，也可能已经离开列空间。我们既要参数怎样改变约束，也要看右端项能否与剩下的约束一致。

计算仍用第2章的方法。需要补上的，是计算后的解释：为什么出现矛盾，为什么只剩一个解，为什么解能沿某个方向连续变化。

定理 5.19 (秩判定的结构汇总)

设 A 为 $m \times n$ 矩阵， $\bar{A} = [A \mid \mathbf{b}]$ 。方程组的三种情形为

$$r(A) < r(\bar{A}) \iff \text{无解}, \quad (5.59)$$

$$r(A) = r(\bar{A}) = n \iff \text{有解且解唯一}, \quad (5.60)$$

$$r(A) = r(\bar{A}) < n \iff \text{有无穷多解}. \quad (5.61)$$

有解时，自由参数个数为 $n - r(A)$ ；齐次方程组必有零解，且有非零解当且仅当 $r(A) < n$ 。

证明： 添加一列 $\mathbf{b}$ ，若秩增加，说明该列不在原列空间中，目标不可达；若秩不增加，说明它能由原列表示。可达之后，再用 $\dim \text{Null}(A) = n - r(A)$ 判断是否留下自由方向。齐次方程的目标为零，始终在列空间中，所以只需判断零空间是否非平凡。 ■

例题 5.20 (三元方程组：主元变化与目标变化)

讨论实参数 λ, μ 下方程组

$$\begin{cases} x_1 + x_2 + x_3 = 3, \\ x_1 + \lambda x_2 + x_3 = 4, \\ x_1 + x_2 + (\lambda - 1)x_3 = \mu + 2 \end{cases} \quad (5.62)$$

的解，并说明秩的变化如何反映输入、输出两端的结构。

解 记系数矩阵为 H_λ ，目标为 $\mathbf{d}_\mu = (3, 4, \mu + 2)^T$ 。按第2章方法，做 $r_2 \leftarrow r_2 - r_1$ 、

$r_3 \leftarrow r_3 - r_1$, 就得到

$$[H_\lambda \mid \mathbf{d}_\mu] \sim \left[\begin{array}{ccc|c} 1 & 1 & 1 & 3 \\ 0 & \lambda - 1 & 0 & 1 \\ 0 & 0 & \lambda - 2 & \mu - 1 \end{array} \right]. \quad (5.63)$$

先保留 $\lambda - 1$ 与 $\lambda - 2$, 不要除去它们; 是否为零, 正是结构发生变化的分界。

当 $\lambda \neq 1, 2$ 时, 三列都有主元, 两个秩均为 3, 唯一解为

$$\mathbf{x} = \left(3 - \frac{1}{\lambda - 1} - \frac{\mu - 1}{\lambda - 2}, \frac{1}{\lambda - 1}, \frac{\mu - 1}{\lambda - 2} \right)^T. \quad (5.64)$$

这里 $\text{Row}(H_\lambda) = \text{Col}(H_\lambda) = \mathbb{R}^3$, 两端零空间都只有零向量。输出端没有不可达的方向, 输入端也没有不影响结果的自由方向。这就是三主元所说明的全部结构, 而不只是一个求解公式。

当 $\lambda = 1$ 时, 第二个条件变为 $0 = 1$ 。系数矩阵仍有两个独立约束, 所以 $r(H_1) = 2$, 增广矩阵却有秩 3; 无论 μ 取什么值, 方程组都无解。这个矛盾也能从左零空间读出:

$$\boldsymbol{\ell} = (-1, 1, 0)^T, \quad H_1^T \boldsymbol{\ell} = \mathbf{0}, \quad \boldsymbol{\ell} \cdot \mathbf{d}_\mu = 1. \quad (5.65)$$

原矩阵的前两行相同, 所以它产生的输出必须满足 $d_1 = d_2$, 而给定目标的这两项为 3 与 4。目标带有非零的左零空间分量, 伸出了列空间。此时输入零空间确实已经扩为一维, 但那只是齐次方程的自由方向, **不能挽救一个不可达的非齐次目标**。

当 $\lambda = 2$ 时, 第三个条件变为 $0 = \mu - 1$ 。若 $\mu \neq 1$, 仍是无解, 两个秩分别为 2 与 3; 若 $\mu = 1$, 则该条件不再增加约束, 两个秩都为 2, x_3 自由。令 $x_3 = t$, 得到

$$\mathbf{x} = (2, 1, 0)^T + t(-1, 0, 1)^T, \quad t \in \mathbb{R}. \quad (5.66)$$

这时四个空间可以直接写成

$$\text{Row}(H_2) = \text{Span}\{(1, 1, 1)^T, (1, 2, 1)^T\}, \quad (5.67)$$

$$\text{Null}(H_2) = \text{Span}\{(-1, 0, 1)^T\}, \quad (5.68)$$

$$\text{Col}(H_2) = \text{Span}\{(1, 1, 1)^T, (1, 2, 1)^T\}, \quad (5.69)$$

$$\text{Null}(H_2^T) = \text{Span}\{(-1, 0, 1)^T\}. \quad (5.70)$$

这个例子中, 输入、输出两侧恰好有相同的数值形状, 但它们的角色仍不同: 输入端的平面满足 $x_1 = x_3$, 输出端的平面满足 $d_1 = d_3$ 。 $\mu = 1$ 时目标为 $(3, 4, 3)^T$, 恰在输出平面内; $\mu \neq 1$ 时目标离开这个平面。前者的解沿零空间直线自由移动, 后者根本没有特解。

若 $\lambda = 2, \mu = 1$, 再检查行空间中的解, 它必须满足 $x_1 = x_3$ 。由 $x_2 = 1, x_1 + x_3 = 2$,

得到唯一的行空间解 $(1, 1, 1)^T$ 。因此同一通解也可以写成

$$\mathbf{x} = (1, 1, 1)^T + s(-1, 0, 1)^T, \quad s \in \mathbb{R}. \quad (5.71)$$

这一补充把参数分类重新接到第 5.5 节: 解虽然无穷多个, 去掉零空间分量后, 行空间中的代表仍恰好一个。



图 5.11: 从满秩到少一个主元: 零空间增加一个方向, 但目标是否可达仍需另外检查。

读图说明: 绿色画的是输入端的零空间, 不是中间情形的非齐次解集。秩下降使输入多出自由方向, 却不能单独判断目标有没有解; 还要看输出端的列空间。右图若改为 $\mu \neq 1$, 同一零空间也会对应无解。

两种异常情形可以再作对照: $\lambda = 1$ 使前两项输出必须相等, $\lambda = 2$ 使第一、三项输出必须相等。它们都让秩降为 2, 但限制的输出方向不同。下面保留一个更短的二元例子, 说明同一系数矩阵下, 仅改变右端项就可以从多解变为无解。

例题 5.21 (一个参数, 三种解的形态)

讨论实参数 λ 下方程组

$$\begin{cases} x_1 + x_2 = 2, \\ \lambda(\lambda - 1)x_2 = \lambda \end{cases} \quad (5.72)$$

的解, 并说明四个子空间怎样随参数改变。

解 其系数矩阵与增广矩阵已经处于便于观察主元的形式:

$$A_\lambda = \begin{pmatrix} 1 & 1 \\ 0 & \lambda(\lambda - 1) \end{pmatrix}, \quad \bar{A}_\lambda = \left[\begin{array}{cc|c} 1 & 1 & 2 \\ 0 & \lambda(\lambda - 1) & \lambda \end{array} \right]. \quad (5.73)$$

先保留第二个主元中的表达式, 不能提前除以 $\lambda(\lambda - 1)$ 。

当 $\lambda \neq 0, 1$ 时, 两主元均非零, $r(A_\lambda) = r(\bar{A}_\lambda) = 2$ 。行空间与列空间都是 $\mathbb{R}^2$, 两端零空间都只有零向量, 目标可达且没有自由方向。唯一解为

$$\mathbf{x} = \left(2 - \frac{1}{\lambda - 1}, \frac{1}{\lambda - 1} \right)^T. \quad (5.74)$$

当 $\lambda = 0$ 时, 第二行变为 $0 = 0$, 两种秩均为 1。此时

$$\text{Row}(A_0) = \text{Span}\{(1, 1)^T\}, \quad \text{Null}(A_0) = \text{Span}\{(-1, 1)^T\}, \quad (5.75)$$

$$\text{Col}(A_0) = \text{Span}\{(1, 0)^T\}, \quad \text{Null}(A_0^T) = \text{Span}\{(0, 1)^T\}. \quad (5.76)$$

目标 $(2, 0)^T$ 仍在列空间中, 但零空间扩大为一条直线, 故有无穷多解: $x = (2, 0)^T + t(-1, 1)^T$ 。

当 $\lambda = 1$ 时, 系数矩阵与 A_0 相同, 四个基本子空间也相同, 右端项却变为 $(2, 1)^T$ 。第二行是 $0 = 1$, 于是 $r(A_1) = 1 < r(\bar{A}_1) = 2$, 无解。目标沿左零空间多出非零分量, 已经离开可达的列空间。




图 5.12: 主元消失之后, 还必须检查目标: 秩下降可以带来多解, 也可以带来无解。

读图说明: 后两幅的系数矩阵相同, 区别仅在右端项。零空间有自由方向, 不能保证非齐次方程一定有解; 存在性仍要由列空间判断。

从已知解反推零空间

若题目给出若干非齐次解, 先取它们的差, 才能得到齐次解。只有进一步确认差向量线性无关, 且数量达到 $n - r(A)$, 才足以构造基础解系。知道几个解, 不自动意味着知道了全部解。

例题 5.22 (由三个已知解恢复通解)

三元非齐次方程组 $Ax = b$ 的系数矩阵秩为 1, 已知

$$p = (2, 0, 0)^T, \quad q = (1, 1, 0)^T, \quad h = (1, 0, 1)^T \quad (5.77)$$

都是解。写出其通解。

解 差向量 $q - p = (-1, 1, 0)^T$ 、 $h - p = (-1, 0, 1)^T$ 都在零空间中。分别检查第二、第三分量, 证明它们线性无关。又因零空间维数为 $3 - 1 = 2$, 这两支向量已经构成基础解系, 故

$$x = p + s(q - p) + t(h - p) = (1 - s - t)p + sq + th. \quad (5.78)$$

这里最后一式的系数之和为 1。对任意非齐次解的组合, 映射后得到的是系数和乘以 b ;

当 $\mathbf{b} \neq \mathbf{0}$ 时, 只有系数和为 1 才仍产生原目标。因此, 不能像齐次解那样任意相加、数乘非齐次解。

易错点: 讨论参数先查可能消失的主元; 判断唯一性必须先确认有解; 由已知解恢复通解, 要同时核对“差向量属于零空间、彼此无关、数量足够”。这三项分别对应解的性质、基的性质和维数的性质。

这一节所说的“结构反推”, 不是看见秩变小就背一句“可能有无穷多解”。我们要说出它具体改变了哪一端: 行空间少一个独立方向, 零空间就多一个自由方向; 列空间少一个可达方向, 左零空间就多一项需要满足的限制。再将右端项与这个可达范围比较, 才得出存在性。**主元、秩和解的种类, 是同一次结构变化的不同读法。**

参数分类告诉我们目标能否到达、到达后有多少自由方向。若目标确实到不了, 是否还能给出一个最接近它的输出? 下一节用已经建立的直和分解回答这个问题。

5.7 无解时的最优近似：最小二乘解与正规方程

第三章留下的读数问题，现在怎样解决？

第 3.5.1 节把矩阵的每一列看作特征探测器：用它扫描目标 $\mathbf{b}$ ，得到点积响应 $A^T \mathbf{b}$ 。那时我们留下了一个问题：探测器若不正交，原始响应读数就包含彼此的串扰，不能直接当作组合系数。现在不仅要分清读数与配方，还要面对更实际的困难：目标可能根本不在特征能够组合出的范围里。怎样处理探测器的重叠，同时让组合出来的输出尽可能靠近目标？这就是本节要回收的伏笔。


目标够不到，还能给出有意义的答案吗？

第 5.5 节说明， $A\mathbf{x} = \mathbf{b}$ 有解当且仅当 $\mathbf{b} \in \text{Col}(A)$ 。目标在列空间外时，解集是空集。但带有测量误差的工程数据、统计数据常常如此。我们可以退一步：在所有可能的输入中，哪个 $A\mathbf{x}$ 最接近 $\mathbf{b}$ ？这就是最小二乘法 (Least Squares) 要解决的问题。本节只用第 0 章的点积、长度，以及第 5.4.2 节的正交直和。

用 $\hat{\mathbf{x}}$ 记待求的最优系数，问题写成

$$\text{寻找 } \hat{\mathbf{x}} \in \mathbb{R}^n, \quad \|\mathbf{b} - A\hat{\mathbf{x}}\|^2 = \min_{\mathbf{x} \in \mathbb{R}^n} \|\mathbf{b} - A\mathbf{x}\|^2. \quad (5.79)$$

白话说，配方可以改变，特征方向固定；我们要让全部输出分量的误差平方和最小。误差在输出端比较，未知的权重却在输入端求，转置正是连接两端的工具。



列空间：特征可组合范围

目标： $\mathbf{b}$

最优近似： $A\hat{\mathbf{x}}$

剩下的残差： $\mathbf{r} = \mathbf{b} - A\hat{\mathbf{x}}$

为什么“垂直”保证最优？
稍后用点积展开严格证明。

图 5.7a: 最小二乘先找最优输出，再找产生它的权重。红色平面代表特征可组合的列空间，橙色目标在平面外，绿色残差垂直于平面；这是式(5.79)的几何图景。

第一步：先扫描目标，得到原始响应读数

设 $A = [\mathbf{a}_1 \cdots \mathbf{a}_n]$ 。输出端的目标 $\mathbf{b}$ 同时接受各列探测器的扫描，读数排成输入端的 n 维向量 $\mathbf{c}$ ：

$$\mathbf{c} = A^T \mathbf{b} = \begin{pmatrix} \mathbf{a}_1 \cdot \mathbf{b} \\ \mathbf{a}_2 \cdot \mathbf{b} \\ \vdots \\ \mathbf{a}_n \cdot \mathbf{b} \end{pmatrix}, \quad c_i = \mathbf{a}_i \cdot \mathbf{b}. \quad (5.80)$$

每个分量都是一个点积响应，不是“第 i 个方向应当取几份”的直接答案；这和第三章

的探测器解释完全一致。若把 $\mathbf{b}$ 当作输出端的评分系数, $\mathbf{c}$ 也就是对偶映射回传的输入评分向量。

沿用第 3.5.1 节的二维例子, 先排除目标不可达的困难, 只观察读数怎样混在一起:

$$\mathbf{a}_1 = \begin{pmatrix} 1 \\ 0 \end{pmatrix}, \quad \mathbf{a}_2 = \begin{pmatrix} 1 \\ 1 \end{pmatrix}, \quad A = \begin{pmatrix} 1 & 1 \\ 0 & 1 \end{pmatrix}, \quad \mathbf{b} = \begin{pmatrix} 2 \\ 1 \end{pmatrix}. \quad (5.81)$$

两列不共线, 能够组合出整个平面, 但它们也不垂直。先把方向看清, 再比较响应与权重。




图 5.7b: 蓝色与红色箭头是两支固定的特征探测器, 橙色箭头是待扫描目标。它们取自式(5.81), 和第三章使用同一组数字; 两列不共线, 却仍会相互响应。

第二步: 目标在范围内, 为什么读数仍不等于配方?

两支探测器给出的原始读数是

$$A^T \mathbf{b} = \begin{pmatrix} 2 \\ 3 \end{pmatrix}, \quad \mathbf{b} = 1\mathbf{a}_1 + 1\mathbf{a}_2, \quad \mathbf{x}_0 = \begin{pmatrix} 1 \\ 1 \end{pmatrix}. \quad (5.82)$$

配方是“各取 1 份”, 扫描却读出 2 和 3。第一支探测器不只读到自身的那一份, 也读到斜向特征的水平部分; 第二支既读到第一支的贡献, 又带有自身长度平方所决定的增益。不是扫描算错了, 而是它测的是点积响应, 问题要的是组合权重。非正交会带来串扰; 即便彼此正交, 若没有单位长度, 自身增益也仍须修正。




图 5.7c: 原始响应读数为 2 与 3，对应式(5.80)的两个分量。色条中的浅色部分提示来自另一探测器的响应；这些读数带有重叠与自身增益，不能直接当作组合系数。

第三步：把探测器的重叠记录成矩阵

若先用权重 x 组合，再扫描组合结果，得到的是 $A^T(Ax)$ 。因此，权重与响应之间的转换由 $A^T A$ 描述：

$$A^T A = \begin{pmatrix} a_1 \cdot a_1 & a_1 \cdot a_2 & \cdots & a_1 \cdot a_n \\ a_2 \cdot a_1 & a_2 \cdot a_2 & \cdots & a_2 \cdot a_n \\ \vdots & \vdots & \ddots & \vdots \\ a_n \cdot a_1 & a_n \cdot a_2 & \cdots & a_n \cdot a_n \end{pmatrix}. \quad (5.83)$$

这就是探测器的互相关矩阵 (Detector Correlation Matrix)。对角线记录每支探测器的自身增益，即长度平方；非对角线记录两支探测器的重叠响应。这里的“互相关”指原始点积，没有归一化，也不是统计学的相关系数；它还受探测器长度影响，不能只用来比较夹角。若两支探测器垂直，相应的非对角线元素才为零。




图 5.7d: 互相关矩阵逐格记录探测器的相互响应，对应式(5.83)。对角线是自身增益，非对角线是串扰系数；本例方格的数字为 1、1、1、2，颜色较深的格子表示读数较大。

第四步：让组合结果与目标具有相同的响应

一个合理的配方，应使组合结果在所有探测器上产生与目标相同的读数。把两组响应相等写出来，就是

$$\underbrace{A^T A \hat{x}}_{\text{组合结果的响应}} = \underbrace{A^T b}_{\text{目标的原始读数}}. \quad (5.84)$$

这就是稍后正式说明的正规方程。两边接受同一套探测器扫描，左边把权重经过自身增益与串扰后的响应写出来，右边给出目标读数；解这个方程，相当于**根据互相关矩阵修正读数，找出应当送回组合器的权重**。这里是解方程，不是把矩阵的非对角线元素删掉。

在二维例子中，这个修正可以完整跟着数字做一遍：

$$\begin{pmatrix} 1 & 1 \\ 1 & 2 \end{pmatrix} \begin{pmatrix} \hat{x}_1 \\ \hat{x}_2 \end{pmatrix} = \begin{pmatrix} 2 \\ 3 \end{pmatrix} \Rightarrow \begin{cases} \hat{x}_1 + \hat{x}_2 = 2, \\ \hat{x}_1 + 2\hat{x}_2 = 3 \end{cases} \Rightarrow \hat{x} = \begin{pmatrix} 1 \\ 1 \end{pmatrix}. \quad (5.85)$$

第二式减去第一式得到 $\hat{x}_2 = 1$ ，再代回得到 $\hat{x}_1 = 1$ ；使用的仍是第二章消元。此次目标本来就在列空间内，修正后的配方确实精确还原目标。若目标在列空间外，就不存在“真实的精确配方”，同一过程求出的是最优拟合权重；若列向量相关，权重还可能有无穷多组。这两个边界不能被“去串扰”这个比喻掩盖。




图 5.7e: 读数修正前是 2、3，修正后组合系数是 1、1，两个面板使用相同刻度。箭头表示解互相关矩阵对应的方程，不表示再次做一次转置；在本例目标可达的条件下，修正后恰好还原原配方。

第五步：目标不可达时，为什么匹配读数就已经最优？

记残差为 $r = b - A\hat{x}$ 。式(5.84)等价于 $A^T r = 0$ ：残差在所有特征探测器上的响应读数都为零。组合结果已经捕捉了这套特征能够捕捉的部分，剩下的是全部列探测器共同的死角，也就是左零空间。残差可能非零，但再调整组合权重，只会沿列空间移动，无法消除这个正交方向上的差距。


前面的二维例子能精确匹配，所以残差为零。要看见“读数全为零，但残差不为零”，

只需把两支探测器补上第三个分量 0，而把目标的第三个分量改为 1：

$$\tilde{A} = \begin{pmatrix} 1 & 1 \\ 0 & 1 \\ 0 & 0 \end{pmatrix}, \quad \tilde{\mathbf{b}} = \begin{pmatrix} 2 \\ 1 \\ 1 \end{pmatrix}, \quad \hat{\mathbf{x}} = \begin{pmatrix} 1 \\ 1 \end{pmatrix}, \quad \mathbf{r} = \tilde{\mathbf{b}} - \tilde{A}\hat{\mathbf{x}} = \begin{pmatrix} 0 \\ 0 \\ 1 \end{pmatrix}. \quad (5.86)$$

互相关矩阵与目标读数仍分别是 $\begin{pmatrix} 1 & 1 \\ 1 & 2 \end{pmatrix}$ 和 $(2, 3)^T$ ，因此最优权重仍是各取 1 份。两列

只能组合出第三分量为 0 的输出，目标多出的那一份没有探测器能够响应。这正是左零空间中的非零残差；图 5.7f 画出了这一关系。



$$\tilde{\mathbf{a}}_1 \cdot \mathbf{r} = 0$$

$$\tilde{\mathbf{a}}_2 \cdot \mathbf{r} = 0$$

$$\tilde{A}^T \mathbf{r} = \mathbf{0}$$

$$\mathbf{r} \in \text{Null}(\tilde{A}^T)$$

余下部分：所有列探测器都读不到。

图 5.7f: 绿色残差与红色平面中的两支特征探测器都正交，因此每支探测器的残差响应都为 0。图中把残差平移到原点，只为比较方向；正规方程要求的是全部读数为零，而不是要求残差本身为零。


“全部读作零”为什么保证误差最小，而不只是一条必要条件？下面保留完整的点积证明：先从正交直和找出唯一的最近输出，再说明正规方程恰好找到它的全部原像。为和原有计算统一，以下用 $\mathbf{e}$ 表示残差，即上面所用的 $\mathbf{r}$ 。

没有精确解时，用什么替代原目标？

设 A 是实 $m \times n$ 矩阵。第 5.4.2 节已经给出

$$\mathbb{R}^m = \text{Col}(A) \oplus \text{Null}(A^T), \quad \mathbf{b} = \hat{\mathbf{b}} + \mathbf{e}, \quad \hat{\mathbf{b}} \in \text{Col}(A), \quad \mathbf{e} \in \text{Null}(A^T). \quad (5.87)$$

也就是说，任意目标都能唯一拆成“A 能产生的部分”与“和列空间垂直的部分”。



$\hat{\mathbf{b}}$ 是列空间中离 $\mathbf{b}$ 最近的点。

$$\mathbf{e} \perp \text{Col}(A).$$

图 5.7g: 红色点是列空间中离目标最近的点，绿色线段记录剩下的误差。正交直和先确定唯一输出，随后才求输入权重；剩下的误差在列探测器上的响应为零。

为什么垂直的偏离最短？任取列空间中的另一点 $\mathbf{c}$ ，则 $\hat{\mathbf{b}} - \mathbf{c}$ 仍在列空间中，与 $\mathbf{e}$ 正

交。用第 0 章的点积展开长度平方，交叉项为零，得到

$$\begin{aligned}\|b - c\|^2 &= \|e + (\hat{b} - c)\|^2 \\ &= \|e\|^2 + 2e \cdot (\hat{b} - c) + \|\hat{b} - c\|^2 \\ &= \|e\|^2 + \|\hat{b} - c\|^2 \geq \|e\|^2.\end{aligned}\quad (5.88)$$

换一个列空间中的点，就会多出一项非负的平方；只有 $c = \hat{b}$ 时取等号。因此最近的输出存在，并且唯一。

怎样把这个输出变成一个解？ $\hat{b}$ 属于列空间，所以一定有输入满足 $A\hat{x} = \hat{b}$ 。这样的输入称为最小二乘解 (Least-Squares Solution)：

$$\|b - A\hat{x}\|^2 \leq \|b - Ax\|^2 \quad \text{对所有 } x \in \mathbb{R}^n. \quad (5.89)$$

这句话就是“所有方程的误差平方和最小”。若原目标可达， $e = 0$ ，它就是精确解；若不可达， $e \neq 0$ ，它则是用列空间分量代替原目标后得到的精确解。

怎样把“误差垂直”写成一个能解的方程组？


把最小二乘解产生的误差 $e = b - A\hat{x}$ 叫作残差向量 (Residual Vector)。它属于左零空间，与 A 的每一列 a_j 都正交。这些逐列条件合在一起，正是转置矩阵的一次作用：

$$a_j \cdot (b - A\hat{x}) = 0 \quad (j = 1, \dots, n), \quad (5.90)$$

$$A^T(b - A\hat{x}) = 0$$

$$A^T b - A^T A\hat{x} = 0 \iff A^T A\hat{x} = A^T b. \quad (5.91)$$

后一式叫作正规方程 (Normal Equations)。白话说，误差和每一列都垂直，把这句话写成矩阵形式，就得到正规方程。



e 与 A 的每一列正交。

这里画出列空间为一维的情形；灰色虚线标出列向量，绿色残差在这些探测器上的读数全为零。

图 5.7h: 每一列都沿着红色直线；最优输出到目标的误差，与这些列全部垂直。每条逐列正交条件都是一个零响应读数，合起来就得到正规方程。

定理 5.23 (最小二乘解的等价条件)

对任意实矩阵 A 和目标 b ，最小二乘解总存在。一个输入 $\hat{x}$ 是最小二乘解，当且仅当它满足正规方程 $A^T A\hat{x} = A^T b$ 。

证明： 先看存在性：式(5.87)给出列空间中的 $\hat{b}$ ，它一定有原像，所以最小二乘解总能找

到。若输入最优，最近输出的唯一性说明 $A\hat{x} = \hat{b}$ ；误差便属于左零空间，上面的逐列推导给出正规方程。反过来，若满足正规方程，则 $b - A\hat{x} \in \text{Null}(A^T)$ ，而 $A\hat{x} \in \text{Col}(A)$ 。直和分解唯一，所以这两部分必定就是 e 和 $\hat{b}$ ；再由式(5.88)，这个输入确实最优。两个方向都已说明。 ■

$$\begin{array}{ccc}
 \begin{array}{|c|} \hline A^T \\ \hline n \times m \\ \hline \end{array} & \times & \begin{array}{|c|} \hline A \\ \hline m \times n \\ \hline \end{array} \longrightarrow \begin{array}{|c|} \hline A^T A \\ \hline n \times n \text{ 方阵} \\ \hline \end{array} \\
 \begin{array}{|c|} \hline A^T \\ \hline n \times m \\ \hline \end{array} & \times & \begin{array}{|c|} \hline b \\ \hline m \text{ 维} \\ \hline \end{array} \longrightarrow \begin{array}{|c|} \hline A^T b \\ \hline n \text{ 维向量} \\ \hline \end{array}
 \end{array}$$

$$A^T A \hat{x} = A^T b$$

图 5.7i: 正规方程把 m 条方程整理为 n 条条件，原始目标读数与组合结果读数在输入端匹配。是否唯一，仍要看 A 的列是否线性无关；转置不是对原映射求逆。

原来的 m 条等式可能无法同时成立；新的 n 条条件要求误差逐列垂直。未知量仍有 n 个，正规方程始终有解，但还没有保证解唯一。

正规方程有一个答案，还是有一整族答案？

问题落在 $n \times n$ 的系数矩阵 $A^T A$ 上。它会不会比 A 多出一些被送到零的输入？下面的事实把新方程重新接回原来的零空间。

定理 5.24 (正规方程保留原来的自由方向)

对任意实矩阵 A ，有

$$\text{Null}(A^T A) = \text{Null}(A). \quad (5.92)$$

也就是说， A 与 $A^T A$ 把同一批输入送到零。

证明： 若 $Az = 0$ ，再乘 A^T ，便有 $A^T Az = 0$ ，所以原零空间包含在新零空间中。反过来，若 $A^T Az = 0$ ，两边左乘 z^T ：

$$0 = z^T A^T Az = (Az)^T (Az) = \|Az\|^2. \quad (5.93)$$

最后一项是各分量的平方和；它为零，每个分量就都为零，所以 $Az = 0$ 。新零空间也包含在原零空间中，两者因此相等。 ■

如果 A 的列线性无关，零空间只有零向量， $A^T A$ 就可逆，正规方程有唯一解：

$$\hat{x} = (A^T A)^{-1} A^T b. \quad (5.94)$$

这个公式写出唯一解；实际计算也可以直接解正规方程。若列线性相关，零空间含有非零方向，正规方程已经有解，所以沿这些方向可以得到无穷多个解。




图 5.7j: 左边只有一个最优输入; 右边有一条解直线, 但线上所有输入都产生同一个最优输出。互相关矩阵修正读数, 却不会消除原矩阵的零空间自由度。

若最优输入不止一个, 它们相差什么? 任选一个最小二乘解 $\hat{x}_p$, 由第 5.1、5.2 节和式(5.92), 全部最小二乘解为

$$\hat{x}_p + \text{Null}(A) = \{\hat{x}_p + z : z \in \text{Null}(A)\}, \quad A\hat{x}_p = \hat{b}. \quad (5.95)$$

因此解集仍是零空间的平移, 维数为 $n - \text{rank}(A)$ 。输入可以不同, 输出却始终是唯一 $\hat{b}$; 这正是本章反复出现的解结构。




图 5.7k: 原方程无解, 正规方程仍有解; 绿色直线表示一个最优输入加上零空间中的变化。沿绿色方向改变权重, 组合结果与全部响应读数都保持不变。

为什么不能随便挑一个方向拆开目标?

同一个目标, 也能沿斜方向接近列空间, 但那样留下的误差更长。本章的直和分解给出右图的分解方式; 第 7 章将从投影的角度系统解释这种最短距离关系。




图 5.7l: 本章的直和分解给出右图: 沿与列空间垂直的方向拆开目标, 误差最短。右图残差在所有特征探测器上读作零, 左图没有满足这一条件; 这种最短距离关系将在第 7 章系统讨论。

怎样用这套结构拟合三个数据点?


给定 $(1,1), (2,2), (3,4)$, 找一条过原点的直线 $y = kx$ 。三条方程要求 k 分别等于

1, 1, 4/3, 无法同时成立。把它们排成矩阵, 正规方程就直接给出最优斜率:

$$A = \begin{pmatrix} 1 \\ 2 \\ 3 \end{pmatrix}, \quad \mathbf{b} = \begin{pmatrix} 1 \\ 2 \\ 4 \end{pmatrix}, \quad A^T A = 1^2 + 2^2 + 3^2 = 14, \quad (5.96)$$

$$A^T \mathbf{b} = 1 \cdot 1 + 2 \cdot 2 + 3 \cdot 4 = 17, \quad 14k = 17, \quad k = \frac{17}{14}. \quad (5.97)$$

三个点不在同一条过原点的直线上, 但 $k = 17/14$ 让三条方程的误差平方和最小。这也回答了第 0 章用点积拟合数据时留下的问题。



$k = 17/14$ 使误差平方和最小。

$$\mathbf{e} = (-3, -6, 5)^T / 14$$

$$e_1 + 2e_2 + 3e_3 = 0,$$

误差与 A 的列向量正交。

残差之和 = $-2/7$, 并不为零;

残差平方和 = $5/14 > 0$ 。

图 5.7m: 这条直线使纵向误差的平方和最小, 三个误差却没有全部变成零。灰色竖线记录纵向差, 不是点到直线的垂直距离; 探测器扫描的是三维残差记录, 而不是这张数据图上的每一段竖线。

这里的最优输出与残差为

$$\hat{\mathbf{b}} = \frac{1}{14}(17, 34, 51)^T, \quad \mathbf{e} = \frac{1}{14}(-3, -6, 5)^T, \quad \|\mathbf{e}\|^2 = \frac{5}{14}. \quad (5.98)$$

误差向量与 $(1, 2, 3)^T$ 的点积为零, 这才是正规方程要求的条件; 过原点拟合不保证残差之和为零。由于 A 只有一列且该列非零, 本例的最小二乘解唯一。

这条路线怎样走向第 7 章?

回到第三章的语言: 先用转置读取目标响应, 再用互相关矩阵把响应关系写成正规方程, 最后检查残差是否在全局探测器上读作零。正向组合、反向评分与四个子空间现在合成了同一条求解路线。读数有确定的含义, 权重是否唯一却仍由零空间决定; “最优输出唯一”与“最优输入唯一”必须分开判断。

最小二乘解把“有解时的全部解”延伸到“无解时的最优近似”: 先用唯一的列空间分量替代原目标, 再求它的全部原像。正规方程把这项任务变成已有的线性方程组问题。我们用点积验证了最短距离, 却还没有建立任意子空间中分解与计算的一般方法; 第 7 章的正交投影将系统回答这些问题。

5.8 【选读】从斐波那契到状态递推： 离散系统中的线性代数


选读·不做考核要求。第五章前面问的是“状态满足什么约束”，工程中还常问“状态怎样一步步演化”。后一类问题由离散线性动力系统 (Discrete-Time Linear Dynamical System) 描述。本节的库存比例、数量和图示均为教学简化模型，不代表真实仓储系统的完整设计。我们仍然关心同一件事：齐次解如何组成空间，非齐次解如何由一个特解生成，平衡状态又有多少自由度。

先看一晚的调拨：今天的库存，怎样变成明天的库存？

设两个相邻仓库分别记为 A 仓、B 仓。每晚，A 仓把原库存的 70% 留在本仓、30% 调往 B 仓；B 仓把原库存的 60% 留在本仓、40% 调往 A 仓。随后向 A 仓补货 10 单位，B 仓暂不补货。所有比例均针对调拨前的库存计算，两个方向的调拨同时完成。把第 k 天的库存排成状态向量 (State Vector) $\mathbf{x}_k = (x_{A,k}, x_{B,k})^T$ ，便有

$$\begin{cases} x_{A,k+1} = 0.7x_{A,k} + 0.4x_{B,k} + u_A, \\ x_{B,k+1} = 0.3x_{A,k} + 0.6x_{B,k} + u_B, \end{cases} \quad u_A = 10, \quad u_B = 0. \quad (5.99)$$

第一行数清明天 A 仓的三份来源，第二行数清明天 B 仓的三份来源；给定今天的库存，明天便能确定。



调拨只换仓库，不减少两仓的总库存

图 5.8a: 两仓库存调拨：按原库存同时调拨，再补入新货。

这个场景有一个值得先问的现实问题：只补货、不出库，库存会不会停下来？把两行相加，得到

$$x_{A,k+1} + x_{B,k+1} = x_{A,k} + x_{B,k} + 10. \quad (5.100)$$

总库存每天增加 10 单位，所以这里不存在固定不变的平衡库存。调拨只能重新分配库存，不能把新增货物消耗掉。先看清这一点，才不会因公式里出现“平衡态”三个字，就误以为任何系统都能回到平衡。

先从最熟悉的递推入门：把两项记忆装进一个向量

库存需要记住两个仓库的数量，斐波那契数列也需要记住两个相邻项。取 $F_0 = 0, F_1 = 1$ ，递推关系 (Recurrence Relation) 为

$$F_{k+2} = F_{k+1} + F_k, \quad \mathbf{s}_k = (F_{k+1}, F_k)^T. \quad (5.101)$$

把“后一项、前一项”一起记住，下一次更新便不需要再回头查找。

$$\mathbf{s}_{k+1} = M\mathbf{s}_k, \quad M = \begin{pmatrix} 1 & 1 \\ 1 & 0 \end{pmatrix}, \quad \mathbf{s}_0 = (1, 0)^T. \quad (5.102)$$

矩阵第一行把两项相加，第二行把原来的后一项保存下来；一个二阶数列递推就变成了向量的一阶更新。




图 5.8b: 斐波那契的状态轨迹：状态按同一规则逐步跳跃。

只要有限阶线性递推能够从已知项确定下一项，就可以把所需的若干项并排装入状态向量，改为一阶矩阵递推。“阶数降低、分量增加”只是记忆方式改变，原来的更新规则没有丢失。

抽象出共同规则：同一个矩阵，反复作用

斐波那契的 M 和库存的调拨矩阵承担同一类任务。一般地，令 F 为 n 阶矩阵， E 为同阶单位矩阵；无外部输入与有常数输入的更新分别写成

$$\mathbf{x}_{k+1} = F\mathbf{x}_k, \quad \mathbf{x}_{k+1} = F\mathbf{x}_k + \mathbf{u}. \quad (5.103)$$

前式称为齐次递推 (Homogeneous Recurrence)；后式在输入非零时称为非齐次递推 (Nonhomogeneous Recurrence)。 F 称为状态转移矩阵 (State-Transition Matrix)，输入 $\mathbf{u}$ 是每次更新额外加入的量；库存例中

$$F = \begin{pmatrix} 0.7 & 0.4 \\ 0.3 & 0.6 \end{pmatrix}, \quad \mathbf{u} = (10, 0)^T. \quad (5.104)$$

矩阵记录“怎样调拨”，输入向量记录“额外补入什么”；二者职责不同。

例题 5.25 (把库存连续更新三晚)

从 $x_0 = (100, 50)^T$ 出发，按上述调拨与补货规则求三次记录。

解 第一次，A 仓为 $0.7 \times 100 + 0.4 \times 50 + 10 = 100$ ，B 仓为 $0.3 \times 100 + 0.6 \times 50 = 60$ 。继续把新记录代回相同规则：

$$x_1 = (100, 60)^T, \quad x_2 = (104, 66)^T, \quad x_3 = (109.2, 70.8)^T. \quad (5.105)$$

三次总库存依次为 160、170、180，验证了每天净增 10 单位，而非向某个固定库存靠近。




图 5.8c: 库存的逐步更新：同一矩阵与输入，联系每晚的记录。

齐次解为什么仍然组成一个空间？

这里的解不是一个静止向量，而是一整串记录 $(x_0, x_1, \dots)$ 。两串齐次解 a_k, b_k 满足同一规则；逐项作线性组合，便有

$$ca_{k+1} + db_{k+1} = F(ca_k + db_k). \quad (5.106)$$

所以两串解的线性组合还是解，零序列也是解，全部齐次解序列构成齐次解空间 (Homogeneous Solution Space)。这与代数方程 $Ax = 0$ 的解空间同源，只是空间中的元素改成了序列。

给定初始状态后，下一项、下下项都依次确定。先算前两次，再归纳到第 k 次：

$$x_1 = Fx_0, \quad x_2 = F(Fx_0) = F^2x_0, \quad x_k = F^kx_0, \quad F^0 = E. \quad (5.107)$$

F^k 就是“更新 k 次”的线性映射矩阵，呼应第三章“矩阵乘法对应映射复合”。

取标准基 $e_1, \dots, e_n$ 分别作为初值，得到 n 串解 $F^k e_j$ 。任意初值是这些标准基的线性组合，因而任意齐次解序列也是这 n 串解的线性组合。若它们的一组线性组合在所有时刻都为零，考察 $k = 0$ 就得到各系数都为零。于是**全部齐次解序列的空间维数为 n ；固定初值后，只有一条解序列**。这个 n 不是 $\dim \text{Null}(F)$ ：例如 $F = E$ 时，每个初值生成一串常值记录，而 $\text{Null}(E)$ 只含零向量。

非齐次通解：先找到一串记录，再加上齐次变化

若 p_k 是同一输入下的一串特解，把任意解与它相减，外部输入恰好抵消：

$$z_{k+1} = x_{k+1} - p_{k+1} = (Fx_k + u) - (Fp_k + u) = Fz_k. \quad (5.108)$$

两串非齐次解之差是一串齐次解。反过来，把任意齐次解加到特解上，代回更新式仍然成立。因此

$$x_k = p_k + F^k(x_0 - p_0). \quad (5.109)$$

这就是第五章“特解加全部齐次解”的动态版本； p_k 可以变化，不必是固定的平衡状态。输入改为给定的 u_k 时，相减证明也完全成立。

平衡状态：动态问题中嵌着一个代数方程组

若更新后状态不变，称为平衡状态 (Equilibrium State)，记为 x_* 。把“不变”代入递推，再移项，得到

$$x_* = Fx_* + u \iff (E - F)x_* = u. \quad (5.110)$$

平衡状态是一串常值特解；求它时，未知量又回到了一个向量，能够直接使用本章代数方程组的理论。

先判断 $u \in \text{Col}(E - F)$ ，否则平衡状态不存在。有解时，任选一个 $x_{*,p}$ ，全部平衡状态为

$$x_{*,p} + \text{Null}(E - F), \quad \text{平衡自由度} = n - r(E - F). \quad (5.111)$$

决定平衡自由度的是 $E - F$ 的零空间，不是 F 的零空间。有解且零空间只含零向量时平衡状态唯一；有解且零空间维数大于 0 时有无穷多个平衡状态。由于 $E - F$ 是方阵，可逆时任何常数输入都对应唯一平衡状态。

在开头的库存模型中， $E - F$ 两行互为相反数：

$$E - F = \begin{pmatrix} 0.3 & -0.4 \\ -0.3 & 0.4 \end{pmatrix}. \quad (5.112)$$

所以平衡方程两行相加必须给出 $u_A + u_B = 0$ 。只向 A 仓补货的 $(10, 0)^T$ 不满足这一条件，正是“目标不在列空间内”的工程解释。

若没有补货也没有出库，平衡关系变成 $0.3x_A = 0.4x_B$ ，全部代数平衡状态为 $t(4, 3)^T$ 。其自由度为 1，因为总库存尚未指定；若另给定总库存，就在这条线上选定一个点。无需调拨比例完全对称，这种自由度来自总库存守恒。实际库存还要求分量非负，因此工程上只取其中合适的部分，这不改变代数方程的解空间结论。




图 5.8d: 平衡状态的自由度: 有解时, 由 $\text{Null}(E - F)$ 的维数决定。

若平衡状态存在, 把式(5.109)的特解选成常值 x_* , 就得到

$$x_k = x_* + F^k(x_0 - x_*). \quad (5.113)$$

任意时刻的状态等于平衡状态加上随时间演化的偏离。“偏离”未必衰减; 例如一维 $F = [2]$ 会把非零偏离逐次加倍。只有在偏离确实趋于零的模型中, 才把这一部分称为暂态响应 (Transient Response)。

回到仓库: 什么时候能看见“回到平衡”?

为体现出库的作用, 另设一个明确的教学变体: 先按原比例调拨, 再从每个仓库发出 20% 的货, 最后向 A 仓补货 10 单位。转移矩阵变为 $H = 0.8F$ 。平衡方程给出

$$H = \begin{pmatrix} 0.56 & 0.32 \\ 0.24 & 0.48 \end{pmatrix}, \quad (E - H)x_* = (10, 0)^T, \quad x_* = \frac{1}{19}(650, 300)^T. \quad (5.114)$$

两条独立方程确定唯一平衡点; 其总库存为 50, 每日发出总量的 20%, 恰好与补货 10 单位平衡。

为什么这个变体的偏离会消失? 两个独立方向 $(4, 3)^T$ 、 $(1, -1)^T$ 能表示任意初始偏离; 直接计算可见

$$H(4, 3)^T = 0.8(4, 3)^T, \quad H(1, -1)^T = 0.24(1, -1)^T. \quad (5.115)$$

沿两个方向的偏离每次分别缩为 0.8 倍、0.24 倍。若初始偏离为 $a(4, 3)^T + b(1, -1)^T$, 更新 k 次便为 $a(0.8)^k(4, 3)^T + b(0.24)^k(1, -1)^T$, 两项都趋于零。这只是用矩阵乘法逐次验证现象, 没有提前使用后续的判据。




图 5.8e: 存在平衡状态时, 轨迹可写为平衡状态加偏离; 本例偏离逐渐消失。

无输入时保存总库存, 有出库并补货时可能达到固定库存, 只补货时则持续积累。同样的矩阵语言帮助我们识别三种不同的工程结果, 而不是预先给所有系统贴上“最终稳定”的标签。




图 5.8f: 斐波那契数列的增长: 同一转移规则反复作用, 后续增量不断增大。

本节把“特解加齐次解”从一个向量延伸到一串记录, 把平衡问题重新落回 $(E - F)x_* = u$ 。轨迹空间的自由度来自初始条件, 平衡集合的自由度来自 $\text{Null}(E - F)$, 二者不能混为一谈。一步更新会怎样改变区域的面积、能否反向还原, 将与第 6 章的行列式联系起来; 不同方向为什么会增长、衰减或往复变化, 第 8 章将用特征空间进一步解释。下一节把时间从一次次记录改为连续流动, 继续观察同一套叠加结构。

5.9 【选读】从逐步更新到连续变化：微分方程与矢量场

选读·不做考核要求。 离散系统一步一步更新状态，连续系统则时时刻刻都在变化。这里需要一个新记号： $\dot{x}$ 表示位移的瞬时变化率，即速度； $\ddot{x}$ 表示速度的瞬时变化率，即加速度。我们只借用这些直观含义与简单的求导规则，不要求先学会求解微分方程。全部模型、参数和图示均为教学简化；本节仍围绕“齐次解构成空间，非齐次通解等于特解加齐次解”展开。

从一块会运动的质量块开始：方程为什么是这样写的？

先把系统看清楚。一个质量为 $m > 0$ 的块，通过劲度系数为 $k > 0$ 的弹簧、系数为 $c \geq 0$ 的阻尼器与固定端相连，另受外力 $f(t)$ 。设 x 从静止平衡位置量起，向右为正；忽略其他作用或认为它们已互相平衡。




图 5.9a: 弹簧、阻尼器与外力共同作用；图中取 $x > 0$ 、 $\dot{x} > 0$ 、 $f(t) > 0$ 的瞬间。

再数清三个力。弹簧恢复力为 $-kx$ ：位移向右时弹簧向左拉，位移向左时弹簧向右推，负号表示“反着位移”。黏性阻尼 (Viscous Damping) 采用最简单的线性近似 $-c\dot{x}$ ，表示油液等介质产生的阻力随速度增大、方向与速度相反；实际空气阻力或材料内摩擦不一定服从这一简化规律。外力为 $f(t)$ ，其正负号决定方向。

接着使用牛顿第二定律。合力等于质量乘加速度，所以三个力相加必须满足

$$-kx - c\dot{x} + f(t) = m\ddot{x}. \quad (5.116)$$

右边记录质量块怎样加速，左边记录造成这份加速的全部力；这一步把物理图变成方程。

把弹簧力与阻尼力移到右边，再交换等号两侧，得到标准形式

$$m\ddot{x} + c\dot{x} + kx = f(t). \quad (5.117)$$

加速度、速度、位移各只出现一次，而且没有互相相乘；这就是方程的“线性”。

最后看熟悉的特例。没有阻尼也没有外力时， $c = 0, f(t) = 0$ ，方程变成 $m\ddot{x} + kx = 0$ ，即高中熟悉的简谐振动。没有外力而 $c > 0$ 时，阻尼消耗运动中的机械能，运动趋向静

止；阻尼较大时可以不往复振动。有持续外力时，运动是否消失还要看外力，不能只凭 $c > 0$ 下结论。这便是连续时间的线性动力模型：状态不等到下一晚更新，而是随时间连续变化。

最简特例告诉我们：只记位置不够，还要记速度

同样位于 $x = 0$ ，向右运动和向左运动的质量块接下来走向不同；因此一个位置数不能完整确定运动。先取 $m = k = 1, c = 0, f(t) = 0$ ，令 $v = \dot{x}$ ，得到


$$\dot{x} = v, \quad \dot{v} = -x. \quad (5.118)$$

第一条说速度怎样推动位置，第二条说弹簧怎样改变速度；二阶方程所需的两份信息，恰好组成一个二维状态。

回到一般弹簧模型，令 $\mathbf{y} = (x, v)^T = (x, \dot{x})^T$ 。第一分量的导数就是第二分量；第二分量的导数由式(5.117)除以 m 得到。于是

$$\dot{\mathbf{y}} = \begin{pmatrix} 0 & 1 \\ -k/m & -c/m \end{pmatrix} \mathbf{y} + \begin{pmatrix} 0 \\ f(t)/m \end{pmatrix}. \quad (5.119)$$

两行分别是“位置怎样变”和“速度怎样变”，没有新添物理规律，只把原方程中的信息重新排列。



需要给定的初始信息仍是 $x(0)$ 与 $\dot{x}(0)$

图 5.9b: 二阶方程化为一阶系统：降低阶数，同时保留位置与速度两份状态。

抽象出共同形式，就得到线性微分方程组 (Linear System of Differential Equations)；本节取 A 为常矩阵、外部输入 $\mathbf{g}(t)$ 为连续函数：

$$\dot{\mathbf{y}} = A\mathbf{y} + \mathbf{g}(t). \quad (5.120)$$

$A\mathbf{y}$ 给出当前状态引起的变化率， $\mathbf{g}(t)$ 给出外部作用补上的变化率。离散系统的 $F\mathbf{x}_k$ 是下一次状态；连续系统的 $A\mathbf{y}$ 是此刻的变化率，二者保持相同的线性叠加结构，却不能当成同一种数值记录。

先看箭头, 再看运动: 矢量场怎样读?

先去掉外部输入, 考察

$$\dot{\mathbf{y}} = A\mathbf{y}. \quad (5.121)$$

在二维情形, 位置与速度等两个状态分量组成一个状态平面 (Phase Plane); 它是状态记录的平面, 不一定是物体实际所在的平面。

定义 5.26 (矢量场与轨线)

在每个状态点 $\mathbf{y}$ 处画出向量 $A\mathbf{y}$, 所得箭头图称为矢量场 (Vector Field)。箭头的指向表示状态变化的方向; 按统一比例绘制的长度表示变化率的大小。与这些箭头处处相切的运动曲线称为流线 (Streamline), 这里也是状态随时间形成的轨线。

箭头表示“此刻怎样开始变化”, 不是一次更新后的完整位移。沿轨线前进时, 要不断参考新位置处的箭头, 不能只顺着第一支箭头一直走直线。

例题 5.27 (一条平衡直线, 许多变化轨线)

取 $A = \begin{pmatrix} -1 & 0 \\ 0 & 0 \end{pmatrix}$ 。每个点的箭头为 $(-y_1, 0)^T$: 右半平面向左, 左半平面向右, 第二分量不变。

从初值 $(a, b)^T$ 出发, 函数 $(ae^{-t}, b)^T$ 的导数正好是 $(-ae^{-t}, 0)^T$, 直接代回即可验证。状态沿固定高度的水平线向纵轴靠近; 纵轴上所有箭头为零, 全部点都保持不动。

$$\text{Null}(A) = \text{Span}\{(0, 1)^T\}, \quad \text{Col}(A) = \text{Span}\{(1, 0)^T\}. \quad (5.122)$$

零空间记录“不动的状态”, 列空间记录“可能出现的变化率”; 它们仍在同一个坐标平面中, 却承担不同角色。




图 5.9c: 线性矢量场：箭头表示变化率，纵轴是平衡状态，水平线是运动轨线。

三种箭头图：向内收拢、拉开两端、绕圈运动

先看稳定结点 (Stable Node)。取 $A = \begin{pmatrix} -1 & 0 \\ 0 & -2 \end{pmatrix}$ ，两条分量关系是 $\dot{y}_1 = -y_1$ 、 $\dot{y}_2 = -2y_2$ 。从 $(a, b)^T$ 出发，直接验证可得

$$\mathbf{y}(t) = (ae^{-t}, be^{-2t})^T. \quad (5.123)$$

两个分量都向零靠近，但第二分量缩得更快，所以轨线通常是弯曲的；箭头并非都沿直线正对原点。这个矩阵描述的是两个简化状态量，不直接等于弹簧系统在“位置、速度”下的矩阵。它帮助我们看见无往复的回归方式，而非替代弹簧模型的推导。




图 5.9d: 稳定结点：两分量都趋向零，轨线通常弯曲地靠近原点。

再看鞍点 (Saddle Point)。取 $A = \begin{pmatrix} 1 & 0 \\ 0 & -1 \end{pmatrix}$ ，得到

$$\mathbf{y}(t) = (ae^t, be^{-t})^T. \quad (5.124)$$

第一分量在非零时向外增长，第二分量向零靠近。只有初值落在纵轴上，才会回到原点；

一般轨线沿横向离开。当 $ab \neq 0$ 时, $y_1 y_2 = ab$ 始终不变, 图中的弯曲轨线是双曲线。这种“一边收、一边放”的形态称为鞍点。




图 5.9e: 鞍点: 纵向收拢, 横向离开; 一般轨线为双曲线。

第三种是中心 (Center)。取 $A = \begin{pmatrix} 0 & -1 \\ 1 & 0 \end{pmatrix}$, 箭头为 $(-y_2, y_1)^T$: 正横轴上的箭头向上, 正纵轴上的箭头向左, 整个图按逆时针方向绕原点转。直接代入验证

$$\mathbf{y}(t) = (a \cos t - b \sin t, a \sin t + b \cos t)^T, \quad y_1^2 + y_2^2 = a^2 + b^2. \quad (5.125)$$

两个分量不断改变, 平方和保持不变, 所以轨线是圆。这个中心模型与无阻尼振动有相同的往复结构; 物理状态取 (x, v) 且 $m = k = 1$ 时矩阵为 $\begin{pmatrix} 0 & 1 \\ -1 & 0 \end{pmatrix}$, 绕行方向相反, 两者不能混写。取 $y_1 = x, y_2 = -v$ 就得到这里的中心模型, 平方和对应该归一化模型机械能的两倍。





图 5.9f: 中心: 状态沿圆周逆时针运动, 平方和保持不变。

三种图共同点不是“运动一定回到原点”, 而是每个箭头都由同样的矩阵乘向量

计算得到。图 5.9g 使用相同坐标范围与箭头缩放，帮助我们比较变化方式；这三类是典型例子，并未穷尽所有线性矢量场。



第 8 章将用特征空间解释不同方向上的演化模式

图 5.9g: 三种典型矢量场对照：同一种矩阵语言，可以产生不同的运动形态。

哪里不动？平衡状态是零空间，但齐次解远不止这些点

箭头为零的状态在这一刻不变；在自治齐次系统中，始终保持这个状态也是一个解。因此

$$\text{平衡状态集合} = \{\mathbf{y}_* : A\mathbf{y}_* = \mathbf{0}\} = \text{Null}(A). \quad (5.126)$$

其自由度就是 $\dim \text{Null}(A)$ ，直接回扣本章齐次代数方程的结论。前面的三个矩阵都只有原点一个平衡状态，图 5.9c 的矩阵则有整条平衡直线。

若输入是常向量 $\mathbf{g}_0$ ，平衡状态要解 $A\mathbf{y}_* = -\mathbf{g}_0$ ：先检查目标是否在列空间，有解时再用“特解加零空间”描述全部平衡状态。输入随时间改变时，不一定存在常值平衡状态。

齐次微分方程的解是函数，平衡状态只是其中的常值函数。例如稳定结点的 $\text{Null}(A)$ 只含零向量，仍有任意初值 $(a, b)^T$ 生成的运动 $\mathbf{y}(t)$ ；不能据此说“只有零解”。

为什么完整运动仍是“特解加齐次解”？

先看齐次系统。若 $\mathbf{y}_1(t), \mathbf{y}_2(t)$ 都满足 $\dot{\mathbf{y}} = A\mathbf{y}$ ，求导的线性性质给出

$$\frac{d}{dt}(a\mathbf{y}_1 + b\mathbf{y}_2) = aA\mathbf{y}_1 + bA\mathbf{y}_2 = A(a\mathbf{y}_1 + b\mathbf{y}_2). \quad (5.127)$$

线性组合还是解，零函数也是解，所以齐次解函数组成一个向量空间；这与代数方程的解空间、离散递推的解序列空间完全平行。

再看同一输入 $\mathbf{g}(t)$ 下的两条解。设 $\mathbf{y}_p(t)$ 为一个特解，任意另一解为 $\mathbf{y}(t)$ ，逐项相减：

$$\frac{d}{dt}(\mathbf{y} - \mathbf{y}_p) = (A\mathbf{y} + \mathbf{g}) - (A\mathbf{y}_p + \mathbf{g}) = A(\mathbf{y} - \mathbf{y}_p). \quad (5.128)$$

外部输入消掉了, 差函数满足齐次系统。这正是第 5.2 节“两个非齐次解之差是齐次解”的同一个证明。

反过来, 若 y_h 是任意齐次解, 便有

$$\frac{d}{dt}(y_p + y_h) = Ay_p + g + Ay_h = A(y_p + y_h) + g. \quad (5.129)$$

所以相加确实得到原系统的解, 而且前面的相减证明保证没有遗漏任何解。于是

$$y(t) = y_p(t) + y_h(t). \quad (5.130)$$

完整运动等于一条特解运动, 加上任意齐次运动; 这里相加的是每个时刻的状态, 不是把两条轨线的形状直接拼接。

对常系数一阶系统, 在上述连续输入条件下, 给定初值 $y(0)$ 后解存在且唯一, 这是微分方程课程中的基本事实, 本节不展开其一般证明。因而不固定初值时, n 维状态系统的齐次解空间有 n 个独立初值参数; 固定初值后, 运动唯一。对于二阶弹簧方程, 这两份参数就是初始位置与初始速度。**运动的自由度来自初值, 平衡集合的自由度才是 $\dim \text{Null}(A)$ 。**不能把代数方程 $Ax = 0$ 的基础解系直接当作动态方程的全部解函数。

回到弹簧: 外力的持续作用, 怎样与初始偏移叠加?

取 $m = 1, c = 2, k = 2$, 外力 $f(t) = \cos t$; 时间与各量均已按教学单位归一化。原方程为

$$\ddot{x} + 2\dot{x} + 2x = \cos t. \quad (5.131)$$

不推导通用求解方法, 只给出可代回检查的运动, 让叠加结构落到具体数值上。

先取一条周期特解 $x_p(t) = (\cos t + 2 \sin t)/5$ 。它满足 $\ddot{x}_p = -x_p$, 所以

$$\ddot{x}_p + 2\dot{x}_p + 2x_p = x_p + 2\dot{x}_p = \frac{\cos t + 2 \sin t + 2(-\sin t + 2 \cos t)}{5} = \cos t. \quad (5.132)$$

代回后恰好得到外力, 证明它确实是一条特解。它持续按外力的周期运动, 称为本例的稳态响应 (Steady-State Response); “稳态”不表示静止, 而表示这里持续存在的周期响应。

再看齐次部分。令 $q = a \cos t + b \sin t$, 则 $\ddot{q} = -q$; 对 $x_h = e^{-t}q$ 连续求两次导数, 有


$$\dot{x}_h = e^{-t}(\dot{q} - q), \quad \ddot{x}_h = e^{-t}(\ddot{q} - 2\dot{q} + q), \quad \ddot{x}_h + 2\dot{x}_h + 2x_h = e^{-t}(\ddot{q} + q) = 0. \quad (5.133)$$

这说明 $e^{-t} \cos t$ 与 $e^{-t} \sin t$ 都是齐次解。若两者的一组线性组合恒为零, 取 $t = 0$ 得 $a = 0$, 再取 $t = \pi/2$ 得 $b = 0$, 故它们线性无关。初始位置、初始速度各提供一个独立条件, 两个解函数因此足以表示全部齐次运动。

按叠加结论，完整运动为

$$x(t) = \frac{\cos t + 2 \sin t}{5} + e^{-t}(a \cos t + b \sin t). \quad (5.134)$$

第一项记录外力持续推动的周期运动，第二项记录初始状态与这条特解之间的偏离；在本例中它随 e^{-t} 衰减，因而是暂态响应。若给定 $x(0) = x_0$ 、 $\dot{x}(0) = v_0$ ，则 $a = x_0 - 1/5$ 、 $b = v_0 - 2/5 + a$ ，两个参数也被唯一确定。



状态平面：绿线趋近蓝色周期轨线

取 $a = 1, b = 0$ ，即 $x(0) = 1.2, v(0) = -0.6$

图 5.9h: 本例完整运动等于周期特解加衰减的齐次偏离；两图展示同一条运动。

这个结论有明确的使用条件：本例有正阻尼、正恢复系数，输入为周期外力，所选齐次运动确实衰减。一般的 $g(t)$ 可能不周期，任意特解也不自动成为“稳态”；不应把本例的最终行为套到所有非齐次系统上。但“特解加齐次解”在相同输入下始终成立。

从向量到序列，再到函数，改变的是解的对象，保持的是“特解加齐次解”的结构。动态运动的自由度看初值，不动的平衡集合看零空间。第 6 章将用行列式描述有限时间映射对面积、体积的改变；第 8 章将用特征空间解释回归、离开与绕行。这里先从箭头图看见运动，再代回方程验证，不提前计算迹、散度或稳定性判据。

5.10 【应用案例】 抖音推荐系统：从组合权重到解的结构

推荐系统常常需要调整内容曝光权重，但又不能改变用户的观看体验。这件事在数学上为什么可能？调整的边界又在哪里？第二章已经替用户反求过一组视频权重，第三章又介绍了双塔召回与 ALS 训练。现在回到这组视频，我们不再追问“怎样算出一个答案”，而是追问“保持同一目标，还能怎样调整”。本节把观看体验简化为四项合成特征；这些特征相同，不意味着实际视频质量、观看顺序与用户感受也完全相同。

先找到一份基准，再看它怎样调整

在教学模型中，按“搞笑、科技、美食、游戏”排列特征。视频 1 兼有搞笑与美食，视频 2 兼有科技与游戏，视频 3 是前两种风格的等权混合。三条视频和原来的用户偏好保持不变：

$$A = (\alpha_1 \ \alpha_2 \ \alpha_3) = \begin{bmatrix} 1 & 0 & \frac{1}{2} \\ 0 & 1 & \frac{1}{2} \\ 1 & 0 & \frac{1}{2} \\ 0 & 1 & \frac{1}{2} \end{bmatrix}, \quad b_0 = \begin{bmatrix} 0.35 \\ 0.65 \\ 0.35 \\ 0.65 \end{bmatrix}. \quad (5.135)$$

把 35% 的权重给视频 1、65% 给视频 2，就得到一份满足偏好的**基准内容配方**。它就是方程 $Ax = b_0$ 的一个**特解**，不是平台唯一可用的方案。

如果视频 3 现在也需要分配曝光，可以给它 40% 的权重，并把视频 1、2 各削减 20 个百分点。新配方是 15%、45%、40%。由于混合视频的一半来自风格 1、另一半来自风格 2，两处削减恰好被它补回，最终四项合成特征仍是原来的 0.35、0.65、0.35、0.65。图 5.10a 先把这件事画出来，再用数学概括它。




图 5.10a: 权重置换不改变本模型的合成口味。左、右两栏采用相同的权重条比例，视频 3 增加 40 个百分点，视频 1、2 各减少 20 个百分点。下方口味记录相同，但视频组合不同；这正是齐次解作为权重调整方案的作用。

第二章求出的通解，现在可以直接读成“基准配方加置换方案”：

$$\mathbf{x} = \mathbf{x}_p + t\mathbf{z}, \quad \mathbf{x}_p = (0.35, 0.65, 0)^T, \quad \mathbf{z} = (-\frac{1}{2}, -\frac{1}{2}, 1)^T. \quad (5.136)$$

其中 $t\mathbf{z}$ 是**齐次解**：视频 3 每增加 t ，视频 1、2 各减少 $t/2$ ，这部分调整被 A 送到零，不改变已有输出。**零空间**就是所有这样的置换方案组成的空间；它装的是权重变化量，而不是某一份完整配方。一般地，全部配方为 $\mathbf{x}_p + \text{Null}(A)$ 。若曝光权重必须非负且总和为 1，本例只能取 $0 \leq t \leq 0.7$ ；负的变化量可以表示削减，最终权重却不能随意变成负数。

内容有多少独立风格，就留下多少调整自由

参与组合的是三条视频，但视频 3 没有增加独立风格。因此 $r(A) = 2$ ，而 $\dim \text{Null}(A) = 1$ ：平台只有一个独立的置换方向，选定视频 3 的权重，另外两个权重就随之确定。秩-零度定理在这里有一份直接的业务读法：

$$\underbrace{r(A)}_{\text{独立风格数}} + \underbrace{\dim \text{Null}(A)}_{\text{权重调整自由度}} = \underbrace{n}_{\text{参与组合的内容数}}. \quad (5.137)$$

本例就是 $2 + 1 = 3$ 。“独立风格”指选定特征表示下的独立方向，不是标签数量，也不是视频质量。再加入一条能由旧视频组合出来的内容，可能增加配方选择，却不会扩大口味覆盖；加入新的独立内容方向，才可能把原先满足不了的需求纳入范围。

这也是无穷多解的工程价值：平台可以在同一合成目标下考虑内容供给、作者曝光和重复观看等因素。零空间指出允许调整的方向，非负权重、容量与质量要求进一步限定可执行的部分。它提供**内部调整自由度**，但不代替真实业务中的评价和约束。

调权重有边界：当前内容池能满足哪些口味？

这三条视频无论怎样组合，输出都具有 $(s, q, s, q)^T$ 的形式：搞笑与美食绑定，科技与游戏绑定。**列空间**就是当前内容池能组合出的全部口味范围，位于四维特征空间；数学上允许任意实数权重时，它是

$$\text{Col}(A) = \{(s, q, s, q)^T : s, q \in \mathbb{R}\}. \quad (5.138)$$

实际推荐若采用非负且总和为 1 的配方，可满足的范围还会缩小为这两种基础风格之间的混合区间。落在列空间内是可表示的必要前提，并不自动保证满足全部业务限制；原偏好 $\mathbf{b}_0$ 则确实有前面的可执行配方。

如果用户希望更搞笑、少美食，给出新偏好 $\mathbf{b} = (0.6, 0.6, 0.1, 0.7)^T$ ，现有组合就无法精确满足。这不是消元不够熟练，而是内容表示把需要分开的特征绑在了一起。**左零空间**在业务上负责检查这些绑定约束：本例的两个检查方向分别是 $(1, 0, -1, 0)^T$ 与

$(0, 1, 0, -1)^T$, 检查“搞笑减美食”“科技减游戏”是否为零。目标在左零空间上留有非零分量, 便伸出了当前内容池的能力边界。




图 5.10b: 当前内容池的口味覆盖与范围外的新需求。淡蓝平面是列空间的一部分示意, 绿色点代表能够满足的原偏好, 红色点代表超出范围的新偏好。图是一张覆盖范围示意图, 不把四维特征画成二维坐标; 非负权重等业务约束还会进一步缩小可执行范围。

这时平台面对的是选择: 补充能够单独体现搞笑的内容, 解除第一处绑定; 若还要区分科技与游戏, 也需相应的独立方向。另一条路线是先给出近似配方。沿用第 5.7 节的最小二乘标准, 本例最近的可达口味仍是 $\hat{b} = b_0$, 剩余误差平方和为 0.13; 残差 $e = b - \hat{b}$ 属于左零空间, 满足 $A^T e = 0$ 。这份残差在提醒平台: 当前表示还有哪些需求没有满足。最优输出唯一, 但生成它的权重仍可加上零空间中的置换方案; 近似不会自动消除内容冗余。

把输入的调节空间, 与输出的能力边界放在一起

四个基本子空间不是四份互不相关的名词。输入端记录三条视频的权重, 输出端记录四项合成特征, 它们分别回答“还能怎样调”和“能够满足什么”。行空间位于权重侧, 是配方中真正决定口味的有效分量; 零空间则是输出看不见的调整分量。任意配方都能唯一拆成 $x = x_R + x_N$, 而 $Ax = Ax_R$ 。所以, 两份配方的差若在零空间中, 合成口味便相同。

输出端也分为两部分: 列空间是能够达到的口味范围, 左零空间指出无法独立满足的需求方向。两端各自正交互补: 若有 m 项特征、 n 条参与组合的视频, 记 $r = r(A)$, 权重侧有 r 个有效方向、 $n - r$ 个调整方向; 口味侧有 r 个可达方向、 $m - r$ 个不可达方向。本例对应 $2 + 1 = 3$ 与 $2 + 2 = 4$ 。图 5.10c 把它们翻译成同一张业务框图: 有效权重分量一一对应可达口味, 内部置换被送到零, 范围外的需求不会由旧权重凭空生成。




图 5.10c: 推荐系统的调节空间与能力边界。左框是三维权重空间，右框是四维特征空间，蓝、绿、红、金四块分别对应行空间、零空间、列空间、左零空间。上方箭头表示有效权重与可达口味一一对应，虚线箭头表示内部置换不产生输出；两端的正交符号表示各自的互补分工。

当目标能够满足时，行空间里恰好有一份基准解：它没有多余的零空间分量。其他解都是在它上面加置换方案。因此，唯一解意味着权重侧没有这种调整自由；无穷多解意味着同一口味还有多种配方；无解意味着目标超出了列空间。业务决策由此分清了三件事：先判断能否覆盖，再辨认能否调节，最后在可执行方案中作选择。行空间中的唯一解是结构参照，不自动代表最合适的实际曝光方案。

真实算法也在处理类似的分工，但任务和变量更复杂。抖音公开资料中的双塔分别学习用户与内容向量，服务于召回；本节的曝光配方只是抽取向量表示思想的教学模型。[8]Hu 等人的隐式反馈 ALS 把行为证据转成不同置信权重，Spark 以带正则化的最小二乘更新隐因子：它在反馈不完整时拟合需求，固定其他因子且正则化系数为正时，一次更新有唯一结果，但这不等于整个训练结果唯一。Netflix 相关工作同样在已观测记录上拟合，并不把缺失评分当零分。[15, 17, 18]

零空间还提供了一种表示学习思路。AlphaFuse 把语言表示中丰富语义与弱语义方向分开，在后者学习 ID 嵌入以加入协同信号。[16] 这与本节“保留指定输出，利用看不见的自由度”相呼应，不过它使用的是语义表示的零空间或近似零方向，不是这里的曝光权重零空间。冷启动 (Cold Start) 主要是行为证据不足，也不能简单等同于用户偏好跑出列空间。

本节所有视频特征、权重及配方规则均为教学简化，不代表抖音线上算法。从特解到齐次解，我们看见一份基准怎样容纳调整；从零空间到列空间，我们又看见调整与覆盖各自的边界。理解解的结构，便不只会算出一组权重，还能判断现有内容池允许怎样调节、哪些需求必须靠补充独立内容或改进表示来满足。列空间决定目标能否到达，零空间决定到达同一目标的全部自由度。

本章小结

本章把第二章的求解过程整理成对全部解的认识。消元给出主元和自由变量，每个自由变量对应一个独立的解方向。这些方向构成**基础解系**，也就是零空间的一组基。若 A 为 $m \times n$ 矩阵、秩为 r ，则

$$\dim \text{Null}(A) = n - r.$$

这既是自由变量的个数，也是齐次解空间的维数；零空间只有零向量时，齐次方程只有零解。

非齐次方程 $Ax = b$ 有解，当且仅当 $b \in \text{Col}(A)$ 。有解时，任选一个特解 x_p ，全部解为

$$x_p + \text{Null}(A).$$

因此，解集的位置由特解决定，方向与自由度由零空间决定： $r = n$ 时解唯一， $r < n$ 时有无穷多解。目标在列空间外时，原方程组无解。

对系数矩阵与右端项同步作可逆行变换，解集不变；系数矩阵的零空间与行空间也不变，列空间的位置却可能改变。求零空间与行空间的基可以借助行最简形；求列空间的基，则应按主元位置回到原矩阵取列。

四个基本子空间把矩阵的两端联系起来：输入端的行空间与零空间、输出端的列空间与左零空间，分别正交，并以直和组成各自的环境空间。 A 把行空间一一映到列空间；同一输出的其他输入，都由零空间中的自由变化补出。于是，**列空间决定目标能否到达，零空间决定到达同一目标的全部自由度**。

目标不可达时，这套结构仍然适用。正交直和给出唯一的最近输出 $\hat{b}$ ，正规方程再求它的全部原像：

$$A^T A \hat{x} = A^T b, \quad \text{全部最小二乘解为 } \hat{x}_p + \text{Null}(A).$$

最优输出总是唯一，输入是否唯一仍由零空间决定。最小二乘解因而是解的结构在无解情形下的延伸。

电网案例让目标、循环自由度与共同约束有了具体含义；选读的递推和微分方程则把线性结构带到时间中。静态方程求向量，递推求向量序列，微分方程求函数，不能只凭形式相似就混用它们的解。下一章将从体积变化出发，用行列式进一步理解线性相关与可逆性。

第 6 章

行列式: 从体积到可逆性

6.0 结构之后: 度量变换的缩放因子

走到这里, 我们已经能从一张数表里辨认出许多东西。第一章教我们看独立方向、张成空间与基; 第二章把方程组读成列向量的线性表示; 第三章让矩阵成为映射的代数语言; 第四章区分向量的变化与描述方式的变化; 第五章则把一次求解扩展为对全部解、不可达目标与近似解的认识。连同第 0 章的向量直观, 这些知识已经搭起一副可以承载复杂问题的骨架。

这副骨架还留下了一个很具体的问题: 矩阵作用以后, 一块空间变大了多少, 还是被压得不再有体积? 秩告诉我们保留了几个独立方向, 却没有告诉我们这些方向围出的区域有多大。两个矩阵都可能满秩, 一个让区域放大十倍, 另一个让它缩小到原来的十分之一。结构相同, 尺度却很不同。




图 6.0.1: 已有知识汇到一个新问题: 方向与解的结构已经看清, 现在还要量一量空间怎样缩放。

人面对混沌, 往往先需要辨认关系, 再需要知道变化的分量。数学不能替我们消除所有不确定, 却能让一个笼统的担心成为可以回答的问题: 方向是否还在, 信息是否还能恢复, 范围到底扩大了多少? 本章继续做这样的工作。先看见一块区域的变化, 再理解变化背后的结构, 最后才把它压缩成一个可计算的数。

先让矩阵作用于一块区域

一支箭头的像我们会算, 那么一整个正方形的像怎样得到? 把正方形内每一个点的坐标向量都送入同一个矩阵, 所得的点共同构成它的像。在线性变换下, 原点不动, 平行边仍然平行; 单位正方形的两条邻边 e_1, e_2 , 变成矩阵的两列。因此, 像通常是一个平行四边形, 也可能退化成线段或一个点。

先取一个可以直接画出的教学矩阵:

$$A = \begin{pmatrix} 2 & 1 \\ 0 & 1 \end{pmatrix}, \quad Ae_1 = \begin{pmatrix} 2 \\ 0 \end{pmatrix}, \quad Ae_2 = \begin{pmatrix} 1 \\ 1 \end{pmatrix}. \quad (6.1)$$

第一条边加长到 2, 第二条边向右倾斜; 四个顶点的像分别是 $(0,0)$ 、 $(2,0)$ 、 $(3,1)$ 、 $(1,1)$ 。新图形的底为 2、高为 1, 面积是 2, 恰好是原面积的两倍。




图 6.0.2: 左边面积为 1; 右边由两列围出, 底为 2、高为 1, 所以面积缩放倍数 $k = 2$ 。一般的像也可能被压成线段, 此时 $k = 0$ 。

三维里, 问题只是把“面积”换成“体积”。单位立方体的三条邻边被送到矩阵的三列, 得到一个平行六面体。若第三个独立方向消失, 立方体就被压到一个平面上。这个平面上的图形仍可能有面积, 但它的三维体积已经为 0; 不要把“没有三维体积”误读成“什么都没有留下”。

例如取

$$B = \begin{pmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 0 \end{pmatrix}, \quad B \begin{pmatrix} s \\ t \\ h \end{pmatrix} = \begin{pmatrix} s \\ t \\ 0 \end{pmatrix}. \quad (6.2)$$

这是向 xy 平面的正交投影。高度 h 不再出现在输出中: 同一竖线上所有点, 都变成同一个点。




图 6.0.3: 立方体被压到平面上。右边的正方形仍有面积，三维体积却为 0；不同高度产生相同输出，丢失的是竖直方向的信息。

我们要度量的究竟是什么？是所有方向共同围出的量，不是任意一条边的长度。沿三个坐标方向分别放大 2、1、1 倍，单位体积变为 2；旋转改变朝向，却不改变体积；向一个平面投影，则让三维体积归零。矩阵的元素可能看起来很不同，这三个效果却都能用一个体积缩放倍数表达。




图 6.0.4: 灰色虚线是原单位立方体，蓝色实线是像。缩放把体积变为 2，旋转仍为 1，投影变为 0；这里比较的是三维体积。

体积为 0，把前三种判断连在一起

什么时候会围不出体积？先统一讨论范围：以下关联都针对实 $n \times n$ 方阵 A ，以及 $\mathbb{R}^n$ 中的 n 维体积。若把长方形矩阵也不加区别地塞进这些结论，“可逆”“唯一解”和“体积”就可能说的不是同一件事。

把 A 的列写成 $\mathbf{a}_1, \dots, \mathbf{a}_n$ 。单位区域的像为

$$\mathcal{P}_A = \{t_1 \mathbf{a}_1 + \dots + t_n \mathbf{a}_n : 0 \leq t_j \leq 1\}. \quad (6.3)$$

这就是说，让每条列向量分别取 0 到 1 倍，所有组合恰好填出一块平行多面体 (Parallelotope)。二维时它是平行四边形，三维时是平行六面体。

若列向量相关，它们只能张成一个维数小于 n 的子空间， $\mathcal{P}_A$ 也被限制在其中，因而没有 n 维体积。若列向量无关，则它们构成 $\mathbb{R}^n$ 的一组基，围出的区域没有塌缩，体

积为正。于是，第一个联系是

$$\text{Vol}_n(\mathcal{P}_A) = 0 \iff r(A) < n \iff A \text{ 的列线性相关.} \quad (6.4)$$

体积归零与秩不足，是同一次降维的两种读法。图中观察到的塌缩，将在本章与行列式的代数性质严格对接。




图 6.0.5: 左边三个不共面的方向围出非零体积；右边第三个向量留在前两个张成的平面内，围不出三维体积。共面图形仍可能有非零面积。

那“信息丢失”具体丢在哪里？不是一个含糊的比喻。若 $r(A) < n$ ，秩-零度定理给出 $\dim \text{Null}(A) = n - r(A) > 0$ ，所以可以找到非零向量 z ，满足 $Az = 0$ 。于是

$$A(x + z) = Ax, \quad z \neq 0. \quad (6.5)$$

两个不同输入得到相同输出。只凭输出，我们不能判断原输入是哪一个，也就不存在能恢复所有输入的逆映射。反过来，满秩方阵的零空间只有零向量，不会发生这种混淆，前几章已经证明它可逆。第二个联系因此是

$$\text{Vol}_n(\mathcal{P}_A) = 0 \iff \text{Null}(A) \neq \{0\} \iff A \text{ 不可逆.} \quad (6.6)$$

所谓丢失信息，正是零空间中的变化无法从输出中辨认。恢复不了整个空间，不妨碍我们在一个合适的受限子空间上恢复；这里讨论的是整个 $\mathbb{R}^n$ 上的可逆性。

可逆：可以逐点恢复

不可逆：高度被忘记




图 6.0.6: 左边可把每个点送回原处；右边不同高度都落到同一位置，输出无法告诉我们该恢复哪个高度。可逆性讨论的是点的对应，不能只比较外轮廓。

回到方程组：体积怎样回答有解与唯一？

一块区域塌缩了，对求解 $Ax = b$ 意味着什么？第五章已经把答案分成两部分：列空间决定目标是否可达，零空间决定到达同一目标的自由度。现在，体积让我们一眼看见这两部分为何同时发生变化。

若 $r(A) = n$ ，列空间就是整个 $\mathbb{R}^n$ ，所有目标都可达；零空间又只有零向量，每个目标只有一个原像。若 $r(A) < n$ ，目标在列空间外时无解，在列空间内时有解，但非零零空间向量会带来无穷多个解。这两个条件必须分别检查，**体积为 0 本身不能告诉我们某个具体目标到底无解，还是有无穷多解。**




图 6.0.7: 满秩时，每个目标都有唯一解；秩不足时，还要看红色目标是否在蓝色列空间中。中图可达而不唯一，右图不可达。这三幅图均在输出空间中。


记住这个数之后，本章会把三重联系整理成同一套判定。它们不是互不相干的口诀：满秩是独立方向的说法，非零体积是几何的说法，可逆与唯一解是映射及方程组的说法。我们正在从不同侧面认识同一个结构。

最后计算：底乘高为什么给出 $ad - bc$ ？

既然先看图，我们是否能从图里读出一个公式？取矩阵的两列

$$A = \begin{pmatrix} a & c \\ b & d \end{pmatrix}, \quad u = \begin{pmatrix} a \\ b \end{pmatrix}, \quad v = \begin{pmatrix} c \\ d \end{pmatrix}. \quad (6.7)$$

它们分别是单位正方形两条邻边的像。我们不数乘积项，先以 u 为底，把 v 沿底边方向的偏移与垂直方向的高度分开。沿底边滑动不会改变面积，真正参与“底乘高”的，是垂直方向留下的长度。



底长 $\|u\|$
 高 $h = |v \cdot n|$
 n 是垂直于底边的单位向量
 面积 $= \|u\|h$

图 6.0.8: 把 v 分成沿底边的偏移和垂直高度。虚线垂足把高度画出来; 沿底边的偏移可以改变倾斜程度, 却不改变底乘高。本图底为 2、高为 1, 面积为 2。

假设 $u \neq 0$, 把它逆时针转过 90° 再除以长度, 得到

$$n = \frac{1}{\sqrt{a^2 + b^2}} \begin{pmatrix} -b \\ a \end{pmatrix}, \quad u \cdot n = 0, \quad \|n\| = 1. \quad (6.8)$$

这支单位箭头垂直于底边, 点积 $v \cdot n$ 给出带正负的高度; 取绝对值才是通常的高度。第 0 章的点积已经足够完成这一步。

$$h = |v \cdot n| = \frac{|ad - bc|}{\sqrt{a^2 + b^2}}, \quad (6.9)$$

$$\text{面积} = \|u\|h = \sqrt{a^2 + b^2} \frac{|ad - bc|}{\sqrt{a^2 + b^2}} = |ad - bc|. \quad (6.10)$$

底长与分母抵消, 留下的就是 $|ad - bc|$ 。若 $u = 0$, 图形直接退化为线段或点, 面积仍为 0, $ad - bc$ 也为 0, 不必使用上面含分母的计算。[2]

这里终于遇见行列式 (Determinant): 二维中记作 $\det A = ad - bc$ 。通常面积的缩放倍数是 $|\det A|$, 行列式本身还保留了方向的正负。交换两条有序边, 或者作一次镜面反射, 可能保留面积大小, 却颠倒方向; 正负号记录的正是这一区别。




图 6.0.9: 两边面积都为 1。左边两条有序基边保持原方向, 右边关于 x 轴反射后方向翻转; 行列式分别是 $+1$ 和 -1 , 面积倍数都为 1。

三维及更高维, 也有一个带符号的数记录这种整体缩放。这里先用单位区域的像把它看见:

$$k(A) = \text{Vol}_n(\mathcal{P}_A) = |\det A|. \quad (6.11)$$

原单位区域的体积是 1，所以像的体积就是体积缩放倍数 (Volume Scale Factor)。本章后面将给出一般行列式的严谨定义与计算规则，并说明为什么同一个线性变换对其他具有体积的区域也给出同样的倍数；此处不把高维图形假装成一张能看全的三维图。

于是，前面三重联系可以收拢为

$$\det A \neq 0 \iff r(A) = n \iff A \text{ 可逆} \quad (6.12)$$

$$\iff \text{对每个 } \mathbf{b}, A\mathbf{x} = \mathbf{b} \text{ 有唯一解};$$

$$\det A = 0 \iff r(A) < n \iff A \text{ 不可逆}. \quad (6.13)$$

第二行还要接上目标的位置： $\mathbf{b} \notin \text{Col}(A)$ 时无解， $\mathbf{b} \in \text{Col}(A)$ 时有无穷多解。特别是齐次方程总有零解，所以行列式为 0 时，齐次方程属于后者。这就把第六章的新度量，牢牢接回第五章的解的结构。

公式应当照亮图景，而不是遮住它

为什么不从排列、逆序数与一长串乘积开始？这些工具有自己的价值，能够给出适用于任意阶方阵的严格公式。但如果把它们放在动机之前，让学生先背符号、后猜用途，行列式就容易变成一个“逆序数算术怪物”：算出了数，却不知道它究竟量了什么。**这样的教学次序值得纠正**。几何不是算完以后附送的插图，它是我们提出这个概念的理由之一；代数定义则让这份直观能够经受证明，并推广到眼睛看不见的维数。

这也解释了它为什么会进入现代工程。图形处理中，把一块纹理区域线性拉伸成新的区域，需要知道覆盖面积的倍数；在本节的 A 下，这个倍数就是 2。把三维状态只保留平面分量，得到简化表示的同时也丢掉高度，原始状态无法从这个输出唯一恢复。在第五章的离散系统教学模型中，一步状态更新若由 $n \times n$ 矩阵给出，单位状态区域下一步的 n 维体积就变为 $|\det A|$ 。这些都是线性模型中的几何判断，不把真实系统中的非线性、误差与额外约束抹去。

还应记住一个界限：整体体积不变，不表示每个方向都不变。例如 $\text{diag}(2, \frac{1}{2})$ 把一个方向拉长、另一个方向压短，面积仍为 1。仅凭一个行列式，不能看清全部形状，也不能判断动态系统的全部长期行为。**秩数出方向，行列式度量整体缩放；二者各有任务，不能互相替代。**

回望前五章，我们并不是又添了一项孤立的计算。原来用基辨认的方向、用矩阵描述的作用、用零空间解释的丢失、用解集刻画自由，如今在一块区域的体积中相遇。秩让我们知道结构是否还完整，行列式让我们知道这副结构经过变换后有多大、方向是否翻转。面对复杂世界，理性所能给予的温柔，是把变化说清楚，把条件留完整，让我们在不确定中仍有一件可以认真辨认、计算和核验的事。带着这幅图景，再进入行列式的定义与运算法则，符号便有了来处。

6.1 几何直观与公理化定义：面积、体积与交错多重线性映射

章首已经看见，矩阵既能拉伸一块区域，也能把它压成没有面积或体积的图形。现在要问：能否用同一种规则记录这些变化，既保留大小，也保留方向？我们先在二维、三维中找出这条规则，再把它写成不依赖图形的公理。**低维几何帮助我们提出定义，代数公理帮助我们带任意维数。**

本章只对方阵讨论行列式。为避免与后面的代数余子式混淆，约定矩阵 $A = (a_{ij})$ 的元素用小写 a_{ij} 表示，大写 A_{ij} 专门留给代数余子式；单位矩阵仍记作 E_n 。讨论一行的几何方向时，把该行的分量写成坐标向量 $\mathbf{r}_i = (a_{i1}, \dots, a_{in})^T$ 。把向量横排为一行或竖排为一列，只是记录方式不同。

二维：平行四边形面积与正交补向量

把两个平面向量 $\mathbf{u} = (a, b)^T$ 、 $\mathbf{v} = (c, d)^T$ 放在同一个起点，便围出一个平行四边形。通常面积只问“有多大”；若还要记录这两条边的先后次序，就需要有向面积 (Oriented Area)：从 $\mathbf{u}$ 转向 $\mathbf{v}$ ，逆时针的情形取正，顺时针的情形取负；共线时面积为 0。这里判断的是两支箭头之间不超过 180° 的转向，不把绕一整圈的额外转动算进去。




图 6.1: 有序的两条边围出有向面积。绿色箭头由第一条边逆时针转过 90° 得到；第二条边在该方向上的带符号高度，决定面积的正负。

怎样把“底乘高”变成坐标运算？先给底边找一支垂直箭头。标准基中的 $\mathbf{e}_1$ 逆时针转过 90° 变为 $\mathbf{e}_2$ ， $\mathbf{e}_2$ 变为 $-\mathbf{e}_1$ ；所以 $a\mathbf{e}_1 + b\mathbf{e}_2$ 变为 $-\mathbf{b}\mathbf{e}_1 + a\mathbf{e}_2$ 。由此得到

$$\mathbf{u}^\perp = \begin{pmatrix} -b \\ a \end{pmatrix}, \quad \mathbf{u} \cdot \mathbf{u}^\perp = -ab + ba = 0, \quad |\mathbf{u}^\perp| = |\mathbf{u}|. \quad (6.14)$$

这是一支按方向约定选出的正交补向量 (Orthogonal Complement Vector)。在二维中，这种从一支箭头生成垂直箭头的操作也可看作二维广义叉乘 (Two-Dimensional Generalized Cross Product)；它只有一个向量输入，要与下一段的三维双向量叉乘区别开。

若 $\mathbf{u} \neq \mathbf{0}$, $\mathbf{u}^\perp/|\mathbf{u}|$ 是垂直于底边的单位向量。由第 0 章的点积公式, $\mathbf{v} \cdot \mathbf{u}^\perp/|\mathbf{u}|$ 就是带符号的高度。乘回底长, 得到

$$S(\mathbf{u}, \mathbf{v}) = \mathbf{v} \cdot \mathbf{u}^\perp = -bc + ad = ad - bc. \quad (6.15)$$

因此, 有向面积是一个数; 通常面积为 $|ad - bc|$ 。若底边为零, 两者也都为 0。把 $\mathbf{u}, \mathbf{v}$ 按行排成 A , 这就是二阶行列式的几何来源。

例题 6.1 (用垂直向量读出面积)

取 $\mathbf{u} = (2, 1)^\mathrm{T}$ 、 $\mathbf{v} = (1, 3)^\mathrm{T}$ 。则

$$\mathbf{u}^\perp = (-1, 2)^\mathrm{T}, \quad S = \mathbf{v} \cdot \mathbf{u}^\perp = -1 + 6 = 5. \quad (6.16)$$

两条边按此顺序围出正向面积 5; 交换它们后得到 -5, 通常面积仍为 5。

这里已经出现一条值得保留的思路: 用其余的边确定一个垂直方向, 再与剩下的一条边作点积, 读出面积或体积。三维中它将成为叉乘与混合积, 高维中它将成为代数余子式向量。

三维: 平行六面体、叉乘与混合积

两条边围出一个底面, 第三条边把底面推到另一位置, 形成平行六面体。底面积仍然容易看见; 困难在于第三条边通常是斜的, 不能直接它的长度当作高。我们需要一支垂直于底面的箭头, 用它读出第三条边的带符号高度。

定义 6.2 (叉乘的几何定义)

两个不共线的三维向量 $\mathbf{u}, \mathbf{v}$ 的叉乘 (Cross Product), 记作 $\mathbf{u} \times \mathbf{v}$, 是垂直于二者所张平面的向量。其长度为底面平行四边形的面积, 即

$$|\mathbf{u} \times \mathbf{v}| = |\mathbf{u}||\mathbf{v}|\sin\theta, \quad 0 \leq \theta \leq \pi. \quad (6.17)$$

方向按右手法则确定: 四指从 $\mathbf{u}$ 转向 $\mathbf{v}$, 拇指指向叉乘方向。若二者共线, 规定叉乘为零向量。

当底面不退化时, 这支箭头是底面的法向量 (Normal Vector), 长度又恰好等于底面积, 所以不必另外保存这两份信息。交换两条底边, 四指的转向颠倒, 叉乘也反向。设 $\mathbf{w}$ 是第三条边, 就有

$$V(\mathbf{u}, \mathbf{v}, \mathbf{w}) = \mathbf{w} \cdot (\mathbf{u} \times \mathbf{v}). \quad (6.18)$$

这个点积称为混合积 (Scalar Triple Product), 给出有向体积 (Oriented Volume); 取绝

对值才是通常体积。第三条边指向法向量同一侧时为正，指向另一侧时为负，落在底面内时为 0。




图 6.2: 叉乘把底面积与法向方向合在一支箭头中。第三条边与它的点积给出有向体积；灰色虚线表示底面与平行边。图中三条边采用正向次序。

坐标公式也能从面积读出。叉乘在各坐标轴上的分量，分别是底面在相应坐标平面上的有向面积；沿 x, y, z 轴观察，依次采用 (y, z) 、 (z, x) 、 (x, y) 的正向次序。因此

$$\mathbf{u} \times \mathbf{v} = \begin{pmatrix} u_2 v_3 - u_3 v_2 \\ u_3 v_1 - u_1 v_3 \\ u_1 v_2 - u_2 v_1 \end{pmatrix}. \quad (6.19)$$

每个分量都是上一段的二阶有向面积。中间分量采用 (z, x) 次序，符号不能凭记忆随意更改。

由几何定义，叉乘与 $\mathbf{u}, \mathbf{v}$ 都正交；坐标上也能核对。例如

$$\mathbf{u} \cdot (\mathbf{u} \times \mathbf{v}) = u_1 u_2 v_3 - u_1 u_3 v_2 + u_2 u_3 v_1 - u_2 u_1 v_3 + u_3 u_1 v_2 - u_3 u_2 v_1 = 0. \quad (6.20)$$

各项成对抵消；换成 $\mathbf{v}$ 同样得到 0。再把第三条边代入，混合积成为

$$V = u_1 v_2 w_3 + u_2 v_3 w_1 + u_3 v_1 w_2 \quad (6.21)$$

$$- u_1 v_3 w_2 - u_2 v_1 w_3 - u_3 v_2 w_1. \quad (6.22)$$

这就是把三条边按行排列后，三阶行列式的六项表达式。循环改变三条边的次序，要作两次交换，方向回到原来的方向，所以

$$\mathbf{w} \cdot (\mathbf{u} \times \mathbf{v}) = \mathbf{u} \cdot (\mathbf{v} \times \mathbf{w}) = \mathbf{v} \cdot (\mathbf{w} \times \mathbf{u}). \quad (6.23)$$

但只交换其中两条边，就会变号。循环不变与交换变号是两件不同的事。

例题 6.3 (一块斜平行六面体的体积)

取 $\mathbf{u} = (1, 2, 0)^T$ 、 $\mathbf{v} = (0, 1, 1)^T$ 、 $\mathbf{w} = (2, 0, 1)^T$ 。则

$$\mathbf{u} \times \mathbf{v} = (2, -1, 1)^T, \quad V = (2, 0, 1) \cdot (2, -1, 1) = 5. \quad (6.24)$$

通常体积为 5。若把第三条边改为 $\mathbf{u} + \mathbf{v}$ ，它落在底面内，混合积为 0；体积的消失正好对应线性相关。

从几何直观到公理：多重线性与交错性

二维、三维的计算看起来不同，却在遵守同一套规则。固定底面，把剩下一条边拉长 c 倍，带符号高度也乘 c ；把这条边换成两支箭头的和，带符号高度相加，有向体积也相加。**加法与数乘都要保持**，才构成线性，仅有“拉伸按比例”还不完整。这种对每一条边分别成立的线性，称为多重线性 (Multilinearity)。另一方面，交换两条有序边，几何方向翻转，这就是交错性 (Alternation)。




图 6.3: 固定底边时，高度相加使有向面积相加；交换有序边则只改变符号。图中三块面积分别为 1、2、3，展示的是对一条边分别成立的线性。

引入公理化定义的目的，是摆脱三维空间直观的限制，把这套规则推广到任意 n 维。我们不再要求先画出一块区域，只要求一个实数值函数保持上述关系。不过，还必须选定度量的基准：如果把所有面积或体积都乘一个常数，两条性质依然成立；恒为 0 的函数也满足它们。单位平行体的值为 1，才能把尺度确定下来。

定义 6.4 (行列式的公理化定义)

固定正整数 n 。设函数 $D: (\mathbb{R}^n)^n \rightarrow \mathbb{R}$ 满足下列条件。

对每个位置 i ，固定其余向量后， D 对第 i 个向量线性：

$$D(\mathbf{r}_1, \dots, \alpha \mathbf{u} + \beta \mathbf{v}, \dots, \mathbf{r}_n) \quad (6.25)$$

$$= \alpha D(\mathbf{r}_1, \dots, \mathbf{u}, \dots, \mathbf{r}_n) + \beta D(\mathbf{r}_1, \dots, \mathbf{v}, \dots, \mathbf{r}_n). \quad (6.26)$$

交换任意两个位置的向量, 函数值变号; 这称为交错性。并规定归一化 (Normalization) 条件

$$D(\mathbf{e}_1, \dots, \mathbf{e}_n) = 1. \quad (6.27)$$

以 $\mathbf{r}_1^T, \dots, \mathbf{r}_n^T$ 为各行的矩阵 A 的行列式 (Determinant), 定义为

$$\det(A) = D(\mathbf{r}_1, \dots, \mathbf{r}_n). \quad (6.28)$$

即行列式是归一化的交错多重线性函数。三项条件共同确定它, 归一化不能省略。

回到刚画过的图: 单位正方形的两条边是 $\mathbf{e}_1, \mathbf{e}_2$, 有向面积为 1; 单位立方体的三条边是 $\mathbf{e}_1, \mathbf{e}_2, \mathbf{e}_3$, 有向体积也为 1。二阶面积公式与三阶混合积都对每条边线性, 交换两条边变号, 且满足这一基准。因此, 几何公式正好落在定义中, 而不是另起一套规则。

定理 6.5 (行列式的存在性与唯一性)

对每个正整数 n , 满足上述三项条件的函数存在且唯一。

证明: 先解释为何只能有一种答案。若有两条边相同, 交换它们既不改变输入, 又使函数值变号, 所以该值只能为 0。再将每个行向量按标准基展开:

$$\mathbf{r}_i = \sum_{j=1}^n a_{ij} \mathbf{e}_j. \quad (6.29)$$

利用多重线性依次展开, 所有项都成为若干坐标的乘积, 乘上 $D(\mathbf{e}_{j_1}, \dots, \mathbf{e}_{j_n})$ 。只要下标重复, 该项为 0; 不重复时, 下标恰好是 $1, \dots, n$ 的一种排列 (Permutation)。其值由交换变号和单位基准唯一确定为 +1 或 -1。

把排列写为 $\sigma = (\sigma(1), \dots, \sigma(n))$, 用逆序数 (Inversion Number) $N(\sigma)$ 记录其中满足 $i < j, \sigma(i) > \sigma(j)$ 的数对个数。相邻交换每次翻转一次符号, 故任何候选函数都只能是

$$D(\mathbf{r}_1, \dots, \mathbf{r}_n) = \sum_{\sigma \in S_n} (-1)^{N(\sigma)} a_{1,\sigma(1)} \cdots a_{n,\sigma(n)}. \quad (6.30)$$

这里 S_n 表示全部排列。另一方面, 这个有限和确实定义了一个函数: 每一项从每行恰取一个元素, 所以对各行线性; 交换两行时, 把相应排列重新配对, 每项符号翻转; 代入 E_n 时只有恒等排列留下, 值为 1。因此它满足三项条件, 存在性也得到证明。 ■

这段排列公式承担的是证明公理能定义出一个对象的任务, 实际计算不必从列出所有排列开始。 $n = 1$ 时得到 $\det([a]) = a$; $n = 2$ 时只留下两项, 得到 $a_{11}a_{22} - a_{12}a_{21}$; $n = 3$ 时恰好得到前面的六项混合积。到了 $n > 3$, 我们虽然无法直接画出整个平行体, 仍然能够严格定义它的有向体积。

还有一个随后会用到的结论：若只要求多重线性与交错性，而不要求基准为 1，则同一展开表明，这个函数必为 $D(E_n) \det(A)$ 。因此，归一化固定尺度，两条运算性质固定结构。下一节就用这套公理，重新解释消元为何能够度量体积。

6.2 从公理到性质：代数骨架的搭建

现在有了严格定义，我们可以回答一个实际问题：图形被拉伸、翻转或倾斜时，行列式会怎样变？第二章的三种初等行变换，恰好对应这三类操作。每一条性质都先在低维图形中看见，再用公理验证；这样，图形给出的直觉就能成为任意阶矩阵的计算规则。

单位基准与三种初等行变换

单位基向量围出单位正方形或单位立方体，这解释了 $\det(E_n) = 1$ 的尺度约定。若某条边为零，图形塌缩；代数上，由该位置的线性性，函数值为 0。若两条边相同，方向没有独立贡献；交换这两行既不改变矩阵，又使行列式变号，因而也为 0。这两件小事，将成为下面推导的支点。

先把三种操作放在图形中看：倍乘一条边使高度按同一比例改变，交换两条边使定向翻转，把底边的倍数加到另一条边上则只让顶端平行移动。这三个几何动作，分别要求尺度变化、符号变化与体积保持。

性质 6.6 (初等行变换对行列式的影响)

对方阵 A 作一次行操作，得到 B 。则

$$R_i \leftarrow kR_i: \quad \det(B) = k \det(A); \quad (6.31)$$

$$R_i \leftrightarrow R_j: \quad \det(B) = -\det(A); \quad (6.32)$$

$$R_i \leftarrow R_i + kR_j \ (i \neq j): \quad \det(B) = \det(A). \quad (6.33)$$

第一条对任意实数 k 都成立；作为可逆的初等行变换使用时，须要求 $k \neq 0$ 。

倍乘一行：改变尺度，也可能改变方向

几何上，固定其余边，把一条边拉长 $|k|$ 倍，带符号高度也乘 k ；若 $k < 0$ ，方向同时翻转。代数上，在第 i 个位置直接使用多重线性，得到 $D(\dots, kr_i, \dots) = kD(\dots, r_i, \dots)$ 。所以不是整个矩阵乘 k 才使行列式乘 k ，只乘一行就已经带来一次尺度变化。若所有 n 行都乘 k ，则

$$\det(kA) = k^n \det(A). \quad (6.34)$$

在平面中，它对应两条边同时伸长；面积乘的是 k^2 。

交换两行：形状不动，方向变号

交换两条有序边，不改变平行体作为一个点集的形状，却改变其定向。公理中的交错性正是这一事实的代数写法。连续作两次交换，符号翻转两次，又回到原值；这也解释了三维混合积循环换序不变。

倍加一行：倾斜而不改变体积

固定底边，把另一条边加上底边的倍数，顶端沿平行于底边的方向移动，底与高都不变。三维中，沿底面移动顶端同样不改变体积。坐标图形可能明显变斜，行列式却保持原值。




图 6.4: 向上边加上底边的倍数，只让顶端横向移动。左、右两块平行四边形的底长与高都相同；灰色虚线标出共同的高度，因此有向面积相等。

代数上，把发生改变的那一行拆开：

$$D(\dots, r_i + kr_j, \dots, r_j, \dots) = D(\dots, r_i, \dots, r_j, \dots) \quad (6.35)$$

$$+ kD(\dots, r_j, \dots, r_j, \dots) \quad (6.36)$$

$$= D(\dots, r_i, \dots, r_j, \dots). \quad (6.37)$$

第二项有两行相同，因而为 0。图形中的“高没变”，在公理中体现为这一项消失。**倍加不改变行列式**，就是用高斯消元计算行列式的基础。

例题 6.7 (一眼分清三种操作)

原矩阵 $A = \begin{pmatrix} 2 & 1 \\ 1 & 3 \end{pmatrix}$ 的行列式为 5。将第 2 行乘 3，行列式变为 15；交换两行，变为 -5；将第 2 行减去第 1 行的 2 倍，变为 $\begin{pmatrix} 2 & 1 \\ -3 & 1 \end{pmatrix}$ ，行列式仍为 $2 + 3 = 5$ 。三个结果分别对应拉伸、换方向和切变。

体积何时塌缩：可逆性判定

面积为0时，两条边共线；体积为0时，三条边共面。高维中，若 n 个方向线性相关，它们围出的平行体也失去完整的 n 维体积。这个图景与第四章“输入信息能否恢复”的问题是同一件事：某个独立方向被压掉，就不可能唯一恢复每个输入。

定理 6.8 (行列式、线性无关与可逆性)

对 n 阶方阵 A ，下列命题等价： A 可逆； $\det(A) \neq 0$ ； A 的行向量组线性无关； A 的列向量组线性无关。

证明：若行向量线性相关，就能选出一行，写成其余行的线性组合。把它代入多重线性公式，每个展开项都出现两行相同，故 $\det(A) = 0$ 。这把几何上的塌缩写成了代数上的零值。

若行向量线性无关，第二章的消元可以把 A 化成 E_n 。沿途只作交换、非零倍乘与倍加；由刚证明的三条规则，行列式只会乘上非零因子，或保持不变。终点的值为1，所以起点不可能为0。于是 $\det(A) \neq 0$ 当且仅当各行线性无关。

第四章已证明行秩等于列秩；对方阵，秩为 n 等价于列向量线性无关，也等价于对应映射为双射，即矩阵可逆。把这些结论连接起来，就得到全部等价关系。 ■

几何直观现在有了严格保证：**有向体积非零，说明方向没有塌缩；方向没有塌缩，说明映射可以撤销。**对方阵而言， $\det(A) = 0$ 不是“方程组必定无解”：右端项在列空间内时仍有解，只是存在自由度。第五章的目标位置与零空间，仍然需要分别检查。

本节得到的是“能不能逆”的新判据。第三章已有消元求逆的方法；下一节还将从代数余子式构造一个显式的逆矩阵公式。先把其余运算性质接好，才能看清这个公式为什么成立。

乘积与转置：从一侧的规则走向两侧的规则

先作一次线性变换，再作另一次，区域经历两次缩放：若第一次的有向倍率为 $\det(B)$ ，第二次为 $\det(A)$ ，合起来应当是二者的乘积。负号也随之相乘：翻转两次，整体方向恢复。第三章的映射复合，在这里获得了体积上的读数。

定理 6.9 (乘积法则)

对同阶方阵 A, B ，有

$$\det(AB) = \det(A) \det(B). \quad (6.38)$$

证明: 固定 B , 把 $F_B(A) = \det(AB)$ 看成关于 A 的函数。 AB 的第 i 行是 A 的第 i 行右乘 B , 这个对应关系线性; 所以 F_B 对 A 的每行线性。交换 A 的两行, 也交换 AB 的两行, 因此 F_B 是交错的。而 $F_B(E_n) = \det(B)$ 。

第 6.1 节的唯一性证明已说明, 任意交错多重线性函数, 都等于它在 E_n 上的值乘以 $\det(A)$ 。因此 $F_B(A) = \det(B) \det(A)$ 。证明没有除以 $\det(B)$, 所以 B 不可逆时也成立。

■

把结论放回图形: 若一步已经把体积压为 0, 后续线性变换不能凭空补回丢失的方向, 乘积的行列式也为 0。若两步都可逆, 缩放倍率与方向则按乘法合成。特别地,

$$\det(A^{-1}) = \frac{1}{\det(A)} \quad (A \text{ 可逆}), \quad \det(A^k) = (\det(A))^k \quad (k \geq 1). \quad (6.39)$$

前者记录撤销作用的反向倍率, 后者记录第五章递推模型中连续 k 步的整体体积倍率。




图 6.5: 复合变换的面积倍率相乘。单位正方形先经 $B = \text{diag}(2, 1)$, 再经 $A = \text{diag}(1, 3)$, 面积依次为 1、2、6; 此例两步都保持方向。

接下来还有一个不那么显然的问题: 我们用各行围出的体积定义行列式, 而映射把单位基送到的是各列。行与列会不会给出不同的体积? 图 6.6 提醒我们, 两幅平行四边形可以形状不同, 面积却相同; 一般情形须由代数证明保证。




图 6.6: 同一矩阵 $A = \begin{pmatrix} 2 & 1 \\ 0 & 1 \end{pmatrix}$ 的行与列围出不同形状的平行四边形, 但有向面积都为 2。转置不求两幅图全等, 只保证行列式相等。

定理 6.10 (转置不改变行列式)

对任意方阵 A , 有

$$\det(A^T) = \det(A). \quad (6.40)$$

证明: 在第 6.1 节的排列式中, A^T 的元素把行列下标互换。把每个排列换成它的逆排列 $\tau = \sigma^{-1}$, 再把乘积中的因子按行号重排, 得到

$$\det(A^T) = \sum_{\sigma \in S_n} (-1)^{N(\sigma)} \prod_{i=1}^n a_{\sigma(i), i} \quad (6.41)$$

$$= \sum_{\tau \in S_n} (-1)^{N(\tau)} \prod_{j=1}^n a_{j, \tau(j)} = \det(A). \quad (6.42)$$

排列与逆排列有相同的逆序数: $i < j$ 而 $\sigma(i) > \sigma(j)$, 恰好对应逆排列中这一对位置的反序。因此重新编号不会改变符号。 ■

这个证明让图中的两种体积读法成为同一个量: 矩阵作用于单位区域时, 各列构成的像的通常体积为 $|\det(A)|$, 与各行的定义一致。既然行和列的地位等价, 三类初等行变换对行列式的影响, 就可以直接平移到列变换上。交换两列变号, 倍乘一列乘相应系数, 把一列的倍数加到另一列上则不变。

推论 6.11 (三角矩阵的行列式)

上三角矩阵或下三角矩阵 U 的行列式, 等于主对角线元素的乘积:

$$\det(U) = u_{11}u_{22} \cdots u_{nn}. \quad (6.43)$$

几何上, 三角排列让逐层的高度容易读出; 对角矩阵就是各边沿坐标轴的长方体。代数上, 以对角矩阵为例, 多重线性直接给出对角元乘积。对上三角矩阵, 在排列式的一个非零项中须有 $\sigma(i) \geq i$; 所有下标之和固定为 $1 + \cdots + n$, 所以只能每个 $\sigma(i) = i$, 只留下主对角线乘积。下三角情形由转置得到。对角元为 0 的情形也包含在内。

例题 6.12 (列公因子与列倍加)

求 $A = \begin{pmatrix} 2 & 6 \\ 4 & 15 \end{pmatrix}$ 的行列式。先从第 1 列提出 2、第 2 列提出 3, 再用 $C_2 \leftarrow C_2 - 2C_1$:

$$\det(A) = 2 \cdot 3 \det \left(\begin{pmatrix} 1 & 2 \\ 2 & 5 \end{pmatrix} \right) = 6 \det \left(\begin{pmatrix} 1 & 0 \\ 2 & 1 \end{pmatrix} \right) = 6. \quad (6.44)$$

第 1 行第 2 列被消为零, 矩阵成为下三角形。提出的两个公因子乘在矩阵外, 列倍加本身不再改变行列式。

注: 列变换可以用于计算行列式, 却不能不加说明地用于增广矩阵并声称原方程组同解。第二章固定未知数的消元使用行变换; 列操作改变系数列, 也改变输入变量的记录。

另外, 行列式一般不满足 $\det(A+B) = \det(A) + \det(B)$: 多重线性说的是每次只改变一行。例如 $\det(E_2 + E_2) = 4$, 而 $\det(E_2) + \det(E_2) = 2$ 。

至此, 大小、方向、可逆性与初等操作已经接在同一套规则上。下一节不再只判断体积是否为零, 而要寻找两条计算路线: 用消元把高度逐层读出, 用代数余子式把任意一行的贡献单独读出。

6.3 行列式的计算

面积与体积的意义已经清楚, 计算才有了明确目标。若矩阵中有不少非零元素, 逐项列出排列会很快变得冗长; 若某一行只有少数非零元素, 逐层拆开反而方便。本节选择两条互补路线: 消元适合系统处理一般数表, 余子式展开适合利用零元素和揭示几何结构。我们会用同一个三阶矩阵贯穿二者, 再由其垂直方向构造逆矩阵。

6.3.1 高斯消元与上下三角矩阵: 工程中最常用的计算路径

第二章消元的目标是整理方程组的解, 现在同样的操作用来整理体积的读数。倍加变换像图 6.4 中的切变: 保持体积, 让边的排列变得更容易计算。得到三角矩阵后, 主对角线乘积就给出有向体积。一般三角矩阵仍可能有斜边, 不必已经成为长方体; 若再消去其余非对角元素, 才得到沿坐标轴排列的长方体。三角形的结构已经足以读数。

例题 6.13 (同一块体积, 用消元读出)

求

$$A = \begin{pmatrix} 1 & 2 & 0 \\ 0 & 1 & 1 \\ 2 & 0 & 1 \end{pmatrix} \quad (6.45)$$

的行列式。沿用第二章行变换的记号,

$$A \xrightarrow{R_3 \leftarrow R_3 - 2R_1} \begin{pmatrix} 1 & 2 & 0 \\ 0 & 1 & 1 \\ 0 & -4 & 1 \end{pmatrix} \quad (6.46)$$

$$\xrightarrow{R_3 \leftarrow R_3 + 4R_2} U = \begin{pmatrix} 1 & 2 & 0 \\ 0 & 1 & 1 \\ 0 & 0 & 5 \end{pmatrix}. \quad (6.47)$$

两次都是倍加, 所以行列式不变。由三角矩阵的公式,

$$\det(A) = \det(U) = 1 \cdot 1 \cdot 5 = 5. \quad (6.48)$$

这与第 6.1 节中三条边的混合积一致：消元改变了边的排列，保留了它们围出的有向体积。

操作之后，矩阵本身通常不再是原矩阵，但行列式如何变化已经逐步记清。如果进行了 s 次交换，又在若干步骤把某行乘以非零数 $k_1, \dots, k_q$ ，最终得到三角矩阵 U ，则

$$\det(A) = \frac{(-1)^s}{k_1 \cdots k_q} u_{11} \cdots u_{nn}. \quad (6.49)$$

倍加步骤不出现在这个因子中。没有倍乘时分母按 1 处理；分母的作用是撤回计算途中主动引入的尺度变化。

例题 6.14 (换行以后，记得把符号换回来)

取 $B = \begin{pmatrix} 0 & 2 & 0 \\ 3 & 0 & 0 \\ 0 & 0 & 4 \end{pmatrix}$ 。交换前两行，得到对角矩阵 $\text{diag}(3, 2, 4)$ ，其行列式为 24。因此

$$\det(B) = -24. \quad (6.50)$$

矩阵变为三角形并不表示原值就是 24；交换的记录属于答案的一部分。

注：如果某一步找不到非零主元，应继续按第二章的规则检查秩；方阵秩小于阶数时，行列式为 0。不能为继续计算而除以零，也不能把“出现一个零对角元”与“矩阵已经不可逆”混为一谈：尚未消元时，换行可能找到合适主元。

第三章的 LU 分解现在又有了一个用途。无换行时 $A = LU$ ，单位下三角矩阵满足 $\det(L) = 1$ ，所以 $\det(A) = \prod_i u_{ii}$ ；带换行时，若 $PA = LU$ ，只须再记录置换的符号。数值计算库通常先保存带选主元的 LU，再利用这些三角因子完成相关计算；LAPACK 的 DGETRF 就提供这样的分解。[28] 这条路线复用了已有的消元工作，适合规模较大的矩阵。余子式展开更适合小阶、含很多零元素的情况，以及理解下面的逆矩阵构造。

6.3.2 代数余子式展开 (Laplace 展开)：从正交补到展开定理

回到平行六面体：先固定两条边，它们的叉乘确定底面法向与面积，再与第三条边作点积，得到体积。若改变被留下来计算的那一行，也应有一支相应的法向量。我们要找的是垂直于其余各行的向量，而不是垂直于这行自身的向量；后一种点积必为 0，不能读出一般的体积。

对三阶矩阵, 以 r_1, r_2, r_3 记各行的坐标向量, 三支带正确方向的垂直向量是

$$c_1 = r_2 \times r_3, \quad c_2 = r_3 \times r_1, \quad c_3 = r_1 \times r_2. \quad (6.51)$$

它们都与相应的其余两行垂直, 而且 $r_i \cdot c_i = \det(A)$ 。第 2 支采用 $r_3 \times r_1$; 若把剩下两行机械地按原序写成 $r_1 \times r_3$, 符号就反了。这正是推广到任意阶时必须保留正负号的原因。




图 6.7: 固定其余两行, 先确定垂直方向, 再与第 i 行作点积。绿色向量 c_i 垂直于蓝色底面; 红色的第 i 行一般不与它垂直, 因此能读出非零体积。

叉乘的三个分量都是二阶面积。高维中, 可以把同样的线索保留下来: 删去一行, 留下其余各行; 再删去一个坐标方向, 得到较低一阶的行列式。这些小行列式记录垂直向量的各个分量, 符号则记录删去位置造成的定向差别。

定义 6.15 (余子式与代数余子式)

对 n 阶方阵 $A = (a_{ij})$, 删去第 i 行、第 j 列, 保留其余行列的原有次序, 所得 $(n-1)$ 阶行列式称为元素 a_{ij} 的余子式 (Minor), 记作 M_{ij} 。它的代数余子式 (Cofactor) 为

$$A_{ij} = (-1)^{i+j} M_{ij}. \quad (6.52)$$

约定 0 阶行列式为 1, 使一阶矩阵也能使用同样的展开公式。

符号沿行、沿列都交替, 左上角为正。三维中它与叉乘的右手方向一致; 任意维中则用“移到参考位置需要多少次交换”确定, 不再依靠画一只右手。

定理 6.16 (按行或按列展开)

沿任意固定的第 i 行, 拉普拉斯展开 (Laplace Expansion) 给出

$$\det(A) = \sum_{j=1}^n a_{ij} A_{ij}. \quad (6.53)$$

沿任意固定的第 j 列, 也有

$$\det(A) = \sum_{i=1}^n a_{ij} A_{ij}. \quad (6.54)$$

每次只沿一行或一列展开, 不把整个矩阵的所有元素一同相加。

证明: 固定其余各行, 将第 i 行展开为 $\mathbf{r}_i = \sum_j a_{ij} \mathbf{e}_j$ 。由多重线性,

$$\det(A) = \sum_{j=1}^n a_{ij} D(\mathbf{r}_1, \dots, \mathbf{e}_j, \dots, \mathbf{r}_n). \quad (6.55)$$

右侧每项的第 i 行只有第 j 个元素为 1。把这一行移到第 1 行, 把第 j 列移到第 1 列, 分别需要 $i-1$ 次、 $j-1$ 次交换。新矩阵的首行是 $(1, 0, \dots, 0)$; 排列式中只可能沿这个 1 取值, 剩下的部分恰好是 M_{ij} 。因此

$$D(\mathbf{r}_1, \dots, \mathbf{e}_j, \dots, \mathbf{r}_n) = (-1)^{i-1+j-1} M_{ij} = A_{ij}. \quad (6.56)$$

代回即得按行展开。对转置矩阵按行展开, 并使用转置不变性, 就得到按列展开。 ■

现在定义第 i 行的代数余子式向量 (Cofactor Vector)

$$\mathbf{c}_i = (A_{i1}, \dots, A_{in})^T. \quad (6.57)$$

展开定理就是 $\mathbf{r}_i \cdot \mathbf{c}_i = \det(A)$ 。为何它确实垂直于其余行? 把第 i 行临时换成第 k 行, $k \neq i$ 。新矩阵有两行相同, 行列式为 0; 删去第 i 行后的各个余子式却都没有变。所以

$$\mathbf{r}_k \cdot \mathbf{c}_i = \sum_{j=1}^n a_{kj} A_{ij} = 0 \quad (k \neq i). \quad (6.58)$$

这也证明了高维的垂直性质: 当其余 $n-1$ 行线性无关时, 这支向量给出垂直于它们的方向, 并带上相应的有向体积尺度; 若其余行已经线性相关, 各个余子式都为 0, 它就是零向量。它是固定其余边以后得到的向量, 不是对第 i 行本身作一次垂直旋转。

例题 6.17 (用同一行展开, 核对消元结果)

仍取 $A = \begin{pmatrix} 1 & 2 & 0 \\ 0 & 1 & 1 \\ 2 & 0 & 1 \end{pmatrix}$ 。第 1 行的余子式为

$$M_{11} = \det \left(\begin{pmatrix} 1 & 1 \\ 0 & 1 \end{pmatrix} \right) = 1, \quad (6.59)$$

$$M_{12} = \det \left(\begin{pmatrix} 0 & 1 \\ 2 & 1 \end{pmatrix} \right) = -2, \quad (6.60)$$

$$M_{13} = \det \left(\begin{pmatrix} 0 & 1 \\ 2 & 0 \end{pmatrix} \right) = -2. \quad (6.61)$$

故 $(A_{11}, A_{12}, A_{13}) = (1, 2, -2)$, 按第 1 行展开得到

$$\det(A) = 1 \cdot 1 + 2 \cdot 2 + 0 \cdot (-2) = 5. \quad (6.62)$$

第 1 行的零元素使最后一项不必计算; 这里仍列出它, 是为了看清整支垂直向量 $\mathbf{c}_1 = (1, 2, -2)^T$ 。它与第 2、3 行的点积分别为 $2 - 2 = 0$ 、 $2 - 2 = 0$, 与第 1 行的点积则为 5。

注: 展开时应把“元素的符号”与“代数余子式的符号”分别记录。 M_{ij} 本身可能为负, $(-1)^{i+j}$ 又可能为负。这里的 A_{ij} 是一个数, $\mathbf{c}_i$ 是由一整行代数余子式组成的向量, 二者不要混用。

有了这些向量, 我们不只能够拆开体积, 还能让一行与一列的点积变成“自己的位置非零, 其余位置为零”。这正好是构造逆矩阵所需要的条件。

6.3.3 伴随矩阵与逆矩阵公式

第三章求逆时, 我们要找到每个标准基的原像。现在换一个角度: 给第 i 列放一支向量, 使它与第 i 行的点积为 1, 与其余行的点积为 0, 那么矩阵作用后就得到 $\mathbf{e}_i$ 。上一段的 $\mathbf{c}_i$ 已经满足后一组垂直条件, 只差把它与第 i 行的点积从 $\det(A)$ 调整为 1。

定义 6.18 (伴随矩阵)

把每一行的代数余子式向量按列排列, 得到矩阵

$$\operatorname{adj}(A) = (\mathbf{c}_1 \cdots \mathbf{c}_n) = \begin{pmatrix} A_{11} & A_{21} & \cdots & A_{n1} \\ A_{12} & A_{22} & \cdots & A_{n2} \\ \vdots & \vdots & \ddots & \vdots \\ A_{1n} & A_{2n} & \cdots & A_{nn} \end{pmatrix}, \quad (6.63)$$

称为 A 的伴随矩阵 (Adjugate Matrix)。它是代数余子式数表的转置, 不是原矩阵 A 的转置。

为什么要转置, 至此可以在运算中看见: 矩阵乘法用左边的行乘右边的列, 所以各行对应的垂直向量须放到右边的列上。若仍把它们按行放着, 刚证明的点积关系就接不上了。

定理 6.19 (伴随矩阵恒等式与逆矩阵公式)

任意 n 阶方阵都满足

$$A \operatorname{adj}(A) = \operatorname{adj}(A) A = \det(A) E_n. \quad (6.64)$$

当且仅当 $\det(A) \neq 0$ 时矩阵可逆, 并有

$$A^{-1} = \frac{1}{\det(A)} \operatorname{adj}(A). \quad (6.65)$$

证明: 从几何上看, $\mathbf{c}_i$ 对其余行都没有沿这些行方向的分量; 只与第 i 行留下体积读数。代数上, $A \operatorname{adj}(A)$ 的第 k 行第 i 列为

$$\sum_{j=1}^n a_{kj} A_{ij} = \begin{cases} \det(A), & k = i, \\ 0, & k \neq i. \end{cases} \quad (6.66)$$

第一种是拉普拉斯展开, 第二种是两行相同的行列式, 所以得到 $\det(A) E_n$ 。

同理, $\operatorname{adj}(A) A$ 的第 i 行第 k 列为 $\sum_j A_{ji} a_{jk}$: 当 $i = k$, 它是按第 i 列展开; 当 $i \neq k$, 它是把第 i 列换成第 k 列后沿该列展开, 出现两列相同, 值为 0。由此得到右乘的恒等式。

若 $\det(A) \neq 0$, 把两边的伴随矩阵除以该数, 就同时满足左右乘积为 E_n , 因此确为逆矩阵。若行列式为 0, 第 6.2 节已经证明矩阵不可逆, 不能使用含这个分母的公式。■

二维验证: 两支垂直箭头为什么成为两列

取 $A = \begin{pmatrix} a & b \\ c & d \end{pmatrix}$, 则

$$c_1 = (d, -c)^T, \quad c_2 = (-b, a)^T, \quad \text{adj}(A) = \begin{pmatrix} d & -b \\ -c & a \end{pmatrix}. \quad (6.67)$$

c_1 垂直于第 2 行, c_2 垂直于第 1 行; 第 1 行与 c_1 、第 2 行与 c_2 的点积都为 $ad - bc$ 。把它们按列排好, 再同除以这个有向面积, 就得到熟悉的二阶逆矩阵公式。




图 6.8: 红色两支箭头是矩阵 $A = \begin{pmatrix} 2 & 1 \\ 1 & 3 \end{pmatrix}$ 的行向量, 蓝色两支是伴随矩阵的列。每支蓝色箭头垂直于另一行; 与对应行的点积都为 5, 除以 5 后成为逆矩阵的两列。

例题 6.20 (三维验证: 叉乘按列排成逆矩阵)

继续使用 $A = \begin{pmatrix} 1 & 2 & 0 \\ 0 & 1 & 1 \\ 2 & 0 & 1 \end{pmatrix}$ 。由式(6.51), 三支叉乘向量为

$$c_1 = (1, 2, -2)^T, \quad c_2 = (-2, 1, 4)^T, \quad c_3 = (2, -1, 1)^T. \quad (6.68)$$

它们按列组成

$$\text{adj}(A) = \begin{pmatrix} 1 & -2 & 2 \\ 2 & 1 & -1 \\ -2 & 4 & 1 \end{pmatrix}, \quad A^{-1} = \frac{1}{5} \begin{pmatrix} 1 & -2 & 2 \\ 2 & 1 & -1 \\ -2 & 4 & 1 \end{pmatrix}. \quad (6.69)$$

以第 1 列为例, 三行与 $(1, 2, -2)^T$ 的点积依次为 5, 0, 0; 另外两列同样分别给出

0,5,0 与 0,0,5。所以

$$A \operatorname{adj}(A) = \begin{pmatrix} 5 & 0 & 0 \\ 0 & 5 & 0 \\ 0 & 0 & 5 \end{pmatrix}. \quad (6.70)$$

这不是另外猜出的数表，而是把三个底面的法向与体积读数组织成了逆映射。

注：伴随矩阵对不可逆矩阵也有定义，恒等式也仍成立；只有求逆公式需要 $\det(A) \neq 0$ 。显式公式适合小阶计算与理论理解，大规模求解仍优先使用第三章的 LU、PLU 等方法，不必先构造全部余子式。

行列式至此已从面积走到任意阶定义，又从定义走向计算与逆映射。下一节再向几何迈进一步：如果一个变换会把直线弯曲，局部还能不能用刚学过的行列式度量它？

6.4 几何形式的深化：微积分思想下的体积度量

线性变换把一个区域整体按同一个倍率缩放，非线性变换则可能在不同位置伸缩得不同。例如，图像变形会使网格线弯曲：同样大小的像素块，放在不同位置，可能覆盖不同大小的区域。我们仍想量面积，只是现在要先把观察范围缩小，找到该处能够近似代替原变换的线性作用。

这一节只使用一元求导的类比与小区域的几何直观，不展开多元微积分的系统理论。偏导、可微性与积分换元的完整推导，留待后续附录 B；这里先说明为什么行列式还会出现在非线性问题中。

局部线性化：把弯曲的小区域看成平行四边形

一元函数在一点附近，可以用切线近似。向量到向量的变换也有类似的想法：固定一个点 $\mathbf{p}$ ，把附近的位移 $\mathbf{h}$ 送入一个矩阵 $J(\mathbf{p})$ ，近似得到输出的位移。这称为局部线性化 (Local Linearization)。需要区分原点的位置与位移本身：输出基点是 $F(\mathbf{p})$ ，矩阵作用的是从基点出发的小箭头。

在能够作这种线性近似的点上，写成

$$F(\mathbf{p} + \mathbf{h}) = F(\mathbf{p}) + J(\mathbf{p})\mathbf{h} + \varepsilon(\mathbf{h}), \quad \frac{|\varepsilon(\mathbf{h})|}{|\mathbf{h}|} \rightarrow 0 \quad (\mathbf{h} \rightarrow \mathbf{0}). \quad (6.71)$$

最后一项比位移本身更小；忽略它，便得到附近的线性模型。不是每个非线性规则、每个点都自动具有这种近似，下一段会给出本节采用的充分条件。

小矩形的两条边分别是 $\Delta x \mathbf{e}_1$ 、 $\Delta y \mathbf{e}_2$ ，在线性近似下变为 $J(\mathbf{p})\mathbf{e}_1\Delta x$ 与 $J(\mathbf{p})\mathbf{e}_2\Delta y$ 。第三章已告诉我们，这两支箭头就是矩阵的两列分别乘边长。所以近似像是一个平行四边形，其面积为

$$\text{线性近似像的面积} = |\det J(\mathbf{p})| \Delta x \Delta y. \quad (6.72)$$

输入小块的面积是 $\Delta x \Delta y$ ，因此局部面积倍率由 $|\det J(\mathbf{p})|$ 给出。带符号的行列式还记录该点附近的定向；实际面积倍率要取绝对值。




图 6.9: 小矩形在非线性变换后具有弯曲边界，灰色虚线平行四边形是局部线性近似。两侧分别采用位移坐标，图形已放大；蓝、绿箭头对应近似矩阵的两列，块越小，边界与线性近似越接近。

偏导与雅可比：把局部变化排成一张数表

怎么得到这张近似矩阵？设

$$F(x, y) = \begin{pmatrix} f(x, y) \\ g(x, y) \end{pmatrix}. \quad (6.73)$$

先固定 y ，只改变 x ，便得到熟悉的一元求导；再固定 x ，只改变 y 。这两种方向的变化率称为偏导数 (Partial Derivative)。例如，

$$f_x(x, y) = \frac{\partial f}{\partial x}(x, y) = \lim_{h \rightarrow 0} \frac{f(x+h, y) - f(x, y)}{h}, \quad (6.74)$$

而 f_y 用固定 x 、改变 y 的方式定义。下标表示对哪个变量求导，不表示向量分量。

本节假设 f, g 在所讨论点附近具有连续的一阶偏导数。在这一充分条件下，式(6.71)的近似成立，矩阵为

$$J(x, y) = \begin{pmatrix} f_x(x, y) & f_y(x, y) \\ g_x(x, y) & g_y(x, y) \end{pmatrix}. \quad (6.75)$$

它称为雅可比矩阵 (Jacobian Matrix)：第 1 列记录只沿输入 x 方向移动时，两项输出怎

样变化；第 2 列记录只沿输入 y 方向移动时的变化。这仍是第 3.1 节“列对应基向量的像”的逻辑，只是现在记录的是局部位移的像。

它的雅可比行列式 (Jacobian Determinant) 为

$$\det J(x, y) = f_x g_y - f_y g_x. \quad (6.76)$$

用普通语言说：四个局部变化率先组成一个局部线性变换，行列式再读出它的有向面积倍率。一般 n 维变换同样用各项输出对各项输入的偏导数组成 $n \times n$ 矩阵；其行列式绝对值给出局部 n 维体积倍率，不需要另造一套高维面积公式。

例题 6.21 (局部倍率依赖所在位置)

取 $F(x, y) = (x, x^2 + y^2)^T$ 。直接对各变量求导，得到

$$J(x, y) = \begin{pmatrix} 1 & 0 \\ 2x & 2y \end{pmatrix}, \quad \det J(x, y) = 2y. \quad (6.77)$$

在 $\mathbf{p} = (1, 1)^T$, $F(\mathbf{p}) = (1, 2)^T$ ，而

$$J(\mathbf{p}) = \begin{pmatrix} 1 & 0 \\ 2 & 2 \end{pmatrix}, \quad J(\mathbf{p})\mathbf{e}_1 = (1, 2)^T, \quad J(\mathbf{p})\mathbf{e}_2 = (0, 2)^T. \quad (6.78)$$

这两支像向量围出的有向面积为 2，故该点附近小块的面积约变为原来的 2 倍。图 6.9 画的就是这个例子：输出第 2 项的增量为 $2\Delta x + 2\Delta y + (\Delta x)^2 + (\Delta y)^2$ ，虚线近似只保留前两项。

在 $y = \frac{1}{2}$ 附近，倍率为 1；在 $y = \frac{3}{2}$ 附近，倍率为 3；在 $y < 0$ 处，符号为负，局部方向翻转。这个变换没有一个适用于所有位置的固定倍率。 $y = 0$ 处的行列式为 0，表示一阶近似发生塌缩，不表示每个有限小块的真实像都恰好面积为 0。

这里要把范围留清楚：一阶偏导数存在本身，并不足以保证任意方向都能由同一个矩阵近似；我们采用的是“附近偏导连续”这个充分条件。把局部面积倍率组织成积分换元公式，还需要可微性、区域与一一对应等条件的系统讨论，后续附录 B 再展开。本节只把行列式与局部线性作用连起来。

再回到平行四边形：用底乘高核对二阶公式

经过高维公理、消元与局部近似，再回看最初的平行四边形，公式中的每一项就有了具体位置。设两条有序边为 $\mathbf{u} = (a, b)^T$ 、 $\mathbf{v} = (c, d)^T$ ，且 $\mathbf{u} \neq \mathbf{0}$ 。取垂直于底边的单位向量

$$\mathbf{n} = \frac{1}{\sqrt{a^2 + b^2}}(-b, a)^T. \quad (6.79)$$

由第 0 章的点积公式，带符号高度为

$$h_s = \mathbf{v} \cdot \mathbf{n} = \frac{ad - bc}{\sqrt{a^2 + b^2}}. \quad (6.80)$$

底长乘上这份高度，分母恰好消去：

$$S = |\mathbf{u}| h_s = ad - bc = \det(A), \quad \text{通常面积} = |\mathbf{u}| |h_s| = |\det(A)|. \quad (6.81)$$

若 $h_s < 0$ ，说明第二条边位于选定法向的另一侧；若底边为零，图形直接退化，两边公式也都给出 0。这样，符号、大小与退化情形都各有解释。




图 6.10: 底乘高与二阶行列式给出同一个面积。示例两条边为 $(2, 1)^T$ 、 $(1, 3)^T$ ，底长与高都为 $\sqrt{5}$ ；灰色虚线为高，直角标记说明它垂直于底边，有向面积为 5。

面积意义由此不是一个事后附加的比喻：二维中的底乘高、三维中的混合积，以及任意维数的归一化交错多重线性函数，描述的是同一套体积规则。行列式为 0 时，我们看见方向塌缩；非零时，我们看见可逆作用的整体倍率；面对非线性变形，又在足够小的范围内把同一套规则交给局部矩阵使用。

到这里，几何提出的问题已经转化为可以证明、可以计算的代数结论。下一章将进一步研究长度、夹角与正交，让我们不只量出一个区域整体缩放多少，还能更细致地理解向量之间的度量关系。

第 7 章

内积空间与正交性: 线性空间中的几何

第 8 章

特征空间与相似变换: 寻找最自然的坐标系

第 9 章

矩阵对角化: 寻找最简单的表示

第 10 章

二次型: 从矩阵到几何形状

第 11 章

奇异值分解: 数据中的主方向 (选读)

后记

我们从一个笼子里的鸡和兔开始。

头 35 个，脚 94 只。这是小学奥数里最朴素的问题，两个未知数，两个方程，用最原始的消元思想就能算出答案。那时，草稿纸上的每一次涂改，都只是为了让头数与脚数相合。我们尚不知道，一个朴素的办法，也会成为跨越时代的共同语言。

一千五百年后，洛斯阿拉莫斯的科学家们抱着同样的思路，在机械台式计算器上求解上百阶的方程组，为核反应堆的临界计算提供了关键数据。第一台通用电子计算机 ENIAC 建成后，最早的核心任务之一，也是求解大型线性方程组。从鸡兔同笼到核反应堆，中间横着的，是一条人类理性踩出来的漫长道路。

纸上的筹算、桌边的摇柄、机房里的灯光，属于不同的年代；被一次次传下来的，却是把问题说清、把关系列出、把未知逐步求出的耐心。

线性代数从来不是一套凭空造出来的符号游戏。它诞生于工程的需求，成长于抽象的思维，最终成为了现代科学的通用语言。从原子弹到登月火箭，从跨海大桥到人工智能，几乎所有伟大的工程背后，都立着它的骨架。

你或许曾觉得，这门课里的定义、定理、公式，只是为了考试而存在。但你回头看看自己走过的路：你学会了用向量描述世界，用消元法拆解方程组，用矩阵组织运算，用线性变换理解结构，用秩与解空间把握存在与唯一，用行列式度量体积与可逆，用特征值寻找系统的固有方向。这些概念从来不是孤立的知识点，它们是同一棵树上的枝干，根植于同一个思想：线性结构，是这个世界上最普遍、最简洁、最有力的描述方式之一。

这就是人类理性的力量。我们从具体的问题出发，靠着逻辑与抽象，一步步走向普遍的规律，再反过来支撑起更宏大的创造。数学是这个过程最纯粹的形式，而线性代数，是这个形式最基础的语法。

如今，这份耐心也来到你的书桌前。一次重算，一处改正，一段终于读懂的推导，都让前人的积累成为你能够亲自使用的知识。

你不需要记住每一个定理的证明，也不需要熟练手算每一个矩阵的化简。真正重要的是，你开始拥有了一种眼光——一种在纷繁复杂中看见线性骨架的眼光。这种眼光会让你在未来的任何领域里，都比别人多一层理解。

所以，当你合上这本书的时候，不要觉得线性代数已经结束了。你只是刚刚开始。后面的路还很长，有更广阔的空间等待你去探索，有更复杂的系统等待你去理解，有更深刻的问题等待你去回答。但无论你走到哪里，你都会发现，这里的每一个概念——向量、矩阵、秩、维数、特征值——都还在那里，安静地、精确地、充满力量地支撑着你眼前的一切。

而你刚刚走完的，就是这段最伟大的理性之路的第一步。

愿你在未来的某个时刻，忽然想起这本书里的某一个概念，发现它正在你眼前的某个系统里安静地运转。

附录 A

复数：从数轴走向平面

在实数范围内，方程 $x^2 + 1 = 0$ 没有解。但“没有实数解”并不意味着只能止步于此：我们可以扩充所用的数，让这个方程也有可讨论的解。正如从二维走向高维时保留向量的运算规则，从实数走向复数时，我们也希望保留熟悉的加法、乘法与分配律。

这次扩充还有一份几何上的收获：实数在数轴上表示位置，复数在平面上同时记录两个坐标；加法仍是位移的合成，乘法却能把伸缩与旋转合在一起。**先在平面上看清位置，再在运算中辨认结构。**本附录沿着复数及其运算、共轭与模、极式与旋转的线索展开，重点说明欧拉公式如何把一条代数等式变成一幅单位圆图景。

A.1 扩充数系：从一个新单位开始

实数的平方总是非负，因此我们引入一个新单位 i ，规定 $i^2 = -1$ 。这样， i 与 $-i$ 都满足 $x^2 + 1 = 0$ 。新符号的意义不在于它能不能画在实数轴上，而在于怎样给它建立一致的运算规则。

定义 A.1 (复数及其实部、虚部)

满足 $i^2 = -1$ 的 i 称为**虚数单位 (Imaginary Unit)**。形如

$$z = a + bi, \quad a, b \in \mathbb{R}$$

的数称为**复数 (Complex Number)**。其中 a 称为**实部 (Real Part)**， b 称为**虚部 (Imaginary Part)**，分别记为 $\operatorname{Re} z = a$ 、 $\operatorname{Im} z = b$ 。复数全体记为 $\mathbb{C}$ 。两个复数相等，当且仅当它们的实部与虚部分别相等。

例如， $z = 2 - 3i$ 的实部为 2，虚部为 -3 ；虚部是实数 -3 ，不是 $-3i$ 。当 $b = 0$ 时， $a + 0i$ 就是实数 a ，所以 $\mathbb{R} \subset \mathbb{C}$ 。当 $a = 0$ 且 $b \neq 0$ 时， bi 称为**纯虚数 (Purely Imaginary Number)**。

第 1 章已经提到复数域：它不是把实数运算推翻，而是在更大的数系中继续使用这些运算。这里的 i 是数，不是向量下标，也不是实数范围内存在的某个平方根。连续相

乘可得

$$i^0 = 1, \quad i^1 = i, \quad i^2 = -1, \quad i^3 = -i, \quad i^4 = 1.$$

再乘 i ，又从这一循环开始。稍后我们会看到，这四个值恰好对应单位圆上每次转过四分之一周的位置。

A.2 分部相加，依律相乘

两个复数相加，就是实部与实部相加、虚部与虚部相加。例如， $(2+i) + (1+2i) = 3+3i$ 。这个规则与平面向量逐个分量相加完全一致。相减也如此，先把实部与虚部分开，再分别计算。

性质 A.2 (复数的加法、减法与乘法)

设 $z = a + bi$ 、 $w = c + di$ ，则

$$z + w = (a + c) + (b + d)i,$$

$$z - w = (a - c) + (b - d)i,$$

$$zw = (ac - bd) + (ad + bc)i.$$

乘法按分配律展开，再把 i^2 换成 -1 。这些运算满足熟悉的交换律、结合律与分配律。

例题 A.3 (展开以后，只留下两部分)

计算 $(2+i)(1+2i)$ 。按分配律，

$$(2+i)(1+2i) = 2 + 4i + i + 2i^2 = 5i.$$

实部相消，虚部合并。复数乘法不等于把两个坐标分别相乘：若错误地把 $(2,1)$ 与 $(1,2)$ 的对应分量相乘，就得不到这里的结果。

加法对应怎样的图形？把复数 $a + bi$ 放在平面中的点 (a, b) 上，再从原点画出箭头，原来的平行四边形定则便直接适用。




图 A.1: 复数加法与向量加法使用同一幅图：从 z 的终点接上代表 w 的箭头，得到 $z + w$ 。

A.3 共轭看镜像，模长看距离

复平面 (Complex Plane) 正是上述表示复数的平面：横坐标记录实部，横轴称为实轴 (Real Axis)；纵坐标记录虚部，纵轴称为虚轴 (Imaginary Axis)。复数是数，平面上的点与箭头是它的几何表示。有了这层对应，我们便能用对称与距离理解两个新的概念。

定义 A.4 (共轭与模)

对 $z = a + bi$, 复数

$$\bar{z} = a - bi$$

称为 z 的共轭复数 (Complex Conjugate)；非负实数

$$|z| = \sqrt{a^2 + b^2}$$

称为 z 的模 (Modulus)。

共轭只把虚部变号，因此将点 (a, b) 映到 $(a, -b)$ ，是关于实轴的镜像；模只问离原点多远，是勾股定理给出的长度。图 A.2 以 $a, b > 0$ 示意，其他象限的解释相同。




图 A.2: 共轭的镜像关系。 $z = a + bi$ 与 $\bar{z} = a - bi$ 关于实轴对称，到原点的距离相同，因此 $|\bar{z}| = |z|$ 。

共轭也使除法变得方便。因为

$$z\bar{z} = (a + bi)(a - bi) = a^2 + b^2 = |z|^2,$$

分母乘上其共轭，就变成了实数。若 $w = c + di \neq 0$ ，则 $c^2 + d^2 > 0$ ，从而

$$\frac{z}{w} = \frac{z\bar{w}}{w\bar{w}} = \frac{ac + bd}{c^2 + d^2} + \frac{bc - ad}{c^2 + d^2}i.$$

这里的条件 $w \neq 0$ 不能省略。每个非零复数都有倒数，因而除法的结果仍在 $\mathbb{C}$ 中。

例题 A.5 (用共轭消去分母的虚部)

$$\frac{2+i}{1-i} = \frac{(2+i)(1+i)}{(1-i)(1+i)} = \frac{1+3i}{2} = \frac{1}{2} + \frac{3}{2}i.$$

分子与分母必须同时乘 $1+i$ ，这才保持原来的商不变。

性质 A.6 (共轭与模的常用关系)

对任意复数 z, w ，有

$$\begin{aligned} \bar{\bar{z}} &= z, & \overline{z+w} &= \bar{z} + \bar{w}, & \overline{z\bar{w}} &= \bar{z}w, \\ |z| &\geq 0, & |z| = 0 &\iff z = 0, & |zw| &= |z||w|. \end{aligned}$$

若 $w \neq 0$ ，还有 $\overline{z/w} = \bar{z}/\bar{w}$ 、 $|z/w| = |z|/|w|$ 。

前几式可以直接展开验证。模的乘法性质也有简洁依据： $|zw|^2 = (zw)\overline{zw} = |z|^2|w|^2$ ，两边均非负，开平方即得。几何上， $|z - w|$ 表示两点之间的距离；这与实数轴上的距离公式具有相同形式。

A.4 换一种坐标：模定长短，角定方向

描述平面上的一个非原点位置，除了给出横、纵坐标，还可以先说离原点多远，再说朝哪个方向。设 $z = a + bi \neq 0$ ，令 $r = |z| > 0$ ，从正实轴转向向量 Oz 的有向角 (Directed Angle) 为 θ ，则

$$a = r \cos \theta, \quad b = r \sin \theta.$$

这里的 θ 称为 z 的辐角 (Argument)。逆时针为正，顺时针为负；本附录的角度均采用弧度制。

定义 A.7 (复数的极式)

非零复数的极坐标形式 (Polar Form) 为

$$z = r(\cos \theta + i \sin \theta), \quad r = |z| > 0.$$

同一复数的辐角可相差 $2k\pi$ ，其中 $k \in \mathbb{Z}$ 。若约定 $-\pi < \theta \leq \pi$ ，所得唯一角称为辐角主值 (Principal Argument)，记为 $\operatorname{Arg} z$ 。

零复数的模为 0，但方向无法确定，**不定义它的辐角**。对于非零复数，判断辐角要同时看实部与虚部的正负，不能只依赖 $\tan \theta = b/a$ ，更不能在 $a = 0$ 时作这个除法。例如， $1 + i$ 与 $-1 - i$ 的比值 b/a 相同，方向却相差 π 。

若 $z_1 = r_1(\cos \alpha + i \sin \alpha)$ 、 $z_2 = r_2(\cos \beta + i \sin \beta)$ ，展开乘法并应用两角和公式，就得到

$$\begin{aligned} z_1 z_2 &= r_1 r_2 [(\cos \alpha \cos \beta - \sin \alpha \sin \beta) \\ &\quad + i(\sin \alpha \cos \beta + \cos \alpha \sin \beta)] \\ &= r_1 r_2 [\cos(\alpha + \beta) + i \sin(\alpha + \beta)]. \end{aligned}$$

模相乘，辐角相加。固定 z_2 后，乘以 z_2 就把原向量长度放大为 r_2 倍，并绕原点旋转 β 。这里的辐角相加按相差整周视为同方向理解，辐角主值的和必要时加减 2π 才能回到约定区间。




图 A.3: 复数乘法的极坐标解释。左图给出两个因子，右图给出乘积：长度变为 $r_1 r_2$ ，方向角变为 $\alpha + \beta$ 。示意取 $r_1 = 1.4$ 、 $r_2 = 1.5$ 、 $\alpha = \pi/9$ 、 $\beta = 5\pi/18$ 。

若除以一个非零复数，过程正好相反：**模相除，辐角相减**。这使乘法与除法都能读成平面上的长度变化与方向变化。

例题 A.8 (乘以 i ，为什么转过直角)

$i = \cos(\pi/2) + i\sin(\pi/2)$ ，模为 1，辐角为 $\pi/2$ 。因此乘以 i 不改变长度，只将向量逆时针转过直角。代数上也能看到同一件事：

$$i(a + bi) = -b + ai, \quad (a, b) \mapsto (-b, a).$$

例如点 $(2, 1)$ 对应 $2 + i$ ，乘以 i 后变成 $-1 + 2i$ ，对应点 $(-1, 2)$ 。

A.5 欧拉公式：把旋转写成指数

在所有非零复数中，模为 1 的情形最能单独显出方向。满足 $|z| = 1$ 的点构成单位圆 (Unit Circle)。单位圆上的一个点转过角 θ 后，其横坐标是 $\cos \theta$ ，纵坐标是 $\sin \theta$ ，所以这个点对应的复数为 $\cos \theta + i\sin \theta$ 。

定理 A.9 (欧拉公式)

对任意实数 θ ，有**欧拉公式 (Euler's Formula)**：

$$e^{i\theta} = \cos \theta + i\sin \theta. \quad (\text{A.1})$$

因此 $|e^{i\theta}| = 1$ ，而 θ 是它的一个辐角。

读这条公式时，可以暂时把右侧看作“点的坐标”，把左侧看作“转过的角度”。它们描述的是同一个单位圆上的位置。指数中的 i 使角度进入复数运算，而模始终保持为 1。




图 A.4: 欧拉公式的单位圆图景。从 1 沿单位圆逆时针转过 θ , 到达 $e^{i\theta}$; 点的两个坐标分别是 $\cos \theta$ 与 $\sin \theta$ 。虚线显示投影, 圆弧显示旋转方向。图中示意 $0 < \theta < \pi/2$, 公式对所有实数角成立。

为什么左边可以使用指数记号? 第 1 章选读曾用有限项多项式近似 e^t 。若把这种展开延伸为无限项, 就可以定义复指数 (Complex Exponential):

$$e^w = \sum_{k=0}^{\infty} \frac{w^k}{k!}.$$

这个展开对每个复数 w 都绝对收敛 (Absolute Convergence), 即各项的模相加仍有有限的和, 因而可以按奇数次幂、偶数次幂重新分组。代入 $w = i\theta$, 利用 $i^2 = -1$, 得到

$$\begin{aligned} e^{i\theta} &= \left(1 - \frac{\theta^2}{2!} + \frac{\theta^4}{4!} - \cdots\right) \\ &\quad + i \left(\theta - \frac{\theta^3}{3!} + \frac{\theta^5}{5!} - \cdots\right) \\ &= \cos \theta + i \sin \theta. \end{aligned}$$

最后一行使用了正弦、余弦各自的展开。这是欧拉公式的一个来源; 尚未学习无穷展开的读者可以把这一段作为选读, 先掌握单位圆上的坐标含义。

长度留给模, 方向交给角。借助欧拉公式, 极式变成更紧凑的指数形式 (Exponential Form)

$$z = re^{i\theta}, \quad (r_1 e^{i\alpha})(r_2 e^{i\beta}) = r_1 r_2 e^{i(\alpha+\beta)}.$$

当 $r_2 = 1$ 时, 这就是纯粹的旋转 (Rotation): 角度增加 β , 长度保持不变。任取实数 a, θ , 还可写成 $e^{a+i\theta} = e^a(\cos \theta + i \sin \theta)$, 其中实部 a 控制模, 虚部 θ 控制方向。

把几个熟悉的角代入, 可以把公式与图上的四个方向一一对应:

$$e^{i0} = 1, \quad e^{i\pi/2} = i, \quad e^{i\pi} = -1, \quad e^{i3\pi/2} = -i.$$

尤其是 $e^{i\pi} + 1 = 0$ ，它在单位圆上说的只是：从 1 转过半周，就到达 -1 。漂亮的等式背后，是一个明确的几何动作。

例题 A.10 (让屏幕上的方向标记转过四分之一周)

把屏幕平面中的一个方向标记用复数 $z = 2 + i$ 表示。若希望绕原点逆时针旋转 $\pi/2$ ，可直接乘 $e^{i\pi/2} = i$ ，得到

$$z' = iz = -1 + 2i.$$

原来与现在的模都为 $\sqrt{5}$ 。这里仅把复数作为平面坐标的计算工具；实际屏幕若采用向下为正的纵轴，需要先统一坐标约定。

A.6 反复旋转：乘方与开方

一次乘法使辐角相加，多次相乘便使角度逐次累积。这把原本可能很长的代数展开，变成了“模的乘方”与“角的倍乘”。

定理 A.11 (棣莫弗定理)

对实数 θ 与整数 n ，**棣莫弗定理 (De Moivre's Theorem)** 给出

$$(\cos \theta + i \sin \theta)^n = \cos(n\theta) + i \sin(n\theta).$$

因而对非零复数 $z = r(\cos \theta + i \sin \theta)$ ，有

$$z^n = r^n (\cos(n\theta) + i \sin(n\theta)).$$

对正整数 n ，反复使用“模相乘、辐角相加”即可得到； $n = 0$ 时两边都是 1，负整数情形再取倒数。非零条件保证负整数次幂有意义。例如， $1 + i = \sqrt{2}e^{i\pi/4}$ ，所以

$$(1 + i)^4 = (\sqrt{2})^4 e^{i\pi} = -4.$$

我们没有逐项展开四次方，而是看见：长度先取四次方，方向角再转到原来的四倍。

反过来，若已知 z ，要求 $w^n = z$ ，就是求复数的 n 次根 (nth Root of a Complex Number)。设 $z = re^{i\theta} \neq 0$ ， n 为正整数，则全部根为

$$w_k = r^{1/n} e^{i(\theta+2k\pi)/n}, \quad k = 0, 1, \dots, n-1.$$

它们有相同的模，辐角依次相差 $2\pi/n$ ，因此均匀分布在同一个圆上。加上 $2k\pi$ 的步骤

不能省略：原来代表同一方向的不同角，在除以 n 后会产生不同的根。若 $z = 0$ ，则只有根 $w = 0$ 。

特别地，方程 $w^n = 1$ 的解称为单位根 (Roots of Unity)。下面以四次单位根为例，看见乘以 i 与四次开方之间的联系。




图 A.5: 四次单位根 $1, i, -1, -i$ 均匀分布在单位圆上。每次乘以 i 都逆时针转过 $\pi/2$ ，四次以后回到原处。

A.7 回到线性代数：对象可变，结构相通

复数与平面向量有相同的两分量加法，但复数还带有自己的乘法。这个区别使我们既能把它看作平面上的位置，也能把一个固定复数看作作用于整个平面的伸缩与旋转规则。例如，固定 $c = p + qi$ ，定义 $T(z) = cz$ ，由分配律立刻有

$$T(z + w) = T(z) + T(w), \quad T(tz) = tT(z) \quad (t \in \mathbb{R}).$$

因此它保留了前文已经认识的线性组合关系。复数运算为“一个数怎样作用于一个平面”提供了直接例子，后续讨论线性变换时，这幅图景还会再次出现。

第1章也提醒过：谈基与维数，要先说明允许使用什么标量。把 $\mathbb{C}$ 看成实向量空间时， $1, i$ 是一组基，维数为2；把它看成复向量空间时，单个向量 1 就是一组基，维数为1。前者用两个实系数表示 $a + bi$ ，后者允许直接使用复系数 z ，写成 $z \cdot 1$ 。对象相同，系数范围不同，维数便随之改变。

练习 A.12 (把运算与图形对应起来)

设 $z = 1 + \sqrt{3}i$ 。求 $\bar{z}$ 与 $|z|$ ，写出一个极式，并计算 iz 、 z^3 。再在复平面上说明：哪一步是镜像，哪一步是旋转，哪一步同时改变了长度与方向？

可用以下结果核对： $\bar{z} = 1 - \sqrt{3}i$ 、 $|z| = 2$ 、 $z = 2e^{i\pi/3}$ 、 $iz = -\sqrt{3} + i$ 、 $z^3 = -8$ 。共轭关于实轴镜像；乘 i 保持长度、转过 $\pi/2$ ；三次方使模变为 2^3 、辐角变为 π 。

从 $a + bi$ 到 $re^{i\theta}$ ，并不是换了一个复数，而是换了描述它的方式。代数形式便于分部运算，极坐标形式便于辨认旋转。共轭把对称写成变号，模把距离写成平方和，欧拉公式把单位圆写成指数；不同表示相互配合，计算才有了可以看见的意义。

附录 B

多元微积分初步：

非线性世界的局部显微镜

选读提示：本附录不做考核要求。它是配合线性代数主线的一段脚手架，不是一门压缩后的微积分课。我们只挑与向量、矩阵、映射和体积缩放直接相连的内容，帮助你读懂第 6 章的雅可比行列式，以及第 5.9 节的矢量场。下面使用的函数都选得足够平滑；遇到尖角、断裂等情形时，不能直接套用这些局部近似。

B.0 引子：二元函数

如果输出同时受两个输入影响，还能把函数画出来吗？一元函数 $y = f(x)$ 的输入是数轴上的一个数；二元函数 $z = f(x, y)$ 的输入是平面上的一对数，输出仍是一个数。把输出当作高度，就得到空间中的曲面。例如

$$z = f(x, y) = x^2 + y^2. \quad (\text{B.1})$$

在原点高度为 0，离原点越远，高度越大，图像像一只向上张开的碗。这里的 $(x, y)^T$ 正是第 0 章熟悉的二维输入向量，只是输出规则不再是线性的。把每个位置对应到一个数的函数，也称为标量场 (Scalar Field)；地形高度、温度都可以这样记录。

面对弯曲的世界，前面学过的矩阵还能帮什么忙？它不能把所有弯曲一次性变成直线，却能描述一个位置附近的小变化。我们把观察尺度缩小，就会反复遇到下面这些对应关系。表中说的是各概念的联系，不是把不同对象混为一谈。

微积分中的对象	线性代数中的对象	联系发生在哪里
导数	线性映射	把输入的小变化变成输出的一阶变化。
梯度	向量	把各坐标方向的变化率排成一支向量。
雅可比矩阵	矩阵	表示多输入、多输出函数的局部线性作用。
链式法则	矩阵乘法	复合函数的小变化，要依次经过两个局部映射。
散度	雅可比矩阵的迹	相加的是各坐标方向的自身变化率。
旋度	叉乘的分量结构	将三维叉乘的排列方式用于偏导运算。

下面的路线是：先从一个方向的斜率走到梯度，再看积分时的小面积，接着看流动中的向量，最后把这些图景收拢到局部矩阵与链式法则。你不必记住一整套微积分技巧，只需不断追问：**眼前的小变化，是由哪一个线性映射在近似描述？**

B.1 偏导数、梯度与方向导数

B.1.1 从一元导数到多元偏导数：变化率的多元视角

沿着地面走，哪一个方向的坡更陡？一元函数的导数记录沿自变量正方向的变化率；二元函数有两个坐标方向，不能只用一个数概括所有坡度。先固定 $y = b$ ，只让 x 变化，就得到一元函数 $x \mapsto f(x, b)$ 。它在 $x = a$ 处的导数称为对 x 的偏导数 (Partial Derivative)，记作 $f_x(a, b)$ 或 $\partial f / \partial x(a, b)$ 。固定 $x = a$ ，则得到对 y 的偏导数。

拿式(B.1)来说，求导时把另一个变量当作常数，便有

$$f_x(x, y) = 2x, \quad f_y(x, y) = 2y; \quad f_x(1, 2) = 2, \quad f_y(1, 2) = 4. \quad (\text{B.2})$$

这句话说的是：在 $(1, 2)$ 附近，沿 x 正方向前进一点，高度约增加前进距离的 2 倍；沿 y 正方向则约增加 4 倍。两个数分别对应标准基 e_1, e_2 所指的方向，和第 3 章“先看映射对基向量做什么”的思路相通。

B.1.2 梯度向量：把各方向的变化率放在一起

知道了两个坐标方向的坡度，能否合成一份方向记录？把偏导数依照输入坐标的顺序竖排，就得到梯度 (Gradient)：

$$\nabla f(x, y) = \begin{pmatrix} f_x(x, y) \\ f_y(x, y) \end{pmatrix}; \quad f = x^2 + y^2 \implies \nabla f(1, 2) = \begin{pmatrix} 2 \\ 4 \end{pmatrix}. \quad (\text{B.3})$$

梯度是一支**位于输入空间中的向量**，不是曲面上画出的高度箭头。它在每一点记录该处各方向的上升倾向。当它非零时，它的方向就是每单位行走距离上升最快的方向；为什么会这样，下一段用点积就能看清。

三元函数只需把三个偏导数排成一列，运算仍沿用第 0 章与第 1 章的向量规则。

B.1.3 方向导数与梯度的几何意义

斜着走时，坡度怎么算？取单位向量 u ，沿 $p + tu$ 移动。函数在这条路线上的瞬时变化率称为方向导数 (Directional Derivative)；对本附录的平滑函数，有

$$D_u f(p) = \nabla f(p) \cdot u = \|\nabla f(p)\| \cos \alpha, \quad \|u\| = 1. \quad (\text{B.4})$$

其中 α 是梯度与行走方向的夹角。方向导数是梯度在该方向上的**带符号的投影长度**，不是投影向量本身；同向时最陡，反向时下降最快，垂直时一阶变化为 0。这正是第 0 章点积的几何含义。若梯度为零，各方向的一阶变化率都为 0，不能据此指定唯一的最陡方向。[51]

把高度相同的输入点连起来，就得到等高线 (Level Curve)。梯度在非零时垂直于经过该点的等高线：沿等高线走，高度不变，切向的方向导数便为 0。




图 B.1: 灰色圆圈是 $f = x^2 + y^2$ 的等高线，同一圈上的高度相同；从 $p = (1, 0)^T$ 出发的蓝箭头是梯度，橙箭头是单位方向 u 。绿色虚线给出梯度在该方向上的投影，长度为方向导数；这与第 0 章用点积计算带符号投影是同一件事。

在图 B.1 中， $\nabla f(1, 0) = (2, 0)^T$ ，取 $u = (\sqrt{3}/2, 1/2)^T$ ，方向导数就是 $2 \times \sqrt{3}/2 + 0 \times 1/2 = \sqrt{3}$ 。再回到三维曲面看：偏导数是两条特定截线的切线斜率，梯度把这些斜率汇总到输入平面。两幅图说的是同一个函数的两种观察方式。




图 B.2: 蓝色网格画出曲面 $z = x^2 + y^2$ ，切点为 $(0.6, 0.4, 0.52)$ ；两条有色直线分别沿固定 y 、固定 x 的截线相切，斜率为 1.2 和 0.8。把这两个斜率按坐标顺序排列，就得到输入平面中的梯度向量，呼应第 3 章按标准基组织映射信息的方式。

B.2 多重积分与换元法

B.2.1 二重积分与三重积分：把小块的贡献加起来

知道某处的高度或密度，怎样得到整个区域的总量？一元积分把许多“小宽度乘以函数值”加起来。二维只是把小线段换成小面积：把区域 D 切成小块，第 i 块面积为 ΔS_i ，在块内取一点 (x_i, y_i) ，其贡献近似为 $f(x_i, y_i)\Delta S_i$ 。网格越细，这种黎曼和 (Riemann Sum) 越能贴近总量，记号写成二重积分 (Double Integral)：

$$\iint_D f(x, y) dx dy \approx \sum_i f(x_i, y_i) \Delta S_i. \quad (\text{B.5})$$

近似号右边是有限小块的求和；左边表示把网格不断细分后得到的积分。若 $f \geq 0$ 是高度，总量是曲面下的体积；若 f 是面密度，总量是质量。这里相加的是贡献，不是把各点的坐标加起来。


三维里，把面积块换成体积块，就得到三重积分 (Triple Integral) $\iiint_{\Omega} f dx dy dz$ 。例如边长为 1 的正方形上高度恒为 2，体积就是 $2 \times 1 = 2$ ；体积为 3 的区域里密度恒为 4，质量就是 12。计算的出发点仍是第 6 章熟悉的面积和体积，微积分只是允许密度或形状逐处改变。

B.2.2 从直角坐标到极坐标：小格子的宽度为什么会变


同一块区域换一套坐标描述，每个小格子的面积还一样吗？圆盘用半径和角度来描述更自然。极坐标 (Polar Coordinates) 把输入写成 (r, θ) ，并用

$$x = r \cos \theta, \quad y = r \sin \theta, \quad r \geq 0. \quad (\text{B.6})$$

描述同一个平面位置。固定角度走一点，移动长度约为 dr ；固定半径转过一点角度，弧长约为 $r d\theta$ ，其中角度用弧度。越靠外，同样的角度张得越宽。



直角坐标：均匀的小格子



极坐标：越往外，格子越宽

图 B.3: 左图的绿色格子有宽 dx 、高 dy ；右图的绿色格子沿半径厚 dr ，沿圆周宽约 $r d\theta$ 。因此极坐标面积微元多出一个 r 因子；它就是第 6 章面积缩放因子在局部坐标变换中的一个例子，图中的格子为便于观察已放大。

一个半径为 r 、厚度为 Δr 、角宽为 $\Delta\theta$ 的有限扇形格，面积为 $r\Delta r\Delta\theta + \frac{1}{2}(\Delta r)^2\Delta\theta$ 。忽略比一阶厚度更小的那项，便得到面积微元

$$dx dy = r dr d\theta. \quad (\text{B.7})$$

这不是说一个有限扇形恰好是矩形，而是说在足够小的尺度下，径向厚度乘圆周宽度给出它的主要面积。于是单位圆盘面积可写成 $\int_0^{2\pi} \int_0^1 r dr d\theta = \pi$ ；漏掉 r ，便把外圈宽格子与内圈窄格子当成了同样大小。

B.2.3 换元法的一般形式：雅可比行列式是局部缩放因子

如果坐标变换比极坐标更复杂，还能找到这个面积倍率吗？设 $x = x(u, v)$ 、 $y = y(u, v)$ ，先把各输出对各输入的偏导数排成雅可比矩阵 (Jacobian Matrix)：

$$J = \begin{pmatrix} x_u & x_v \\ y_u & y_v \end{pmatrix}, \quad dx dy = |\det J| du dv. \quad (\text{B.8})$$

两列分别描述沿 u 、 v 方向迈出小步后，位置在 xy 平面中的一阶变化。它们围成的小平行四边形的面积倍率，就是雅可比行列式 (Jacobian Determinant) 的绝对值；取绝对值是因为面积不带方向正负。第 6 章用行列式度量线性变换的整体缩放，这里用同一规则度量非线性变换的局部缩放。




图 B.4: 左侧绿色小格经过变换 $H(u, v) = (u, v + 0.4u^2)^T$ ，在中间变成橙色曲边格；右侧放大图用蓝色平行四边形近似它在一点附近的形状。这里 $|\det J| = 1$ ，局部面积倍率为 1；第 6 章的行列式仍在计算两条局部边围出的面积，而不是衡量整幅曲线网格是否弯曲。

把面积倍率放进求和，便得到换元积分公式。这里要求变换在所用区域内不把不同小块折叠到同一处、局部倍率不为零；边界或极坐标原点等特殊位置另行处理。对这样的区域对应 $S \rightarrow D$ ，有

$$\iint_D f(x, y) dx dy = \iint_S f(x(u, v), y(u, v)) |\det J(u, v)| du dv. \quad (\text{B.9})$$

右边仍在计算左边的同一份总量，只是改用新坐标，并给每个小格补上真实的面积倍率。三维同理，用 3×3 雅可比矩阵的行列式绝对值乘体积微元。[52]

极坐标能否经受这个矩阵检查？把式(B.6)求偏导，得到

$$J(r, \theta) = \begin{pmatrix} \cos \theta & -r \sin \theta \\ \sin \theta & r \cos \theta \end{pmatrix}, \quad \det J = r \cos^2 \theta + r \sin^2 \theta = r. \quad (\text{B.10})$$

第一列是一支径向单位向量，第二列是一支长度为 r 的切向向量；二者垂直，底乘高恰好给出 r 。刚才的小格子直觉，现在成了一次可以核对的矩阵计算。

B.3 向量场、散度与旋度

B.3.1 从静态向量到空间中的流动

一支向量描述一个位置的速度，整个空间的速度怎样描述？给空间中每个点都指定一支向量，就得到向量场，也就是第 5.9 节已经见过的矢量场 (Vector Field)。这里统一写成 $\mathbf{v}(\mathbf{x})$ ，它记录位置 $\mathbf{x}$ 处的速度；也可以记录力，或一般状态的变化率。

线性场尤其熟悉： $\mathbf{v}(\mathbf{x}) = A\mathbf{x}$ 。同一个矩阵在各处作用，但输入位置不同，箭头便不同。若粒子随这些箭头流动，它的位置满足 $\dot{\mathbf{x}} = A\mathbf{x}$ ；箭头是此刻的速度，轨线则是随时间走出的路径，二者不能混为一谈。




图 B.5: 左图的 $\mathbf{v} = (x, y)^T$ 从原点向外展开；右图的 $\mathbf{v} = (y, 0)^T$ 水平流动，上方越高，箭头越长。每支箭头都属于它所在的点，这两个例子分别由单位矩阵和剪切型矩阵产生，与第 5 章连续线性系统的状态箭头图直接相连。

B.3.2 散度：各方向的膨胀率为什么要相加

流动是在把一小团物质撑开，还是把它挤紧？散度 (Divergence) 记录一个位置附近单位体积的净流出率。在二维用单位面积理解，对 $\mathbf{v} = (v_x, v_y)^T$ ，定义

$$\operatorname{div} \mathbf{v} = \frac{\partial v_x}{\partial x} + \frac{\partial v_y}{\partial y}. \quad (\text{B.11})$$

第一项比较小格子左右两边的水平流动，第二项比较上下两边的竖直接流动：流出去的多，结果为正；反过来则为负。三维再加上 $\partial v_z / \partial z$ 。它衡量净膨胀，不是只看箭头是否朝外，也不是把速度的三个分量直接相加。




图 B.6: 绿色小区域的红边界用来比较流入与流出：左侧场 $\mathbf{v} = \mathbf{x}$ 向外撑开，右侧场 $\mathbf{v} = -\mathbf{x}$ 向内收紧。它们的散度分别为 2 与 -2，恰好是相应矩阵的迹；这里度量的是瞬时的相对面积变化，与第 6 章行列式度量的面积倍率相呼应。

这些相加的量在线性代数里叫什么？方阵对角线上元素的和称为迹 (Trace)，记作 $\operatorname{tr} A$ 。偏导数矩阵的对角线恰好是式(B.11)中的各项，所以

$$\operatorname{div} \mathbf{v}(\mathbf{x}) = \operatorname{tr} J_{\mathbf{v}}(\mathbf{x}), \quad \mathbf{v} = A\mathbf{x} \implies \operatorname{div} \mathbf{v} = \operatorname{tr} A. \quad (\text{B.12})$$

散度等于场的雅可比矩阵的迹；线性场的雅可比处处都是 A ，散度因而是常数。图 B.5 的剪切场有运动，却没有净面积膨胀，因为它的迹为 0。[53]

为什么这个和能说明体积变化？经过很短的时间 Δt ，线性场中的位移近似由 $E + \Delta t A$ 作用产生。对于 2×2 的 A ，直接展开行列式有

$$\det(E + \Delta t A) = 1 + \operatorname{tr} A \Delta t + \det A (\Delta t)^2. \quad (\text{B.13})$$

忽略二次小量，面积相对于原面积的变化约为 $\operatorname{tr} A \Delta t$ 。因此迹给出的是瞬时相对膨胀率，不是经过一段有限时间后的全部面积倍率；后者还要看持续演化。这把第 5 章的动态箭头与第 6 章的行列式接在了一起。

B.3.3 旋度：小桨轮会不会转起来

如果放入一只很小的桨轮，流动会让它转动吗？旋度 (Curl) 描述这种局部旋转倾向。三维场 $\mathbf{v} = (v_x, v_y, v_z)^T$ 的旋度写成

$$\nabla \times \mathbf{v} = \begin{pmatrix} \partial v_z / \partial y - \partial v_y / \partial z \\ \partial v_x / \partial z - \partial v_z / \partial x \\ \partial v_y / \partial x - \partial v_x / \partial y \end{pmatrix}. \quad (\text{B.14})$$

每个分量都比较两个横向变化率，它们的差决定绕相应轴的旋转倾向。符号 $\nabla \times \mathbf{v}$ 沿用三维叉乘的分量排列，但 ∇ 在这里是一组求偏导的操作，不是一支普通数值向量；它要作用于场的分量。




图 B.7: 蓝箭头画出刚体旋转场 $\mathbf{v} = (-y, x, 0)^T$ ，沿圆周切线指向逆时针，长度随半径增大；中心的圆点符号表示旋度沿 z 轴正向、朝读者伸出。其旋度为 $(0, 0, 2)^T$ ，方向遵循右手法则，分量排列与第 6 章三维叉乘相连；这个 2 是角速度 1 的两倍。

更一般的刚体场 $\mathbf{v} = (-\omega y, \omega x, 0)^T$ 的旋度为 $(0, 0, 2\omega)^T$ ，不要把旋度大小直接当作角速度。散度则为 0：它在转动，却没有净体积膨胀。这与旋转矩阵保持体积的图景相符。

不旋转就一定能由一个函数产生吗？对本附录的平滑函数，梯度场 $\mathbf{v} = \nabla \phi$ 的旋度为零，因为成对的混合偏导相消； ϕ 称为势函数 (Potential Function)。反过来，“旋度为零”能推出势函数，通常需要在所讨论区域内没有绕不过去的孔洞等条件，不能不加条件地断言。局部取一个足够小、无孔洞的区域，就可以这样理解。[53] 例如 $\mathbf{v} = (2x, 2y, 0)^T$ 来自 $\phi = x^2 + y^2$ ；物理中也常把保守力 (Conservative Force) 写成 $-\nabla \phi$ ，负号表示力指向势能下降的方向。本附录到这里为止，不展开势函数的求法。

B.4 非线性变换的局部线性化与链式法则

B.4.1 一元函数的线性逼近：先把观察尺度缩小

一条曲线弯着走，直线为什么还能近似它？在某点附近，切线抓住该点的高度和瞬时斜率。把展开点记为 a ，输入的小变化记为 h ，一阶近似写成

$$f(a+h) \approx f(a) + f'(a)h. \quad (\text{B.15})$$

右边就是一阶泰勒多项式：起点的函数值，加上“斜率乘小位移”。例如 $f(x) = x^2$ ，在 $a = 1$ 处， $(1+h)^2 = 1 + 2h + h^2$ ；取 $h = 0.1$ ，线性近似为 1.2，实际为 1.21，误差 0.01；取 $h = 0.01$ ，误差就变为 0.0001。缩小尺度，弯曲造成的差别也随之减小。

这就是局部线性化 (Local Linearization)。需要留意第 4 章讲过的区别： $h \mapsto f'(a)h$ 是对变化量的线性映射；带有起点常数项的整条切线通常是仿射的。我们不是说原函数突然成了线性函数，而是说它的小变化有一个线性的主要部分。

B.4.2 多元函数的线性逼近：由斜率向量走到雅可比矩阵

曲线有切线，曲面有没有相应的近似？对标量函数 $f(x, y)$ ，在 (a, b) 附近把两个坐标方向的变化合起来，得到切平面 (Tangent Plane)：

$$f(a+h_1, b+h_2) \approx f(a, b) + f_x(a, b)h_1 + f_y(a, b)h_2 = f(a, b) + \nabla f(a, b) \cdot \mathbf{h}. \quad (\text{B.16})$$

这里 $\mathbf{h} = (h_1, h_2)^T$ 。每个坐标方向贡献一份一阶高度变化，相加就得到平面的高度；这仍是第 1 章的线性组合。




图 B.8: 左图的蓝色网格是 $z = x^2 + y^2$ ，红色平面在 $(0.6, 0.4, 0.52)$ 处与它相切；右图固定 $y = 0.4$ 后放大比较曲线与切线，橙色线段标出近似误差。离切点更近，误差从 0.16 减到 0.04；对向量值函数，这种对小变化的线性近似由雅可比矩阵表示，呼应第 3 章的矩阵与映射。

输出有两个分量时，怎样记录它们的局部变化？把 $u(x, y)$ 、 $v(x, y)$ 竖排为 $F(x, y)$ ，再按输出逐行排列偏导数，得到

$$J_F(\mathbf{p}) = \begin{pmatrix} u_x(\mathbf{p}) & u_y(\mathbf{p}) \\ v_x(\mathbf{p}) & v_y(\mathbf{p}) \end{pmatrix}, \quad F(\mathbf{p} + \mathbf{h}) - F(\mathbf{p}) \approx J_F(\mathbf{p})\mathbf{h}. \quad (\text{B.17})$$

矩阵把输入的小位移送到输出的小位移。它随观察点改变，但在固定一点后，就是第 3 章已经会使用的线性映射矩阵。一般的 n 个输入、 m 个输出对应 $m \times n$ 雅可比矩阵；只有输入、输出维数相同时，才能谈它的行列式。




图 B.9: 左图是均匀的输入网格，中间是 $H(x, y) = (x, y + 0.4x^2)^T$ 产生的弯曲网格；橙色小格被圈出，在右侧放大。右图蓝边是雅可比矩阵给出的平行四边形，橙边保留真实的弯曲差别；全局非线性与局部的一阶线性近似同时可见，正是“先看见，再理解，最后计算”的矩阵视角。

这幅图可以亲手验算。在 $\mathbf{p} = (0.5, 0.5)^T$ 处，雅可比矩阵的两列分别为 $(1, 0.4)^T$ 、 $(0, 1)^T$ 。取 $\mathbf{h} = (0.1, 0)^T$ ，矩阵预测输出变化为 $(0.1, 0.04)^T$ ；真实变化为 $(0.1, 0.044)^T$ 。差出的 0.004 来自 $0.4h_1^2$ ；缩小输入变化，这项就比主要变化消失得更快。**局部线性化近似的是变化量，不是把原函数变成全局线性函数。**

B.4.3 链式法则：微积分中的矩阵乘法

一个小变化先经过一层函数，再经过另一层，最后怎样传下去？一元复合 $z = f(y)$ 、 $y = g(x)$ 满足链式法则 (Chain Rule): $\frac{dz}{dx} = f'(g(x))g'(x)$ 。先由 g 的斜率放大输入变化，再由 f 在**中间输出处**的斜率放大，两个倍率相乘。

多元复合不再只有一个倍率，却仍是同一条路线。设 $G: \mathbb{R}^n \rightarrow \mathbb{R}^m$ 、 $F: \mathbb{R}^m \rightarrow \mathbb{R}^p$ ，则

$$J_{F \circ G}(\mathbf{x}) = J_F(G(\mathbf{x}))J_G(\mathbf{x}), \quad (p \times m)(m \times n) = p \times n. \quad (\text{B.18})$$

输入变化先乘右边的 J_G ，再乘左边的 J_F ；后一矩阵要在 $G(\mathbf{x})$ 处取值。于是第 3.3 节的“矩阵乘法表示映射复合”，在微积分里成为小变化的传递法则。

不妨用一个两层规则核对。取 $G(x, y) = (x^2, y)^T$, $F(u, v) = (u + v, 2v)^T$ 。在 $(1, 1)$ 处有

$$J_G = \begin{pmatrix} 2 & 0 \\ 0 & 1 \end{pmatrix}, \quad J_F = \begin{pmatrix} 1 & 1 \\ 0 & 2 \end{pmatrix}, \quad J_F J_G = \begin{pmatrix} 2 & 1 \\ 0 & 2 \end{pmatrix}. \quad (\text{B.19})$$

直接对复合函数 $(x^2 + y, 2y)^T$ 求偏导，也得到最后这个矩阵。维数、乘法次序、数值三者一起对上了；交换次序一般会描述另一条路线。

B.4.4 局部线性化的代数意义：重访“先看见，再理解，最后计算”

这些图为什么都能用线性代数解释？偏导数记录局部基方向的作用；梯度把标量输出的变化率排成向量；雅可比把多分量输出的变化排成矩阵；链式法则把局部映射复合；行列式读出局部的面积或体积倍率。

先看见曲线、曲面与流动，再理解小尺度上的线性结构，最后用矩阵计算：这不是忽略弯曲，而是使用与观察尺度相配的尺子。线性代数就是非线性世界的局部显微镜，但要说明在哪一点、看多小的变化，以及忽略了什么。

B.5 【应用案例】梯度下降与反向传播

B.5.1 参数也是向量：让误差往下走

网络输出与目标有差别，怎样判断应当调哪一个参数？把所有参数按固定顺序排成向量 θ ，用损失函数 (Loss Function) $\mathcal{L}(\theta)$ 记录预测偏差。它是一个多元标量函数，梯度的每个分量回答“单独增加这个参数一点，损失的一阶变化有多大”。

想让损失下降，就沿负梯度试着走一小步。这称为梯度下降 (Gradient Descent)：

$$\theta_{\text{new}} = \theta - \eta \nabla \mathcal{L}(\theta), \quad \eta > 0. \quad (\text{B.20})$$

正数 η 称为学习率 (Learning Rate)，控制这一步走多远。在梯度非零且步子足够小时，损失的一阶变化为 $-\eta \|\nabla \mathcal{L}\|^2$ ，是负数；走得太大则可能越过低处，不能保证下降。梯度为零也不自动说明找到了最低点，更不保证找到了全局最优解。

B.5.2 反向传播：沿着复合路线把变化率送回来

层数很多时，每个参数都要从头求一遍导数吗？不必。第 3 章已经见过网络中的矩阵运算，这里把一层写成 $h_\ell = \sigma(W_\ell h_{\ell-1} + c_\ell)$ ，其中 σ 是逐分量作用的激活函数 (Activation Function)。矩阵部分线性，激活部分一般非线性；整个网络不能当作一个固定的线性映射。

在当前输入处，把激活函数的各分量导数放在对角矩阵 D_ℓ 上，这一层对输入小变化的局部矩阵便是 $J_\ell = D_\ell W_\ell$ 。多层正向变化依照式(B.18)逐层相乘。反向传播 (Back-propagation) 则用同一条链式法则，从输出端向输入端传递损失的梯度。若 $\mathbf{g}_\ell$ 是损失对本层输出的梯度，则

$$\mathbf{g}_{\ell-1} = J_\ell^T \mathbf{g}_\ell = W_\ell^T D_\ell^T \mathbf{g}_\ell. \quad (\text{B.21})$$

转置把输出各方向的损失敏感度汇总到输入各方向；它不是把非线性网络“求逆”。这与第3章的转置、矩阵乘法和复合映射相接。反向传播负责**算梯度**，梯度下降负责**用梯度更新参数**，两件事分工不同。[54]

B.5.3 一个可以手算的微型网络

能否看见一次更新到底改变了什么？以下是**教学简化模型**，不代表 Transformer 或任何实际产品的内部实现。输入固定为 $\mathbf{x} = (1, 2)^T$ ，网络只有一个隐藏输出，目标为 1：

$$z = \mathbf{w}^T \mathbf{x}, \quad h = \tanh z, \quad \hat{y} = v h, \quad \mathcal{L} = \frac{1}{2}(\hat{y} - 1)^2. \quad (\text{B.22})$$

这里 $\tanh z = (e^z - e^{-z}) / (e^z + e^{-z})$ 是把输入平滑压到 -1 与 1 之间的激活函数，导数为 $1 - \tanh^2 z$ ；两个待调的输入权重在 $\mathbf{w}$ 中，输出权重是 v 。

先取 $\mathbf{w} = (0, 0)^T$ 、 $v = 1$ 。正向计算给出 $z = 0, h = 0, \hat{y} = 0, \mathcal{L} = 1/2$ 。反向依次经过平方误差、乘法、激活和输入乘法，得到

$$\frac{\partial \mathcal{L}}{\partial v} = (\hat{y} - 1)h = 0, \quad \nabla_{\mathbf{w}} \mathcal{L} = (\hat{y} - 1)v(1 - h^2)\mathbf{x} = \begin{pmatrix} -1 \\ -2 \end{pmatrix}. \quad (\text{B.23})$$

这次输出权重的一阶梯度为 0，两个输入权重的梯度分别为 $-1, -2$ ，是各层局部变化率连乘后传回的结果。取学习率 $\eta = 0.1$ ，同步更新便得到 $\mathbf{w}_{\text{new}} = (0.1, 0.2)^T$ 、 $v_{\text{new}} = 1$ 。重新正向计算有 $z_{\text{new}} = 0.5$ 、 $\hat{y}_{\text{new}} \approx 0.4621$ ，损失约为 0.1447，确实小于原来的 0.5。

这个小模型展示了一条路线：用向量存参数，用矩阵传小变化，用链式法则求梯度，再沿负梯度调整。第3章的 Transformer 展示了矩阵怎样组织计算，本附录补上了非线性计算怎样在局部求导。它的任务正是：**在非线性世界里，辨认出可以用线性代数理解的一小片结构。**

术语表

本表按英文术语的首字母分组，组内按英文字母顺序排列，统一采用“中文术语 (English Term) [释义]”格式。条目涵盖已撰写正文与附录 A、B 的关键概念；正文只作预告的后续术语，在释义中注明相应章节。英语中的同义说法及本书采用的简称，尽量合并在同一词条中。

A

绝对收敛 (Absolute Convergence) [无穷和中各项绝对值（复数项取模）的和有限；附录用它说明复指数展开可以按奇偶次幂分组。]

抽象向量空间 (Abstract Vector Space) [不限定元素具体形式，只要求加法与数乘满足向量空间公理的集合。]

激活函数 (Activation Function) [神经网络中对线性组合结果施加的函数，常逐分量作用并引入非线性；局部导数参与链式法则。]

主动旋转 (Active Rotation) [固定坐标基，对向量或物体施加旋转作用，用同一组基记录作用前后的坐标；转轴上的向量可以保持不变。]

加减消元法 (Addition Method of Elimination) [把一个方程的倍数加到另一个方程，以消去某个未知数的方法。]

映射的加法 (Addition of Maps) [对同定义域、同目标空间的映射逐点相加， $(S + T)(x) = S(x) + T(x)$ 。]

相反向量 (Additive Inverse) [与原向量相加得到零向量的向量，记为 $-v$ 。]

可加性 (Additivity) [映射保持向量加法的性质，即 $T(x + y) = T(x) + T(y)$ 。]

伴随矩阵 (Adjugate Matrix) [代数余子式数表的转置，记作 $\text{adj}(A)$ ；其第 i 列是第 i 行对应的代数余子式向量，满足 $A \text{adj}(A) = \det(A)E$ 。]

仿射映射 (Affine Map) [由线性作用与固定平移组成的映射 $x \mapsto Ax + a$ ；在原向量空间中，只有 $a = 0$ 时才是线性映射。]

仿射子空间 (Affine Subspace) [子空间的一次平移 $p + W$ ；其维数为 $\dim W$ ，当 $p \notin W$ 时不经过原点。]

交替最小二乘法 (Alternating Least Squares) [交替固定一组参数、对另一组参数求解最小二乘问题的方法；第 3 章以它说明推荐教学模型中的矩阵求解。]

交错性 (Alternation) [本书实数情形中, 交换两个输入使函数值变号的性质; 与多重线性结合时, 两输入相同则值为 0。]

向量夹角 (Angle Between Vectors) [两个非零实向量的夹角, 取值在 $[0, \pi]$; 余弦等于点积除以两向量长度之积。]

辐角 (Argument) [从正实轴转向非零复数所对应向量的有向角, 相差 $2k\pi$ 的角表示同一方向。]

结合律 (Associative Law) [改变相邻运算的分组方式不改变结果; 如 $(u + v) + w = u + (v + w)$ 。]

注意力机制 (Attention Mechanism) [根据查询与键计算权重, 再对值向量加权求和的信息汇聚方法; 第 3 章介绍性实例采用单头的简化图示。]

姿态矩阵 (Attitude Matrix) [常指机体系相对参考系的方向余弦矩阵; 只改变参考基时按坐标转换链左乘。若记录同一个旋转作用并同时更换输入与输出的基, 其表示矩阵才按相似关系改变。]

增广矩阵 (Augmented Matrix) [在系数矩阵右侧附上常数项列得到的矩阵, 记为 $[A \mid b]$ 。]

B

回代 (Back Substitution) [从阶梯形的最后一个有效方程开始, 逐行向上求出主元变量的方法。]

反向传播 (Backpropagation) [利用链式法则, 从计算的输出端向前层依次传递梯度的方法; 负责计算梯度, 与使用梯度更新参数的优化步骤不同。]

主元变量 (Basic Variable) [系数部分的主元列所对应的未知数; 有解时由自由变量确定。]

基 (Basis) [既线性无关又张成整个所讨论空间的向量组。]

基扩充定理 (Basis Extension Theorem) [有限维空间中的任意线性无关组, 都能通过添加该空间中的向量扩充为一组基。]

双射 (Bijection) [同时为单射和满射的映射; 每个目标元素恰好对应一个输入。]

分块对角矩阵 (Block Diagonal Matrix) [除主对角块之外各块均为零的矩阵; 本书讨论的可逆性结论要求对角块为方阵。]

分块矩阵 (Block Matrix) [按若干固定行、列边界分成子矩阵的矩阵, 用于记录分组输入与分组输出之间的作用。]

分块上三角矩阵 (Block Upper Triangular Matrix) [主对角块下方各块全为零的分块矩阵, 可按组从后向前求解对应方程。]

C

加法消去律 (Cancellation Law for Addition) [由 $u + w = v + w$ 可推出 $u = v$ 。]

柯西-施瓦茨不等式 (Cauchy-Schwarz Inequality) [实向量点积的绝对值不超过两向量长度之积；保证非零向量夹角余弦公式的取值在 $[-1, 1]$ 内，第 7 章给出证明。]

中心 (Center) [附近非平衡状态沿闭合轨线绕行的典型矢量场形态；本书用二维圆周运动模型建立直观。]

链式法则 (Chain Rule) [复合函数的局部变化率由各层局部映射复合得到；多元情形按正确取值位置将雅可比矩阵依次相乘。]

基变换 (Change of Basis) [改变描述向量所用的有序基，从而改变坐标表示；向量本身不变。第 4 章选读讨论坐标转换。]

过渡矩阵 (Change-of-Coordinates Matrix) [把同一向量在一组有序基下的坐标转换到另一组基下的坐标的可逆矩阵；必须同时指明输入基与输出基。]

对运算封闭 (Closure under an Operation) [集合中允许的元素按指定运算组合后，结果仍属于该集合。]

陪域 (Codomain) [定义映射时预先指定的目标集合；对 $T: \mathbb{R}^n \rightarrow \mathbb{R}^m$ ，陪域为 $\mathbb{R}^m$ ，其中的元素不一定都被取到。]

系数 (Coefficient) [在给定表达式中乘在未知数或向量前的数。]

系数矩阵 (Coefficient Matrix) [按固定未知数次序逐行收集线性方程组系数形成的数表。]

代数余子式 (Cofactor) [余子式乘位置符号所得的数， $A_{ij} = (-1)^{i+j}M_{ij}$ ；本章矩阵元素另记作小写 a_{ij} 。]

代数余子式向量 (Cofactor Vector) [由某一行的全部代数余子式组成的向量，记作 c_i ；垂直于其余各行，与该行的点积为行列式。]

冷启动 (Cold Start) [新用户或新内容缺少交互记录、相应参数尚未充分训练的推荐问题；不能简单等同于向量不在某个子空间中。]

共线 (Collinear) [向量起点统一后位于同一直线上；两个非零向量共线当且仅当一个是另一个的数倍。]

列秩 (Column Rank) [矩阵列向量张成空间的维数；等于矩阵的秩，也等于行秩。]

列空间 (Column Space) [矩阵各列向量张成的空间，即全部可能输出组成的集合； $m \times n$ 矩阵的列空间是 $\mathbb{R}^m$ 的子空间。第 3.5 节从转置引入。]

列向量 (Column Vector) [将分量按固定次序竖排得到的向量形式。]

交换图 (Commutative Diagram) [用箭头表示映射，且任意两条起终点相同的相配路径具有相同的合成作用；本书用它说明换基与矩阵表示的关系。]

交换律 (Commutative Law) [交换运算对象的次序不改变结果；如 $u + v = v + u$ 。]

共轭复数 (Complex Conjugate) [与 $z = a + bi$ 对应的 $\bar{z} = a - bi$ ，在复平面上关于实轴镜像对称。]

复指数 (Complex Exponential) [对实数 a, θ , $e^{a+i\theta} = e^a(\cos \theta + i \sin \theta)$ ；模为 e^a ，辐角可取 θ 。]

复数 (Complex Number) [形如 $a + bi$ 的数，其中 $a, b \in \mathbb{R}$, $i^2 = -1$ 。]

复平面 (Complex Plane) [将复数 $a + bi$ 对应到点 (a, b) 的坐标平面，横轴为实轴，纵轴为虚轴。]

复向量空间 (Complex Vector Space) [以复数作为数乘系数的向量空间；讨论线性关系时必须允许复系数。]

分量 (Component) [有序数组中某个固定位置的数，位置次序是向量表示的一部分。]

复合 (Composition) [把一个映射的输出作为另一个映射的输入； $(S \circ T)(x) = S(T(x))$ ，先作右侧映射。]

保守力 (Conservative Force) [可由单值势能函数的负梯度表示的力；力的方向指向势能下降的方向。]

有解 (Consistent) [线性方程组至少有一个公共解，也称相容。]

常数项 (Constant Term) [线性方程中不含未知数的已知量；本书通常将其放在等号右端。]

内容空间 (Content Space) [教学推荐案例中由给定视频特征向量张成的子空间；不是有限视频集合本身。]

坐标向量 (Coordinate Vector) [将向量关于有序基的表示系数按次序排成的列向量，记为 $[v]_{\mathcal{B}}$ 。]

坐标 (Coordinates) [向量关于一组有序基的唯一线性表示系数，随所选基及其顺序而定。]

共面 (Coplanar) [向量起点统一后位于同一个平面内；三个空间向量共面时线性相关。]

余弦相似度 (Cosine Similarity) [两个非零实向量的标准内积除以各自长度的乘积，用于比较方向的接近程度。]

叉乘 (Cross Product) [两支三维向量所确定的法向量，长度为平行四边形面积，方向按右手法则；共线时为零向量。]

旋度 (Curl) [三维向量场横向偏导数按叉乘结构成对作差得到的向量，描述局部旋转倾向；刚体旋转场的旋度为角速度向量的两倍。]

D

棣莫弗定理 (De Moivre's Theorem) [对整数 n , $(\cos \theta + i \sin \theta)^n = \cos(n\theta) + i \sin(n\theta)$ 。]

自由度 (Degrees of Freedom) [表示全部解所需的独立自由参数个数；线性方程组有解时等于相应零空间的维数。]

导数 (Derivative) [函数相对于自变量的瞬时变化率，记作 f' ；求导保持函数的加法与实数数乘。]

互相关矩阵 (Detector Correlation Matrix) [本书在特征探测器语境中指矩阵 $A^T A$ ；其第 (i, j) 个元素为列向量的点积 $a_i \cdot a_j$ ，对角线记录自身增益，非对角线记录重叠响应；这里未作归一化，不是统计学的相关系数矩阵。]

行列式 (Determinant) [与方阵对应的标量，绝对值是线性变换的体积缩放倍数，符号记录方向是否翻转；为零时方阵不可逆。第 6 章展开。]

对角矩阵 (Diagonal Matrix) [主对角线以外的元素全为零的方阵，对应各坐标分量分别缩放。]

矩阵对角化 (Diagonalization) [选择适当的基，使某个线性变换的矩阵表示成为对角矩阵；并非所有方阵都能对角化。第 9 章展开。]

维数 (Dimension) [有限维空间中任意一组基所含的向量个数，记为 $\dim V$ ；零子空间的维数为 0。]

维数公式 (Dimension Formula) [有限维子空间满足 $\dim(U + V) = \dim U + \dim V - \dim(U \cap V)$ 。]

直和 (Direct Sum) [当 $U \cap V = \{0\}$ 时的子空间和，记作 $U \oplus V$ ；等价地，每个和向量的分解唯一。]

有向角 (Directed Angle) [同时记录转动大小与方向的角；本附录约定逆时针为正、顺时针为负。]

方向余弦矩阵 (Direction Cosine Matrix) [两组单位且两两垂直的基之间的坐标过渡矩阵；第 (i, j) 个元素为旧基第 i 个向量与新基第 j 个向量的夹角余弦，须注明换算方向。]

方向导数 (Directional Derivative) [沿指定单位方向的瞬时变化率；对本附录的平滑函数，等于梯度与该单位方向的点积，是带符号的投影长度。]

离散余弦变换 (Discrete Cosine Transform) [把有限个采样值改写为不同余弦模式的系数；本书使用规范化的二型 DCT，完整保留系数时可以逆变换恢复输入。]

离散线性动力系统 (Discrete-Time Linear Dynamical System) [按离散时刻用线性规则更新状态的系统，如 $x_{k+1} = Fx_k + u_k$ ；解是一串状态记录。]

分配律 (Distributive Law) [数乘对向量加法与标量加法分别满足分配规则。]

散度 (Divergence) [向量场各分量对相同坐标方向的偏导数之和，即场的雅可比矩阵的迹；表示局部单位体积的净流出率。]

定义域 (Domain) [映射允许的全部输入组成的集合；对 $T: \mathbb{R}^n \rightarrow \mathbb{R}^m$ ，定义域为 $\mathbb{R}^n$ 。]

数量积 (点积) (Dot Product) [实向量对应分量乘积之和；在二维、三维中等于两向量长度之积乘夹角余弦，零向量与任意向量的点积为 0。]

二重积分 (Double Integral) [对平面区域上小面积的函数贡献进行累积的积分；可表示曲面下的体积或由面密度决定的总质量。]

对偶基 (Dual Basis) [与一组基对应的坐标提取泛函所组成的基; 标准基的对偶基由 $\alpha_j(\mathbf{x}) = x_j$ 这些坐标尺子组成, 每个线性评分器由它们唯一线性组合得到。]

对偶映射 (Dual Map) [线性映射 $T: V \rightarrow W$ 所诱导的反向评价传递 $T': W' \rightarrow V'$, 定义为 $T'(\varphi) = \varphi \circ T$; 在标准对偶基下由转置矩阵表示, 不是逆映射。]

对偶空间 (Dual Space) [实向量空间 V 上全体线性泛函按逐点加法与数乘组成的向量空间, 记为 V' ; 有限维时与 V 维数相等, 可理解为所有线性测量尺子的集合。]

E

特征空间 (Eigenspace) [给定特征值对应的全部特征向量连同零向量构成的子空间; 第 8 章展开。]

特征值 (Eigenvalue) [线性变换在某个非零向量方向上表现为数乘时的缩放系数; 第 8 章展开。]

初等列变换 (Elementary Column Operations) [交换两列、非零倍乘一列、把一列的倍数加到另一列, 分别对应右乘合适的初等矩阵。]

同解初等变换 (Elementary Equation Operations) [交换方程、非零倍乘一个方程、把一方程的倍数加到另一方程的操作, 均保持解集不变。]

初等矩阵 (Elementary Matrix) [由单位矩阵作一次初等行变换得到的矩阵; 左乘它等价于对原矩阵作同一次行变换。]

初等行变换 (Elementary Row Operations) [交换两行、非零倍乘一行、把一行的倍数加到另一行的三种矩阵操作。]

消元乘数 (Elimination Multiplier) [也称消元倍数; 行消元 $r_i \leftarrow r_i - \ell_{i,k}r_k$ 中的系数 $\ell_{i,k}$; 无换行的标准 LU 消元将它记录在 L 的第 (i, k) 位置。]

向量嵌入 (Embedding) [把对象或特征表示为供模型计算的向量, 其分量不必对应人为命名的现实属性。]

嵌入表 (Embedding Table) [按对象或特征 ID 索引向量参数的数据组织方式; 数学上可将有限表理解为每个 ID 对应一行的矩阵。]

平衡状态 (Equilibrium State) [更新后或随时间不改变的状态; 离散系统满足 $(E - F)\mathbf{x}_* = \mathbf{u}$, 齐次连续系统满足 $A\mathbf{y}_* = \mathbf{0}$ 。]

同解方程组 (Equivalent Linear Systems) [解集相同的两个线性方程组。]

等价向量组 (Equivalent Sets of Vectors) [能够相互线性表示的向量组; 其张成空间相同, 但向量个数可以不同。]

模长 (Euclidean Length) [实向量各分量平方和的平方根, 等于向量与自身点积的平方根; 也称向量的长度。]

欧拉角 (Euler Angles) [以约定轴序的三次旋转描述姿态的角度参数；须说明转轴固定还是随动。某些姿态可由不同角度组表示，本书也以此广义称呼三个不同轴的角度参数。]

欧拉公式 (Euler's Formula) [对实数 θ , $e^{i\theta} = \cos \theta + i \sin \theta$, 将单位圆上的旋转与复指数联系起来。]

指数形式 (Exponential Form) [用 $z = re^{i\theta}$ 表示非零复数的形式, 其中 $r = |z|$, θ 是其一个辐角。]

F

特征向量 (数据表示) (Feature Vector) [按约定顺序记录对象各项特征的向量；此处不是后续特征值理论中的特征向量。]

域 (Field) [含不同的 0 与 1, 支持加减乘除 (除数非零) 并满足相应基本运算律的数系。]

复数域 (Field of Complex Numbers) [复数全体 $\mathbb{C}$ 连同通常的加法和乘法, 构成一个域。]

有理数域 (Field of Rational Numbers) [有理数全体 $\mathbb{Q}$ 连同通常的加法和乘法, 构成一个域。]

实数域 (Field of Real Numbers) [实数全体 $\mathbb{R}$ 连同通常的加法和乘法；本书主线所用的标量来源。]

有限域 (Finite Field) [只含有限个元素的域；本书仅作拓展提及。]

有限维空间 (Finite-Dimensional Space) [具有有限基的向量空间, 零空间也属于有限维空间。]

向前消元 (Forward Elimination) [逐列选择主元并消去其下方元素, 将方程组或增广矩阵化成阶梯形的过程。]

前代 (Forward Substitution) [从下三角方程组的第 1 行开始, 自上而下依次求出未知量的方法。]

四个基本子空间 (Four Fundamental Subspaces) [矩阵的列空间、行空间、零空间与左零空间；行空间和零空间位于输入空间, 列空间和左零空间位于输出空间。第 3.5 节铺垫, 后续研究维数与正交关系。]

自由变量 (Free Variable) [系数矩阵非主元列对应的未知数；有解时可独立指定其值, 再求主元变量。]

自由向量 (Free Vector) [只由大小和方向确定、允许平移而不改变自身的几何向量。]

列满秩 (Full Column Rank) [矩阵的列向量全部线性无关, 即其列向量组的秩等于列数。]

行满秩 (Full Row Rank) [矩阵的行向量全部线性无关, 即其行向量组的秩等于行数。]

函数 (Function) [为定义域中的每个元素指定唯一输出的对应规则；函数与映射是同一种概念, 输入和输出可以是数, 也可以是向量等对象。]

基础解系 (Fundamental Set of Solutions) [齐次线性方程组零空间的一组基；每个齐次解均可唯一表示为这些基向量的线性组合，向量个数为未知数个数减系数矩阵的秩。]

平面向量基本定理 (Fundamental Theorem of Plane Vectors) [同一平面内任意向量可唯一表示为两个不共线向量的线性组合。]

空间向量基本定理 (Fundamental Theorem of Space Vectors) [空间中任意向量可唯一表示为三个不共面向量的线性组合。]

G

高斯-若尔当消元法 (Gauss-Jordan Elimination) [继续把主元化为 1 并消去主元列其余元素，得到行最简形的方法。]

高斯消元法 (Gaussian Elimination) [通过同解初等变换化为行阶梯形，再指定自由变量并回代求解的方法。]

通解 (General Solution) [以任意参数或自由的齐次解完整表示全部解的表达式；不是一个特解或有限几个解。]

梯度 (Gradient) [把标量函数对各输入坐标的偏导数按顺序排成的列向量；对平滑函数，非零梯度指向每单位距离上升最快的方向。]

梯度下降 (Gradient Descent) [按负梯度方向小步调整参数的方法；梯度非零且步长足够小时局部下降，不自动保证达到全局最低点。]

H

齐次性 (Homogeneity) [映射保持数乘的性质，即对所有实数 c 和允许的向量 x 有 $T(cx) = cT(x)$ 。]

齐次坐标 (Homogeneous Coordinates) [用增加一个分量的方式表示几何点；本章把二维点记为 $(x, y, 1)^T$ ，以三阶矩阵统一表示平移与线性作用。]

齐次线性方程组 (Homogeneous Linear System) [常数项全为 0 的线性方程组 $Ax = 0$ ，必有零解。]

齐次递推 (Homogeneous Recurrence) [没有外部输入的线性状态更新，如 $x_{k+1} = Fx_k$ ；全部解序列对逐项加法和数乘封闭。]

齐次解空间 (Homogeneous Solution Space) [齐次线性方程全部解在相应加法与数乘下构成的向量空间；动态系统中，其元素是解序列或解函数，不能与平衡状态的零空间混同。]

超平面 (Hyperplane) [$\mathbb{R}^n$ 中维数为 $n - 1$ 的仿射子空间；可由一条系数不全为零的线性方程描述。]

I

恒等映射 (Identity Map) [把每个输入原样输出的映射, $I(x) = x$, 其标准基矩阵为单位矩阵。]

单位矩阵 (Identity Matrix) [主对角线全为 1、其余元素全为 0 的方阵, 本书统一记为 E_n 或 E_o]

像 (Image) [给定输入在映射下对应的输出; x 在 T 下的像记为 $T(x)$ 。]

虚轴 (Imaginary Axis) [复平面中实部为 0 的点组成的坐标轴。]

虚部 (Imaginary Part) [复数 $a + bi$ 中的实数 b , 不是 bi 。]

虚数单位 (Imaginary Unit) [满足 $i^2 = -1$ 的数 i ; 它的连续整数次幂以 4 为周期重复。]

关联矩阵 (Incidence Matrix) [记录网络节点与线路连接的矩阵; 本书取节点为行、定向线路为列, 每列在流出节点记 +1、流入节点记 -1, 其余为 0。]

无解 (Inconsistent) [线性方程组没有公共解, 也称不相容; 消元后可见 $0 = c$ 、 $c \neq 0$ 的矛盾。]

无限维空间 (Infinite-Dimensional Space) [不存在有限基的向量空间; 例如实连续函数空间 $C[a, b]$, 其中 $a < b$ 。]

无穷多解 (Infinitely Many Solutions) [实线性方程组有解且存在自由变量时的情形, 对应无穷多个不同的解向量。]

单射 (Injection) [不同输入具有不同输出的映射; 等价地, 每个输出至多对应一个输入。]

内积 (Inner Product) [用于定义长度、夹角及正交性的一种向量配对运算; 第 7 章正式定义。]

内积空间 (Inner Product Space) [配有指定内积的向量空间, 使长度与正交性有准确含义; 第 7 章展开。]

子空间的交 (Intersection of Subspaces) [同时属于两个子空间的向量全体, 仍是子空间, 记为 $U \cap V$ 。]

反函数 (Inverse Function) [在指定定义域与目标集合之间, 双射函数把输出唯一还原为输入的函数; 它与原函数两个方向的复合均为相应集合的恒等映射。]

逆映射 (Inverse Map) [双射把每个输出反查为唯一输入的映射; 双射线性映射的逆仍是线性映射。]

逆矩阵 (Inverse Matrix) [满足 $AB = BA = E$ 的方阵 B , 记为 A^{-1} , 表示撤销 A 对应线性作用的映射。]

逆序数 (Inversion Number) [排列中前项大于后项的数对个数; 行列式项的符号为 $(-1)^{N(\sigma)}$ 。]

可逆矩阵 (Invertible Matrix) [存在双侧逆的方阵; 等价于对应线性映射为双射。]

J

雅可比行列式 (Jacobian Determinant) [输入与输出维数相同时，雅可比矩阵的行列式；绝对值表示局部的面积或体积缩放倍率，正负记录方向。]

雅可比矩阵 (Jacobian Matrix) [按输出分量为行、输入坐标为列排列偏导数的矩阵；在固定一点，把输入小变化映到输出的一阶变化。]

K

键 (Key) [注意力计算中与查询配对、用来计算关联分数的向量，常按行组成矩阵 K 。]

L

拉普拉斯展开 (Laplace Expansion) [沿固定的一行或一列，将元素与对应代数余子式的乘积求和，得到整个行列式的计算公式。]

隐因子 (Latent Factor) [模型用于表示潜在联系的向量分量；本章以少量隐因子展示用户与内容的匹配。]

余弦定理 (Law of Cosines) [三角形一边的平方等于另两边的平方和减去这两边与其夹角余弦乘积的两倍；将勾股定理推广到任意三角形。]

学习率 (Learning Rate) [梯度下降中控制每次参数更新步长的正数；太大的步长可能使损失增加。]

最小二乘法 (Least Squares) [通过使误差平方和尽可能小来确定参数的方法；第 3 章先应用其线性方程形式，第 5.7 节用正交直和说明最优近似与解的结构。]

最小二乘解 (Least-Squares Solution) [使 $\|b - Ax\|^2$ 最小的输入；等价于正规方程的解，最优输出唯一，输入是否唯一取决于 A 的零空间。]

左零空间 (Left Null Space) [转置矩阵的零空间，即满足 $A^T y = 0$ 的全部向量；等价地有 $y^T A = 0^T$ 。若 A 为 $m \times n$ ，它是 $\mathbb{R}^m$ 的子空间。]

等高线 (Level Curve) [二元标量函数中具有相同函数值的输入点组成的曲线；非零梯度垂直于经过该点的等高线切向。]

线性代数 (Linear Algebra) [研究向量的线性关系、向量空间与线性映射及其代数表示的数学分支。]

线性组合 (Linear Combination) [对给定向量分别作数乘后相加得到的向量。]

线性方程 (Linear Equation) [形如 $a_1 x_1 + \cdots + a_n x_n = b$ 的方程，未知数只以一次项出现。]

线性泛函 (Linear Functional) [从实向量空间到 $\mathbb{R}$ 的线性评分规则，如坐标提取、固定权重点积和多项式在固定点的取值；在 $\mathbb{R}^m$ 中可唯一写成 $\varphi_y(b) = y \cdot b$ 。]

线性映射 (Linear Map) [保持向量加法和数乘的映射。在线性代数中也称线性变换；固定定义域与目标空间的标准基后，由各个基向量的像唯一确定其矩阵。]

线性运算 (Linear Operations) [向量加法与数乘的统称。]

线性算子 (Linear Operator) [从一个向量空间到它自身的线性映射；例如，次数不超过 n 的多项式空间上的求导映射 $D(f) = f'$ 。]

线性表示 (Linear Representation) [给定向量可写成某向量组的线性组合这一关系。]

线性结构 (Linear Structure) [由向量加法、数乘及其线性表示关系构成的结构；其研究不要求预先给定长度与夹角。]

线性方程组 (Linear System) [要求同一组未知数同时满足的若干线性方程。]

线性微分方程组 (Linear System of Differential Equations) [以状态分量的导数为未知变化率的线性关系，如 $\dot{y} = Ay + g(t)$ ；其解是随时间变化的函数。]

线性变换 (Linear Transformation) [保持加法和数乘的向量映射，即 $T(u + v) = Tu + Tv$ 、 $T(cu) = cTu$ 。]

线性相关 (Linearly Dependent) [存在不全为零的系数，使给定向量组的线性组合等于零向量。]

线性无关 (Linearly Independent) [只有全部系数为零，给定向量组的线性组合才等于零向量。]

荷载工况 (Load Case) [结构分析中一组指定的外部荷载情形；结构参数固定时，不同工况通常对应不同右端项。]

局部线性化 (Local Linearization) [在固定位置，用一个线性映射近似输入小变化引起的输出变化；加上起点输出后的近似通常是仿射映射，不是把原函数变成全局线性函数。]

损失函数 (Loss Function) [用一个标量衡量模型预测与目标的偏差或其他训练目标的函数；把模型参数视为输入时，是一个多元标量函数。]

下三角矩阵 (Lower Triangular Matrix) [主对角线上方全为零的方阵。]

LU 分解 (LU Factorization) [将矩阵写成 $A = LU$ ，其中 L 为单位下三角矩阵， U 为上三角矩阵，用来保存并复用无换行消元。]

M

主对角线 (Main Diagonal) [矩阵中行下标与列下标相等的位置，即 $A_{1,1}, A_{2,2}, \dots$ 所在的对角线。]

映射 (Mapping) [给每个输入指定唯一输出的对应规则。]

矩阵 (Matrix) [按固定行列次序排列的矩形数表，可组织方程系数或记录线性映射的信息。]

矩阵加法 (Matrix Addition) [同型矩阵按对应位置元素相加的运算，表示相应线性映射输出的逐点叠加。]

矩阵乘法 (Matrix Multiplication) [表示线性映射复合的运算；相邻尺寸匹配时，乘积元素由左矩阵的一行与右矩阵的一列对应相乘求和。]

矩阵的幂 (Matrix Power) [方阵与自身反复相乘，表示同一映射反复复合；约定 $A^0 = E$ 。]

矩阵表示 (Matrix Representation) [选定两端的有序基后，按列记录定义域各基向量的像目标空间基下的坐标所得的矩阵；本书第 3 章使用标准基，记为 $M(T)$ 。]

矩阵数乘 (Matrix Scalar Multiplication) [将矩阵每个元素同乘一个标量，表示把线性映射的所有输出作相同倍数的缩放。]

极大线性无关组 (Maximal Linearly Independent Subset) [从原向量组中选出的无关部分组，并能线性表示原组的全部向量。]

度量结构 (Metric Structure) [用于刻画长度、夹角等几何量的附加结构；本书第 0 章从实向量的标准点积出发建立直观。]

余子式 (Minor) [删去指定元素所在的一行和一列，保留其余行列次序得到的低一阶行列式，记作 M_{ij} ；约定 0 阶行列式为 1。]

模 (Modulus) [复数 $z = a + bi$ 对应点到原点的距离， $|z| = \sqrt{a^2 + b^2}$ 。]

多重线性 (Multilinearity) [多输入函数固定其他输入后，对每一个输入分别保持加法与数乘；不是要求所有输入同时改变时仍整体线性。]

N

n 维实向量 (n-Dimensional Real Vector) [由 n 个实数按固定次序组成的数组，是 $\mathbb{R}^n$ 的元素。]

必要条件 (Necessary Condition) [某结论成立时必须满足的条件；条件成立本身未必能推出该结论。例如，线性映射必须把零向量送到零向量。]

负矩阵 (Negative Matrix) [将原矩阵各元素变号所得的矩阵，表示把原映射的每个输出取相反向量。]

非齐次线性方程组 (Nonhomogeneous Linear System) [至少有一个常数项不为 0 的线性方程组 $Ax = b$ 。]

非齐次递推 (Nonhomogeneous Recurrence) [带不恒为零的给定外部输入的线性状态更新，如 $x_{k+1} = Fx_k + u_k$ ；其通解是一串特解加任意齐次解序列。]

非零解 (Nontrivial Solution) [分量不全为 0 的解向量；不要求每个分量都非零。]

正规方程 (Normal Equations) [最小二乘问题对应的线性方程组 $A^T Ax = A^T b$ ；它始终有解，全部解构成原矩阵零空间的一次平移。]

法向量 (Normal Vector) [垂直于所讨论平面或其方向子空间的非零向量；底面不退化时，又乘与代数余子式向量提供相应的构造。]

归一化 (Normalization) [选定度量基准的条件；行列式规定标准基有序组或单位矩阵的值为 1，以固定整体尺度。]

复数的 n 次根 (nth Root of a Complex Number) [满足 $w^n = z$ 的复数 w ；非零复数有 n 个互异的 n 次根。]

零空间 (Null Space) [线性映射把它映为零向量的全部输入所成的子空间，记为 $\text{null } T$ ；矩阵的零空间就是齐次方程组的解空间。]

零度 (Nullity) [线性映射或矩阵的零空间的维数；等于相应齐次方程组自由变量的个数。]

数值稳定性 (Numerical Stability) [描述算法控制有限精度误差影响的性质；选主元可避免过小主元造成过大的消元倍数，但不保证一切误差消失。]

O

斜投影 (Oblique Projection) [沿与目标子空间不垂直的互补方向投到该子空间、并保持其上的向量不动的线性映射；本章以沿 $(1,1,1)^T$ 投到 xy 平面为例。]

一一对应 (One-to-One Correspondence) [两类对象之间互相唯一确定、没有遗漏的配对关系；固定标准基后， $\mathbb{R}^n$ 到 $\mathbb{R}^m$ 的线性映射与 $m \times n$ 矩阵一一对应。]

有序基 (Ordered Basis) [指定了基向量先后次序的一组基，坐标必须按该次序排列。]

有向面积 (Oriented Area) [按两条边的先后次序记录正负的平行四边形面积；平面标准定向中逆时针为正，共线时为 0。]

有向体积 (Oriented Volume) [按有序边的定向记录正负的体积；三维中由混合积给出，通常体积为其绝对值。]

正交补向量 (Orthogonal Complement Vector) [本章指按既定方向约定选出的垂直向量；二维取原向量逆时针旋转 90 度的像，高维余子式向量垂直于其余各行。]

正交互补子空间 (Orthogonal Complementary Subspaces) [在给定实向量空间中互相正交，且直和等于整个空间的两个子空间；每个向量均有唯一分解，二者维数之和等于环境空间的维数，并不要求维数相等。]

正交直和 (Orthogonal Direct Sum) [互相正交的子空间所构成的直和；其中每个向量的分量分解唯一。]

正交矩阵 (Orthogonal Matrix) [满足 $Q^T Q = E$ 的实方阵；列向量单位且两两垂直，逆矩阵等于转置，保持标准点积；不一定表示旋转，也可能包含反射。]

正交投影 (Orthogonal Projection) [沿垂直于目标直线或平面的方向得到投影的对应规则；向 xy 平面投影得到 $(x, y, 0)^T$ ，用平面坐标记录则为 $(x, y)^T$ 。]

子空间正交 (Orthogonal Subspaces) [两个子空间中任取一支向量配对，标准点积均为零的关系；仅有正交并不保证二者之和为整个空间。]

正交性 (Orthogonality) [内积为 0 所刻画的关系，是几何垂直的推广；第 7 章展开。]

外积 (Outer Product) [列向量与行向量的矩阵乘积 uv^T ；第 (i, j) 个元素为 $u_i v_j$ ，两向量均非零时秩为 1。]

P

平行四边形定则 (Parallelogram Rule) [以同一起点的两个向量为邻边作平行四边形，其从共同起点出发的对角线表示向量和。]

平行多面体 (Parallelotope) [由同一空间中的向量作为邻边、系数分别在 0 到 1 之间变化而得到的区域；边向量相关时退化到较低维子空间。]

偏导数 (Partial Derivative) [固定其余输入变量，只改变一个变量时的瞬时变化率；在二元曲面上对应固定另一坐标的截线切线斜率。]

部分选主元 (Partial Pivoting) [每一步在当前列尚未处理的行中选绝对值最大的元素，交换到主元行后再消元。]

特解 (Particular Solution) [一个确实满足给定方程组的具体解；一个特解未必代表全部解。]

被动旋转 (Passive Rotation) [向量不动，转动描述它的坐标架；新坐标由对应主动旋转矩阵的逆矩阵换算。]

排列 (Permutation) [把 $1, \dots, n$ 的全部下标按某一顺序重排，或相应的下标一一对应；行列式排列式中每行每列恰取一个元素。]

置换矩阵 (Permutation Matrix) [单位矩阵的行重新排列所得矩阵，每行每列恰有一个 1；左乘它可重排行，且 $P^{-1} = P^T$ 。]

状态平面 (Phase Plane) [用二维状态的两个分量作为坐标形成的平面；点代表状态，曲线代表状态演化，不一定是物体运动的实际空间。]

主元 (Pivot) [阶梯形非零行的首个非零元素，用于组织消元与确定主元变量。]

主元列 (Pivot Column) [阶梯形中含主元的列；原矩阵对应列号的列可用于选取极大无关组。]

主元位置 (Pivot Position) [阶梯形中主元所在的位置；讨论原矩阵时指与化简后主元对应的位置。]

像素 (Pixel) [数字图像中一个采样位置及其数值记录；灰度图像的像素值表示亮度，彩色图像通常记录多个颜色分量。]

像素基 (Pixel Basis) [每个基图案仅在一个像素位置取 1、其他位置取 0；按固定顺序展开后就是图像向量空间的标准基。]

平面向量 (Plane Vector) [位于一个平面内的向量，选定平面基后可用两个坐标表示。]

PLU 分解 (PLU Factorization) [把换行记录到置换矩阵中的 LU 分解，本书约定写成 $PA = LU$ ；第 3.8 节为选读。]

极坐标 (Polar Coordinates) [用从原点的距离 r 与方向角 θ 描述平面位置, 满足 $x = r \cos \theta, y = r \sin \theta$; 面积微元为 $r \, dr \, d\theta$ 。]

极坐标形式 (Polar Form) [用模 r 和辐角 θ 表示非零复数的形式 $r(\cos \theta + i \sin \theta)$, 也称极式。]

多项式空间 (Polynomial Space) [以多项式为元素、按通常加法和数乘运算组成的向量空间; P_n 表示次数不超过 n 的情形。]

势函数 (Potential Function) [其梯度给出某个向量场的标量函数; 物理中的保守力也常以负梯度表示。无旋场能否在整个区域具有势函数还取决于区域条件。]

原像 (Preimage) [若 $T(x) = y$, 则输入 x 是输出 y 的一个原像; 双射中每个目标向量有唯一原像。]

辐角主值 (Principal Argument) [按约定区间选出的唯一辐角, 本附录采用 $(-\pi, \pi]$, 记为 $\operatorname{Arg} z$ 。]

纯虚数 (Purely Imaginary Number) [实部为 0 且虚部非零的复数 bi 。]

Q

二次型 (Quadratic Form) [若干变量的齐次二次多项式; 第 10 章研究其代数表示与几何形状。]

量化 (Quantization) [把连续或精细的数值归并为有限精度的代表值; 本例通过除以指定间隔并取最近整数实现, 会丢失精度, 一般不是线性映射。]

查询 (Query) [注意力计算中用于与键比较的向量, 常将各位置的查询按行组成矩阵 Q 。]

R

值域 (Range) [线性映射全部输出向量组成的目标空间的子空间, 记为 $\operatorname{range} T$; 矩阵的值域等于其列空间。]

列秩分解 (Rank Factorization) [也称 CR 分解, 将秩为 r 的矩阵写成 $A = CR$; C 有 r 个独立列, R 有 r 个独立行, 分别记录核心列与组合系数。]

矩阵的秩 (Rank of a Matrix) [矩阵列向量组的秩, 等于列向量张成空间的维数, 也等于行阶梯形的主元数。]

向量组的秩 (Rank of a Set of Vectors) [向量组的任意极大线性无关组所含向量个数, 等于其张成空间的维数。]

秩与零度定理 (Rank-Nullity Theorem) [有限维线性映射的定义域维数等于零空间维数与值域维数之和; 对 $m \times n$ 矩阵, 有 $\dim \operatorname{null} A = n - \operatorname{rank}(A)$ 。]

秩一矩阵 (Rank-One Matrix) [列向量组的秩为 1 的非零矩阵; 所有列均可由同一个非零列向量数乘得到。]

实轴 (Real Axis) [复平面中虚部为 0 的点组成的坐标轴。]

实部 (Real Part) [复数 $a + bi$ 中的实数 a 。]

实向量空间 (Real Vector Space) [以实数作为数乘系数的向量空间。]

递推关系 (Recurrence Relation) [用已有项或当前状态确定后续项或状态的关系；线性状态更新可写为 $\mathbf{x}_{k+1} = F\mathbf{x}_k + \mathbf{u}_k$ 。]

行最简形矩阵 (Reduced Row Echelon Form) [主元为 1 且主元列其他元素均为 0 的行阶梯形矩阵，也称简化行阶梯形矩阵。]

反射变换 (Reflection) [关于过原点直线或平面作镜像的线性变换；反射两次恢复原向量。]

反身性 (Reflexivity) [某种关系对每个对象与其自身都成立；如向量组与自身等价。]

正则化 (Regularization) [在拟合目标中加入对参数等对象的约束或惩罚，以改善模型的稳定性与泛化；本章示例采用参数平方和惩罚。]

余项 (Remainder) [原函数与截断多项式之间的差，如 $R_n(t) = f(t) - T_n(t)$ 。]

残差向量 (Residual Vector) [目标与实际输出之差 $\mathbf{b} - A\mathbf{x}$ ；最小二乘解的残差属于 $\text{Null}(A^T)$ ，与列空间正交。]

黎曼和 (Riemann Sum) [把区域分成有限小块，将每块中的函数采样值乘以该块大小后求和；网格逐渐细分时用于描述积分的累积思想。]

右手法则 (Right-Hand Rule) [右手拇指指向转轴正向，四指弯曲方向规定为正向旋转；用于统一三维旋转的正负约定。]

单位根 (Roots of Unity) [方程 $w^n = 1$ 的解，均在单位圆上，辐角相邻间隔为 $2\pi/n$ 。]

旋转 (Rotation) [绕原点转过固定有向角的变换；复平面上乘 $e^{i\theta}$ 表示旋转 θ 。]

旋转矩阵 (Rotation Matrix) [表示绕原点旋转的矩阵；平面逆时针旋转 θ 时，两列依次为 $(\cos \theta, \sin \theta)^T$ 与 $(-\sin \theta, \cos \theta)^T$ 。]

舍入误差 (Rounding Error) [计算或存储时只保留有限位数字，舍去或舍入其余数字所产生的偏差。]

行阶梯形矩阵 (Row Echelon Form) [零行置底、每个非零行的首个非零位置逐行右移的矩阵。]

行阶梯形方程组 (Row Echelon System) [方程按固定未知数次序排列，全零方程置底，其余方程的首个非零项逐行右移的形式。]

行等价 (Row Equivalence) [两个矩阵可通过有限次初等行变换互相得到的关系。]

行秩 (Row Rank) [矩阵行向量张成空间的维数；等于列秩。]

行空间 (Row Space) [矩阵各行竖排后张成的空间，等于转置矩阵的列空间； $m \times n$ 矩阵的行空间是 $\mathbb{R}^n$ 的子空间。第 3.5 节从转置引入。]

行向量 (Row Vector) [将分量按固定次序横排得到的向量形式，是相应列向量的转置。]

S

鞍点 (Saddle Point) [有的方向靠近平衡点、有的方向离开的矢量场形态；本节通过一个分量增长、另一个分量衰减的例子观察。]

标量 (Scalar) [来自所选域、用于数乘向量的数。]

标量场 (Scalar Field) [给空间中每个位置指定一个数的函数，如高度、温度；输入可用位置向量表示，输出是标量。]

数乘 (Scalar Multiplication) [以一个标量乘一个向量；在 $\mathbb{R}^n$ 中，每个分量都乘同一个数。]

映射的数乘 (Scalar Multiplication of a Map) [把映射的每个输出同乘标量， $(\lambda T)(x) = \lambda T(x)$ 。]

有符号投影长度 (Scalar Projection) [向量 y 沿单位方向 q 的带符号分量 $q \cdot y = |y| \cos \theta$ ；反向一侧为负，原始非单位探测器的点积还需乘探测器的长度。]

混合积 (Scalar Triple Product) [三维中的 $w \cdot (u \times v)$ ；给出三条有序边围出的有向体积，循环换序不变、交换两条边变号。]

缩放变换 (Scaling Transformation) [将各坐标分量分别乘以固定实数的线性变换；所有缩放因子非零时可逆，因子为零时会压缩相应方向。]

剪切变换 (Shear Transformation) [保持一组平行方向不变、使另一方向按位置成比例偏移的线性变换；平面例为 $(x, y) \mapsto (x + ky, y)$ 。]

Sigmoid 函数 (Sigmoid Function) [本书指函数 $\sigma(t) = 1/(1 + e^{-t})$ ，把实数映入 0 与 1 之间；数值处于该区间不自动保证概率预测准确。]

相似矩阵 (Similar Matrices) [存在可逆矩阵 P 使 $B = P^{-1}AP$ 的两个同阶方阵，表示同一线性变换在不同基下的矩阵。]

相似变换 (Similarity Transformation) [用可逆矩阵建立 $B = P^{-1}AP$ 的关系，表示同一线性变换在不同基下的矩阵；第 4 章选读引入。]

奇异矩阵 (Singular Matrix) [不存在双侧逆的方阵。]

奇异值分解 (Singular Value Decomposition) [用两组正交方向和非负缩放量分解矩阵的方法；第 11 章选读。]

反对称矩阵 (Skew-Symmetric Matrix) [满足 $A^T = -A$ 的实方阵，主对角线元素全为 0。]

Softmax 归一化 (Softmax) [对一组实数分别取指数，再除以所有指数之和，得到总和为 1 的正权重；注意力通常逐行进行该操作。]

解 (Solution) [同时满足方程组所有方程的一组有序数。]

解集 (Solution Set) [方程组全部解构成的集合。]

解空间 (Solution Space) [齐次线性方程组全部解组成的向量空间；非齐次方程组有解时，其解集一般是该空间的平移，不是子空间。]

连续函数空间 (Space of Continuous Functions) [区间上所有连续函数按逐点加法与数乘组成的向量空间, 记为 $C[a, b]$ 。]

空间向量 (Space Vector) [日常三维空间中的向量, 选定空间基后可用三个坐标表示。]

张成空间 (Span) [给定向量组的全部线性组合构成的集合, 是包含该组向量的最小子空间。]

生成组 (Spanning Set) [能够张成给定空间的向量组, 不要求线性无关。]

方阵 (Square Matrix) [行数与列数相同的矩阵; $n \times n$ 方阵称为 n 阶方阵。]

稳定结点 (Stable Node) [附近状态向平衡点靠近而不绕行的典型线性矢量场形态; 本节通过两个分量分别衰减的例子观察。]

标准基 (Standard Basis) [在 $\mathbb{R}^n$ 中由 $e_1, \dots, e_n$ 组成的有序基, 第 i 个向量仅第 i 分量为 1。]

状态向量 (State Vector) [把模型中足以描述当前状态、并结合更新规则与输入确定后续演化的量有序排成的向量; 其分量与所选模型有关。]

状态转移矩阵 (State-Transition Matrix) [在线性离散模型中把当前状态映到下一状态的矩阵; 本书以固定矩阵 F 和无外部输入的关系 $x_{k+1} = Fx_k$ 作初步说明。]

稳态响应 (Steady-State Response) [在本节周期受迫且齐次偏离衰减的模型中, 长期保留下来的周期响应; 稳态不意味着状态静止, 一般特解不一定是稳态响应。]

刚度矩阵 (Stiffness Matrix) [在线性结构模型中把节点位移映射为平衡外力的矩阵; 本章三节点教学模型写成 $Ku = f$ 。]

流线 (Streamline) [在自治矢量场中处处与场向量相切的曲线; 本书连续系统中用作状态轨线的几何描述。]

严格对角占优 (Strict Diagonal Dominance) [本书采用按行条件: 每行主对角元绝对值严格大于其余元素绝对值之和; 它是无换行 LU 消元可行的一类充分条件。]

子空间 (Subspace) [沿用母空间运算、对加法和数乘封闭的非空子集。]

代入消元法 (Substitution Method) [先由一个方程表示某未知数, 再代入其他方程以减少未知数的方法。]

充分条件 (Sufficient Condition) [满足该条件就能推出相应结论的条件; 与必要条件须加以区别。仅把零向量送到零向量不足以保证映射线性。]

子空间的和 (Sum of Subspaces) [所有 $u + v$ 构成的子空间, 其中 $u \in U, v \in V$, 记为 $U + V$ 。]

满射 (Surjection) [目标空间的每个元素都至少能由一个输入得到的映射。]

对称矩阵 (Symmetric Matrix) [满足 $A^T = A$ 的实方阵, 对称位置的元素相等。]

对称性 (Symmetry) [某种关系成立时交换两个对象, 关系仍成立; 如向量组等价关系。]

T

切平面 (Tangent Plane) [平滑曲面在一点附近的一阶仿射近似, 由该点高度和各输入方向的偏导数决定。]

泰勒多项式 (Taylor Polynomial) [用函数在某一点的有限阶导数作系数构造的多项式, 本书用于选读的函数近似例子。]

词元 (Token) [分词器按规则将文本切分得到的基本处理单元, 可为完整的词、词的一部分或标点等, 不必与汉字或自然语言中的词一一对应。模型先将其映射为初始向量, 再通过后续计算融入上下文信息。]

迹 (Trace) [方阵主对角线上元素的和, 记作 $\text{tr } A$; 在线性向量场中表示体积的瞬时相对膨胀率。]

暂态响应 (Transient Response) [在本书选读的衰减模型中, 由初始状态偏离特解所产生、并随时间消失的齐次响应; 一般齐次偏离未必衰减。]

传递性 (Transitivity) [若对象一与二、二与三具有某种关系, 则对象一与三也具有该关系。]

转置 (Transpose) [对偶映射在原标准基所对应的对偶基下的矩阵, 满足 $\mathbf{y} \cdot (A\mathbf{x}) = (A^T\mathbf{y}) \cdot \mathbf{x}$; 行列互换是其坐标计算形式, 通常不是逆矩阵。向量横排与竖排的转换也沿用上标 T 。]

三角形定则 (Triangle Rule) [把两个向量首尾相接, 从第一支起点指向第二支终点的向量表示它们的和。]

三重积分 (Triple Integral) [对空间区域上小体积的函数贡献进行累积的积分; 如把体密度乘体积微元后相加得到总质量。]

零解 (Trivial Solution) [所有未知数均为 0 的解, 是任意齐次线性方程组的一个解。]

平凡子空间 (Trivial Subspaces) [所讨论空间的零子空间与全空间; 零空间情形二者重合。]

二维广义叉乘 (Two-Dimensional Generalized Cross Product) [本章采用一个平面向量输入的垂直生成操作, $(a, b)^T \mapsto (-b, a)^T$; 区别于三维的双向量叉乘。]

双塔召回模型 (Two-Tower Retrieval Model) [分别生成用户与候选内容的向量表征, 再按匹配程度筛选候选的模型; 两座塔通常包含非线性运算。]

U

唯一解 (Unique Solution) [方程组恰有一个解向量; 有解且没有自由变量时出现。]

单位圆 (Unit Circle) [复平面上满足 $|z| = 1$ 的点集, 即以原点为圆心、半径为 1 的圆。]

单位下三角矩阵 (Unit Lower Triangular Matrix) [主对角线元素全为 1 的下三角矩阵, 其对角线下方元素可为任意实数。]

单位向量 (Unit Vector) [长度为 1 的向量。]

上三角矩阵 (Upper Triangular Matrix) [主对角线下方全为零的方阵。]

用户—物品交互矩阵 (User-Item Interaction Matrix) [用行对应用户、列对应物品，按位置记录行为或反馈的矩阵；未记录到行为不自动等于不喜欢。]

V

值 (Value) [注意力计算中被权重加权汇聚的信息向量，常按行组成矩阵 V 。]

向量 (Vector) [向量空间中的元素；在本书主线中主要表现为有序实数组，低维时可画成箭头。]

向量加法 (Vector Addition) [在 $\mathbb{R}^n$ 中将相同位置的分量分别相加的运算。]

向量方程 (Vector Equation) [两端为向量表达式的等式；本章重点为 $x_1 \mathbf{a}_1 + \cdots + x_n \mathbf{a}_n = \mathbf{b}$ 。]

矢量场 (Vector Field) [为状态空间的每个点指定一支向量的对应；连续系统的 $A\mathbf{y}$ 在该点表示瞬时变化率。]

向量组 (Vector List) [按次序列出的有限个向量，允许出现重复向量和零向量。]

向量空间 (Vector Space) [配有封闭的加法与数乘并满足相应八条运算公理的非空集合。]

向量减法 (Vector Subtraction) [加上相反向量的运算， $\mathbf{u} - \mathbf{v} = \mathbf{u} + (-\mathbf{v})$ 。]

黏性阻尼 (Viscous Damping) [采用阻力与速度成正比、方向相反的线性近似；在一维教学模型中写为 $-c\dot{x}$ 。]

体积缩放倍数 (Volume Scale Factor) [实方阵表示的线性变换对区域体积的乘数，等于行列式的绝对值；退化变换的倍数为 0。]

W

权重矩阵 (Weight Matrix) [包含模型可训练系数、用于线性映射的矩阵；注意力中的 A 也称权重矩阵，但它由当前输入计算得到，与可训练投影参数 W_Q, W_K, W_V 不同。]

全空间 (Whole Space) [所讨论的整个向量空间，它也是自身的子空间。]

Z

零矩阵 (Zero Matrix) [所有元素都为 0 的矩阵。]

零子空间 (Zero Subspace) [只含零向量的子空间 $\{\mathbf{0}\}$ ，其基可取空组，维数为 0。]

零向量 (Zero Vector) [加法的零元素；在 $\mathbb{R}^n$ 中各分量均为 0，几何上长度为 0 且没有确定方向。]

参考文献

- [1] Axler S. *Linear Algebra Done Right* (《线性代数应该这样学》)[M]. 4th ed. Cham: Springer, 2024.
<https://doi.org/10.1007/978-3-031-41026-0>.
- [2] MIT OpenCourseWare. *18.013A Calculus with Applications*, Fall 2001, Online Textbook, sec. 4.1: Area, Volume and the Determinant in Two and Three Dimensions[EB/OL]. 面积、体积与行列式绝对值的几何联系 [2026-10-02].
<https://ocw.mit.edu/ans7870/18/18.013a/textbook/chapter04/section01.html>.
- [3] Lay D C, Lay S R, McDonald J J. *Linear Algebra and Its Applications* (《线性代数及其应用》)[M]. 6th ed., Global Edition. Pearson, 2021.
- [4] Vaswani A, Shazeer N, Parmar N, et al. Attention Is All You Need[C]//*Advances in Neural Information Processing Systems*. Vol. 30. 2017: 5998–6008.
<https://arxiv.org/abs/1706.03762>.
- [5] Archer B J. The Los Alamos Computing Facility during the Manhattan Project[R/OL]. LA-UR-21-20164, 2021.
<https://arxiv.org/abs/2103.05705>.
- [6] OpenAI. Understanding and counting tokens[EB/OL]. OpenAI Help Center [2026-09-25].
<https://help.openai.com/en/articles/4936856-understanding-and-counting-tokens>.
- [7] Hugging Face. Tokenization algorithms[EB/OL]. Transformers documentation [2026-09-25].
https://huggingface.co/docs/transformers/tokenizer_summary.
- [8] 抖音安全与信任中心. 什么是推荐系统 [EB/OL]. [2026-09-25].
<https://trust.douyin.com/algorithm/>.
- [9] 抖音安全与信任中心. 抖音安全与信任中心网站上线一周年, 让信任可见、让安全可感 [EB/OL]. 2026-03-30 [2026-09-26].
<https://95152.douyin.com/article/9171774861438144>.

-
- [10] 抖音安全与信任中心. 从零开始了解推荐系统 [EB/OL]. 2025-03-30 [2026-09-26].
<https://95152.douyin.com/article/15358>.
- [11] 抖音安全与信任中心. 用户行为背后的算法推荐逻辑 [EB/OL]. 网页标示日期 2025-01-20 [2026-09-26].
<https://95152.douyin.com/article/15381>.
- [12] 抖音安全与信任中心. 抖音算法的多目标平衡 [EB/OL]. 网页标示日期 2025-01-20 [2026-09-26].
<https://95152.douyin.com/article/15383>.
- [13] Cheng H T, Koc L, Harmsen J, et al. Wide & Deep Learning for Recommender Systems[EB/OL]. 2016 [2026-09-26].
<https://arxiv.org/abs/1606.07792>.
- [14] Kula M, Chen J. Introducing TensorFlow Recommenders[EB/OL]. Google, 2020-09-23 [2026-09-26].
<https://blog.tensorflow.org/2020/09/introducing-tensorflow-recommenders.html>.
- [15] Hu Y, Koren Y, Volinsky C. Collaborative Filtering for Implicit Feedback Datasets[C]//2008 Eighth IEEE International Conference on Data Mining. 2008: 263–272.
<https://yifanhu.net/PUB/cf.pdf>.
- [16] Hu G, Zhang A, Liu S, et al. AlphaFuse: Learn ID Embeddings for Sequential Recommendation in Null Space of Language Embeddings[C/OL]//Proceedings of the 48th International ACM SIGIR Conference on Research and Development in Information Retrieval. 2025.
DOI: 10.1145/3726302.3729894. <https://arxiv.org/abs/2504.19218>.
- [17] Apache Spark. Collaborative Filtering: Explicit vs. Implicit Feedback, Scaling of the Regularization Parameter, and Cold-start Strategy[EB/OL]. [2026-10-02].
<https://spark.apache.org/docs/latest/ml-collaborative-filtering.html>.
- [18] Koren Y, Bell R, Volinsky C. Matrix Factorization Techniques for Recommender Systems[J]. Computer, 2009, 42(8): 30–37.
DOI: 10.1109/MC.2009.263. <https://gwern.net/doc/ai/tabular/2009-koren.pdf>.

- [19] Strang G. Singular Value Decomposition[EB/OL]. MIT OpenCourseWare, 18.06SC Linear Algebra, Fall 2011 [2026-10-02].
<https://ocw.mit.edu/courses/18-06sc-linear-algebra-fall-2011/pages/positive-definite-matrices-and-applications/singular-value-decomposition/>.
- [20] Liu Z, Zou L, Zou X, et al. Monolith: Real Time Recommendation System With Collisionless Embedding Table[EB/OL]. arXiv:2209.07663, 2022 [2026-09-26].
<https://arxiv.org/abs/2209.07663>.
- [21] 作者不详. Glen Beck and Betty Snyder program the ENIAC in building 328 at the Ballistic Research Laboratory[图像/OL]. U.S. Army Photo, Wikimedia Commons [2026-09-25].
<https://commons.wikimedia.org/wiki/File:Eniac.jpg>.
- [22] Raytheon Company. *Apollo Guidance Computer Program, Block I (100) and Block II: Final Report*[R/OL]. NASA-CR-108361, SR-70-4053, 1969, sec. 2.3.1.1.
<https://ntrs.nasa.gov/citations/19700015154>.
- [23] Hiranabe K. *The Art of Linear Algebra: Graphic Notes on “Linear Algebra for Everyone”*[EB/OL]. With help from Gilbert Strang; 刘可方译, 2023 年更新。
<https://github.com/kenjihiranabe/The-Art-of-Linear-Algebra>.
- [24] Chan M, Leung Y W, Premaud V, et al. *Challenges in Hong Kong–Zhuhai–Macao Bridge (HZMB) Hong Kong Link Road Project*[R/OL]. 项目团队技术论文, 见桩帽有限元模型及荷载讨论。
<https://ywlgroup.com/ywl-wp/article/a04.pdf>.
- [25] N509FZ. *West section of Hong Kong–Zhuhai–Macau Bridge (20180902174105)*[图像/OL]. 2018-09-02. Wikimedia Commons, CC BY-SA 4.0;
[https://commons.wikimedia.org/wiki/File:West_section_of_Hong_Kong-Zhuhai-Macau_Bridge_\(20180902174105\).jpg](https://commons.wikimedia.org/wiki/File:West_section_of_Hong_Kong-Zhuhai-Macau_Bridge_(20180902174105).jpg).
许可: <https://creativecommons.org/licenses/by-sa/4.0/>.
- [26] Ngspice Development Team. Documentation: manual and control flow[EB/OL]. 仿真流程中的电路装配与矩阵建立。
<https://ngspice.sourceforge.io/docs.html>.
- [27] Anderson E, Bai Z, Bischof C, et al. *LAPACK Users’ Guide: Linear Equations*[EB/OL]. Netlib [2026-09-26].
<https://www.netlib.org/lapack/lug/node38.html>.

- [28] LAPACK Authors. DGETRF: LU factorization with partial pivoting[EB/OL]. Netlib [2026-09-26].
https://www.netlib.org/lapack/explore-html/db/d04/group__getrf_gaea332d65e208d833716b405ea2a1ab69.html.
- [29] Khronos Group. *OpenVG Lite Specification*, sec. 6.5: Transformations[EB/OL]. 齐次坐标与二维仿射变换 [2026-09-26].
https://registry.khronos.org/OpenVG/specs/openvg_lite_spec.pdf.
- [30] 成都航空职业技术学院成航科普基地. 钱学森弹道（第十届全国科普讲解大赛）[EB/OL]. [2026-09-26].
<https://www.cap.edu.cn/chkpjd/info/1371/2401.htm>.
- [31] NASA/JPL NAIF. *SPICE Required Reading: Reference Frames*[EB/OL]. 向量分量与状态的参考系转换 [2026-09-26].
https://naif.jpl.nasa.gov/pub/naif/toolkit_docs/C/req/frames.html.
- [32] NASA Engineering and Safety Center. *Datums and Coordinate Systems*[EB/OL]. 地面参考坐标与机体轴约定 [2026-09-26].
https://nescacademy.nasa.gov/flightsim/2015/datum_coordinate_system.
- [33] Talay T. A. *Introduction to the Aerodynamics of Flight*, NASA SP-367, Appendix C: Coordinate Systems[R/OL]. NASA, 1975 [2026-09-26].
<https://ntrs.nasa.gov/api/citations/19760003955/downloads/19760003955.pdf>.
- [34] 关世义. 基于钱学森弹道的新概念飞航导弹 [J]. 飞航导弹, 2003(01): 1–4.
<https://doi.org/10.16338/j.issn.1009-1319.2003.01.001>.
- [35] 陈阳泉. 坐标系转换矩阵与几何关系方程式的推导程序 [J]. 西安工业学院学报, 1989, 9(3).
https://mechatronics.ucmerced.edu/sites/mechatronics.ucmerced.edu/files/documents/papers-in-chinese/222.zuo_biao_xi_zhuan_huan_ju_zhen_yu_ji_he_guan_xi_fang_cheng_shi_de_tui_dao_cheng_xu_chen_yang_quan_.pdf.
- [36] Henderson D M. *Euler Angles, Quaternions, and Transformation Matrices: Working Relationships*[R/OL]. NASA-TM-74839, JSC-12960, 1977. 第 4.1.1 节使用单轴矩阵与反向转换的内容。
<https://ntrs.nasa.gov/citations/19770024290>.

- [37] Zanetti R. Rotations, Transformations, Left Quaternions, Right Quaternions?[J]. *The Journal of the Astronautical Sciences*, 2019, 66(3): 361–381. 用于区分主动旋转与坐标转换。
<https://doi.org/10.1007/s40295-018-00151-2>.
作者公开稿: <https://sites.utexas.edu/near/files/2022/07/Rotations.pdf>.
- [38] 码农爱学习. 3 维旋转矩阵推导与助记 [EB/OL]. 知乎, 2023-04-03 更新 [2026-09-30]. 图解辅助阅读; 讲义公式按自身约定独立推导。
<https://zhuanlan.zhihu.com/p/183973440>.
- [39] NASA Glenn Research Center. *Force Balance Coordinates*[EB/OL]. 2021-05-13 [2026-09-30].
<https://www.grc.nasa.gov/www/k-12/airplane/tunbalaxes.html>.
- [40] Chen K, Zhou J, Shen F Q, et al. Hypersonic boost–glide vehicle strapdown inertial navigation system/global positioning system algorithm in a launch-centered earth-fixed frame[J]. *Aerospace Science and Technology*, 2020, 98: 105679. 本节仅引用引言中的参考系选择背景。
<https://doi.org/10.1016/j.ast.2020.105679>.
- [41] JPEG Committee. *JPEG 1: Workplan & Specs*[EB/OL]. ISO/IEC 10918 与 ITU-T T.81 的官方对应说明 [2026-09-26].
<https://jpeg.org/jpeg/workplan.html>.
- [42] ITU-T. *Recommendation T.81: Information Technology—Digital Compression and Coding of Continuous-Tone Still Images—Requirements and Guidelines*[S/OL]. 1992. 对应 ISO/IEC 10918-1:1994; 附录 A.3.1–A.3.4 (像素平移、DCT 及量化), 第 26–28 页。公开文本由 W3C 托管 [2026-09-26].
<https://www.w3.org/Graphics/JPEG/itu-t81.pdf>.
- [43] SciPy Developers. *scipy.fft.dct: Notes, Type II*[EB/OL]. DCT-II 及规范化形式的公开定义 [2026-09-26].
<https://docs.scipy.org/doc/scipy/reference/generated/scipy.fft.dct.html>.
- [44] Gonzalez R C, Woods R E. *Digital Image Processing*[M]. 4th ed. Pearson, 2018. 第 6 章 “Matrix-based Transforms” “Basis Images” “Fourier-Related Transforms”; 第 8 章 “Block Transform Coding”, 第 632–649 页。作者官网公开样章及目录 [2026-09-26].
https://imageprocessingplace.com/DIP-4E/dip4e_main_page.htm.

- [45] Wallace G K. The JPEG Still Picture Compression Standard[J]. *Communications of the ACM*, 1991, 34(4): 30–44.
<https://doi.org/10.1145/103085.103089>.
本节核对采用作者 1992 年发表于 *IEEE Transactions on Consumer Electronics* 的同题修订版；首页注明其源于 1991 年原文，公开全文由 Stanford 课程网站托管。
<https://web.stanford.edu/class/ee398a/handouts/papers/Wallace%20-%20JPEG%20-%201992.pdf>.
- [46] Thomas A. Edison Papers, Rutgers University. *Chronology Details: 1882*[EB/OL]. 记载 1882 年 9 月 4 日珍珠街电站开始运营 [2026-09-30].
<https://edison.rutgers.edu/edit-chronology/chronology-details/1881---1890/1882>.
- [47] U.S.–Canada Power System Outage Task Force. *Final Report on the August 14, 2003 Blackout in the United States and Canada: Causes and Recommendations*[R/OL]. 2004-04. 第 1 页（影响规模）、第 2 章（互联电网背景）、第 100 页图 6.29（影响区域）[2026-09-30].
<https://www.energy.gov/sites/default/files/oeprod/DocumentsandMedia/BlackoutFinal-Web.pdf>.
- [48] Natural Resources Canada. *Canada–U.S. Task Force Presents Final Report on Blackout of August 2003*[EB/OL]. 2004-04-05 [2026-09-30].
<https://www.canada.ca/en/news/archive/2004/04/canada-task-force-presents-final-report-blackout-august-2003.html>.
- [49] Strang G. *Graphs, Networks, Incidence Matrices*[EB/OL]. MIT OpenCourseWare, 18.06SC Linear Algebra, Fall 2011 [2026-09-30]. 本讲义自拟网络取“节点为行、线路为列”，与该讲中矩阵的排列方向互为转置。
<https://ocw.mit.edu/courses/18-06sc-linear-algebra-fall-2011/pages/ax-b-and-the-four-subspaces/graphs-networks-incidence-matrices/>.
- [50] U.S. Department of Energy, Electricity Advisory Committee. *National Distributed Energy Storage in the Electric Grid*[R/OL]. 2016. 第 2 部分 “Current State of Distributed Energy Storage” [2026-09-30].
<https://www.energy.gov/oe/articles/eac-recommendations-national-distributed-energy-storage-electric-grid>.
- [51] Strang G, Herman E J. *Calculus Volume 3*[M/OL]. OpenStax, 2016. 第 4.6 节：方向导数、梯度与等高线的几何关系 [2026-10-03].
<https://openstax.org/books/calculus-volume-3/pages/4-6-directional-derivatives-and-the-gradient>.

- [52] Strang G, Herman E J. *Calculus Volume 3*[M/OL]. OpenStax, 2016. 第 5.7 节: 多重积分换元与雅可比行列式 [2026-10-03].

<https://openstax.org/books/calculus-volume-3/pages/5-7-change-of-variables-in-multiple-integrals>.

- [53] Strang G, Herman E J. *Calculus Volume 3*[M/OL]. OpenStax, 2016. 第 6.5 节: 散度、旋度, 以及无旋场与势函数的适用条件 [2026-10-03].

<https://openstax.org/books/calculus-volume-3/pages/6-5-divergence-and-curl>.

- [54] Zhang A, Lipton Z C, Li M, Smola A J. *Dive into Deep Learning*[M/OL]. 在线版 1.0.3, 第 5.3 节: Forward Propagation, Backward Propagation, and Computational Graphs. 链式法则、反向计算与转置矩阵乘法 [2026-10-03].

https://d2l.ai/chapter_multilayer-perceptrons/backprop.html.